



基于扩散模型的具身智能模仿学习综述

李牧^{1,2,4,5}, 刘雪峰^{1,2}, 李青锋^{1,4,5}, 于晓龙^{4,5}, 崔景志^{1,2}, 赵凌冉^{4,5}, 韩锋^{1,2},
杨心怡^{1,2}, 周彬^{1,3}, 牛建伟^{1,3,4,5*}, 吕金虎^{1,2}, 吕卫锋^{1,3*}

1. 北京航空航天大学计算机学院, 北京 100191

2. 复杂关键软件环境全国重点实验室, 北京 100191

3. 虚拟现实技术与系统全国重点实验室, 北京 100191

4. 北京航空航天大学杭州创新研究院, 杭州 310020

5. 浙江省全省工业大数据与机器人智能系统重点实验室, 杭州 310020

* 通信作者. E-mail: niujianwei@buaa.edu.cn, lvwf@buaa.edu.cn

收稿日期: 2025-07-03; 修回日期: 2025-09-09; 接受日期: 2025-10-21; 网络出版日期: 2026-01-27

国家重点研发计划 (批准号: 2023YFB4503700)、国家自然科学基金 (批准号: 62372028, U23B200287, 62372027) 和浙江省“尖兵领雁+X”研发攻关计划 (批准号: 2024C01071) 资助项目

摘要 近年来, 具身智能技术展现出巨大潜力, 其能够充分释放灵活、通用且灵巧的机器人系统的全部潜能, 标志着人工智能由“虚拟智能”向“物理智能”的跨越. 模仿学习作为具身智能中的重要学习框架, 能够直接从专家示范中学习策略, 具有简洁高效的训练优势, 但其在数据使用效率、任务建模复杂性和泛化能力等方面仍面临挑战. 扩散模型凭借其扎实的理论基础、强大的分布建模能力和稳定的训练过程, 已在图像生成领域取得了显著成果. 鉴于扩散模型在数据生成、高维数据处理和复杂分布建模上的优势, 越来越多的工作将其引入模仿学习, 为应对上述挑战提供支持. 本文围绕扩散模型在模仿学习中的应用, 从原理、改进、应用、数据集和展望五个方面进行深入的调研与分析. 首先, 介绍了扩散模型的基本原理, 并探讨其引入模仿学习后形成扩散策略的背景与意义, 然后介绍了扩散策略的基本框架. 其次, 深入讨论了扩散策略各个组成模块改进的方法, 包括条件输入、策略输出、网络架构以及训练和采样方法. 第三, 介绍了扩散策略在机器人操作控制、移动导航两方面的应用. 第四, 总结了用于评估扩散策略使用的数据集和基准. 最后, 分析了当前扩散策略面临的挑战, 并给出了几种未来可能的技术发展路线, 为研究者提供参考.

关键词 具身智能, 扩散模型, 模仿学习, 扩散策略, 机器人控制

1 引言

具身智能 (embodied AI) 作为一种融合感知、推理、决策与行动的多模态智能系统, 是人工智能领域的重要研究方向^[1]. 其概念可追溯至 Turing^[2] 在 20 世纪中期的经典理论工作, 旨在研究机器人如何在复杂的物理环境中实现类似人类的感知、理解与决策能力. 随着深度学习和强化学习的快速发展, 具身智能适应动态环境和处理复杂任务的能力显著增强, 不仅能更准确地感知和理解信息, 还具备更强的泛化能力以应对多样化任务^[3], 即

引用格式: 李牧, 刘雪峰, 李青锋, 等. 基于扩散模型的具身智能模仿学习综述. 中国科学: 信息科学, 2026, 56: 245–276, doi: 10.1360/SSI-2025-0307

Li M, Liu X F, Li Q F, et al. Recent advances in diffusion-based embodied imitation learning: a survey. Sci Sin Inform, 2026, 56: 245–276, doi: 10.1360/SSI-2025-0307

不仅拥有抓、拿、放等基本技能,而且还能自主使用技能完成长程任务.这些技术进步推动了具身智能在精密操作、路径导航等领域具有越来越广泛的应用.

在具身智能的研究中,策略学习是实现感知与行动闭环的核心技术,其主要方法包括强化学习^[4]和模仿学习^[5].强化学习是一种通过智能体与环境的交互不断试错来优化行为的策略学习方法.由于其能够充分利用低成本的仿真数据,强化学习在操作控制任务中具有很高的灵活性和适应性.然而,强化学习在实际应用中面临着众多的挑战.首先,仿真环境与现实环境之间的差距^[6] (Sim2Real gap)使得在仿真环境中学习到的策略难以直接迁移到真实世界中,特别是在机器人控制任务中,这一问题尤为突出.其次,强化学习需要在高维动作空间中处理多自由度机械系统,训练过程往往受到数值计算误差和梯度震荡等问题的限制,训练稳定性较差.此外,强化学习依赖奖励函数的设计,而复杂任务中的奖励信号可能难以明确表达^[7],从而导致模型优化困难甚至偏离期望目标.

相比之下,模仿学习通过从专家示范中直接学习策略^[8],避免了强化学习中对奖励函数的强依赖以及复杂的试错过程.模仿学习将专家的行为记录为状态-动作对,通过最小化智能体策略和专家策略的回报期望学习状态与最优动作之间的映射^[5].这种方法在减少试错成本、提高训练效率方面具有明显优势,尤其适用于需要直接在真实环境中应用的任务.模仿学习还能够绕过仿真与现实之间的差距,通过真实数据进行训练来实现对环境的直接适应.尽管模仿学习能够减少强化学习中的复杂探索,通过专家演示直接学习策略,并能够通过行为克隆^[9]、对抗式模仿学习^[10]等方法学习复杂的动作序列,但在面对实际任务时,仍然存在显著的局限性.这些局限性主要体现在数据高效利用、复杂分布建模和泛化能力三大挑战上.

首先,模仿学习中专家数据的获取通常需要高昂的硬件成本和长时间的人工干预;策略模型为了高效学习,对数据多样性和规模有进一步要求,这两方面因素使得模仿学习数据采集的难度大大增加^[3,11].为此,如何在数据稀缺的条件下实现高效学习,成为策略学习的重要研究方向.例如,通过利用少量真实数据进行强化学习或模仿学习,或借助低成本仿真数据并采用领域适配技术弥合虚拟场景与真实世界的差距^[12],可以有效降低数据依赖并提高学习效率.虽然有许多研究机构构建了各种开源数据集以训练操作策略模型^[13~17],但对于特定场景的具体任务,数据的获取仍然是一项耗费巨大的工程.

其次,在实际任务中,状态与动作之间的映射往往具有多模态特性,即在同一状态下可能存在多种合理的动作选择^[18].这种多模态特性主要源于任务场景的复杂性以及环境的不确定性^[19].例如,在机器人操作任务中,机械臂的路径规划可能受到多个因素的影响,如目标物体的形状、位置以及环境中的障碍物分布等.此外,任务目标本身可能存在多种实现方式,例如,搬运物品时既可以选择直接抓取,也可以选择辅助工具搬运.这种多模态特性对模仿学习的策略建模提出了更高要求,尤其在需要处理动态环境或复杂任务时,更需要模型能够灵活捕捉动作分布中的多种可能性.研究者提出了显式建模和隐式建模等多种方法来应对这一问题,包括混合高斯模型^[20] (Gaussian mixed model, GMM)、隐式行为克隆^[21] (implicit behavior cloning, IBC) 以及基于 Transformer 的行为建模方法^[22] (如 behavior Transformers, BeT) 等.然而,这些方法在应对高维复杂场景时依然面临计算复杂性和数据需求的权衡,如何在提升建模效率的同时保持较高的精度,仍是该领域亟待解决的重要研究问题.

最后,模仿学习模型在训练数据覆盖的单一任务和静态环境下通常表现良好,但在多任务环境或动态场景中,其泛化能力往往不足^[23].这种局限性主要源于模仿学习依赖于专家示范数据,而这些数据通常覆盖有限的状态分布.当任务需求或环境条件超出示范范围时,模型无法适应新情况,智能体的行为可能导致其进入训练数据未覆盖的状态,从而偏离专家示范分布.这种现象称为分布偏移^[24],是泛化能力不足的典型表现.这种偏移现象在长程任务中尤为显著,因为误差会随着任务的推进逐渐累积,最终导致模型推理结果可能完全脱离目标.为提升泛化能力,研究者提出了一些增强模型鲁棒性的策略.例如,利用大规模预训练模型或多模态模型扩展策略的认知和行为范围^[25],通过数据增强技术增加训练数据的多样性^[26~28],以及利用抽象中间表征来实现跨任务和跨场景的策略迁移^[29].然而,这些方法通常伴随着更高的计算成本和训练复杂性.如何有效解决分布偏移问题,并使得策略模型在动态和长程任务中拥有稳定的表现,仍然是模仿学习面临的核心挑战.

扩散模型^[30] (diffusion model, DM) 作为一种强大的生成模型,已经在图像和视频生成领域取得了显著成果.其核心思想是,通过逐步去噪的过程生成高质量的样本,这一过程尤其适合于处理复杂的多模态数据和高维

度动作空间. 扩散模型的逐步去噪过程使其在高维空间中能够灵活地捕捉动作分布的多样性, 还能够显著提升模型在复杂环境中的训练效率与稳定性, 从而使扩散模型成为解决模仿学习核心问题的有效工具. 扩散策略^[19] (diffusion policy, DP) 将扩散模型引入模仿学习, 并凭借其高效的高维数据处理能力、优秀的复杂分布建模能力和较强的泛化能力, 为解决模仿学习中的多重挑战提供了强大支持, 在具身智能领域中展现出广阔的应用前景.

在具身智能的应用中, 许多工作已经开始探索扩散策略在机器人控制任务中的优化与应用. 扩散策略在场景表示^[31~33]、长程任务学习^[34]、多任务学习^[35]、轨迹导航^[36~38]、简化训练^[39,40]、人机协同训练^[12,41,42]、快速推理^[43~45]等方面的研究取得了重要进展. 例如, 通过灵活的扩散生成策略, 支持智能体在面对长程任务时保持稳定表现^[34]. 在轨迹导航中, 扩散策略帮助机器人在复杂环境中高效规划路径并避免障碍物^[46]. 在多个任务的联合训练中, 扩散策略能够更好地处理任务之间的共享信息, 提高多任务学习的效率和泛化能力^[35]. 此外, 扩散策略还可以结合混合专家策略简化训练过程^[39,40], 通过有效利用不同专家的策略, 减少训练数据的需求, 并提升训练过程的收敛速度. 同时, 扩散策略在与人机协同训练结合时, 能够使机器人与人类共同完成复杂任务, 进一步拓宽其应用范围^[12,41,42]. 为了提高推理效率, 研究者还提出了简化去噪步骤的技术, 能够在保持生成质量的同时加速模型推理过程^[43~45]. 基于这些创新的扩散策略方法, 模仿学习中的许多挑战正得到持续解决.

本文围绕具身智能中的扩散策略方法展开讨论. 首先, 从模仿学习入手, 介绍模仿学习的定义、发展历程及面临的挑战, 并由此引出扩散模型. 其次, 深入解析扩散模型的数学原理, 包括条件扩散模型及其在微分方程视角下对采样过程的改进方法. 在阐明扩散模型的数学表达后, 结合模仿学习中的具体问题与已有解决方案, 讨论扩散模型在模仿学习中的优势, 进一步引出扩散策略. 随后, 本文从条件输入、策略输出、网络架构以及训练和采样方法四个方面详细剖析当前扩散策略的改进与变种. 在扩散策略的应用方面, 本文讨论了其在机器人操作控制、动作规划、移动导航等任务场景中的应用情况. 同时, 总结了训练部署时常用的数据集与基线. 最后, 基于以上内容, 本文归纳了扩散策略在具身智能领域的应用前景, 总结了五项关键挑战, 并提出了相应的研究路线.

本文选取的文献主要来自 IEEE Xplore, ACM Digital Library, ArXiv, 部分文章收录于 ICRA, IROS, CVPR 等论文集, 时间范围集中在 2021 年至 2025 年 6 月, 关键词包括 “Diffusion” “Imitation” “Policy learning” “Planning” 等. 本文与现有具身智能领域的综述都聚焦具身智能这一重要研究领域, 围绕机器人操作、规划、导航等核心任务展开讨论, 并探讨智能体在感知、交互和策略优化中的技术与应用. 然而, 本文的独特性主要体现在专题深度、研究前沿和覆盖范围等方面. 相比于其他综述, 本文深入剖析扩散策略的数学原理、改进方法以及在具身智能中的具体应用, 特别是在模仿学习与策略优化中的优势. 与相对早期综述^[47~49]相比, 本文覆盖了扩散策略的最新研究进展, 而与近期综述^[1,50]相比, 本文更加专注于扩散策略的细节及其应用价值.

2 扩散模型

2.1 基础扩散模型介绍

近年来, 扩散模型^[30,51,52] 凭借其坚实的理论基础以及卓越的生成质量在生成模型领域展现出了巨大的潜力. 与生成对抗网络 (generative adversarial networks, GAN)^[53] 不同, 扩散模型通过逐步去噪的方式实现了从高斯噪声到目标分布的生成过程^[54]. 相比于其他生成模型, 扩散模型具有以下优点.

(1) 高质量生成: 扩散模型通过预测噪声并逐步去噪的方式生成数据, 避免了 GAN 中常见的模式崩塌问题, 在图像生成任务上具有优越表现^[55~59].

(2) 理论基础扎实: 扩散模型基于概率论和随机过程, 具有较高的可解释性, 尤其在随机微分方程 (stochastic differential equation, SDE)^[60] 视角下可统一描述多个生成模型.

(3) 训练稳定性高: 扩散模型因其损失函数简单且可微、无需交替对抗等特点, 相比其他生成式模型, 如 GAN、变分自编码器^[61] (variational autoencoder, VAE) 等, 其训练过程更加稳定, 且生成的样本多样性高, 已经广泛地应用于图像、视频、文本和音频等模态的生成任务^[62~70].

基础扩散模型, 即去噪扩散概率模型^[30] (denoising diffusion probabilistic model, DDPM), 其原理建立在正向

扩散和逆向生成上. 去噪扩散概率模型是一种特殊的隐变量生成模型, 其模型形式为 $p_\theta(x_0) := \int p_\theta(x_{0:T}) dx_{1:T}$, 其中 $x_1, \dots, x_T$ 是与数据 $x_0 \sim q(x_0)$ 维度相同的隐变量. 正向扩散过程 $q(x_{1:T} | x_0)$ 基于马尔可夫过程逐步添加噪声:

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad (1)$$

其中, x_0 是原始数据; x_t 是原始数据经过 t 步加噪后的数据; 累积参数 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, α_s 是噪声调度, 用来控制噪声大小; I 是单位阵. 逆向生成过程 $p_\theta(x_{0:T})$ 的初始高斯分布为 $p(x_T) = \mathcal{N}(x_T; 0, I)$, 其基于马尔可夫过程逐步去除噪还原数据:

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I), \quad (2)$$

其中, 均值 $\tilde{\mu}_t(x_t, x_0)$ 与方差 $\tilde{\beta}_t$ 可解析计算.

2.2 条件扩散模型

条件扩散模型通过引入额外的条件信息 (如文本描述、类别标签等), 显著增强了生成任务的可控性, 从而使得模型能够在特定条件下生成符合预期的高质量样本^[54]. 其基本原理与传统扩散模型相似, 即通过正向扩散过程逐步向数据添加噪声, 然后通过逆向生成过程去噪恢复数据. 不同之处在于, 条件扩散模型在扩散过程中引入了条件信息 c , 确保生成的样本符合特定的约束.

在正向扩散过程中, 数据通过逐步加噪转化为高斯噪声, 条件信息 c 被结合到每一步的噪声添加中, 以确保生成过程符合给定的条件. 具体而言, 正向过程的条件概率分布可以表示为

$$q(x_t | x_{t-1}, c) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1} + \beta_t c, \beta_t I), \quad (3)$$

其中, x_t 表示在时间步 t 时的样本; x_{t-1} 是上一时刻的样本; β_t 是噪声调度参数, 它控制着每步噪声的大小; c 是条件信息 (如文本描述或标签), 被加到每一步的噪声中, 确保生成过程受条件约束. 通过这种方式, 正向扩散过程将数据从原始分布逐步转化为接近高斯噪声的分布, 而条件信息 c 则确保了每一步的噪声添加都与指定条件相关.

在逆向生成过程中, 条件信息 c 同样被引入, 以确保生成的样本符合指定的条件. 逆向过程通过学习一个条件分布 $p_\theta(x_{t-1} | x_t, c)$, 逐步去噪, 从高斯噪声恢复到原始数据. 逆向过程的条件概率分布同样也为高斯分布, 表示为

$$p_\theta(x_{t-1} | x_t, c) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, c), \Sigma_\theta(x_t, c)), \quad (4)$$

其中, $\mu_\theta(x_t, c)$ 和 $\Sigma_\theta(x_t, c)$ 分别是由神经网络 θ 预测的均值和方差; 均值 $\mu_\theta(x_t, c)$ 是模型预测的去噪结果, 决定了从当前样本 x_t 和条件信息 c 出发的下一个样本 x_{t-1} 的值; 协方差矩阵 $\Sigma_\theta(x_t, c)$ 则控制了噪声的大小, 通常由模型根据当前样本和条件信息动态预测.

随着条件扩散模型的进展, 跨模态生成任务 (如文本到图像生成) 成为重要研究方向. CLIP (contrastive language-image pretraining)^[71] 模型通过对比学习将图像和文本嵌入到共享语义空间, 使得扩散模型能够根据文本生成符合语义要求的图像. 这一方法在图像生成、编辑及风格迁移等任务中表现出色.

2.3 微分方程视角下对扩散模型采样过程的改进

在微分方程视角下, 扩散模型的采样过程得到了显著的改进, 主要通过优化生成路径和简化计算来加速采样, 同时保持高质量的生成能力. 这一视角将离散的去噪步骤抽象为连续的时间轨迹, 其演化过程可由一个常微分方程 (ordinary differential equation, ODE) 描述. 通过求解该 ODE, 可以实现确定性的高效采样. 这一求解过程被称为概率流 ODE (probability flow ODE), 其形式如下:

$$\frac{dx}{dt} = f(x, t) - \frac{1}{2}g^2(t)\nabla_x \log p_t(x), \quad (5)$$

其中, $p_t(x)$ 是 t 时刻的数据分布的概率密度; $f(x, t)$ 和 $g(t)$ 分别是预设的漂移和扩散系数; 而 $\nabla_x \log p_t(x)$ 则是关键的“分数函数”, 由神经网络进行估计. 在此统一框架下, 核心方法包括隐式扩散模型 (denoising diffusion implicit models, DDIMs)^[52]、流匹配生成建模 (flow matching)^[72] 和一致性模型^[73] 等.

DDIMs 通过引入非马尔可夫过程, 简化了逆向生成过程, 提升了采样效率. DDIMs 采用确定性的生成路径, 与传统的马尔可夫过程不同, 这使得其能够显著加速采样, 缩短了采样时间 (通常缩短 10~50 倍), 并支持语义一致的图像插值, 扩展了其在高效生成和图像重建中的应用.

流匹配生成建模提出了一种基于连续归一化流 (continuous normalizing flows, CNFs) 的方法, 解决了传统扩散路径计算开销大的问题. 该方法通过回归固定条件概率路径的向量场, 并利用最优传输路径替代传统扩散路径, 从而使生成过程更高效且稳定. 流匹配方法能够以较低计算成本实现更高质量的生成.

一致性模型通过直接将噪声映射为数据, 从而支持一步生成并允许多步采样, 平衡了计算成本和生成质量. 该方法确保每一步生成过程与前一状态一致, 进一步提升了生成质量.

一致性模型在生成质量上达到了新的基准, 计算成本方面相比于基础扩散模型的迭代过程可以带来 1~3 个数量级的下降^[73].

这些方法相比于基础扩散模型更稳定, 更高效, 可以更加广泛地应用于不同的任务场景. 此类改进为扩散模型在实时生成、图像编辑和语义插值等领域的应用提供了强有力的技术支持.

3 模仿学习中的扩散模型

3.1 扩散模型在解决模仿学习问题上的优势

模仿学习作为一种让机器人从专家示例中学习策略的方法, 在具身智能领域取得了显著的进展. 其中, 行为克隆^[74] (behavior cloning, BC) 是最直接且常用的方法, 其将行为学习视为一种监督学习过程: 通过记录专家的状态-动作对, 在训练阶段以示范数据为输入, 学习从环境状态到专家动作的映射函数. 例如, Zhang 等^[75] 提出了一种基于深度神经网络的架构, 能够将原始像素输入直接映射到机器人动作. 行为克隆的一大优势在于无需了解环境的底层动力学, 仅依赖专家示范即可学习行为, 同时其训练过程属于成熟的监督学习范式, 因而具有较高的计算效率. 然而, 其主要缺陷在于分布偏移, 即训练时基于专家生成的状态学习, 而测试时则基于自身动作所产生的状态分布, 两者存在差异. 当模型偏离示范轨迹并遇到分布外状态时, 模型缺乏回到专家状态的能力, 性能表现大幅下降.

除行为克隆外, 模仿学习的另一重要方法是逆向强化学习^[76] (inverse reinforcement learning, IRL). IRL 的核心思想是, 假设专家行为接近最优, 通过观察专家示范来推断其背后的奖励函数, 然后基于推断得到的奖励函数利用强化学习训练策略^[77]. 与行为克隆不同, 强化学习智能体通过与环境交互、观测动作后果并基于奖励信号调整策略, 以最大化长期累积回报, 使其具备从错误中恢复的能力^[24]. 因此, IRL 相较于 BC 对分布偏移问题具有明显优势. 然而, IRL 在实际应用中面临两大核心挑战. 首先, 由于智能体需要通过大量与环境的交互来精确推断潜在奖励函数, IRL 计算开销较高且资源需求大, 在真实世界部署操作任务较为困难^[78]; 其次, 策略与奖励函数并非一一对应, 同一最优策略通常可以由无限多种奖励函数生成. 这种不唯一性带来三个严重后果: (1) 通过 IRL 恢复的奖励函数缺乏唯一性, 难以准确反映专家的真实意图; (2) 在不同的模型假设或正则化约束下, 得到的奖励估计可能截然不同; (3) 基于不恰当奖励函数训练的策略在面对未见状态时可能出现性能下降, 甚至出现危险行为^[79].

对抗式模仿学习 (adversarial imitation learning, AIL) 在克服 IRL 局限方面表现出的有效性引发了持续研究. 其中最具代表性的方法是生成式对抗模仿学习 (generative adversarial imitation learning, GAIL^[80]). GAIL 是将 GAN 应用到模仿学习领域的典型工作, 其通过训练判别器区分专家与智能体轨迹, 并以判别器的混淆程度作为奖励信号, 推动智能体生成更接近专家的行为. 随后, 大量研究在采样效率、可扩展性与鲁棒性方面对 GAIL 进行了改进^[80], 如调整判别器损失函数^[81] 和基于同策略 (on-policy) 向异策略 (off-policy) 方法转变^[82] 等. 但

是 GAIL 同样面临 GAN 存在的致命缺陷——鞍点问题, 会出现训练不稳定, 模式坍塌的问题。

尽管上述三类方法可以适应简单任务, 但对于一些较为复杂的情况, 如灵巧操作任务, 仍面临着复杂分布建模、高维动作空间输出、奖励函数难以探索等困难。首先是动作的复杂分布建模问题, 该问题产生的主要原因是人类示范者的行为往往存在显著的多样性, 这源于个体差异、专业知识、工作习惯以及问题解决策略等方面的差异。这种多样性通常表现为示范行为的多峰值分布, 这使得直接使用回归方法求解变得困难。已有研究尝试通过探索不同的动作表示来应对这一挑战, 例如, 采用高斯混合模型^[20]、量化动作的分类表示^[22], 或通过切换策略表示方式, 从显式表示转向隐式表示^[18, 21], 以更好地刻画多模态分布。为解决高维输出问题, 研究者提出了低维动作特征迁移方法^[83], 通过映射高维动作到低维特征空间降低建模复杂性, 但这种方法依赖人工设计低维特征。同时, 潜在空间表示^[84]通过编码器-解码器压缩高维动作至低维空间以提高训练稳定性和性能, 但引入了更高的计算成本。这些方法均针对高维空间和序列预测问题提供了解决思路, 但各自仍存在应用限制。在奖励函数探索方面, 逆向强化学习算法依赖两个先验条件, 即环境的状态转移规律和专家的决策策略^[85], 这两者在推理奖励函数之前必须完全已知。然而在真实场景中, 智能体通常需要从样本中估计专家策略与状态转移规律, 这个过程不可避免地导致奖励函数推断产生累计误差^[86]。

扩散模型作为一种生成式建模方法, 展现了其在高维复杂数据分布建模方面的强大能力^[30]。其逐步去噪的生成过程不仅能够建模多模态分布, 还具备稳定的训练特性, 这些特性恰好对应了模仿学习中的关键挑战。扩散模型通过逐步去噪的生成机制, 在多模态数据分布建模中展现出卓越的性能。不同于显式建模方法, 如 GMM, BeT 和 IBC, 扩散模型通过逐步去噪的方式自动捕获复杂多模态特性, 不必对数据分布进行显式假设, 也不依赖额外设计的能量函数。这使得扩散模型在处理示范行为的多样性时尤为出色, 例如, 能够在相似观测条件下生成多样化的动作序列, 从而更好地适应模仿学习中多样化的专家策略, 提升策略的鲁棒性与适应性^[19]。

在高维动作空间中, 扩散模型的分阶段生成机制为建模复杂动作分布提供了有效的解决方案^[19]。相比直接预测高维动作输出的传统方法, 扩散模型逐步逼近目标动作分布的方式有效降低了采样难度, 避免了高维空间中的不稳定性问题。这种生成过程不仅增强了训练的稳定性 and 模型生成结果的可靠性^[19], 还能自然地支持连续动作序列的生成, 从而在涉及高自由度机器人任务的序列预测中展现出极大的适用性。扩散模型的这一特性使其成为解决高维复杂场景模仿学习问题的关键工具。扩散模型在模仿学习中的引入不仅有效解决了多模态分布建模和高维动作输出的挑战, 还在稳定性与生成质量上优于 VAE^[61], GAN^[53] 等方法。尽管在推理效率上仍存在一定限制, 但其在连续控制和复杂机器人任务中的表现已显示出巨大的应用潜力, 成为模仿学习未来的重要研究方向。

3.2 扩散模型在模仿学习中的早期应用

当前, 扩散模型已成为生成建模领域的一个重要方向, 其应用也不仅限于传统的图像生成和语音合成等任务。在策略学习中, 扩散模型的引入为解决复杂的行为生成和策略优化问题提供了新的思路。策略学习在实际应用中面临着如何处理多模态、随机性和高维度动作空间等挑战^[87], 扩散模型的强大生成能力和灵活性为这些问题提供了潜在的解决方案。

在 Chi 等^[19]的扩散策略这一开创性工作提出之前, 扩散模型已在模仿学习领域得到了一些应用。例如, Pearce 等^[87]提出, 扩散模型在模仿人类行为时能够有效捕捉动作空间中的结构化关联, 更准确地建模复杂动作分布, 并且能够通过逐步去噪的过程生成更加准确的模仿行为。这一方法弥补了传统行为克隆中由于模型表达能力有限所带来的偏差问题, 展现了扩散模型在多模态、随机行为生成中的独特优势^[88]。

Reuss 等^[89]提出了基于得分扩散模型 (score-based diffusion models, SDMs) 的新型目标条件模仿学习方法。这一方法通过解耦得分扩散模型的学习和推理过程, 能够在没有明确奖励信号的情况下, 通过少量的去噪步骤生成目标指定的行为。该方法展示了扩散模型在无需传统奖励反馈的目标导向任务中的有效性, 并且避免了以往方法中需要复杂策略分层或聚类的挑战。

这些前期的工作为扩散模型在策略学习中的应用奠定了坚实基础, 它们主要通过利用扩散模型的生成特性来克服传统方法的局限性, 如在复杂环境下的策略生成。然而, 这些方法在处理高维动作空间或动作变化率较高

的任务时,往往暴露出泛化性能和训练稳定性不足的问题,并且难以有效学习跨时间步的动作相关性^[87].因此,进一步优化扩散模型以提升其实用性和灵活性,特别是在高维任务适应性与视觉运动策略性能方面的改进,已成为推动该领域发展的关键方向.

3.3 扩散策略

有效捕捉并生成多模态动作分布,是机器人视觉运动策略(visuomotor policy)学习领域的核心问题.基于显式策略^[11](explicit policy)和隐式策略^[90](implicit policy)的传统策略表示方法,难以有效捕捉人类示范数据并生成多模态动作分布.基于扩散模型的策略学习方法^[87]难以解决跨时间步动作的相关性学习问题,无法准确捕捉和再现多种可能的复杂动作及行为逻辑.

通过将机器人的视觉运动策略表示为条件去噪扩散过程,Chi等^[19]创新性地提出了扩散策略,这一成果为解决上述问题提供了新的视角.扩散策略的核心在于将策略的输出过程建模为一个条件去噪扩散过程.这一过程可以视为一系列预测并逐步去除噪声的迭代步骤,最终从完全随机的初始状态(如高斯噪声)中生成出符合任务需求的动作策略.去噪扩散概率模型是扩散策略中一种重要的扩散采样方式,在推理过程中通过一系列随机朗之万动力学(stochastic Langevin dynamics)步骤对该梯度场进行迭代优化,其中策略生成被建模为一个去噪过程.

如图1所示,在扩散策略架构中,系统的主要输入是一个历史视觉观测序列 $O_t = \{o_{t-L+1}, o_{t-L+2}, \dots, o_t\}$,其中 L 代表历史观测长度,用于为策略提供充足的时序上下文信息.获取视觉观测信息后,模型将从高斯噪声中采样得到初始潜在动作状态,经过一个包含多次迭代的反向去噪过程得到动作策略.该过程生成一系列噪声逐渐减小的中间状态,最终得到所需的无噪声动作序列 $A_t = \{a_{t+1}, a_{t+2}, \dots, a_{t+T}\}$,其中 T 为预测长度.在实际控制中,通常不会执行全部预测动作.整个序列 A_t 被分为两部分:执行长度 E ($E \leq T$)和规划长度 $T - E$.智能体仅输出前 E 步动作 $\{a_{t+1}, \dots, a_{t+E}\}$ 至执行器,并在下一个控制周期中基于新的观测重新进行扩散规划,以此应对环境变化与模型预测误差,增强系统的鲁棒性.每一次去噪迭代均遵循扩散模型的理论框架,其状态更新过程由以下公式描述:

$$A_t^{k-1} = \alpha(A_t^k - \gamma \epsilon_\theta(O_t, A_t^k, k) + \mathcal{N}(0, \sigma^2 I)), \quad (6)$$

其中, ϵ_θ 是一个可学习的噪声预测网络, α , γ 和 σ 是随迭代步数 k 变化的噪声调度参数, I 是单位阵, $\mathcal{N}(0, \sigma^2 I)$ 是一个均值为0、方差为 σ^2 的高斯噪声.这个过程也可以解释为一个单步的梯度下降过程,其中噪声预测网络 ϵ_θ 实际上预测了梯度场 $\nabla E(x)$,如式(7)所示,

$$x' = x - \gamma \nabla E(x), \quad (7)$$

其中, x 表示某一步动作的隐变量, x' 表示 x 经过一步去噪后的动作隐变量.

在扩散策略的架构中,噪声预测网络 ϵ_θ 的核心作用是从带噪声的动作中预测出应去除的噪声成分,进而逐步生成出精确的动作序列.该网络的构成并非固定不变,常见的有基于卷积神经网络(convolutional neural networks, CNN)和基于Transformer两种实现方式,它们以不同的机制实现对动作的预测.基于CNN的扩散策略利用卷积结构强大的局部特征提取能力,以滑动窗口方式逐步感知观测与动作间的局部依赖关系,从而预测出去噪方向.其核心原理在于通过堆叠的多层卷积来构建深度网络,以逐步扩大感受野并提取从低级到高级的层次化特征. Chi等^[19]在系统比较不同网络架构后指出,基于CNN的主干网络在绝大多数任务中性能稳定良好,且不需要大量超参数调优,因此尤其适合快速适配到新任务中.具体实现中,视觉观测特征 O_t 会通过特征线性调制(feature-wise linear modulation, FiLM)^[91]对每一层卷积进行通道尺度与偏置的调节,其具体操作是使用状态特征生成一对调制参数对卷积层的特征图进行仿射变换,即图中的尺度参数 a 和偏置参数 b ,从而将环境状态信息有效融入噪声预测过程,最终输出用于去噪的梯度场 $\nabla E(x)$.在任务复杂度高、动作变化速率快的场景中,CNN模型由于感受野有限,往往会产生过平滑效应,导致难以捕捉高度动态的动作模式,此时引入时序扩散Transformer网络进行补充调优成为一种有效策略.基于Transformer^[92]的扩散策略借助自注意力机




图 1 (网络版彩图) 扩散策略架构, 分为基于 CNN 和基于 Transformer 两种网络。

Figure 1 (Color online) Diffusion policy architecture with CNN-based and Transformer-based networks.

制, 显式地建模整个动作序列中不同时间步之间的全局依赖关系. 其原理是自注意力机制允许序列中的任何一个时间步直接关注到所有其他时间步的信息, 进而捕获长程的、复杂的时序依赖关系, 避免了 CNN 的归纳偏置所带来的感受野限制. 在该结构中, 观测 O_t 的嵌入向量被传入每一个 Transformer 解码器块中的多头交叉注意力层, 用于调节去噪过程. 同时, 为确保动作生成的自回归特性, 对动作嵌入施加因果掩码限制, 确保每一步的动作预测仅依赖于当前及之前的历史动作, 保持自回归生成的一致性. 值得注意的是, 无论是 CNN-based 还是 Transformer-based 的扩散策略, 尽管网络架构迥异, 但均可采用同一扩散训练目标来优化噪声预测网络, 进而在不同的归纳偏置下实现协同优化.

通过学习噪声预测网络 ϵ_θ , 扩散模型可以表达任意可归一化的概率分布, 从而能够很好地捕捉动作的多模态特性, 这是显式策略所不具备的能力. 同时, 扩散模型的训练过程不需要负采样, 因此可以避免隐式策略训练不稳定的问题. 此外, 扩散策略将动作表示为一个高维的动作序列, 而不是单个动作, 这样可以更好地捕捉动作之间的时序相关性, 提升动作的时间连续性和平滑性. 并且将动作序列预测与收缩视野控制相结合, 在保持长期规划能力的同时, 也能够对意外观测作出及时反应. 具体来说, 在每个时间步, 模型会预测未来几个时间步的动作序列, 但只执行其中的部分动作, 并在下一个时间步重新规划, 这种方式平衡了长期规划和实时响应的需求, 解决了扩散模型无法学习跨时间步动作相关性的问题.

凭借在机理和实际性能上表现出的优势, 扩散策略逐渐成为一种解决现有具身智能领域问题的新思路, 例如, 文献 [93] 使用了扩散策略来预测连续的、多模态的动作分布, 并进一步讨论了扩散策略相较于 MSE 动作头和离散动作分布 [94] 在零样本泛化及少样本微调应用中的优势. 此外, 扩散策略还被应用于机器人操作优化 [95]、车辆自动驾驶 [96] 等相关研究中. 而在本文重点讨论的模仿学习领域, 目前行为克隆、ACT [11] 和 Dagger [24] 等主流方法依旧存在泛化能力不足的问题, 这些问题有望通过扩散策略进行解决, 但相关研究尚处于起步阶段. Lee 等 [97] 提出了 Diff-Dagger, 采用基于 CNN 的扩散策略从静态专家数据中学习技能, 并通过 Dagger 计算损失, 根据损失大小决定继续执行动作或向专家策略申请演示, 新的专家演示数据会继续通过扩散策略来学习, 从而有效提高了机器人在新场景中执行任务的成功率. Wu 等 [98] 基于混合专家策略 (mixture of experts, MoE) 和扩散策略提出了一种蒸馏学习方法以实现灵巧手的预抓握操作策略学习, 首先在 MoE 模型的训练过程中引入互相奖励机制 (mutual reward), 以应对局部最优问题, 提高操作成功率, 然后以 MoE 模型作为教师模型, 以扩散策略作为离线模仿学习框架运行, 从而将多个专家策略蒸馏为单一的学生策略 (即扩散策略), 由于扩散策略具有学习复杂多模态动作策略的能力, 因此能够有效保留 MoE 模型应对不同物体和目标姿态的抓取能力.

表 1 扩散策略中的扩散模型改进.

Table 1 Improvement of the diffusion model in diffusion strategies.

Policy component	Improved aspect	Type	Method	Reference
Conditional input	Model input	Observation input	Vision	RGB [26~28, 101, 102], 3D [31~33, 103, 104]
			Proprioception	[102, 105~111]
			Others	Auditory [112, 113], tactile [114, 115], latent representation [116]
Policy output	Model output	Task input	Natural language	[25, 29, 117, 118]
		Discrete/continuous	Keyframe	[119, 120]
			Trajectory	[120, 121]
		Action space	Joint position	[122, 123]
			End-effector pose	[124]
		Coordinate frame	Relative (incremental)	[125, 126]
Network architecture	Encoder	Visual encoding	2D	ViT [128~130], CLIP [131~133]
			3D	PointNet [134~136], PointNet++ [137~139], DP3-Encoder [32, 33]
		Language encoding	T5	[140~142]
	Noise prediction network	-	U-Net	[143~145]
			Transformer	[146~149]
Training and sampling process	Training process	Pre-training	-	[13, 93, 99, 150]
		Fine-tuning/post-training	-	[30, 151]
	Diffusion sampling process	-	DDPM	[30]
			DDIM	[52]
			Consistency model	[152]
			Flow matching	[153, 154]
			Distillation	[43]
			Shortcut model	[45]

Wen 等 [99] 基于视觉 – 语言模型 (vision language model, VLM) 等多模态模型和扩散策略提出了 TinyVLA 模型, 其中多模态模型编码当前观测和语言指令, 并将其作为条件输入到扩散策略中, 以控制扩散去噪过程, 从而预测机器人的动作序列并控制机器人的动作. 在实验中, TinyVLA 体现出了优异的多视角泛化能力, 该方法有助于模仿学习应对不同视角下的技能泛化问题. 此外, 与使用离散化的动作表示 [100] 相比, 扩散策略可以更好地处理连续或高维的动作数据, 并且训练效率更高.

综上所述, 由于扩散策略在处理多模态动作分布时能够表现出更高的灵活性, 即其每次迭代都能从新的随机噪声样本开始, 因此不同的初始噪声样本可以引导出不同的动作序列, 从而实现对多模态动作分布的有效捕捉和生成, 这一能力为模仿学习领域带来更广阔的改进空间. 同时, 作为一种开创性的工作, 扩散策略本身的相关工作仍需完善, 其在多模态特征输入、策略输出、网络架构和训练方法等方面均有较大改进空间.

4 扩散策略的改进

扩散策略因其在处理复杂数据分布和多模态输入方面的巨大潜力而受到广泛关注, 被应用于机器人导航、路径规划以及状态估计等方面. 当前工作通常针对不同的下游任务, 对扩散策略的各组成部分作出改进, 如表 1 所示.

4.1 面向条件输入的改进

根据不同的输入目的, 扩散策略可以分为基于观测输入的扩散策略和基于任务输入的扩散策略两类, 其中观测输入涉及视觉信息、本体信息和其他观测信息, 任务输入多为自然语言文本信息.

4.1.1 输入观测信息的改进

扩散策略中常见的观测信息是基于图像和视频的视觉表示信息 [19]. 为了进一步提升机器人的操作精度, 深度信息也被引入到扩散策略的视觉输入中. 例如, Ze 等 [32] 为了提升机器人对于复杂技能学习的鲁棒性和泛化性, 提出了三维扩散策略, 将三维点云数据融入扩散策略. Wang 等 [103] 通过从单视图点云中直接预测连续动作, 展示了如何利用三维感知提高模仿学习的效率和准确性. 在最近的机器人运动研究中, 结合三维视觉表示和扩散模型的学习方法已经被广泛用于长程任务、复杂多任务 [33, 104]. 这些研究证实了三维算法能够为物理世界的

机器人控制领域提供帮助,使机器人的自主操作能力泛化到复杂多样的环境中^[31]。尽管基于视觉的扩散策略在任务泛化方面表现出色,但其对高质量视觉输入的依赖也带来了明显的局限性。例如,在光照剧烈变化、存在遮挡或视觉噪声较大的实际场景中,仅依赖视觉输入的策略性能可能显著下降。相比之下,基于本体感觉信息的扩散策略对环境的感知干扰更具鲁棒性。

本体感觉信息也是机器人运动研究中常见的一类观测输入。本体感觉信息指机器人的状态空间,描述机器人当前状态的所有可能值的集合。在机器人导航和控制中,状态空间通常包括机器人在某一时刻的所有必要信息,通常用于描述机器人在空间中的位置、速度、方向、姿态等动态参数。输入本体感觉信息的维度取决于需要描述机器人的特征及其控制的精细程度。对于不同的任务(如导航、路径规划、任务执行等),状态空间的定义可能会有所不同。输入本体感觉作为条件信息的扩散策略,通常涉及利用模仿学习从某种低维的控制信号或位置状态中生成或预测未来的运动轨迹^[105~107],能够让机器人系统在不确定性环境下生成更加稳定且符合预定目标的运动轨迹,尤其适合对硬件和软件的精度和鲁棒性都有严格要求的灵巧机器人操纵^[102,108~110]。这类策略能使机器人在处理具有高维状态空间、复杂动态和多模态动作分布的任务时有更高的完成质量^[111]。

然而,本体感觉信息通常局限于低维数值表示,难以直接表达复杂的任务语义或环境上下文,这在很大程度上限制了其在需要高层次推理任务中的应用。与视觉输入方法相比,其在跨任务泛化和场景迁移方面也存在一定不足。

除了视觉表征和本体感觉外,也有工作研究尝试在扩散策略中加入多感官信息,如触觉^[114,115]、听觉^[112,113]等,利用力学反馈和音频信息来补充视觉信息,提升机器人的精细操作或定位能力。Gerges等^[116]提出了一种基于潜表征的新型视觉伺服方法,通过跨模态变异自动编码器学习潜表征,用于估算去噪扩散概率模型轨迹生成条件的返回值。最近还有学者尝试比较机器人基础模型究竟应该在哪些数据上进行训练^[155]。这些工作表明,通过整合多模态信息,扩散策略能够显著提升机器人在复杂环境中的具身操作能力。

4.1.2 面向任务指令的改进

为了准确理解任务指令,通常使用大语言模型作为策略模型的任务规划器^[156]。这类策略利用大语言模型强大的语言理解和生成能力,作为多任务场景中的中枢工具。例如,Zhang等^[117]提出了通过语言提示器的方式,将可学习的文本提示嵌入到冻结的视觉模型中,使其在处理多任务场景时能够根据任务需求准确预测操作能力。这种方法不仅能够多任务环境中表现出较强的灵活性,还在不同规模的数据集上展现了具有竞争力的性能。Hua等^[118]则探索了具有多模态理解与推理能力的编码大语言模型,创建了复杂且高度逼真的仿真任务场景。通过大规模自动生成任务的演示数据,该方法显著提高了仿真训练策略的可扩展性,解决了传统仿真训练中因数据不足导致的瓶颈问题。

将大语言模型与扩散策略相结合,不仅能够提升复杂任务规划与执行的智能化水平和人机交互能力,也为长程任务的实现提供了强有力的工具支持。Sun等^[25]的研究通过引入GPT-2模型,提出了一种关键点建议机制,用以生成行动序列。通过限制大输出空间的复杂性,该方法有效提升了长期规划任务中的复杂推理能力,可以为解决多步骤任务提供更加高效的解决方案。Hao等^[29]利用VLM,将自然语言描述的任务转换为三维空间中可操作的关键帧,从而指导机器人完成复杂的行动序列扩散过程,这种方法在机器人动作生成领域具有较高的实用价值。

面向条件输入的改进呈现出从单一模态到多模态融合、从高层语义理解与低层感知相结合的清晰发展趋势。早期研究主要依赖单一的视觉或本体感觉信息,而当前的前沿工作则致力于融合视觉、语言、触觉等多种信号,以构建对环境的全面感知。特别是大语言模型(large language model, LLM)和VLM的引入,极大地提升了机器人对抽象任务指令的理解和分解能力,使其能够执行开放词汇的复杂任务,这是迈向通用机器人的关键一步。未来的挑战在于如何高效、鲁棒地实现不同模态信息在时间与空间上的对齐与融合。

4.2 面向策略输出的改进

输出形式的选择与动作空间的设计是影响机器人学习效果的核心要素。基于任务需求,扩散策略的输出分

为连续和离散两种形式。离散输出主要用于关键帧的选择和决策。在轨迹生成任务中,需要通过离散化的时间步长确定一系列关键帧的位置,每个关键帧代表轨迹的重要节点^[119]。在复杂任务中,离散输出通过细粒度状态-动作映射优化了策略表现^[120]。在机器人多步骤操作中,离散化的动作序列能够显著提高策略的全局规划能力,并通过对关键帧位置的精准选择,提升任务完成效率和可靠性。He等^[157]根据离散的潜在表示来生成可执行的动作序列,在多任务机器人问题上表现出优越的性能。连续输出用于生成关键帧之间的平滑轨迹。用一组连续变量来表示轨迹,描述其在时间轴上的变化,如 $[x(t), y(t), z(t)]$ 。为了确保轨迹的生成过程符合物理约束,Chu等^[121]利用扩散模型的逆过程生成连续轨迹。连续轨迹生成的优化方法通过引入时间参数化模型和平滑约束来进行轨迹生成优化,能够在复杂轨迹任务中实现精度与复杂度的有效平衡^[120],通过优化控制策略和轨迹生成的参数,能够提高任务执行的成功率与稳定性。离散输出方法在可解释性和决策透明度方面具有优势,但难以表达细粒度的连续运动;连续输出能生成平滑轨迹,但对高维动作空间的建模和训练复杂度较高,且容易产生物理空间上不可行的策略输出。

动作空间的选择是影响策略模型输出的一个重要因素。动作空间是指智能体在每个时间步骤可以选择的所有可能动作的集合,它是状态空间的一个子集。动作空间的选择直接影响学习效率和算法的可扩展性^[122]。对于关节控制任务,动作空间由机械臂的关节位置 $[\theta_1, \theta_2, \dots, \theta_n]$ 表示,每个关节位置对应于一个独立的自由度。策略输出关节位置的目标值,一般通过直接回归或分布采样实现控制精度。在复杂关节系统中,关节空间的设计对输出的鲁棒性和精度有直接影响^[123],通过不同的状态-动作空间可以控制操作和视点的选择。在涉及精细操作的任务中,动作空间使用末端执行器的位姿 $[x, y, z, \alpha, \beta, \gamma]$ 来表示,其中 $[x, y, z]$ 表示末端执行器的空间位置, $[\alpha, \beta, \gamma]$ 表示末端执行器的方向或姿态。末端执行器的精确位置和姿态控制是机器人任务空间控制中的核心问题。通过控制末端执行器的位置 $[x, y, z]$ 和姿态 $[\alpha, \beta, \gamma]$,机器人能够完成复杂的操作任务^[124]。

在动作空间设计的基础上,不同坐标系的选择也可以进一步影响扩散策略输出的效果。坐标系分为相对坐标和绝对坐标两种。相对坐标系以智能体作为参考点,用于表示动作的相对变化,在轨迹生成任务中,输出相对于当前状态的位移 $[\Delta x, \Delta y, \Delta z]$,这种方式在局部规划任务中具有较强的灵活性。相对坐标系的优势在于减少了环境复杂性对策略的影响,能够显著提高动态环境下的适应性和灵活性^[125],主要用于局部目标搜索、路径调整等任务中。绝对坐标系则以固定的参考点为基准,描述智能体在环境中的绝对位置和方向。绝对坐标系的优点是便于统一描述多智能体或多任务场景,在长期规划和多智能体协作任务中具有显著优势。Xu等^[126]以地面参考系为基础,使得物体在相对接触参考系下的运动模式更简单,更容易被预测。适当选择坐标系不仅能提升策略的适应性,还可以在多任务场景中优化智能体之间的协作效率。Gao等^[127]通过协方差矩阵构建特征坐标系,提升了策略的适应性。

策略输出的优化设计核心在于平衡动作表达的抽象程度与控制精确性。根据输出形式的不同,可将其分为离散输出和连续输出两类:离散输出适用于高层规划决策,能够处理符号化的任务描述;连续输出则专注于底层精细控制,实现平滑的运动轨迹生成。在实际应用中,两种输出形式常协同工作,例如,通过LLM生成离散化的关键动作序列,再由扩散策略补全关键帧之间的连续运动轨迹。在具体实现层面,动作空间和坐标系的选择是影响策略性能的关键因素。在动作空间设计方面,关节空间控制方式计算效率高,避免了复杂的逆运动学求解过程,适用于需要精确关节控制的任務;末端执行器空间控制则更贴近人类操作习惯,便于任务理解和策略调试。在坐标系选择方面,相对坐标系以当前状态为参考基准,在动态环境中展现出优异的适应性和泛化能力;绝对坐标系则提供全局一致的参考框架,可用于实现多智能体协同和全局路径规划。合理的输出架构设计能够有效简化策略学习过程,提升整体任务完成质量。

4.3 面向网络架构的改进

模型网络架构是扩散策略实现复杂场景建模与任务优化的关键环节。根据功能与数据处理需求的不同,其整体架构可划分为编码器和噪声预测网络两大模块。编码器的设计体现了扩散策略对多模态信息融合的需求,以适应不同类型数据的特征提取,其中2D视觉编码器适用于图像数据,擅长捕捉局部纹理与结构信息;3D视觉编码器侧重于建模空间几何关系,提升三维数据理解能力;自然语言编码器则用于深度挖掘文本的语义结构。




图 2 (网络版彩图) 基于对比学习的跨模态领域适配框架。

Figure 2 (Color online) A contrastive learning-based cross-modal domain adaptation framework.

噪声预测网络通常选用 U-Net^[158] 或 Transformer^[92] 作为主干网络, 前者因其在图像分割任务中的高效性而被广泛应用, 而后者凭借其在长序列建模中的强大能力, 增强了扩散策略在多任务场景下的鲁棒性和泛化能力。最后, 围绕混合专家架构和视觉-语言-动作 (vision language action, VLA) 架构展开讨论。

4.3.1 编码器优化

2D 视觉编码器主要用于处理图像数据的局部特征, 通常使用 CNN、视觉 Transformer (vision Transformer, ViT) 和混合架构 (如 CLIP) 等来提取纹理、边缘等关键信息, 并适配扩散策略在图像生成、分割和编辑任务中的需求。这些模型能够在二维空间内高效建模, 并通过多层特征聚合增强局部与全局信息的交互。基于 CNN 视觉编码器的工作已在第 3.3 小节中介绍。在 ViT 方面, Zhu 等^[128] 提出了 SPA (spatial-awareness) 框架, 利用三维空间感知技术显著增强了具身智能任务中的模型性能。Huang 等^[129] 通过 3D-ViTac 框架整合视觉与触觉信息, 在复杂的精细操作任务中表现出色。关于多模态特征提取的研究同样取得了进展, 例如, Yu 等^[130] 基于 ViT 架构提出了一种多模态特征融合方法, 通过自适应注意力机制大幅提升了模型在动态环境下的鲁棒性。Liu 等^[131] 提出了一种基于 CLIP 的语言驱动机器人抓取检测方法, 通过视觉与语言特征融合, 提升了复杂场景下目标物体定位与抓取的精度。Yao 等^[132] 则结合 CLIP 模型与提示学习技术, 采用了如图 2 所示的结构。通过特征融合模块整合文本提示信息 (通过 Text Encoder 获得) 与图像空间特征 (通过 Image Encoder 获得) 并输入到解码器中。回归模块预测目标的位置坐标与方向参数 (分别对应图 2 中的参数 x 和 q), 实现了将跨模态语义对应转化为定位结果; 判别模块 (图中 Discriminator) 则通过对抗训练机制区分合成与真实数据特征, 减小域间差异, 显著提升了模型在跨域场景中的泛化性能。Yang 等^[133] 提出了一种基于 CLIP 的跨模态语义分割方法, 利用多模态特征对齐, 在复杂环境中的语义分割任务中表现出色。三种类型的编码器各有优劣, 基于 CNN 的编码器在提取局部纹理与边缘特征方面具有计算高效和架构层次化的优势, 但其全局建模能力有限; 基于 ViT 的编码器通过自注意力机制实现了强大的全局上下文感知和多模态融合灵活性, 但存在计算复杂度高和数据需求大的不足; 多模态编码器 (如 CLIP) 依托对比学习获得了卓越的跨模态语义对齐和零样本泛化能力, 然而在精细几何细节编码方面存在局限, 且计算成本较高。

3D 视觉编码器主要关注点云或体数据的空间几何关系, 常采用 PointNet^[159], PointNet++^[160] 或扩散模型来建模复杂的三维结构。通过适配扩散策略, 这些模型能够在 3D 目标检测、语义分割和场景重建任务中提供更加精细的几何理解。PointNet 作为一种以直接点云为输入的深度学习架构, 能够高效提取点云中的全局和局部几何特征, 为多种 3D 任务提供支持。Seppänen 等^[134] 提出了一种基于 PointNet 的轻量级 3D 道路用户检测框架, 结合位置感知和分布外检测, 实现了非 GPU 设备上的实时推理, 为资源受限的移动机器人提供了高效的




图3 (网络版彩图) SensoryT5 模型架构.

Figure 3 (Color online) SensoryT5 model architecture.

3D 目标检测方案. Parsons 等^[135]则结合 PointNet 与课程学习策略,提出了一种视触觉跨模态识别方法,通过逐步引入不同难度的点云样本进行训练,显著提升了模型对部分点云数据的识别能力.此外,Arroyo 等^[136]基于 PointNet 提出了一种多模态融合方法,通过点云和图像的联合特征学习,提升了模型在多模态 3D 感知任务中的精度和鲁棒性.针对多尺度特征的捕捉, Huang 等^[137]通过改进 PointNet++, 利用局部特征深度学习建模,增强了模型的局部细节感知能力. Wang 等^[138]进一步引入课程学习策略,设计了一种分阶段训练框架,逐步引入稀疏的点云样本以适应不同复杂度的数据分布,从而在稀疏点云数据下显著提升了识别性能. Xiang 等^[139]则基于 PointNet++ 提出了一种混合注意力机制,将全局和局部注意力结合,用于提升多尺度点云特征的捕获效率,在多样化场景下表现出色.基于上述工作, Ze 等^[33]提出了一种基于扩散模型的 3D 视觉表示学习框架 DP3,结合点云采样与生成策略,有效地将稀疏采样的点云编码为紧凑的 3D 表示,有效提高了机器人在多种任务中的学习效率、泛化能力以及其在复杂场景下的模仿学习能力.之后, Ze 等^[32]进一步扩展了这一方法,通过融合自适应扩散策略与多模态数据,显著提高了模型在多任务场景中的泛化能力以及在动态环境下的决策效率.目前的 3D 视觉编码器在几何感知、多模态融合与形状生成方面优势显著,但计算复杂度高、标注数据稀缺以及对噪声和稀疏数据敏感等问题不可忽视.很大程度上制约了其在实时系统和复杂场景中的广泛应用.

自然语言编码器聚焦于语言信息的结构化表达, Ingelhart 等^[140]提出了一种基于 Text-to-Text Transfer Transformer (T5) 的自然语言处理框架,能够在多任务学习中实现不同任务间的知识迁移. Zhao 等^[141]进一步扩展了这一方法,提出了一种优化的训练策略,如图 3 所示,构建了一种多模态融合架构,结合 T5 语言模型和多模态感知信息,通过多头注意力机制进行特征交互,输入包括文本数据和多模态感知信息(涵盖视觉、听觉、触觉、嗅觉等模态),并通过线性层进行处理. T5 负责提取文本特征,生成隐藏状态,随后通过键值对 (K, V) 参与注意力计算,同时感知信息经过编码后作为查询进入注意力模块.最终,融合后的表示通过分类器进行任务预测,并计算损失梯度以优化不同模块的参数,有效提升了模型在低资源条件下的生成能力和泛化性能,增强了跨模态任务的理解能力,尤其在多语言翻译和领域迁移任务中表现出色. Chen 等^[161]将 T5 的文本特征对齐到动作专家模块,并输出整段动作序列,显著提升了模型在复杂任务下的跨模态推理和动作序列生成能力.

4.3.2 噪声预测网络优化

在扩散策略中,噪声预测网络 ϵ_θ 是实现逆向去噪的关键.它通过预测噪声来估计动作分布的得分或能量梯度,其网络结构、条件融合方式以及与采样和蒸馏机制的耦合设计,直接影响着生成策略的质量、时序一致性及推理延迟.

作为扩散策略的经典基线架构, U-Net 凭借其多尺度编码-解码结构与跳跃连接机制,展现了强大的局部细节恢复能力.在开创性的工作中,基于 U-Net 的扩散策略在 11 个不同复杂度的机器人操作任务中被验证优于传统行为克隆方法,尤其在多模态动作分布和长时序依赖任务中表现突出,成功率提升达 42%^[19].其时间卷积变体在短时域动作预测任务中表现优异. Yuan 等^[162]的工作进一步解构了扩散策略的核心组件,通过大规模消

融实验揭示了 U-Net 架构中五个关键要素的作用机制,即观测序列输入通过 ResNet 编码器提取视觉特征,动作序列执行采用滑窗预测策略保证时序连续性,网络架构设计平衡了感受野与计算效率,FiLM 条件融合机制实现了观测信息与噪声预测的有效结合.该研究还发现 U-Net 的性能很大程度上依赖于其归纳偏置,特别是在处理局部时空模式方面的优势.

Transformer 架构^[92]在处理长序列依赖和多模态条件融合方面具有显著优势.Hou 等^[163]提出的 DiT-Policy (diffusion transformer policy) 首次将 Transformer 架构引入扩散策略学习.该方法采用分层注意力机制,底层处理局部时空特征,顶层建模全局语义依赖,在长期操作任务中展现出比 U-Net 基线高出 15%~20% 的成功率.DiT-Policy 的核心创新在于引入了动作-观测交叉注意力层,使得模型能够显式建模不同时刻观测与动作之间的复杂关联.实验证明了 Transformer 架构在需要长程时序推理的复杂操作任务中优势明显.Zhai 等^[164]进一步探索了 ViT (vision Transformer) 在扩散策略中的应用潜力,其引入分层视觉编码器,采用 patch-based 注意力机制处理高分辨率图像输入,并通过位置编码增强空间信息的表示能力.ViT 的引入使得策略网络能够更精确地理解复杂视觉场景中的细微空间关系,在精细操作任务中的像素级定位精度提升了 32%,显著改善了抓取成功率和轨迹平滑性.

为解决大规模扩散策略的计算效率问题,专家混合 (MoE) 架构在扩散策略中得到了深入应用和发展.Reuss 等^[165]提出的专家去噪器混合 (mixture of expert denoisers, MoDE) 架构代表了扩散策略中 MoE 设计的重要突破.该方法采用任务特定的专家去噪器,每个专家专门处理特定类型的任务或感知模态.通过门控网络动态选择激活的专家子集,MoDE 在保持模型表达能力的同时显著降低了计算开销.在多任务机器人学习基准测试中,MoDE 相比密集扩散模型减少了 90% 的 FLOP,同时在跨任务泛化等方面表现出色,平均任务成功率提升了 15%.该架构的关键创新在于引入了任务相关性度量机制,能够智能地复用和组合不同专家的知识.Zhou 等^[40]通过变分推断 (variational distillation of diffusion, VDD) 框架将复杂的扩散策略蒸馏为高效的专家混合模型,其核心是变分专家分配机制和知识保持约束.该方法采用分层蒸馏策略,即底层专家学习局部动作,顶层专家建模全局策略决策,中间层实现两者的有机结合.实验结果表明,VDD 能够将大型扩散策略压缩为原来大小的 1/8,同时保持 95% 以上的性能,适用于资源受限的移动机器人平台.Liu 等^[166]提出了基于任务和条件的自适应专家选择机制,进一步提升了 MoE 架构的灵活性和效率.该系统包含多层次路由决策,任务级路由根据高级任务目标选择专家池,条件级路由基于当前观测状态精细调整专家权重,执行级路由在动作生成过程中动态优化专家组合.通过引入路径正则化和负载均衡机制,动态路由系统有效避免了专家退化问题,在长程任务中展现出优异的稳定性和适应性.

为了更好地实现智能体对语言指令的具身理解和执行,众多工作聚焦 VLA 模型,旨在融合多模态感知与运动控制.流匹配 (flow matching)^[72]通过构建从简单噪声分布到复杂动作分布的确定性流,为 VLA 模型提供了一种高效的连续动作生成范式.该方法通过直接学习向量场指导噪声到动作的转换,避免了传统扩散模型的多步去噪过程,显著提升了机器人策略的推理效率和动作精度. Kevin 团队^[167]提出了基于流匹配的 VLA 模型 π_0 ,通过将预训练的 PaliGemma^[168]视觉语言模型骨干网络与流匹配动作专家模块相结合,从而实现高频动作生成;其采用预训练与后训练两阶段范式,在包含 10000 h 数据的跨实体数据集上训练,实现了折叠衣物、桌面清理等长时序精细操作任务.后续 Kevin 团队^[169]提出了 $\pi_{0.5}$ 模型,通过引入分层动作块预测和语义引导的流匹配机制,进一步增强了复杂长视野任务中动作生成的连贯性与语义对齐能力,扩展了流匹配在输出策略中的应用.Shukor 等^[170]提出了 SmolVLA 模型,通过紧凑的 Transformer 架构结合视觉-语言表征学习,实现了高效的多模态动作预测,为轻量化通用机器人策略奠定了基础.这些工作标志着机器人学习范式向大规模预训练与生成式动作规划的重要转变.相比于传统扩散策略和 VLA 结合的方式(如 DiffusionVLA^[148]),流匹配提供了一种比传统扩散更高效的动作表征方式,而基于 VLA 的架构则有效融合了视觉-语言的语义理解与连续动作生成的灵活性,为构建通用、高效且能处理长时序复杂任务的机器人基础模型奠定了关键技术基础.

网络架构的改进遵循着“专用编码器处理特定模态,通用主干网络进行融合与生成”的设计范式.编码器的发展得益于计算机视觉和自然语言处理领域的进步,强大预训练模型(如 CLIP, PointNet, T5)可直接迁移到机器人领域,进行高效的特征提取.噪声预测网络的核心争论点在于 U-Net 与 Transformer 的选择:U-Net 在处理

具有强烈空间结构的图像数据方面具有天然优势;而 Transformer 则因其强大的序列建模和全局注意力机制,更擅长处理多模态融合和长时序依赖关系,正逐渐成为通用架构的选择. VLA 模型的发展进一步体现了这一趋势,它通过将强大的视觉-语言预训练骨干网络与高效的动作生成模型相结合,构建端到端的具身决策系统,为通用机器人基础模型提供了重要的架构蓝图.

4.4 面向训练和采样过程的改进

4.4.1 基于训练过程的改进

扩散策略在机器人操作任务中表现出色,展现了其处理复杂动态过程和决策过程的能力.然而,当面临未曾见过的场景和任务时,其性能往往会大幅下降,说明其泛化能力有待提升.尽管近期的一些研究尝试通过改进扩散策略框架中的视觉特征编码质量来提高策略的泛化性,但增强的能力通常仅限于相似类别或外观与训练数据高度相似的对象.所以为了使基于扩散模型的策略能够执行多种多样的任务,具备更好的泛化能力,一些如 VLA 模型参数量大的工作通过预训练使得模型学习到先验知识,通过微调来提升下游任务的表现及相应泛化能力.

在预训练阶段,依托覆盖多种机器人形态与任务场景的高质量多任务示范数据集(如 Open X-Embodiment^[13]),不同网络结构的扩散策略模型均可显著提升跨任务与跨形态的泛化能力.在微调阶段,方法则更加多样化,如 Octo^[93]利用 Transformer 架构统一处理多模态输入(如视觉观察、语言指令或目标图像),并借助 DDPM^[30]生成精确且多模态的动作输出,从而能够灵活适应不同的机器人平台、传感器配置和任务,并通过少量数据高效微调到新领域. DiT Policy^[163]则使用 LoRA^[151]+AdamW^[171]方法进行微调,在小样本学习场景下取得了优异表现.

此外,不同于一般 VLA 模型使用大规模机器人操作数据进行预训练, TinyVLA^[99]为了追求轻量化,省去机器人数据预训练步骤,使用 VLM 权重来初始化 VLA 模型,采取扩散策略头(DP head)网络替换大语言模型头(LLM head),并用下游机器人数据(遥操作收集)对模型进行 LoRA^[151]微调,从而在不破坏动作连续性、保证模型效果的同时,使得模型训练更加简单.

4.4.2 基于采样过程的改进

由于扩散模型的采样效率通常较低,许多研究提出了改进方案以提升其在推理过程中的实时性和适应性.这些方法主要包括优化采样过程的改进技术,基于蒸馏的高效策略提取,以及通过网络架构创新实现的少步推理技术.

原生 DP^[19]在训练时使用 DDPM^[30]方法采样噪声,但迭代步骤多,实时性较差.为了在推理过程中达到实时控制的效果, Song 等^[52]使用了 DDIM 方法,迭代次数降低至大约 100 步,机器人控制频率可达到 10 Hz. AdaFlow^[154]则使用了条件流匹配(也被称作 rectified flow, RF)^[153]进行训练和推理采样,并结合一个方差估计网络预测当前状态的方差,并据此动态调整步长与函数评估次数,在低方差(近确定性)状态下可退化为一步生成,从而显著降低平均推理时间.

为进一步提升扩散策略的采样效率,许多研究聚焦于蒸馏方法. OneDp^[43]提出了一种基于训练的扩散策略蒸馏方法,该方法将预训练的扩散策略的知识蒸馏到单步动作生成器中,从而实现快速的动作采样.类似地,一致性策略(consistency policy^[152])同样从预训练的扩散策略中蒸馏而来,在扩散策略学习到的轨迹上强制执行自一致性,在保证成功率的情况下将推理效率较经典扩散策略提升了一个数量级.

不同于使用蒸馏方法, Shortcut Models^[45]采用了单网络和单阶段训练.其通过在网络中加入对当前噪声水平和期望步长的条件,模型能够在生成过程中跳过中间步骤,降低了模型复杂性,支持单步/少步推理,并可在推理时灵活调整步长预算,相比蒸馏方案显著简化训练与系统复杂度.

面向训练方式的改进是扩散策略从理论研究迈向实际应用的关键,其核心是实现“强大性能”与“高效部署”之间的平衡.大规模预训练是提升模型通用性的根本路径,但成本高昂;参数高效微调(如 LoRA)则提供了轻量化的适配方案,是通往实用化的重要技术.在推理端,最初的采样方法无法满足实时控制需求,因此催生了

表 2 扩散策略在机器人领域的应用对比分析.

Table 2 Comparative analysis of diffusion strategy applications in robotics.

Application domain	Specific task	Representative method	Core advantage	Method limitation	Applicable scenarios
Robotic manipulation	Single-task vision	GADP [172]	High task success rate and strong generalization	Limited task scope	High-precision manipulation tasks; scenarios requiring strong generalization
	Vision-language multitask	Octo [93]	Strong zero-shot generalization; supports natural-language interaction	Large model size; high computational cost	Multi-object complex manipulation; dynamic environments
	Multimodal input task	ManiWAV [113]	Integrates multisensory signals; enhances contact-rich manipulation	Multimodal data alignment is challenging	Fine-grained manipulation; tasks under low-visibility conditions
	Long-horizon task	GFC [173]	Handles long-term temporal dependencies; supports stage-wise planning	Errors may accumulate over steps	Multi-step complex assembly tasks
	Deformable object	FlowBotHD [174]	Handles deformation uncertainty; resolves visual ambiguity	Difficult to precisely model deformable states	Manipulation of flexible objects such as cloth and rope
Mobile robot navigation and planning	Single-robot navigation planning	DARE [175]	Generates smooth trajectories; strong robustness to noise	Slow inference speed	Navigation in complex static environments
	Multi-robot navigation planning	MMD [176]	Explicitly models multi-robot coordination and collision avoidance	Computational complexity grows sharply with robot count	Multi-robot coordination in logistics and warehouse scenarios
	Navigation planning in static environments	SafeDiffuser [177]	Strict collision-free guarantees; smooth and safe trajectories	Relies on accurate environment maps	Structured static environments
	Navigation planning in dynamic environments	CoBL-Diffusion [178]	Predicts intentions of dynamic obstacles; enables proactive avoidance	Requires high prediction accuracy	Human-robot shared dynamic environments
	Local navigation planning	NoMaD [179]	Rapid response to local variations	Prone to local minima	Navigation planning within limited sensing range
	Global navigation planning	NavigateDiff [180]	Integrates global information; avoids local traps	Requires access to or construction of global maps	Large-scale cross-region navigation; long-horizon planning

蒸馏和一致性模型等“一步/少步生成”技术, 它们通过将复杂的迭代过程压缩进单步/少步网络, 实现了数量级的速度提升, 并在多数基准上保持相当的成功率, 使扩散策略更接近于机器人在线、低时延的实际应用.

5 扩散策略在机器人领域的应用

扩散策略在机器人领域的应用, 近年来逐渐受到关注. 它借鉴了扩散模型在生成式任务中的成功经验, 将其用于机器人策略生成和运动规划, 以提升鲁棒性、泛化性和动作生成的平滑性. 其主要应用场景包括了机械臂操作控制、移动机器人导航规划等方面, 相关应用及对比情况如表 2 所示.

5.1 在机械臂操作控制方面的应用

机械臂的操作控制是扩散策略在机器人领域的重要应用方向之一. 在机械臂的操作控制方面, 扩散策略保持了其高效性, 在视觉单任务、视觉语言多任务、多模态输入任务等不同类型的任务中均获得了不同程度的应用与改进, 这些方法显著提升了机械臂在复杂操作环境中的效率与稳定性. 扩散策略在机械臂操作控制方面的任务方法及案例如图 4 所示.

视觉单任务: 视觉单任务是指基于视觉输入完成某类特定操作任务. 扩散策略凭借其精确的动作生成与轨迹规划能力, 能够显著提升视觉单任务的准确性与执行稳定性. Chi 等 [19] 以环境图像与关节状态为条件, 生成平滑且鲁棒的末端轨迹, 在物体搬运和桌面操作任务中表现优异. 基于扩散策略, 研究人员针对不同的本体和场景进行探索. GADP [172] 在不重新训练的情况下实现跨不同夹爪的拾取和放置操作 (pick-and-place), 通过在推理阶段适配动作轨迹至不同夹爪的物理约束 (如工具中心点偏移、抓取宽度等), 在六种夹爪上实现平均成功率达到 93.3%. DexDiffuser [181] 专注于提升灵巧手抓取任务的泛化能力, 通过结合条件扩散采样器与抓取评估器, 从部分点云中生成、评估并优化三维灵巧手抓取姿态, 实现训练分布外任务中平均成功率达 59.2%, 较其他方法




图4 (网络版彩图) 扩散策略在机械臂操作控制方面的任务方法及案例. (a) GADP^[172], 物品拾取和放置操作方法; (b) DexDiffuser^[181], 物品抓取任务操作方法; (c) OpenVLA^[182], 视觉语言多任务操作方法; (d) ManiWAV^[113], 音频与视觉结合操作方法; (e) GFC^[173], 长程任务操作方法; (f) Diffusion policy^[19], 桌面操作任务方法; (g) JUICER^[183], 视觉精密装配任务方法; (h) ALOHA unleashed^[184], 视觉语言多任务操作方法; (i) TacDiffusion^[185], 视觉与触觉结合装配任务方法; (j) Im2Flow2Act^[186], 可变形物品操作方法.

Figure 4 (Color online) Task methods and examples of diffusion policy in robotic manipulation control. (a) GADP^[172], pick-and-place operation method; (b) DexDiffuser^[181], grasping task operation method; (c) OpenVLA^[182], vision-language multitask operation method; (d) ManiWAV^[113], audio-visual combined operation method; (e) GFC^[173], long-horizon task operation method; (f) Diffusion policy^[19], desktop operation task method; (g) JUICER^[183], vision-based precision assembly task method; (h) ALOHA unleashed^[184], vision-language multitask operation method; (i) TacDiffusion^[185], vision-tactile combined assembly task method; (j) Im2Flow2Act^[186], deformable object manipulation method.

提升了2倍. JUICER^[183]是一种针对精密装配任务的模仿学习方法,通过结合扩散模型和仿真数据扩增技术,实现从RGB图像直接学习多部件、多阶段装配策略,使机械臂能够完成近2500个时间步长内最多五个部件的组装,显著降低对于大规模演示数据的依赖.扩散策略通过高效的轨迹生成与优化,显著提升了机械臂在视觉单任务操作中的表现,提高了任务完成率.

视觉语言动作多任务:视觉语言动作多任务是指在统一框架下结合视觉(vision)、语言信息(language)与动作轨迹(action),完成涵盖多个任务类别、场景和操作需求的机器人操作.相比单任务设定,这类任务更强调在复杂多变的环境中理解和执行自然语言指令的能力,提升跨任务的泛化能力.扩散策略有效融合视觉与语言输入,生成多样且一致的操作轨迹,提升跨任务学习的灵活性与适应性. Octo^[93]提出了一种结合扩散策略的VLA模型,通过将大规模预训练的视觉语言模型与机器人动作生成相结合,显著提升了任务规划和操作的泛化能力.该方法被用在简单的物品叠放、反转等桌面操作任务中,相较于从零开始的模仿学习方法提升了20.4%的任务成功率. ALOHA unleashed^[184]首次提出了一种基于Transformer架构的扩散策略,并结合大规模数据收集实现了对高难度双手操作任务的学习.该方法使用扩散策略稳定训练过程,通过编码器-解码器结构处理高维动作序列,成功应用于多种真实与仿真任务,如系鞋带、挂T恤等. 3D diffuser actor^[31]将扩散模型与三维场景表示相结合,在给定机器人与环境状态的条件学习动作分布,并通过3D去噪变换器预测末端执行器动作,能够有效捕捉多模态动作分布.在多视角设置下,相较于其他先进模型 Act3D^[187],其性能提升达到18.1%,凸显了扩散策略在机器人控制中的优势.在这些研究中,扩散策略的引入不仅提升了高精度操作的处理能力,还在真实机器人上实现了高效、可靠的任务执行.

多模态输入任务:多模态输入任务是指利用视觉、语言、触觉等多种感知模态的联合信息来完成复杂机器人操作,其核心挑战在于实现多源信息的高效融合、冲突消解与策略协同生成.扩散策略可以有效整合多模态特征并输出一致、鲁棒的动作序列,从而提升任务执行的精度与泛化性. ManiWAV^[113]提出了一种结合音频与视觉反馈的端到端机器人学习系统,利用扩散策略作为动作预测生成头,实现跨模态感知与动作生成协同,显著提升接触丰富操控任务的执行质量与多样性. TacDiffusion^[185]融合触觉与视觉信息,在动态环境中的插入与装配任务中显著提升成功率,并基于扩散模型生成的力反馈策略实现多种高精度插入任务的零样本迁移(95.7%成功

率), 并采用动态系统滤波器缓解频率不匹配问题进一步提升了 9.15% 的成功率. VTLA^[188] 综合视觉、触觉与语言三模态输入, 通过跨模态语言对齐与直接偏好优化提升策略生成能力, 在未知插头形状的接触密集型插入任务中成功率超过 90%, 并展现出优异的 Sim2Real 迁移效果. 多模态扩散策略的共同机理是把多源条件显式写入迭代去噪, 使采样每一步都在一致性约束下生成连贯、鲁棒的动作序列. 不同方法的主要差异体现在对齐方式与控制接口上. ManiWAV 偏重音-视对齐以增强接触判别; TacDiffusion 将触觉与视觉对齐并在力域直接输出控制量, 通过动态滤波提升稳定性并适应微小公差的装配任务; VTLA 则以语言为对齐桥梁, 结合偏好优化以强化指令一致性并改善跨模态与 Sim2Real 的泛化能力.

长程任务: 长程任务是指需要长时间规划、跨多个阶段与子目标才能完成的机器人操作, 核心挑战在于保持跨时间尺度的策略一致性、处理长时依赖以及减少误差累计. 受益于扩散策略强大的多模态分布建模能力, GFC (generative factor chaining)^[173] 将长时规划任务建模为空间-时间因子图, 并融合空间约束与基于扩散策略的技能因子, 实现了多操控器任务的灵活规划与泛化, 在并行技能链建模、长时依赖推理和协作任务中均表现优异. TRANSIC^[189] 则采用不同的技术路线, 该算法在模拟环境中利用扩散策略替代传统混合高斯模型训练基础策略, 并结合人类在线纠正信号实现仿真到现实的平滑迁移. 该方法通过未来轨迹规划增强策略性能, 并采用门控残差机制缓解误差积累与数据不平衡问题, 在接触复杂的长程任务中实现了高效稳定的策略迁移. 在模仿学习中, 研究人员聚焦使用扩散策略解决多步规划和泛约束满足等问题, 减少动作轨迹的累积误差, 增强任务执行的鲁棒性.

可变形物体任务: 可变形物体任务旨在操控具有形变特性的柔性物体或铰接物体, 核心挑战在于应对形变带来的高维状态空间与动态不确定性, 并生成稳定、高效的操作策略. 扩散策略能够建模物体形变过程的多模态轨迹分布, 从而在规划中兼顾精度与鲁棒性. Im2Flow2Act^[186] 使用扩散模型作为下游动作解码器, 提出了基于物体流的扩散策略框架. 该方法将物体流作为跨机器实体与跨环境的统一表示, 通过流生成网络从真人演示视频合成任务特定的物体流, 并利用条件流策略将其映射为机器人动作, 实现无需真实机器人训练数据的多任务真实场景操作, 适配刚体、关节体及可变形物体操作. 与之不同, FlowBotHD^[174] 则使用扩散模型的多模态生成特性作为上游预测器, 通过历史感知的扩散建模, 预测关节化物体在视觉歧义或遮挡条件下的多种可能开启方向, 再结合历史观测进行消歧, 从而应对操作歧义, 并在复杂场景中显著提升任务成功率与鲁棒性. 针对可变形物体的任务, 扩散策略有助于实现跨领域学习的目标, 提升模型的泛化能力和操作鲁棒性.

5.2 在移动机器人导航及规划方面的应用

在移动机器人导航规划领域, 存在两类相关但不同的应用: 一类是严格意义上的扩散策略, 即直接从感知输入生成动作序列的端到端学习方法; 另一类是基于扩散模型的路径/轨迹规划方法, 主要用于几何路径生成而非直接的感知-动作映射. 尽管后者在技术实现上更接近扩散模型, 但由于其在机器人控制领域的重要作用以及与扩散策略在应用目标上的相关性, 本小节将两类方法一并讨论. 扩散策略在移动机器人导航及规划方面的应用如图 5 所示.

单一移动机器人的导航规划任务: 单一移动机器人的导航规划任务旨在为单个机器人生成安全、平滑且高效的路径, 同时满足避障、平滑性与实时导航需求. Alejandro 团队^[46] 基于反应扩散模型构建路径规划算法, 利用其自然并行性、抗噪性以及碰撞不湮灭特性, 相比距离变换与扩展 Voronoi 图算法在路径长度与安全距离指标上均具有竞争力, 并生成更平滑路径. 该方法通过偏微分方程的连续演化过程天然保证路径平滑性, 其基于梯度场的确定性优化机制计算效率高, 适合实时性要求严格的场景, 但限制了对复杂多模态路径分布的表达能力. DiPPeR^[192] 面向四足机器人提出了基于扩散的 2D 路径规划框架, 并引入了可扩展的地图-轨迹数据生成器, 以支持多场景模型训练与泛化. DARE^[175] 使用在专家演示上训练的扩散策略一次性生成自主探索路径, 结合基于注意力的编码器与扩散模型, 实现无规划循环的高效路径生成. 通过引入注意力机制, 该方法能够选择性编码环境关键信息, 有利于扩散采样过程捕获路径规划中的不确定性, 在未知环境的探索任务中提升避障成功率. Zhang 等^[193] 针对部分可观测环境, 将扩散模型与值函数引导相结合以生成长时序规划轨迹, 有效克服传统路径规划方法 (如自回归规划) 在长时间范围任务中缺乏远见的问题. 该方法将路径规划转化为价值最大化问题,




图 5 (网络版彩图) 扩散策略在移动机器人导航及规划方面的应用. (a) DARE^[175], 单一机器人在环境中探索任务; (b) T-Diff^[190], 静态环境目标导航任务; (c) NoMaD^[179], 实现局部目标导航策略; (d) SMD^[191], 多机器人协同运动规划导航任务; (e) CoBL-Diffusion^[178], 动态环境中机器人规划器; (f) NavigateDiff^[180], 与大模型结合的全局导航方法.

Figure 5 (Color online) Application of diffusion policy in mobile robot navigation and planning. (a) DARE^[175], single robot exploration task in an environment; (b) T-Diff^[190], static environment goal navigation task; (c) NoMaD^[179], local goal navigation policy implementation; (d) SMD^[191], multi-robot coordinated motion planning navigation task; (e) CoBL-Diffusion^[178], robot planner in a dynamic environment; (f) NavigateDiff^[180], global navigation method combined with a large model.

通过迭代优化逼近全局最优解, 能够处理长时序依赖和复杂约束. Meng 等^[194] 将信号时序逻辑与扩散模型融合, 结合可微分规划器与状态估计, 在部分可观测环境下生成具有前瞻性的多步动作序列, 实现目标导向与探索行为的统一. 该方法通过逻辑约束确保路径安全性, 在安全关键任务中表现突出. PoPi^[195] 提出了分层规划框架, 先由运动规划器确定全局方向与避障策略, 再利用短时域扩散策略精细化局部导航, 实现复杂环境下的高精度路径生成. “粗粒度全局规划 + 细粒度局部优化” 策略在路径平滑性方面表现最优, 但两层次间的信息传递损失和目标函数不一致性导致子任务衔接处的不连续性问题. 采用扩散策略能够提升单一机器人的导航规划任务的成功率, 但会引入额外的计算开销, 从而限制了实时响应能力.

多移动机器人的导航规划任务: 多移动机器人的路径规划任务需要在共享空间中为多个机器人同时规划无碰撞路径, 并实现任务分配与协作优化, 以达到整体任务的最优完成. MMD^[176] 利用单机器人数据训练的多机器人多模型规划扩散方法, 结合数据驱动模型与基于搜索的经典技术, 在物流式多机器人场景中实现高效无碰撞轨迹生成. 该方法的核心优势在于通过单机器人到多机器人的知识迁移大幅降低了训练数据需求, 其混合架构结合了扩散模型的生成灵活性和经典搜索的可靠性, 在仓储物流场景中碰撞避免成功率显著提升. SMD^[191] 将约束优化嵌入扩散模型采样过程, 实现多机器人运动规划中同时生成无碰撞、运动学可行的轨迹, 实验表明 SMD 在复杂多机器人环境中的成功率与规划效率均优于经典方法与其他学习型方法. 该方法将硬约束直接集成到扩散采样过程中, 通过约束投影确保每一步采样都满足安全性和运动学要求, 相比后处理约束检查的方法, 规划成功率提升 25%~35%. 在多移动机器人的导航规划任务中, 如何提高扩散策略的采样效率, 降低推理计算时间, 是实现在真实场景中大规模部署的重要挑战.

静态场景下的机器人导航规划任务: 静态场景导航主要关注在环境结构相对固定、障碍物不随时间变化的场景中规划安全且高效的路径, 关键挑战是同时保证安全性约束与规划效率. 例如, SafeDiffuser^[177] 将控制屏障函数融入扩散去噪过程, 使采样过程中每一步都受到安全可行域的约束, 从而把“安全保证”前移到生成内部; 在迷宫路径规划、腿式机器人运动等任务中, 相比基础扩散策略表现出更强的鲁棒性. 与之互补, Yu 等^[190] 提

出了 T-Diff 方法实现目标导航任务, 利用 DDPM 来训练轨迹扩散模型, 该模型可以根据当前观察和设定的目标生成连贯的动作序列, 让机器人少走弯路并提高到达目标的效率. 总体而言, 通过改变基础扩散模型的约束条件, 可以使生成轨迹具有更好的长一致性与到达率, 提升生成轨迹的安全性与鲁棒性.

动态场景下的机器人导航规划任务: 主要挑战在于需在存在移动障碍物或其他智能体干扰的环境中实现实时避障并保持轨迹连贯性. Niedoba 等^[196] 利用扩散模型的生成能力, 提出了一种多智能体联合轨迹生成方法, 可在灵活条件约束下模拟多样且真实的交通场景. 与之不同, CoBL-Diffusion^[178] 在动态环境中结合扩散模型与控制屏障函数及李雅普诺夫 (Lyapunov) 函数, 引导去噪过程迭代生成满足安全与稳定约束的控制序列. 该方法在单机器人合成环境与真实行人数据集上验证, 可生成平滑轨迹并在到达目标的同时保持低碰撞率. 通过优化基础扩散模型, 能够实现在动态环境中的不确定性建模与推理, 提升轨迹预测或动作生成的多样性与可行性.

针对局部范围的机器人导航规划任务: 局部导航面向有限感知范围内的即时路径生成, 强调对环境局部变化的快速响应. NoMaD^[179] 模型通过使用 Transformer 架构编码 RGB 观测值, 并采用扩散模型解码器灵活处理带目标条件与无目标条件的任务, 实现了高效的目标导向导航及未见环境探索. ViNT (visual navigation transformer)^[197] 是一个旨在将通用预训练模型应用于视觉导航的基础模型, 利用灵活的 Transformer 架构学习通用的目标到达能力并支持扩散采样探索未知环境及大规模规划. NWM^[198] 则采用了 CDiT (conditional diffusion Transformer), 以预测未来视觉观察结果, 从而优化路径规划决策. LDP^[38] 在扩散模型的基础上引入轻量化的全局观测信息, 有效缓解了因局部视野导致的短视性决策问题, 提升了机器人在多样场景下的避障能力与导航鲁棒性. NoMaD 和 ViNT 等方法凭借视觉与 Transformer 架构的通用性在未知环境局部导航任务中表现优异, 而随着数据规模和算法的进一步结合, NWM 等方法展现出基于扩散策略的世界模型在导航任务中的巨大潜力.

针对全局范围的机器人导航规划任务: 主要是融合宏观信息以支持长程规划并避免陷入局部极小值. Zhang 等^[193] 在部分可观测条件下提出了融合多信息源的价值引导扩散策略提升长程导航性能; NavigateDiff^[180] 将零样本导航分为预测中间目标生成与低层控制两阶段, 结合多模态大语言模型与扩散模型生成未来目标, 并通过 hybrid fusion 解耦局部与全局时序信息, 在新环境下实现跨仿真与真实场景的高效全局导航. 长序列的全局导航任务通常面临环境复杂性与动态变化的挑战, 通过结合辅助记忆等方法, 扩散策略可以进一步实现路径规划决策的有效性.

6 数据集和基准

用于评估扩散策略的方法涵盖运动规划、机器人导航与机器人操作等不同任务场景. 本节对常用数据集与基准进行梳理, 概述其内容与挑战, 以便刻画扩散策略的能力边界. 主要数据集和基准对比如表 3 所示.

- **Open X-Embodiment**^[13] 数据集由全球 34 个机器人研究实验室联合构建, 包含超过 100 万条真实机器人轨迹, 涵盖 22 种不同的机器人形态, 包括单臂机器人、双手机器人和四足机器人. 该数据集通过整合 60 个现有数据集, 并统一为 RLDS 数据格式^[206], 便于跨平台使用与复用. RLDS 格式支持多种机器人配置、动作空间和输入模态 (如 RGB 图像、深度图和点云数据). 尽管大部分技能集中于抓取-放置任务, 该数据集还包括擦拭、组装等多种技能, 涉及的物品种类广泛, 从家用电器到食品和餐具. Ghosh 等^[93] 设计并在该数据集上预训练了首个开源的通用机器人操作策略 Octo, 其具备任务与观察方式的灵活定义能力, 并能够高效适配新的动作空间. 作为大规模的开放数据集, Open X-Embodiment 为跨机器人形态的通用学习提供了较好的数据集基础.

- **RH20T**^[199] 数据集包含超过 11 万条真实世界的机器人操作序列, 覆盖 140 多种操作任务, 并配有人类演示视频. 该数据集整合了视觉、力觉、音频和本体感知等多模态数据, 专注于复杂操作技能, 特别是需要接触感知的任务, 如抓取、插入和组装. 其高质量数据采集平台包括机械臂、力矩传感器、夹爪、多摄像头和麦克风, 经过精确校准以确保时间同步性和多模态一致性. 数据集采用层次化组织, 将相似任务归类, 便于提取跨任务共性, 同时为研究复合任务对技能泛化的影响提供支持. Xia 等^[207] 基于该数据集设计了新型机器人操纵策略 (causal attention generalizable policy, CAGE), 该策略通过因果感知器实现高效令牌压缩, 并结合扩散动作预测

表 3 数据集与基准对比.

Table 3 Comparison between datasets and benchmarks.

Name	Number of scenes	Number and types of objects	Dataset size	Tasks	Observation modality	Physics engine	Hardware
Open X [13]	–	–	1M trajectories	Grasping, pushing, etc.	RGB, RGB-D, point cloud	–	Single-arm robot, dual-arm robot, quadruped robot, etc.
RH20T [199]	–	Hundreds of objects	110k manipulation sequences	Cutting, insertion, rotation, etc.	Vision, force sensing, audio, proprioception	–	Robot arm, torque sensor, gripper, etc.
RP1M [110]	–	2000 music pieces	1M performance trajectories	Piano playing	Robot hand states	MuJoCo	Dual robotic hands
DROID [200]	564	–	76k demonstration trajectories	Grasping, switching, object manipulation	RGB, RGB-D, proprioception	–	7-DOF manipulator, gripper, vision sensors
BEHAVIOR-1k [201]	50	9000 objects	–	Cleaning, cooking, leisure services	Vision, lidar, proprioception	OMNIGIBSON	–
QDGset [202]	–	40k objects	60M grasp poses	Grasping	–	–	–
Robo360 [104]	–	100 objects	2000 manipulation trajectories	Grasping, moving, folding, pouring	RGB, RGB-D, audio, proprioception	–	Robot arm
ManiSkill3 [203]	12	20 robot types	Millions of demonstration frames	Grasping, placing, drawing, cleaning	RGB-D, tactile sensing, proprioception	PhysX	–
RoboCasa [204]	120	2500 objects	100k trajectories	Grasping, placing, cooking, cleaning	RGB-D, tactile sensing, proprioception	MuJoCo	–
FMB [205]	–	66 objects	22550 demonstration trajectories	Grasping, relocation, insertion, assembly	RGB-D, force sensing, proprioception	–	Robot arm, torque sensor

头和注意力机制增强了任务细粒度调节能力. 在 RH20T 数据集的运输任务上, CAGE 展现了预训练后开箱即用的强大泛化能力. 此外, He 等 [208] 提出了力感知反应策略 (force-aware reactive policy, FoAR), 将高频力/扭矩传感与视觉输入结合, 显著提升了擦除、剥皮和切割任务的操作性能. RH20T 数据集的广泛任务覆盖和高质量支持, 为一次性模仿学习和机器人基础模型的研究提供了较好的数据集基础.

● **RP1M** [110] 是一个专为研究灵巧机器人手钢琴演奏而设计的大规模数据集, 包含超过 100 万条专家级双手机器人演奏轨迹, 涵盖 2000 多首音乐作品. 数据集支持学习全自动指法生成方法, 将指法规划形式化为最优传输问题, 从而优化双手动作轨迹. 这一方法无需人类演示或指法注释, 仅通过 MIDI 文件即可实现高效且灵活的钢琴演奏. 通过该过程, 机器人双手能够自主学习并执行精准、动态的演奏策略. RP1M 数据集不仅为开发具有人类级钢琴演奏能力的灵巧机器人手提供了关键数据支持, 也为机器人自主学习和运动规划开辟了新的研究方向.

● **DROID** [200] 是一个大规模、多样化的机器人操作数据集, 旨在提高机器人操作策略的泛化能力. 该数据集包含 76000 个演示轨迹, 总计约 350 h 的交互数据, 涵盖 564 个场景和 86 个任务. 数据采集使用统一的硬件平台, 包括 Franka Panda 7 自由度机器人手臂、Robotiq 2F-85 夹持器及多个 ZED 立体相机, 通过 Oculus Quest 2 控制器远程操作采集数据. 每个数据集包括三路 RGB 摄像机视角、深度信息、摄像机标定数据和自然语言指令. DROID 数据集的多样性体现在任务、物体、场景和视角上, 任务从简单的拾取放置到复杂的多阶段操作, 场景包括厨房、卧室、实验室等, 交互对象包括家电、工具、食品包装等. 摄像机视角的频繁调整增强了数据的泛化能力. 与现有数据集相比, 使用 DROID 进行联合训练的策略在成功率方面平均提高了约 20%, 尤其在分布外任务测试中, DROID 展现了更强的泛化能力, 能够适应未见过的场景、物体和任务. Hou 等 [163] 把 Droid 数据集与其他 14 个来自 Open X-Embodiment 的大型数据集融合在一起, 经权重设置、图像尺寸调整、动作预处理后用于 diffusion Transformer policy 模型的预训练, 有效增强了模型在多种机器人操作任务和不同环境下的泛化能力. Wen 等 [209] 使用 Droid 数据集对 DiVLA-2B 和 DiVLA-7B 模型进行预训练, 并将其与 OXE 数据集共同用于 DiVLA-72B 模型预训练, 经数据增强后使模型在多任务学习、物体分拣、零样本无序抓取 (bin-picking) 等任务中表现出色.

● **BEHAVIOR-1k** [201] 数据集涵盖 1000 种基于人类需求的日常活动, 涉及清洁、烹饪、整理与维护等任务. 每个活动通过谓词逻辑进行形式化描述, 明确了活动的初始条件、目标状态以及所需的对象状态转换. 例

如,“清理桌面”任务包括物体污渍状态、位置及最终干净整洁的目标,方便高层次任务规划和评估。数据集包含 50 个多样化的场景,如住宅、办公室、餐馆等,以及超过 9000 个 3D 对象模型,涉及 1900 多个类别,包含详细的物理和语义属性(如质量、摩擦、湿润度等)。这些多样化场景和对象为具身 AI 提供了丰富的学习和测试环境。通过定义复杂的物理任务状态和转换规则(如食物加热、布料折叠、污渍擦拭等),BEHAVIOR-1K 能够模拟真实的物理操作,支持任务仿真。与以往数据集相比,BEHAVIOR-1K 不仅扩展了场景和对象的覆盖范围,还首次将温度、湿润度等物理状态变化纳入任务定义,提升了仿真的物理真实感与任务可判定性,成为 AI 系统开发的重要平台。

- **QDGset**^[202] 是一个包含约 6000 万条 6-DOF 抓取位姿和 4 万个模拟物体的大规模机器人抓取数据集。基于质量-多样性(QD)框架 QDG-6DoF, QDGset 通过物体网格变换和抓取迁移学习实现了高效数据生成,减少了评估次数约 20%。该数据集涵盖范围广泛,包括从常见物体到对抗性设计物体,并支持通过语义标签扩展抓取任务的应用场景,可广泛用于机器人技能学习及 Sim2Real 迁移研究。

- **Robo360**^[104] 关注机器人在复杂现实世界中的操作任务。该数据集包含 2000 多条多视角机械操作轨迹,由 86 个经过校准和时间对齐的相机捕捉,涵盖 100 个具有 20 多种不同材料的物体,同时还包括机器人本体感知和控制信号等多模态数据。数据集创建使用 RoboStage 系统,可以实现动态 3D 场景捕获。通过动态 NeRF 和基于学习的机器人控制实验,验证了数据集对策略学习和泛化的作用。该数据集解决了数据收集系统中的技术难题,提出了适应多视图输入的策略学习算法,为 3D 机器人操作研究提供了重要资源。

- **ManiSkill3**^[203] 提供了一个基于 SAPIEN^[210] 构建的 GPU 并行化机器人模拟与渲染基准,旨在解决现有模拟基准存在场景或任务支持有限及关键功能缺失等问题。该基准的核心贡献是其拥有先进的 GPU 并行模拟和渲染能力,使模仿学习算法在视觉任务上的处理时间大幅缩短。该基准实现了对机器人仿真领域的全面覆盖,支持异构模拟,便于泛化学习。此外,该基准还提供了针对多种主流学习算法的基线,覆盖离线和在线的模仿学习,为探索和开发机器人操控和学习策略提供丰富而灵活的工具包。Shen 等^[211] 将该基准用于类别级可泛化对象操作策略学习,通过利用其包含的四个任务的训练与测试实例划分、机器人和场景的观察数据以及设定的奖励机制,训练和评估所提方法,以验证方法的有效性和泛化能力。

- **RoboCasa**^[204] 是一个用于训练通用机器人的大规模模拟基准,其核心模拟平台基于 RoboSuite^[212] 构建,扩展后支持多种移动操纵器。该基准包含 120 个以厨房为中心的真实场景,涵盖多种风格和布局,包括超过 2500 个 3D 资产,覆盖 150 多个对象类别,且多数由 text-to-3D 工具生成,确保了模拟环境的丰富性和细节的精确性。该基准设计了 100 项任务,包括 25 个原子任务和 75 个由大语言模型指导生成的复合任务,并配有大规模多任务数据集,通过人类演示和自动轨迹生成方法收集数据。该方法证明了机器生成轨迹有助于学习多任务策略,且随着训练数据集增大,模仿学习策略的泛化性能也可以逐渐提升。

- **FMB**^[205] 旨在解决机器人操作领域中的关键挑战:如何将原子操作组合成复杂的长链操作。该基准涵盖单对象和多对象多阶段操作任务,并对比了不同模仿学习技术在这些任务中的表现,如 ResNet^[213] 和 Transformer^[92] 模型在抓取、重定位、插入等任务中的差异,并系统评估输入模态对策略表现的影响。该基准为机器人操作学习提供了一个综合性的研究框架,提供受控且多样化的任务,有效平衡了任务复杂性与可及性,并着重强调了技能泛化性的挑战。Octo^[93] 在 Berkeley 插入任务的微调评估中,选取了该基准中的 100 个人类演示数据作为微调数据集,通过这些数据对模型进行训练,机器人能够学习将预抓取的 3D 打印销插入 3D 打印板上匹配插槽的策略。OpenVLA^[182] 将该基准作为训练数据混合物的一部分进行预训练,以帮助模型学习不同机器人场景、任务和对象的特征。

7 当前挑战与未来方向

虽然扩散策略在具身智能领域展现出巨大潜力,但其在实际应用中仍面临诸多关键挑战,主要体现在数据使用效率优化、泛化能力增强、长程任务执行一致性保障、统一评测标准构建以及安全性与可解释性提升等方面。为构建基于扩散策略的通用具身智能系统,未来研究需要在以下几个方向协同发力:通过低成本硬件平台和

虚实贯通技术提升数据效率;采用通用模型与专业模型相结合的策略,或利用世界模型的生成与预测能力增强模型对未知环境的泛化性;通过优化扩散策略输出和快-慢系统融合实现更自然的子任务衔接,从而提升子任务间的轨迹一致性.本节旨在进一步分析当前存在的核心挑战并探讨相应的解决路径,以期为该领域的未来发展提供有价值的参考.

7.1 数据使用效率问题

扩散策略面临的核心挑战之一是数据使用效率不足,即如何在有限的专家演示数据下高效学习复杂的决策策略.具身智能系统的示范数据通常依赖人工采集(如遥操作^[184]、专家手工标注等),这一过程不仅成本高昂,还需要大量的人力投入,极大限制了模型的推广与应用.针对数据采集成本问题,已有研究通过精巧的工程设计实现了低成本且信息丰富的硬件方案^[214],显著降低了数据采集门槛.随着模型输入模态的不断增多,设计信息全面、成本低廉的数据收集硬件将成为一个极具前景的研究方向.尽管现有开源数据集^[13,199]在一定程度上缓解了数据短缺问题,但其覆盖的场景范围仍然有限,难以满足具身智能多样化的应用需求.为此,研究者开始采用高保真仿真平台(如 MuJoCo^[215], Isaac Gym^[216], Maniskill^[203])生成大规模仿真数据,以降低对真实世界数据采集的依赖性.

未来提升数据使用效率的关键在于实现有效的虚实贯通,即将仿真环境与真实环境的数据有机结合.除直接利用仿真平台生成数据外,还可采用 Real2Sim2Real^[217,218]的技术路线,将真实场景数字化建模,利用仿真平台训练模型,最终迁移到真实环境中应用.另一种有效途径是从人类活动视频中自动提取演示轨迹,虽然存在一定的分布差异,但能够显著扩展训练数据的覆盖范围和多样性.此外,结合小样本学习(few-shot learning^[219])和迁移学习(transfer learning^[220])等技术,将进一步提升扩散模型的数据利用效率,实现更具成本效益的学习范式.

7.2 泛化能力问题

尽管扩散策略在特定任务和环境中表现良好,但当应用于未见的环境或新任务时,往往难以保持稳定性能.这种局限性主要源于模仿学习对专家演示数据的高度依赖,而示范数据通常覆盖有限的状态-动作空间.当前,数据增强技术被广泛用于提升模型泛化性.例如,域随机化(domain randomization^[221])通过对环境颜色、光照、物体位置等的扰动,使模型学习到更具鲁棒性的策略.

除了数据增强技术,使用世界模型或利用预训练的基础模型可以有效提高模型的泛化能力.世界模型(world model)是一种能够对现实世界环境进行仿真,并基于文本、图像、视频和运动等输入数据来生成视频、预测未来状态的生成式 AI 模型,其强大的泛化能力可以应用于具身智能.例如,可以利用世界模型基于当前的图像观测生成视频,再用逆运动学求解出动作^[222].基础模型(foundation models)^[71]通过在大规模、多样化的数据集上预训练,学习得到通用的数据分布表征.“通专融合”是指以基座模型提供广泛分布表征,再结合专用模型精调或 RAG 等技术适配任务,从而兼顾广度与深度.自监督学习^[223]也为提升泛化性提供了新思路,可以利用大规模未标注视频或多模态数据学习通用技能.除此之外,引入 3D 表征及触觉等多模态数据对齐技术有望显著增强跨场景与跨任务的泛化性.

7.3 长程任务的执行一致性问题

在长程任务(如自主导航、复杂装配等)中,扩散策略面临的核心挑战是如何在长时间决策过程中保持生成策略的连贯性和稳定性.当前主要的解决思路包括如下三方面.一是通过层次化策略学习^[224]将复杂长程任务分解为一系列相对简单的子任务来降低整体复杂度;Transformer^[92]架构提供记忆机制,能够有效保留历史信息并提升长期决策的连贯性.二是借助大语言模型的规划能力,将任务拆解为高层规划(慢思考)和低层执行(快思考)两个层次.然而,这种分层架构在子任务衔接时可能存在不自然的问题,影响整体执行效果.未来研究应重点关注生成过程中的轨迹一致性优化,通过构建快-慢系统融合机制以及扩散策略与强化学习(DP + RL)的有机结合,建立闭环反馈机制,实现更加稳定和灵活的长程任务执行.三是采用扩散策略与轨迹优化、路径平滑

等方法深度融合,提升执行一致性。例如,采用实时轨迹控制(RTC^[225])或均值流方法(mean flow^[226])等技术,可以有效优化决策过程中的动作轨迹,减少误差积累并显著提升长程任务执行的质量和可靠性。

7.4 构建统一的评测标准

随着具身智能领域的快速发展,建立公平、客观、全面的模型评测体系已成为推动技术进步的关键问题。目前,由于不同研究采用差异化的数据集、实验设置和任务定义,跨研究的模型比较面临巨大挑战。统一的评测标准对促进模型间的公平比较和加速技术迭代具有重要意义。

当前已有多个评测框架致力于解决这一问题。RoboTwin^[227]提供了专门的评测框架,Open X-Embodiment^[13]实现了跨平台大规模数据整合,RoboVerse^[228]建立了跨平台和跨任务的评测标准。这些框架为不同研究领域提供了宝贵的工具支撑,旨在通过标准化的评估体系促进跨平台和跨任务的有效比较。然而,现有评测框架仍存在显著局限性。首先,现有框架往往过于简化,难以完全适应不同任务领域的特定需求。对于高度定制化的任务或极端环境条件(如复杂长程任务、跨模态交互任务等),标准化评测难以全面捕捉现实世界的复杂性。其次,尽管RoboVerse等框架支持虚实环境结合(通过real2sim2real技术),但仿真与现实间的域差距仍是长期挑战。物理建模差异、感知噪声、环境变化等因素导致仿真环境与真实环境间存在难以弥合的鸿沟,使得仿真中表现优异的模型在真实环境中可能失效。因此,如何最小化虚实环境差异,以及如何在真实环境中实现公平的模型评测,仍是亟待攻克的核心问题。此外,目前的评测标准尚未充分考虑长程任务中的轨迹一致性、决策延迟、多模态输入等关键评估维度。这些复杂任务通常涉及长期决策与动态环境的深度交互,标准化评测在此类场景下的有效性有待进一步验证和提升。

尽管面临诸多挑战,随着相关工具、数据和评测框架的持续完善,统一的评测标准必将成为推动具身智能领域发展的重要驱动力。未来研究需要在以下方向深入发展:一方面,持续提升标准化评测方法的灵活性和适应性,确保其能够覆盖不同任务、场景及跨模态交互等复杂情况;另一方面,开发更具挑战性和代表性的评测任务,特别是能够充分反映长期决策、复杂动态环境和真实世界不确定性的评估任务。通过这些努力,统一评测标准将为不同模型的公平比较提供有力支撑,促进具身智能技术的理论突破和实际应用。

7.5 安全性和可解释性

安全性和可解释性是具身智能系统走向真实应用的关键挑战。扩散策略的高度复杂性和随机性可能导致不确定行为,影响系统可靠性,尤其在自动驾驶、医疗机器人等高风险领域。与此同时,其作为概率生成模型的“黑盒”特性使其决策过程缺乏透明度,这又会严重削弱用户的信任。

未来研究可从两个方面展开,一是在安全性方面,可通过在策略生成中嵌入安全约束、引入自适应控制以及设计故障检测与恢复机制,以提升系统在真实环境下的鲁棒性;二是在可解释性方面,可借助可视化、因果推断等方法阐明其决策逻辑,从而提升人机交互中的信任度。

总体而言,扩散策略面临的核心挑战呈现出系统性关联特征,各问题间存在深度耦合与协同演化关系。解决其中一个关键问题往往能够产生显著的正向溢出效应,进而带动整个技术体系的全面提升。从技术发展的内在逻辑来看,数据效率的根本性改善是增强模型泛化能力的重要前提,丰富多样的高质量数据为模型应对分布外任务和复杂环境变化提供了坚实基础。泛化能力的持续增强能够有效减少长程任务执行中的误差传播与积累,从而保证任务执行的连贯性与一致性。在长程任务执行层面,轨迹一致性和长期决策稳定性直接决定了复杂任务的成功率,这是模型整体性能和具身应用可靠性的关键保障。统一评测标准作为技术发展的重要支撑,不仅为不同模型间的公平比较提供客观依据,更是推动技术快速迭代与持续优化的必要条件。

在短期,研究重点应聚焦于通过低成本硬件平台和高效仿真环境提升数据利用效率,积极探索Real2Sim2-Real等虚实结合方法优化训练数据质量,同时结合小样本学习与迁移学习等前沿技术,系统性增强扩散策略在多任务环境下的快速适应能力。在中期,核心任务是全面提升模型泛化性能,探索基座模型与专用模型结合的“通专融合”策略,或利用世界模型的泛化性增强模型在未知环境的任务执行成功率。同时,加入轨迹一致性优化方法提升长程任务执行的一致性和稳定性。在长期,目标是构建一个具备高效、安全、可解释性和鲁棒性的通用

具身智能系统. 这一愿景需要通过深度整合视觉感知、语言规划和扩散策略等方法, 确保在多任务、多环境下都能稳定工作, 并通过统一的评测标准为各类模型的公平比较提供有力支持.

参考文献

- 1 Bai C J, Xu H Z, Li X L. Embodied-AI with large models: research and challenges. *Sci Sin Inform*, 2024, 54: 2035–2082 [白辰甲, 许华哲, 李学龙. 大模型驱动的具身智能: 发展与挑战. *中国科学: 信息科学*, 2024, 54: 2035–2082]
- 2 Turing A M. Computing machinery and intelligence. *Creative Comput*, 1980, 6: 44–53
- 3 Lin F, Hu Y, Sheng P, et al. Data scaling laws in imitation learning for robotic manipulation. *ArXiv:2410.18647*
- 4 Sutton R S, Barto A G. Reinforcement Learning: an Introduction. *IEEE Trans Neural Netw*, 1998, 9: 1054
- 5 Zare M, Kebria P M, Khosravi A, et al. A survey of imitation learning: algorithms, recent developments, and challenges. *IEEE Trans Cybernetics*, 2024, 54: 7173–7186
- 6 Jakobi N, Husbands P, Harvey I. Noise and the reality gap: the use of simulation in evolutionary robotics. In: *Advances in Artificial Life*. Berlin-Heidelberg: Springer, 1995. 704–720
- 7 Ravichandar H, Polydoros A S, Chernova S, et al. Recent advances in robot learning from demonstration. *Annual Review of Control, Robotics, and Autonomous Systems*. 2020. <https://www.annualreviews.org/content/journals/10.1146/annurev-control-100819-063206>
- 8 Osa T, Pajarinen J, Neumann G, et al. An algorithmic perspective on imitation learning. *Found Trends Robot*, 2018, 7: 1–179
- 9 Pomerleau D A. Efficient training of artificial neural networks for autonomous navigation. *Neural Comput*, 1991, 3: 88–97
- 10 Ho J, Ermon S. Generative adversarial imitation learning. *ArXiv:1606.03476*
- 11 Zhao T Z, Kumar V, Levine S, et al. Learning fine-grained bimanual manipulation with low-cost hardware. *ArXiv:2304.13705*
- 12 Jaquier N, Welle M C, Gams A, et al. Transfer learning in robotics: an upcoming breakthrough? A review of promises and challenges. *Int J Robotics Res*, 2025, 44: 465–485
- 13 O'Neill A, Rehman A, Gupta A, et al. Open X-Embodiment: robotic learning datasets and RT-X models. *ArXiv:2310.08864*
- 14 Walke H, Black K, Lee A, et al. Bridgedata v2: a dataset for robot learning at scale. In: *Proceedings of Conference on Robot Learning (CoRL)*, 2023
- 15 Kalashnikov D, Varley J, Chebotar Y, et al. Mt-opt: continuous multi-task robotic reinforcement learning at scale. *ArXiv:2104.08212*
- 16 Fang H S, Fang H, Tang Z, et al. Rh20t: a robotic dataset for learning diverse skills in one-shot. In: *Proceedings of RSS 2023 Workshop on Learning for Task and Motion Planning*, 2023
- 17 Gu J, Xiang F, Li X, et al. Maniskill2: a unified benchmark for generalizable manipulation skills. In: *Proceedings of International Conference on Learning Representations*, 2023
- 18 Wu J, Sun X, Zeng A, et al. Spatial action maps for mobile manipulation. In: *Proceedings of Robotics: Science and Systems XVI*, 2020
- 19 Chi C, Xu Z, Feng S, et al. Diffusion policy: visuomotor policy learning via action diffusion. *ArXiv:2303.04137*
- 20 Mandlekar A, Xu D, Wong J, et al. What matters in learning from offline human demonstrations for robot manipulation. *ArXiv:2108.03298*
- 21 Florence P, Lynch C, Zeng A, et al. Implicit behavioral cloning. In: *Proceedings of Conference on Robot Learning*, 2022. 158–168
- 22 Shafiullah N M, Cui Z, Altanzaya A A, et al. Behavior transformers: Cloning k modes with one stone. *Advances in neural information processing systems*, 2022, 35: 22955–22968
- 23 Zhou K, Liu Z, Qiao Y, et al. Domain generalization: A survey. *IEEE Trans Pattern Anal Mach Intell*, 2023, 45: 4396–4415
- 24 Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning. In: *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, 2011. 627–635
- 25 Sun Q, Zhang S, Ma D, et al. Large trajectory models are scalable motion predictors and planners. *ArXiv:2310.19620*
- 26 Jiang Z, Xie Y, Lin K, et al. Dexmimicgen: automated data generation for bimanual dexterous manipulation via imitation learning. *ArXiv:2410.24185*
- 27 Garrett C, Mandlekar A, Wen B, et al. Skillmimicgen: automated demonstration generation for efficient skill learning and deployment. *ArXiv:2410.18907*
- 28 Mandlekar A, Nasiriany S, Wen B, et al. Mimicgen: a data generation system for scalable robot learning using human demonstrations. *ArXiv:2310.17596*
- 29 Hao C, Lin K, Luo S, et al. Language-guided manipulation with diffusion policies and constrained inpainting. *ArXiv:2406.09767*
- 30 Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models. *Adv Neural Inform Process Syst*, 2020, 33: 6840–6851
- 31 Ke T W, Gkanatsios N, Fragkiadaki K. 3D diffuser actor: policy diffusion with 3D scene representations. *ArXiv:2402.10885*
- 32 Ze Y, Zhang G, Zhang K, et al. 3D diffusion policy: Generalizable visuomotor policy learning via simple 3D representations.

ArXiv:2403.03954

- 33 Ze Y, Chen Z, Wang W, et al. Generalizable humanoid manipulation with improved 3D diffusion policies. ArXiv:2410.10803
- 34 Mishra U A, Xue S, Chen Y, et al. Generative skill chaining: long-horizon skill planning with diffusion models. In: Proceedings of Conference on Robot Learning, 2023. 2905–2925
- 35 Yan G, Wu Y H, Wang X. Dnact: diffusion guided multi-task 3D policy learning. ArXiv:2403.04115
- 36 Liang J, Payandeh A, Song D, et al. Dtg: diffusion-based trajectory generation for mapless global navigation. In: Proceedings of 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2024. 5340–5347
- 37 Stamatopoulou M, Liu J, Kanoulas D. Dippest: diffusion-based path planner for synthesizing trajectories applied on quadruped robots. In: Proceedings of 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2024. 7787–7793
- 38 Yu W, Peng J, Yang H, et al. Ldp: a local diffusion planner for efficient robot navigation and collision avoidance. In: Proceedings of the 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2024. 5466–5472
- 39 Wang Y, Zhang Y, Huo M, et al. Sparse diffusion policy: a sparse, reusable, and flexible policy for robot learning. ArXiv:2407.01531
- 40 Zhou H, Blessing D, Li G, et al. Variational distillation of diffusion policies into mixture of experts. In: Proceedings of the 38th Conference on Neural Information Processing Systems (NeurIPS 2024), 2024
- 41 Bronars M, Cheng S, Xu D. Legibility diffuser: offline imitation for intent expressive motion. IEEE Robot Autom Lett, 2024, 9: 10161–10168
- 42 Ng E, Liu Z, Kennedy M. Diffusion co-policy for synergistic Human-Robot collaborative tasks. IEEE Robot Autom Lett, 2023, 9: 215–222
- 43 Wang Z, Li Z, Mandlekar A, et al. One-step diffusion policy: fast visuomotor policies via diffusion distillation. ArXiv:2410.21257
- 44 Shih A, Belkhal S, Ermon S, et al. Parallel sampling of diffusion models. Adv Neural Inform Process Syst, 2023, 36: 4263–4276
- 45 Frans K, Hafner D, Levine S, et al. One step diffusion via shortcut models. ArXiv:2410.12557
- 46 Vázquez-Otero A, Faigl J, Muñuzuri A P. Path planning based on reaction-diffusion process. In: Proceedings of the 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2012. 896–901
- 47 Duan J, Yu S, Tan H L, et al. A survey of embodied AI: from simulators to research tasks. IEEE Trans Emerg Top Comput Intell, 2022, 6: 230–244
- 48 Pfeifer R, Iida F. Embodied artificial intelligence: trends and challenges. In: Embodied Artificial Intelligence. Lecture Notes in Computer Science, vol. 3139. Berlin-Heidelberg: Springer, 2004. 1–26
- 49 Haugeland J. Artificial Intelligence: the Very Idea. Cambridge: MIT Press, 1989
- 50 Liu Y, Chen W, Bai Y, et al. Aligning cyber space with physical world: a comprehensive survey on embodied AI. ArXiv:2407.06886
- 51 Sohl-Dickstein J, Weiss E, Maheswaranathan N, et al. Deep unsupervised learning using nonequilibrium thermodynamics. In: Proceedings of International Conference on Machine Learning, 2015. 2256–2265
- 52 Song J, Meng C, Ermon S. Denoising diffusion implicit models. ArXiv:2010.02502
- 53 Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks. Commun ACM, 2020, 63: 139–144
- 54 Dhariwal P, Nichol A. Diffusion models beat GANs on image synthesis. Adv Neural Inform Process Syst, 2021, 34: 8780–8794
- 55 Ding M, Zheng W, Hong W, et al. Cogview2: Faster and better text-to-image generation via hierarchical transformers. Advances in Neural Information Processing Systems, 2022, 35: 16890–16902
- 56 Podell D, English Z, Lacey K, et al. SDXL: improving latent diffusion models for high-resolution image synthesis. ArXiv:2307.01952
- 57 Ramesh A, Dhariwal P, Nichol A, et al. Hierarchical text-conditional image generation with clip latents. ArXiv:2204.06125
- 58 Zhang L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models. In: Proceedings of IEEE/CVF International Conference on Computer Vision, 2023. 3836–3847
- 59 Ruiz N, Li Y, Jampani V, et al. Dreambooth: Fine tuning text-to-image diffusion models for subject-driven generation. In: Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023. 22500–22510
- 60 Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations. ArXiv:2011.13456
- 61 Kingma D P, Welling M. Auto-encoding variational Bayes. ArXiv:1312.6114
- 62 He Y, Yang T, Zhang Y, et al. Latent video diffusion models for high-fidelity video generation with arbitrary lengths. ArXiv:2211.13221
- 63 Zhou D, Wang W, Yan H, et al. Magicvideo: efficient video generation with latent diffusion models. ArXiv:2211.11018
- 64 Wang J, Yuan H, Chen D, et al. Modelscope text-to-video technical report. ArXiv:2308.06571
- 65 Wang W, Liu J, Lin Z, et al. Magicvideo-v2: multi-stage high-aesthetic video generation. ArXiv:2401.04468
- 66 Blattmann A, Dockhorn T, Kulal S, et al. Stable video diffusion: scaling latent video diffusion models to large datasets. ArXiv:2311.15127

- 67 Chen H, Xia M, He Y, et al. Videocrafter1: open diffusion models for high-quality video generation. ArXiv:2310.19512
- 68 Chen H, Zhang Y, Cun X, et al. Videocrafter2: overcoming data limitations for high-quality video diffusion models. In: Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024. 7310–7320
- 69 Chai W, Guo X, Wang G, et al. Stablevideo: text-driven consistency-aware diffusion video editing. In: Proceedings of IEEE/CVF International Conference on Computer Vision, 2023. 23040–23050
- 70 Bar-Tal O, Chefer H, Tov O, et al. Lumiere: a space-time diffusion model for video generation. In: Proceedings of SIGGRAPH Asia 2024 Conference Papers, 2024. 1–11
- 71 Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision. In: Proceedings of International Conference on Machine Learning, 2021. 8748–8763
- 72 Lipman Y, Chen R T, Ben-Hamu H, et al. Flow matching for generative modeling. ArXiv:2210.02747
- 73 Song Y, Dhariwal P, Chen M, et al. Consistency models. ArXiv:2303.01469
- 74 Bain M, Sammut C. A Framework for Behavioural Cloning. Machine Intelligence 15, Intelligent. Oxford: Oxford University, 1999. 103–129
- 75 Zhang T, McCarthy Z, Jow O, et al. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. In: Proceedings of the 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018. 5628–5635
- 76 Russell S. Learning agents for uncertain environments. In: Proceedings of Eleventh Annual Conference on Computational Learning Theory, 1998. 101–103
- 77 Piot B, Geist M, Pietquin O. Bridging the gap between imitation learning and inverse reinforcement learning. IEEE Trans Neural Netw Learn Syst, 2016, 28: 1814–1826
- 78 Hassan M S, Sanaullah S M. Robotic arm manipulation with inverse reinforcement learning & TD-MPC. ArXiv:2407.12941
- 79 Ng A Y, Russell S, et al. Algorithms for inverse reinforcement learning. In: Proceedings of the Seventeenth International Conference on Machine Learning, 2000
- 80 Orsini M, Raichuk A, Hussenot L, et al. What matters for adversarial imitation learning? Adv Neural Inform Process Syst, 2021, 34: 14656–14668
- 81 Fu J, Luo K, Levine S. Learning robust rewards with adversarial inverse reinforcement learning. ArXiv:1710.11248
- 82 Kostrikov I, Agrawal K K, Dwivedi D, et al. Discriminator-actor-critic: addressing sample inefficiency and reward bias in adversarial imitation learning. ArXiv:1809.02925
- 83 Wei W, Xu L, Li M, et al. Optimizing high-dimensional learner with low-dimension action features. In: Proceedings of the 2019 12th International Symposium on Computational Intelligence and Design (ISCID), 2019. 31–34
- 84 Wang T, Karnwal N, Atanasov N. Latent policies for adversarial imitation learning. ArXiv:2206.11299
- 85 Levine S, Popovic Z, Koltun V. Nonlinear inverse reinforcement learning with Gaussian processes. In: Proceedings of Advances in Neural Information Processing Systems, 2011
- 86 Lindner D, Krause A, Ramponi G. Active exploration for inverse reinforcement learning. Adv Neural Inform Process Syst, 2022, 35: 5843–5853
- 87 Pearce T, Rashid T, Kanervisto A, et al. Imitating human behaviour with diffusion models. ArXiv:2301.10677
- 88 Ajay A, Du Y, Gupta A, et al. Is conditional generative modeling all you need for decision-making? ArXiv:2211.15657
- 89 Reuss M, Li M, Jia X, et al. Goal-conditioned imitation learning using score-based diffusion policies. ArXiv:2304.02532
- 90 Du Y, Mordatch I. Implicit generation and modeling with energy based models. In: Proceedings of Advances in Neural Information Processing Systems, 2019
- 91 Perez E, Strub F, de Vries H, et al. Film: visual reasoning with a general conditioning layer. In: Proceedings of AAAI Conference on Artificial Intelligence, 2018
- 92 Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. In: Proceedings of Advances in Neural Information Processing Systems, 2017
- 93 Octo Model Team, Ghosh D, Walke H, et al. Octo: An open-source generalist robot policy. In: Proceedings of Robotics: Science and Systems, Delft, 2024
- 94 Brohan A, Brown N, Carbajal J, et al. Rt-1: robotics transformer for real-world control at scale. ArXiv:2212.06817
- 95 Aburub M, Beltran-Hernandez C C, Kamijo T, et al. Learning diffusion policies from demonstrations for compliant contact-rich manipulation. ArXiv:2410.19235
- 96 Garg A, Krishna K M. Imagine-2-drive: high-fidelity world modeling in carla for autonomous vehicles. ArXiv:2411.10171
- 97 Lee S W, Kang X, Kuo Y L. Diff-dagger: uncertainty estimation with diffusion policy for robotic manipulation. In: Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA), 2025. 4845–4852
- 98 Wu T, Gan Y, Wu M, et al. Dexterous functional pre-grasp manipulation with diffusion policy. ArXiv:2403.12421
- 99 Wen J, Zhu Y, Li J, et al. Tinyvla: towards fast, data-efficient vision-language-action models for robotic manipulation. ArXiv:2409.12514

- 100 Brohan A, Brown N, Carbajal J, et al. Rt-2: vision-language-action models transfer web knowledge to robotic control. ArXiv:2307.15818
- 101 Srirama M K, Dasari S, Bahl S, et al. HRP: human affordances for robotic pre-training. ArXiv:2407.18911
- 102 Chernyadev N, Backshall N, Ma X, et al. Bigym: a demo-driven mobile bi-manual manipulation benchmark. ArXiv:2407.07788
- 103 Wang C, Fang H, Fang H S, et al. Rise: 3D perception makes real-world robot imitation simple and effective. ArXiv:2404.12281
- 104 Liang L, Bian L, Xiao C, et al. Robo360: a 3D omnispective multi-material robotic manipulation dataset. ArXiv:2312.06686
- 105 Doshi K, Bagatella M, Coros S. Problem space transformations for generalisation in behavioural cloning. ArXiv:2411.04056
- 106 Sridhar K, Dutta S, Jayaraman D, et al. Memory-consistent neural networks for imitation learning. ArXiv:2310.06171
- 107 Dalal M, Mandlekar A, Garrett C, et al. Imitating task and motion planning with visuomotor transformers. ArXiv:2305.16309
- 108 Hou Y, Liu Z, Chi C, et al. Adaptive compliance policy: learning approximate compliance for diffusion guided control. ArXiv:2410.09309
- 109 Si Z, Zhang K L, Temel Z, et al. Tilde: teleoperation for dexterous in-hand manipulation learning with a deltahand. ArXiv:2405.18804
- 110 Zhao Y, Chen L, Schneider J, et al. RP1M: a large-scale motion dataset for piano playing with bi-manual dexterous robot hands. ArXiv:2408.11048
- 111 Chen W, Xue H, Zhou F, et al. Deformpam: data-efficient learning for long-horizon deformable object manipulation via preference-based action alignment. ArXiv:2410.11584
- 112 Mejia J, Dean V, Hellebrekers T, et al. Hearing touch: audio-visual pretraining for contact-rich manipulation. ArXiv:2405.08576
- 113 Liu Z, Chi C, Cousineau E, et al. Maniwav: learning robot manipulation from in-the-wild audio-visual data. In: Proceedings of the 8th Annual Conference on Robot Learning, 2024
- 114 Diaz R, Imdieke A, Veeriah V, et al. Auginsert: learning robust visual-force policies via data augmentation for object assembly tasks. ArXiv:2410.14968
- 115 Xie W, Caldararu S, Correll N. Just add force for contact-rich robot policies. ArXiv:2410.13124
- 116 Gerges B, Bazzana B, Botteghi N, et al. Invisible servoing: a visual servoing approach with return-conditioned latent diffusion. ArXiv:2409.13337
- 117 Zhang F, Gienger M. Affordance-based robot manipulation with flow matching. ArXiv:2409.01083
- 118 Hua P, Liu M, Macaluso A, et al. Gensim2: scaling robot data generation with multi-modal and reasoning LLMs. ArXiv:2410.03645
- 119 Mellinger D, Kumar V. Minimum snap trajectory generation and control for quadrotors. In: Proceedings of the 2011 IEEE International Conference on Robotics and Automation, 2011. 2520–2525
- 120 Drolet M, Stepputtis S, Kailas S, et al. A comparison of imitation learning algorithms for bimanual manipulation. IEEE Robot Autom Lett, 2024, 9: 8579–8586
- 121 Chu C, Zhang H, Wang P, et al. Simulating human mobility with a trajectory generation framework based on diffusion model. Int J Geograph Inf Sci, 2024, 38: 847–878
- 122 Zhu J, Wu F, Zhao J. An overview of the action space for deep reinforcement learning. In: Proceedings of the 2021 4th International Conference on Algorithms, Computing and Artificial Intelligence, 2022
- 123 Sun X, Fan F, Chen Y, et al. A comparative study on state-action spaces for learning viewpoint selection and manipulation with diffusion policy. ArXiv:2409.14615
- 124 Sadeghian H, Villani L, Keshmiri M, et al. Task-space control of robot manipulators with null-space compliance. IEEE Trans Robot, 2014, 30: 493–506
- 125 Zhang F, Tan D. Motion planning based on relative coordinates in dynamic environments for mobile robot. In: Proceedings of ICARCV 2004 8th Control, Automation, Robotics and Vision Conference, 2004. 1564–1568
- 126 Xu S, Li Z, Wang Y X, et al. Interdiff: generating 3D human-object interactions with physics-informed diffusion. In: Proceedings of IEEE/CVF International Conference on Computer Vision, 2023. 14928–14940
- 127 Gao W, Dang Q, Gong M. An adaptive framework to select the coordinate systems for evolutionary algorithms. Appl Soft Comput, 2022, 129: 109585
- 128 Zhu H, Yang H, Wang Y, et al. Spa: 3D spatial-awareness enables effective embodied representation. ArXiv:2410.08208
- 129 Huang B, Wang Y, Yang X, et al. 3D-vitac: learning fine-grained manipulation with visuo-tactile sensing. ArXiv:2410.24091
- 130 Yu S, Zhai D H, Xia Y. A novel robotic pushing and grasping method based on vision transformer and convolution. IEEE Trans Neural Netw Learn Syst, 2024, 35: 10832–10845
- 131 Liu J, Xie J, Xiao L, et al. Hierarchical multi-modal fusion for language-conditioned robotic grasping detection in clutter. IEEE Robot Autom Lett, 2024, 9: 8762–8769
- 132 Yao D, Zhu M, Zhu H, et al. Integrating synthetic datasets with clip semantic insights for single image localization advancements. ISPRS J Photogrammetry Remote Sens, 2024, 218: 198–213

- 133 Yang Z, An G, Zheng Z, et al. GBC: guided alignment and adaptive boosting CLIP bridging vision and language for robust action recognition. *IEEE Trans Circuits Syst Video Technol*, 2024, 34: 8172–8187
- 134 Seppänen A, Alamikkotervo E, Ojala R, et al. Out-of-distribution- and location-aware PointNets for real-time 3D road user detection without a GPU. *J Big Data*, 2024, 11: 2
- 135 Parsons C, Albini A, Martini D D, et al. Visuo-tactile recognition of partial point clouds using pointnet and curriculum learning: Enabling tactile perception from visual data. *IEEE Robot Autom Magazine*, 2023, 30: 69–78
- 136 Arroyo H, Keir P, Angus D, et al. Segmentation of drone collision hazards in airborne RADAR point clouds using PointNet. *IEEE Trans Intell Transp Syst*, 2024, 25: 17762–17777
- 137 Huang S, Lu Z, Shi Y, et al. A novel method for filled/unfilled grain classification based on structured light imaging and improved PointNet++. *Sensors*, 2023, 23: 6331
- 138 Wang G, Peng C, Gu Y, et al. Interactive multi-scale fusion of 2D and 3D features for multi-object vehicle tracking. *IEEE Trans Intell Transp Syst*, 2023, 24: 10618–10627
- 139 Xiang Y, Mu A, Tang L, et al. Person identification method based on PointNet++ and adversarial network for mmWave radar. *IEEE Internet Things J*, 2024, 11: 10104–10114
- 140 Ingelhart N, Munkeby J, van Haastregt J, et al. A robotic skill learning system built upon diffusion policies and foundation models. In: *Proceedings of the 2024 33rd IEEE International Conference on Robot and Human Interactive Communication (ROMAN)*, 2024. 748–754
- 141 Zhao Q, Xia Y, Long Y, et al. Leveraging sensory knowledge into text-to-text transfer transformer for enhanced emotion analysis. *Inform Process Manag*, 2025, 62: 103876
- 142 Rodriguez-Torrealba R, Garcia-Lopez E, Garcia-Cabot A. end-to-end generation of multiple-choice questions using text-to-text transfer Transformer models. *Expert Syst Appl*, 2022, 208: 118258
- 143 Shiri M, Hosseinzadeh M, Shiri S, et al. Adsorbent based on MOF-5/cellulose aerogel composite for adsorption of organic dyes from wastewater. *Sci Rep*, 2024, 14: 15623
- 144 Zhou X Y, Yang G Z. Normalization in training U-Net for 2-D biomedical semantic segmentation. *IEEE Robot Autom Lett*, 2019, 4: 1792–1799
- 145 Xu X, Wang J, Zhu Q, et al. EIDU-Net: edge-preserved inception DenseGCN U-Net for LiDAR point cloud segmentation. *Sci Rep*, 2024, 14: 24620
- 146 Wang H, Tan A H, Nejat G. NavFormer: a transformer architecture for robot target-driven navigation in unknown and dynamic environments. *IEEE Robot Autom Lett*, 2024, 9: 6808–6815
- 147 Yang L, Zhang C, Liu G, et al. A model for robot grasping: integrating transformer and CNN with RGB-D fusion. *IEEE Trans Consumer Electron*, 2024, 70: 4673–4684
- 148 Zhu M, Zhu Y, Li J, et al. Scaling diffusion policy in transformer to 1 billion parameters for robotic manipulation. In: *Proceedings of 2025 IEEE International Conference on Robotics and Automation (ICRA)*, 2025. 10838–10845
- 149 Liu J, Sun W, Liu C, et al. Robotic continuous grasping system by shape transformer-guided multiobject category-level 6-D pose estimation. *IEEE Trans Ind Inf*, 2023, 19: 11171–11181
- 150 Peebles W, Xie S. Scalable diffusion models with transformers. In: *Proceedings of IEEE/CVF International Conference on Computer Vision*, 2023. 4195–4205
- 151 Hu E J, Shen Y, Wallis P, et al. Lora: low-rank adaptation of large language models. *ArXiv:2106.09685*
- 152 Prasad A, Lin K, Wu J, et al. Consistency policy: accelerated visuomotor policies via consistency distillation. *ArXiv:2405.07503*
- 153 Liu X, Gong C, Liu Q. Flow straight and fast: learning to generate and transfer data with rectified flow. *ArXiv:2209.03003*
- 154 Hu X, Liu B, Liu X, et al. Adaflow: imitation learning with variance-adaptive flow-based policies. *ArXiv:2402.04292*
- 155 Hejna J, Bhateja C, Jian Y, et al. Re-mix: optimizing data mixtures for large scale imitation learning. *ArXiv:2408.14037*
- 156 Parakh M, Fong A, Simeonov A, et al. Lifelong robot learning with human assisted language planners. In: *Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024. 523–529
- 157 He H, Bai C, Pan L, et al. Learning an actionable discrete diffusion policy via large-scale actionless video pre-training. *Adv Neural Inform Process Syst*, 2024, 37: 31124–31133
- 158 Ronneberger O, Fischer P, Brox T. U-net: convolutional networks for biomedical image segmentation. In: *Proceedings of International Conference on Medical Image Computing and Computer-Assisted Intervention*, 2015. 234–241
- 159 Qi C R, Su H, Mo K, et al. PointNet: deep learning on point sets for 3D classification and segmentation. In: *Proceedings of IEEE Conference on Computer Vision and Pattern Recognition*, 2017. 652–660
- 160 Qi C R, Yi L, Su H, et al. PointNet++: deep hierarchical feature learning on point sets in a metric space. In: *Proceedings of Advances in Neural Information Processing Systems*, 2017
- 161 Chen S F, Wang H C, Hsu M H, et al. Diffusion model-augmented behavioral cloning. *ArXiv:2302.13335*
- 162 Yuan X. Unpacking the individual components of diffusion policy. *ArXiv:2412.00084*

- 163 Hou Z, Zhang T, Xiong Y, et al. Diffusion transformer policy. ArXiv:2410.15959
- 164 Zhai W, Li J, Chen X. Vision transformer for diffusion-based policy learning in robotics. *IEEE Robot Autom Lett*, 2024, 9: 3421–3428
- 165 Reuss M, Pari J, Agrawal P, et al. Efficient diffusion transformer policies with mixture of expert denoisers for multitask learning (mode). ArXiv:2412.12953
- 166 Liu Z, Chen Y, Zhao T. Dynamic expert routing for efficient diffusion policy learning. In: *Proceedings of the Seventeenth International Conference on Machine Learning*, 2024
- 167 Black K, Brown N, Driess D, et al. $\pi 0$: a vision-language-action flow model for general robot control. ArXiv:2410.24164
- 168 Beyer L, Steiner A, Pinto A S, et al. Paligemma: a versatile 3b VLM for transfer. ArXiv:2407.07726
- 169 Black K, Brown N, Darpanian J, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. ArXiv:2504.16054
- 170 Shukor M, Aubakirova D, Capuano F, et al. Smolvla: a vision-language-action model for affordable and efficient robotics. ArXiv:2506.01844
- 171 Loshchilov I. Decoupled weight decay regularization. ArXiv:1711.05101
- 172 Yao X, Zhou Y, Meng Y, et al. Pick-and-place manipulation across grippers without retraining: a learning-optimization diffusion policy approach. ArXiv:2502.15613
- 173 Mishra U A, Chen Y, Xu D. Generative factor chaining: coordinated manipulation with diffusion-based factor graph. In: *Proceedings of ICRA 2024 Workshop Back to the Future: Robot Learning Going Probabilistic*, 2024
- 174 Li Y, Leng W H, Fang Y, et al. Flowbothd: History-aware diffuser handling ambiguities in articulated objects manipulation. ArXiv:2410.07078
- 175 Cao Y, Lew J, Liang J, et al. Dare: diffusion policy for autonomous robot exploration. In: *Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA)*, 2025. 11987–11993
- 176 Shaoul Y, Mishani I, Vats S, et al. Multi-robot motion planning with diffusion models. ArXiv:2410.03072
- 177 Xiao W, Wang T H, Gan C, et al. Safediffuser: safe planning with diffusion probabilistic models. ArXiv:2306.00148
- 178 Mizuta K, Leung K. Cobl-diffusion: diffusion-based conditional robot planning in dynamic environments using control barrier and Lyapunov functions. ArXiv:2406.05309
- 179 Sridhar A, Shah D, Glossop C, et al. Nomad: goal masked diffusion policies for navigation and exploration. In: *Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024. 63–70
- 180 Qin Y, Sun A, Hong Y, et al. Navigatediff: visual predictors are zero-shot navigation assistants. ArXiv:2502.13894
- 181 Weng Z, Lu H, Kragic D, et al. DexDiffuser: generating dexterous grasps with diffusion models. *IEEE Robot Autom Lett*, 2024, 9: 11834–11840
- 182 Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: an open-source vision-language-action model. ArXiv:2406.09246
- 183 Ankile L, Simeonov A, Shenfeld I, et al. Juicer: data-efficient imitation learning for robotic assembly. ArXiv:2404.03729
- 184 Zhao T Z, Tompson J, Driess D, et al. Aloha unleashed: a simple recipe for robot dexterity. ArXiv:2410.13126
- 185 Wu Y, Chen Z, Wu F, et al. Tacdiffusion: force-domain diffusion policy for precise tactile manipulation. ArXiv:2409.11047
- 186 Xu M, Xu Z, Xu Y, et al. Flow as the cross-domain manipulation interface. ArXiv:2407.15208
- 187 Gervet T, Xian Z, Gkanatsios N, et al. Act3d: 3D feature field transformers for multi-task robotic manipulation. ArXiv:2306.17817
- 188 Zhang C, Hao P, Cao X, et al. Vtla: vision-tactile-language-action model with preference learning for insertion manipulation. ArXiv:2505.09577
- 189 Jiang Y, Wang C, Zhang R, et al. Transic: sim-to-real policy transfer by learning from online correction. ArXiv:2405.10315
- 190 Yu X, Zhang S, Song X, et al. Trajectory diffusion for objectgoal navigation. In: *Proceedings of the Thirty-Eighth Annual Conference on Neural Information Processing Systems*, 2024
- 191 Liang J, Christopher J K, Koenig S, et al. Simultaneous multi-robot motion planning with projected diffusion models. ArXiv:2502.03607
- 192 Liu J, Stamatopoulou M, Kanoulas D. Dipper: diffusion-based 2D path planner applied on legged robots. In: *Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024. 9264–9270
- 193 Zhang G, Tang H, Yan Y. Versatile navigation under partial observability via value-guided diffusion policy. In: *Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024. 17943–17951
- 194 Meng Y, Fan C. Diverse controllable diffusion policy with signal temporal logic. *IEEE Robot Autom Lett*, 2024, 9: 8354–8361
- 195 Ravan Y, Yang Z, Chen T, et al. Combining planning and diffusion for mobility with unknown dynamics. ArXiv:2410.06911
- 196 Niedoba M, Lavington J, Liu Y, et al. A diffusion-model of joint interactive navigation. In: *Proceedings of Advances in Neural Information Processing Systems*, 2024
- 197 Shah D, Sridhar A, Dashora N, et al. Vint: a foundation model for visual navigation. ArXiv:2306.14846
- 198 Bar A, Zhou G, Tran D, et al. Navigation world models. In: *Proceedings of Computer Vision and Pattern Recognition Conference*,

2025. 15791–15801

- 199 Fang H S, Fang H, Tang Z, et al. Rh20t: a comprehensive robotic dataset for learning diverse skills in one-shot. In: Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA), 2024. 653–660
- 200 Khazatsky A, Pertsch K, Nair S, et al. Droid: a large-scale in-the-wild robot manipulation dataset. ArXiv:2403.12945
- 201 Li C, Zhang R, Wong J, et al. BEHAVIOR-1K: a benchmark for embodied AI with 1000 everyday activities and realistic simulation. In: Proceedings of Conference on Robot Learning, 2022
- 202 Huber J, H  l  non F, Kappel M, et al. Qdgs  t: a large scale grasping dataset generated with quality-diversity. In: Proceedings of the 2025 IEEE International Conference on Robotics and Automation (ICRA), 2025. 01–08
- 203 Tao S, Xiang F, Shukla A, et al. Maniskill3: GPU parallelized robotics simulation and rendering for generalizable embodied AI. ArXiv:2410.00425
- 204 Nasiriany S, Maddukuri A, Zhang L, et al. Robocasa: large-scale simulation of everyday tasks for generalist robots. ArXiv: 2406.02523
- 205 Luo J, Xu C, Liu F, et al. FMB: a functional manipulation benchmark for generalizable robotic learning. Int J Robot Res, 2023, 44: 592–606
- 206 Ramos S, Girgin S, Hussenot L, et al. Rlds: an ecosystem to generate, share and use datasets in reinforcement learning. ArXiv:2111.02767
- 207 Xia S, Fang H, Fang H S, et al. Cage: causal attention enables data-efficient generalizable robotic manipulation. ArXiv:2410.14974
- 208 He Z, Fang H, Chen J, et al. Foar: Force-aware reactive policy for contact-rich robotic manipulation. ArXiv:2411.15753
- 209 Wen J, Zhu Y, Zhu M, et al. Diffusionvla: scaling robot foundation models via unified diffusion and autoregression. In: Proceedings of Forty-second International Conference on Machine Learning, 2025
- 210 Xiang F, Qin Y, Mo K, et al. Sapien: a simulated part-based interactive environment. In: Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020. 11097–11107
- 211 Shen H, Wan W, Wang H. Learning category-level generalizable object manipulation policy via generative adversarial self-imitation learning from demonstrations. IEEE Robot Autom Lett, 2022, 7: 11166–11173
- 212 Zhu Y, Wong J, Mandlekar A, et al. robosuite: a modular simulation framework and benchmark for robot learning. ArXiv:2009.12293
- 213 He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. In: Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2016. 770–778
- 214 Chi C, Xu Z, Pan C, et al. Universal manipulation interface: in-the-wild robot teaching without in-the-wild robots. In: Proceedings of Robotics: Science and Systems (RSS), 2024
- 215 Todorov E, Erez T, Tassa Y. Mujoco: a physics engine for model-based control. In: Proceedings of the 2012 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2012. 5026–5033
- 216 Makoviychuk V, Wawrzyniak L, Guo Y, et al. Isaac Gym: high performance GPU-based physics simulation for robot learning. ArXiv:2108.10470
- 217 Wang L, Guo R, Vuong Q, et al. A real2sim2real method for robust object grasping with neural surface reconstruction. In: Proceedings of the 2023 IEEE 19th International Conference on Automation Science and Engineering (CASE), 2023. 1–8
- 218 Wang H, Chen J, Huang W, et al. Grutopia: dream general robots in a city at scale. ArXiv:2407.10943
- 219 Wang Y, Yao Q, Kwok J T, et al. Generalizing from a few examples: a survey on few-shot learning. ACM Comput Surveys (csur), 2020, 53: 1–34
- 220 Weiss K, Khoshgoftaar T M, Wang D D. A survey of transfer learning. J Big Data, 2016, 3: 1–40
- 221 Tobin J, Fong R, Ray A, et al. Domain randomization for transferring deep neural networks from simulation to the real world. In: Proceedings of the 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017. 23–30
- 222 Bai Y, Tran D, Bar A, et al. Whole-body conditioned egocentric video prediction. ArXiv:2506.21552
- 223 Liu X, Zhang F, Hou Z, et al. Self-supervised learning: generative or contrastive. IEEE Trans Knowl Data Eng, 2021, 35: 857–876
- 224 Chen L, Jin S, Wang H, et al. Exact: an end-to-end autonomous excavator system using action chunking with transformers. ArXiv:2405.05861
- 225 Black K, Galliker M Y, Levine S. Real-time execution of action chunking flow policies. ArXiv:2506.07339
- 226 Geng Z, Deng M, Bai X, et al. Mean flows for one-step generative modeling. ArXiv:2505.13447
- 227 Chen T, Chen Z, Chen B, et al. Robotwin 2.0: a scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. ArXiv:2506.18088
- 228 Geng H, Wang F, Wei S, et al. Roboverse: towards a unified platform, dataset and benchmark for scalable and generalizable robot learning. ArXiv:2504.18904

Recent advances in diffusion-based embodied imitation learning: a survey

Mu LI^{1,2,4,5}, Xuefeng LIU^{1,2}, Qingfeng LI^{1,4,5}, Xiaolong YU^{4,5}, Jingzhi CUI^{1,2}, Lingran ZHAO^{4,5}, Feng HAN^{1,2}, Xinyi YANG^{1,2}, Bin ZHOU^{1,3}, Jianwei NIU^{1,3,4,5*}, Jinhu LV^{1,2} & Weifeng LV^{1,3*}

1. School of Computer Science and Engineering, Beihang University, Beijing 100191, China

2. State Key Lab of Complex & Critical Software Environment, Beijing 100191, China

3. State Key Lab of Virtual Reality Technology and Systems, Beijing 100191, China

4. Hangzhou Innovation Institute, Beihang University, Hangzhou 310020, China

5. Zhejiang Key Laboratory of Industrial Big Data and Robot Intelligent Systems, Hangzhou 310020, China

* Corresponding author. E-mail: niujianwei@buaa.edu.cn, lvwf@buaa.edu.cn

Abstract In recent years, embodied intelligence technology has held tremendous promise for unlocking the full potential of flexible, general, and dexterous robot systems, bridging the gap between virtual and physical intelligence. Imitation learning, a key framework in this field, enables the direct learning of policies from expert demonstrations, offering simplicity and efficient training. However, it faces challenges related to data efficiency, task modeling complexity, and generalization. Diffusion models, recognized for their solid theoretical foundation, strong distribution modeling capabilities, and stable training processes, have achieved notable success in image generation. Given their strengths in data generation, high-dimensional data processing, and complex distribution modeling, an increasing number of studies are integrating diffusion models into imitation learning to address these challenges. This article provides a comprehensive analysis of the applications of diffusion models in imitation learning, focusing on four aspects: principles, improvements, applications, and prospects. We first introduce the fundamental principles of diffusion models and explore their integration into imitation learning, forming diffusion policies, along with the basic framework of these policies. Next, we detail improvement methods for various components of diffusion policies, including conditional inputs, policy outputs, network architecture, and training strategies. We then review the applications of diffusion policies in robotic manipulation and mobile navigation. Finally, we discuss the challenges of using diffusion models in imitation learning and outline potential technical routes, offering references for researchers.

Keywords embodied intelligence, diffusion models, imitation learning, diffusion policy, robotic manipulation