

密

级：

公开

北京科技大学

University of Science and Technology Beijing



博士学位论文

论文题目：协作机器人模仿学习运动规划与轨迹跟踪控制研究

学号：B20180303

作者：闫子晨

专业名称：控制科学与工程

2023 年 06 月 01 日

协作机器人模仿学习运动规划与轨迹跟踪控制研究

Imitation Learning Based Motion Planning and  
Trajectory Tracking Control for Collaborative Robots

研究生姓名：闫子晨

指导教师姓名：贺威

北京科技大学自动化学院

北京 100083，中国

Doctor Degree Candidate: Zichen Yan

Supervisor: Wei He

School of Automation and Electrical Engineering

University of Science and Technology Beijing

30 Xueyuan Road, Haidian District

Beijing 100083, P.R.CHINA

分类号: TP18

密 级: 公开

U D C: 621.3

单位代码: 1 0 0 0 8

北京科技大学博士学位论文

论文题目: 协作机器人模仿学习运动规划与轨迹跟踪控制研究

作者: 闫子晨

指 导 教 师: 贺威 教授 单 位: 北京科技大学

论文提交日期: 2023 年 06 月 01 日

学位授予单位: 北 京 科 技 大 学

## 摘 要

协作机器人是一种能与人类在共享空间中直接近距离互动的机器人。由于其具有安全、低成本、部署灵活、操作简单等特点,近年来在工业制造、医疗康复、仓储物流、家庭服务等领域被广泛应用。然而,随着协作机器人从简单环境与低难度任务转向复杂非结构化环境与高难度任务,加之其关节刚性较低导致重复定位精度较差,因此,协作机器人面临运动规划、高精度轨迹跟踪控制等难题。为此,本文重点研究协作机器人模仿学习运动规划技术与柔性关节协作机器人高精度轨迹跟踪控制技术。

本文首先提出了两种改进的模仿学习运动规划算法。将动态运动基元(Dynamic Movement Primitives, DMP)算法的拓扑等价性引入核化运动基元(Kernelized Movement Primitives, KMP)算法,提出了将KMP算法与DMP算法相结合的DS-KMP算法,解决KMP算法难以进行整体轨迹调制的问题。以及,提出了改进的带有辅助分类器的生成式对抗模仿学习(Auxiliary Classifier Generative Adversarial Imitation Learning, ACGAIL)算法,解决生成式对抗模仿学习算法存在的模态崩塌、梯度消失与专家轨迹利用效率低等问题。

本文进而提出了一种针对高刚度柔性关节协作机器人的自适应神经网络轨迹跟踪控制器(Adaptive Neural Network Trajectory Tracking Controller for High-Rigidity Flexible-Joint Cobots, ANN-F 控制器),实现了对模仿学习运动规划结果的高精度跟踪。

进一步地,将所提出的算法应用于实际协作机器人系统中。使用提出的DS-KMP算法,根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能,并满足安全约束,保证人类给予者可以自然地进行交接操作。使用提出的ANN-F控制器高精实时跟踪模仿学习运动规划结果。实现了人与协作机器人双臂高效、自然地物体交接。并使用提出的改进的ACGAIL算法实现协作机器人智能化化学合成。通过实验验证与实际应用,所提出的模仿学习运动规划与轨迹跟踪控制算法能有效解决协作机器人面临的运动规划与高精度轨迹跟踪控制难题。

**关键词:** 模仿学习, 运动规划, 柔性关节, 自适应神经网络控制, 人机物理交互



# Imitation Learning Based Motion Planning and Trajectory Tracking Control for Collaborative Robots

## Abstract

Cobots are robots that can interact directly and closely with humans in shared spaces. Due to their safety, low cost, flexibility in deployment, and simplicity of operation, they have been widely used in various fields such as industrial manufacturing, medical rehabilitation, warehouse logistics, and home services in recent years. However, as cobots move from simple environments and low-difficulty tasks to complex non-structured environments and high-difficulty tasks, coupled with their lower rigidity resulting in poor repeatability of positioning accuracy, they currently face the challenges of difficult motion planning and high-accuracy trajectory tracking control. Therefore, this paper focuses on the research of cobot imitation learning motion planning technology and high-accuracy trajectory tracking control technology for flexible-joint cobots.

Firstly, this paper proposes two improved imitation learning motion planning algorithms. The topological equivalence of the Dynamic Movement Primitives (DMP) algorithm is introduced into the Kernelized Movement Primitives (KMP) algorithm, and the DS-KMP algorithm is proposed to combine the KMP algorithm with the DMP algorithm. The DS-KMP algorithm solves the problem of difficult overall trajectory modulation of the KMP algorithm. Additionally, this paper proposes an improved Auxiliary Classifier Generative Adversarial Imitation Learning (ACGAIL) algorithm to solve the problems of mode collapse, gradient vanishing, and low efficiency of expert trajectory utilization found in the generative adversarial imitation learning algorithm.

Secondly, this paper proposes an adaptive neural network trajectory tracking controller for high-rigidity flexible-joint cobots (ANN-F controller), which realizes high-accuracy tracking of the results of imitation learning motion planning.

Further, the proposed algorithms are applied to practical cobot systems. The proposed DS-KMP algorithm is used to adaptively learn object receiving skills based on online prediction of human giver motion trajectories, meet safety constraints and ensure human givers to perform handover operations naturally. The proposed ANN-F controller is used for high-accuracy real-time tracking of the results of imitation learning motion planning. Then, efficient and natural human-to-cobot dual-arm handover can be achieved. The improved ACGAIL algorithm is used to achieve intelligent chemical synthesis by cobots. Through experimental

verification and practical application, the proposed imitation learning motion planning and trajectory tracking control algorithm can effectively solve the problems of motion planning and high-precision trajectory tracking control faced by cobots.

**Key Words:** imitation learning, motion planning, flexible-joint, adaptive neural network control, physical human-robot interaction

# 目 录

|                                        |    |
|----------------------------------------|----|
| 1 引言.....                              | 1  |
| 1.1 研究背景及意义.....                       | 1  |
| 1.2 国内外研究现状.....                       | 5  |
| 1.2.1 协作机器人模仿学习运动规划算法研究现状 .....        | 5  |
| 1.2.2 柔性关节协作机器人轨迹跟踪控制算法研究现状 .....      | 7  |
| 1.2.3 人与协作机器人双臂交接系统研究现状 .....          | 8  |
| 1.2.4 智能化化学合成协作机器人系统研究现状 .....         | 10 |
| 1.3 本文的组织结构.....                       | 11 |
| 2 协作机器人模仿学习运动规划算法研究 .....              | 14 |
| 2.1 预备知识.....                          | 14 |
| 2.1.1 动态运动基元算法.....                    | 14 |
| 2.1.2 高斯混合回归算法.....                    | 15 |
| 2.1.3 逆强化学习算法.....                     | 20 |
| 2.1.4 生成对抗式模仿学习算法.....                 | 24 |
| 2.2 模仿学习运动规划框架与专家轨迹数据集的建立 .....        | 27 |
| 2.2.1 模仿学习运动规划框架.....                  | 27 |
| 2.2.2 专家轨迹数据集建立.....                   | 28 |
| 2.3 核化运动基元算法及改进 .....                  | 30 |
| 2.3.1 核化运动基元算法.....                    | 31 |
| 2.3.2 结合动态运动基元与核化运动基元的 DS-KMP 算法 ..... | 33 |
| 2.3.3 算法实验设计与结果分析.....                 | 36 |
| 2.4 带有辅助分类器的生成式对抗模仿学习算法及改进 .....       | 38 |
| 2.4.1 带有辅助分类器的生成式对抗模仿学习算法 .....        | 38 |
| 2.4.2 改进的带有辅助分类器的生成式对抗模仿学习算法 .....     | 41 |
| 2.4.3 算法实验设计与结果分析.....                 | 44 |
| 2.5 本章小结.....                          | 48 |
| 3 协作机器人自适应神经网络轨迹跟踪控制算法研究 .....         | 49 |
| 3.1 问题描述.....                          | 49 |
| 3.2 控制设计和稳定性分析.....                    | 50 |
| 3.2.1 动力学模型转换.....                     | 51 |
| 3.2.2 降阶系统和边界层系统.....                  | 52 |
| 3.2.3 降阶系统控制设计(ANN-R 控制器) .....        | 53 |
| 3.2.4 边界层系统控制设计.....                   | 58 |
| 3.2.5 复合控制设计(ANN-F 控制器).....           | 58 |

|                                      |    |
|--------------------------------------|----|
| 3.2.6 轨迹跟踪控制算法数值仿真.....              | 60 |
| 3.3 轨迹跟踪控制算法实验设计与结果分析 .....          | 63 |
| 3.3.1 实验设计.....                      | 63 |
| 3.3.2 实验结果分析.....                    | 64 |
| 3.4 本章小结.....                        | 70 |
| 4 人与协作机器人双臂交接系统研究 .....              | 71 |
| 4.1 人与人双臂交接大箱型物体研究 .....             | 71 |
| 4.1.1 实验设计.....                      | 71 |
| 4.1.2 实验结果分析与交接系统设计.....             | 71 |
| 4.2 给予者运动轨迹预测算法研究 .....              | 73 |
| 4.2.1 运动轨迹建模与预测.....                 | 74 |
| 4.2.2 预测交接任务开始和交接位置.....             | 75 |
| 4.2.3 模型在线更新.....                    | 76 |
| 4.3 接收者模仿学习运动规划 DS-KMP 算法应用 .....    | 77 |
| 4.3.1 从专家轨迹中学习.....                  | 77 |
| 4.3.2 概率专家轨迹调制与轨迹生成.....             | 78 |
| 4.4 双臂精准轨迹跟踪控制与力控制研究 .....           | 79 |
| 4.4.1 夹持器设计.....                     | 79 |
| 4.4.2 双臂抓取策略设计.....                  | 80 |
| 4.4.3 双臂抓取控制设计.....                  | 80 |
| 4.5 系统实施、实验设计与结果分析 .....             | 81 |
| 4.5.1 系统实施.....                      | 81 |
| 4.5.2 给予者运动轨迹预测算法实验.....             | 82 |
| 4.5.3 接收者模仿学习运动规划算法实验.....           | 85 |
| 4.5.4 双臂抓取控制算法实验.....                | 86 |
| 4.5.5 讨论.....                        | 88 |
| 4.6 本章小结.....                        | 89 |
| 5 智能化化学合成协作机器人系统研究 .....             | 90 |
| 5.1 智能化化学合成协作机器人系统设计 .....           | 90 |
| 5.1.1 硬件平台设计.....                    | 91 |
| 5.1.2 仿真平台设计.....                    | 92 |
| 5.1.3 软件系统设计.....                    | 92 |
| 5.2 改进的带有辅助分类器的生成式对抗模仿学习算法应用 .....   | 94 |
| 5.2.1 专家轨迹数据集建立.....                 | 95 |
| 5.2.2 改进的带有辅助分类器的生成式对抗模仿学习算法实现 ..... | 95 |
| 5.3 实验设计与结果分析.....                   | 95 |
| 5.3.1 实验设计.....                      | 95 |
| 5.3.2 实验结果分析.....                    | 97 |

|                            |     |
|----------------------------|-----|
| 5.4 智能化化学合成协作机器人系统实施 ..... | 99  |
| 5.5 本章小结.....              | 101 |
| 6 结论与展望.....               | 103 |
| 6.1 论文工作总结.....            | 103 |
| 6.2 论文工作展望.....            | 105 |
| 参考文献.....                  | 109 |

1 引言

1.1 研究背景及意义

协作机器人（Collaborative Robot, Cobot）是一种能与人类在共享空间中直接近距离互动的机器人，如图 1-1 所示。由于其具有安全、低成本、部署灵活、操作简单等特点，近年来在工业制造、医疗康复、仓储物流、家庭服务等领域被广泛应用。因此，协作机器人是当前机器人领域一个热点研究方向。UR5 是世界上第一台协作机器人，由丹麦 Universal Robot 公司在 2009 年推出，后续还推出 UR3e、UR5e、UR10e、UR16e 和 UR20 等型号，具有很高的通用性和适应性，可集成到广泛的应用中。Rethink 公司首先推出的 Baxter 市场表现一般，后续推出的单臂 Sawyer 硬件配置很不错，但在国内的售价较高。德国 Franka Emika 公司的 Panda，其更为智能化/简单化的编程方式令人印象深刻。以及为人熟知的 KUKA\_iiwa、Kinova、和 ABB 公司的 YuMi。



图 1-1 市面上几款常见的协作机器人

在工业领域，对于中小企业来说，协作机器人具有较低的综合成本、快速部署与重部署的能力以及上手简单的优势。在某些新兴工业领域中，即使大企业也有着与中小企业相似的需求，例如 3C（Computer, Communication, Consumer Electronics）制造产业就是该领域中的一个典型代表。在这个领域，主流产品的迭代速度非常快，注重时间成本。此外，在商业领域，由于劳动力成本的上升，很多行业开始寻求机器人自动化解决方案。目前研究和产品化比较好的是仓储物流领域中的拣货协作机器人以及医疗康复协作机器人。

仓储物流领域：一种思路是货架移动而拣货员不动，以亚马逊的 Kiva 系统为代表；另一种思路是保持货架不动，而使用移动机器搭载机械臂来代替工人完成移动拣货的功能。例如 IAM Robotics，使用了 FANUC 的 LR Mate 200 系列轻型机器人搭配 3D 视觉系统来做货架分拣。对于高度柔性和灵活性的工序，仍然需要人类进行操作。而协作机器人则可以利用其快速和精准的特点来负责重复性的工序。医疗康复协作机器人，由于协作机器人安全性高，可一定程度上模仿人类手臂工作，非常适合用在这些场合。尤其是我国在 2020 年初开始抗击新冠肺炎疫情过程中，协作机器人在医疗等领域起到十分重要的作用，得到了社会的充分肯定。除了以上两个领域，还有很多协作机器人在生活中的尝试也取得了不错的成果，如家装、按摩、餐饮等，协作机器人可以非常好的满足这些需求。不仅如此，协作机器人的出现为人类提供了一个让协作机器人走入普通人生活的可能性，被寄希望于在更一般的服务或辅助任务中协助于人类，例如辅助实验人员完成实验操作、帮助人类整理衣物、炒菜做饭等。



图 1-2 在工业制造、医疗康复、仓储物流、家庭服务等领域的广泛应用

由此可见，不仅在工业领域、商业领域、甚至是日常生活中，协作机器人具有很多传统工业机器人无法比拟的优势，如图 1-2 所示。在协作机器人与环境交互过程中，提高安全性的措施可以分为被动和主动两类。协作机器人的被动安全主要由机械设计来实现，如协作机器人的轻质材料、圆滑边缘以及柔性关节等。主动安全主要由系统设计来实现，须要集成多种传感器感知环境并应用智能算法来保证。国际机器人联合会定义了四种类型的协作，包括：共同存在、顺序协作、共同作业、响应协作。目前难点在响应协作上，协作机器人实时响应人的运动行为。随着协作机器人从简单环境与低难度任务转向复杂非结构化环境与高难度任务，且协作机器人并不具备像人一样出



色的运动能力和强大的感知能力,因此,协作机器人当下面临运动规划难的问题。为了避免碰撞造成的损失,协作机器人速度和重量被严格限制,导致协作机器人的速度普遍较慢,负载相对较低。由于其较小的自重,导致刚度比传统工业机器人要差很多,重复定位精度一般会比传统工业机器人低一个数量级,因此,协作机器人当下还面临高精度轨迹跟踪控制的难题。为此,本文重点研究协作机器人模仿学习运动规划技术与柔性关节协作机器人高精度轨迹跟踪控制技术。

协作机器人与传统工业机器人在工作环境和任务方面存在巨大差异,因此需要更高效、直接的算法来学习技能和执行任务。于是,模仿学习运动规划算法应运而生。它通过学习专家轨迹并模仿专家策略来进行运动规划。在模仿学习运动规划领域,存在两类主流算法:基于概率模型的模仿学习运动规划算法和基于生成模型的模仿学习运动规划算法。核化运动基元(Kernelized Movement Primitives, KMP)算法是一种基于概率模型的模仿学习运动规划算法。该算法保留了专家轨迹的概率特性,使得协作机器人能够更准确的学习运动技能。与依赖基函数的方法相比,模型具有更少的开放参数,能够处理高维输入。保证协作机器人能够动态、快速地响应实时变化的起止点并通过相应的经过点。难以根据实际情况进行整体轨迹调制。不具备拓扑等价性,仅适用于相对简单的协作机器人运动规划任务。生成式对抗模仿学习(Generative Adversarial Imitation Learning, GAIL)算法是一种基于生成模型的模仿学习运动规划算法。该算法解决了逆强化学习(Inverse Reinforcement Learning, IRL)算法学习目标函数效率不高,计算开销大的问题,准确学习专家策略,并能拓展到高维空间,适用于较为复杂的协作机器人运动规划任务。但它仍存在模态崩塌、梯度消失和专家轨迹利用效率较低等问题。本文针对以上问题对两种算法提出改进。首先规范了专家轨迹数据集的构建方法与标准。将动态运动基元(Dynamic Movement Primitives, DMP)算法的拓扑等价性引入 KMP 算法,提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法,解决 KMP 算法难以进行整体轨迹调制的问题。以及,提出了改进的带有辅助分类器的生成式对抗模仿学习(Auxiliary Classifier Generative Adversarial Imitation Learning, ACGAIL)算法,解决生成式对抗模仿学习算法存在的模态崩塌、梯度消失与专家轨迹利用效率低等问题。

最近几年,人们对于能够与人类在共享空间中直接近距离互动的柔性关节协作机器人的需求越来越大。柔性关节也叫串联弹性驱动器(Series Elastic Actuator, SEA)。其可以实现协作机器人的柔性和轻量化,并且可以实现关节转矩的测量。因此,柔性关节协作机器人擅长力操作,有效提高了人与协作



机器人物理交互的安全性和柔顺性<sup>[1]</sup>。当协作机器人突然失去动力,导致关节执行器受到外部冲击时,保护必须依赖于在物理层面上具有柔性的柔性关节。尽管柔性关节协作机器人具有上述优点<sup>[2]</sup>,但柔性结构也会给协作机器人带来不希望的弹性震动。因此,协作机器人高精轨迹跟踪控制器的设计难度大大增加,成为一个亟待解决的问题。柔性关节根据柔性结构刚度的不同可大致分为两类:高刚度柔性关节与低刚度柔性关节。在之前的工作中,针对低刚度柔性关节协作机器人<sup>[3]</sup>提出了一种自适应神经网络轨迹跟踪控制器。此工作保证了柔性关节满足输出约束,提高了柔性关节协作机器人的安全性<sup>[4]</sup>,但该控制器不仅需要连杆角位移和角速度的反馈信号,还需要电机轴角位移和角度速度的反馈信号。本文针对高刚度柔性关节协作机器人提出了一种自适应神经网络高精轨迹跟踪控制器(Adaptive Neural Network Trajectory Tracking Controller for High-Rigidity Flexible-Joint Cobots, ANN-F 控制器)。根据奇异摄动理论,ANN-F 控制器只需要连杆角位移、连杆角速度和柔性结构扭矩的反馈信号,因此具有很高的实用性。其使用神经网络处理协作机器人动力学中的不确定性问题。为了进一步保证协作机器人轨迹跟踪控制的安全性和精度,在满足输出约束的同时,其通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。通过李雅普诺夫稳定性分析,所提出的 ANN-F 控制器还可保证系统达到指数稳定。近些年除了理论成果外,在柔性关节协作机器人硬件平台方面也有很多突破<sup>[5][6][7][8]</sup>。麻省理工学院的 G. A. Pratt 和 M. M. Williamson 发明了一种基于应变片传感器的 SEA<sup>[9][10][11]</sup>。在这项工作的基础上,Rethink Robotics 发明了 Baxter 双臂协作机器人。Baxter 双臂协作机器人的出现为研究人员提供了研究的基础<sup>[12]</sup>。因此,本文还基于 Baxter 双臂协作机器人进行了一系列轨迹跟踪控制实验,以评估 ANN-F 控制器的性能。

进一步,本文聚焦于人与协作机器人双臂交接任务,设计人与协作机器人双臂交接系统。交接操作的效率及自然性须被提高,就像在两个人之间进行交接一样。首先,研究了人与人双臂自然交接过程来指导本研究。然后为了提高效率,将基于概率模型的模仿学习运动规划高斯混合回归(Gaussian Mixture Regression, GMR)算法与在线学习算法相结合来预测交接任务的开始和交接位置。在线更新概率模型不仅可以处理人类给予者的规则运动模式,还可以处理他们的不规则运动模式。然后,为了保证人类给予者可以自然地执行交接操作,应用基于概率模型的模仿学习运动规划 DS-KMP 算法,根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能,并满足安全约束。此外,还设计了双臂抓取策略和控制,以保证稳定的抓取。最后,

将此交接系统装备在 Baxter 协作机器人上，并扩展了夹持器，使其更适合双臂交接操作。实验结果表明，所提出的交接系统可以自然地、高效地解决人与协作机器人双臂交接操作<sup>[13]</sup>。

近年来，智能化化学合成研究引起了学者们的广泛关注，涌现出了许多自动化化学合成系统，收集了大量数据，并建立了数据集<sup>[14][15][16]</sup>。在本文中，设计了一个基于视觉辅助的智能化化学合成协作机器人系统。其中，设计并搭建了一个通用、可扩展的自动化化学合成硬件平台，该平台基于 UR3 协作机器人和双目 RGB 相机，可以完成多种化学操作，包括：在 UR3 协作机器人末端装配移液枪实现液体试剂混合、实现移液枪枪头更换、转运试管等操作。然后，设计并搭建了一个试管转运仿真平台，用于基于生成模型的模仿学习运动规划算法的训练，该算法在虚拟仿真平台中训练到接近最优策略时应用于真实物理系统。在仿真平台中，使用所提出的刚体关节协作机器人自适应神经网络轨迹跟踪控制器（Adaptive Neural Network Trajectory Tracking Controller for Rigid-Joint Cobots, ANN-R 控制器）实现 UR3 高精度轨迹跟踪<sup>[17]</sup>。进一步，提出了一种分步控制方案，主要分为三个部分：环境感知层、运动规划层和控制执行层。在化学合成操作中，对于包含多个步骤和意图的化学合成任务来说，单模态模仿学习运动规划算法性能不足，当专家轨迹具有多个模态分布时，很容易导致模态崩塌。因此，对于运动规划层，使用改进的 ACGAIL 算法学习专家轨迹，并模仿专家策略进行运动规划。控制执行层来跟踪运动规划层的结果，以完成化学合成任务。试管和试管架之间有很强的约束。如果 UR3 协作机器人仅跟踪轨迹，则不足以完成高精度试管传输任务。有必要通过在 UR3 协作机器人<sup>[17][18][19]</sup>的末端安装一个高精度六轴力传感器，根据导纳控制器校正和协调试管和试管架之间的相对位置。

## 1.2 国内外研究现状

### 1.2.1 协作机器人模仿学习运动规划算法研究现状

模仿学习目前分为三类主流算法：第一类是行为克隆（Behavior Cloning, BC）。BC 通过训练策略网络等机器学习算法去模仿专家行为。但在这种机制下，训练的策略所产生的状态分布通常会与训练数据中状态的分布不一致，即由于环境随机性，当策略与环境交互碰到一个它从没见过的状态时，策略会得到一个较差的动作。因为这个状态训练数据里没有，这个较差的动作又会使智能体进入另一个更陌生的状态，循环下去最终导致智能体的轨迹逐渐与正确轨迹发生偏移。在序列决策问题中，状态分布不一致会导致模仿学习

运动规划算法的误差逐渐累积, 从而使得轨迹偏离正确的轨迹。因此, 在序列决策问题中直接使用类似于监督学习的模仿学习运动规划算法通常无法获得良好的效果。因此, BC 的优点是学习过程简单, 无需与环境交互。缺点是单步决策、陌生状态无法决策、无法拟合大环境的专家策略、积累误差。专家的数据集有限, 只能通过不断增加数据集去覆盖所有可能发生的状态来保证学习的效果, 导致成本升高。协作机器人领域常用的模仿学习 BC 算法有: 基于动态系统的 DMP 算法、基于概率模型的 GMR 算法与 KMP 算法等。

第二类是 IRL<sup>[20][21][22]</sup>。IRL 前提假设专家行为是(近似)最优的。希望通过逆向强化学习得到一个奖励函数去解释专家行为, 换言之, 马尔可夫决策过程的奖励函数被认为是未知的, 须要从专家轨迹数据集中恢复, 从而避免人为设定奖励函数, 然后通过强化学习从该奖励函数中提取策略<sup>[23][24][25]</sup>。首先, 初始化一个奖励函数, 通过强化学习算法可以得到当前奖励函数下最优的一组策略, 并根据假设专家策略是最优奖励函数下的最优解, 优化奖励函数使得专家策略获得更高的奖励值, 再由强化学习算法得到最新奖励函数下的最优策略, 不断迭代上述过程至收敛, 最终根据得到的奖励函数下的最优策略应该与专家策略一致, 说明专家行为已经被很好地解释。因此, IRL 的优点是马尔可夫决策, 能够探索整个空间, 对专家轨迹数据集的要求比 BC 算法要低。缺点是对专家轨迹数据集的使用是间接的, 在每一轮内循环中都包含强化学习过程, 可能导致训练速度慢, 时间成本高, 一定程度上限制了 IRL 的发展和实际的应用<sup>[26][27][28]</sup>。

第三类是 GAIL<sup>[29][30][31]</sup>。IRL 须要学习一个代价函数来解释专家行为。鉴于模仿者的真正目标是模仿专家行为来采取行动, 而学习代价函数会招致大量的计算开销, 不能直接告诉模仿者如何行动。于是有了 GAIL 算法, 它可以绕过 IRL 算法的中间步骤<sup>[32][33]</sup>, 直接从专家行为学习到策略<sup>[34]</sup>, 明确地告诉模仿者如何行动<sup>[35][36]</sup>。GAIL 算法的基本思想是将生成对抗网络(Generative Adversarial Nets, GANs)引入 IRL, 利用 GANs 的对抗训练来生成专家数据分布<sup>[37][38][39]</sup>。根据 GANs 包含生成模型 G 和判别模型 D<sup>[40][41]</sup>, GAIL 使用强化学习策略梯度算法来更新生成模型 G 中的策略网络。生成模型 G 根据输入当前状态输出动作。判别模型 D 判断输入动作的来源是生成模型 G 还是专家轨迹数据集, 以此来使生成模型学习的策略逼近专家策略。该算法与现有的无模型方法相比, 在大型、高维环境中, 模仿复杂行为的能力获得了显著的提升。

### 1.2.2 柔性关节协作机器人轨迹跟踪控制算法研究现状

许多研究人员已经对柔性关节协作机器人的建模和控制设计进行了一些理论研究<sup>[42][43][44]</sup>。M. W. Spong 以纯扭转弹簧的形式建模了关节弹性<sup>[45][46]</sup>，该模型后来被广泛认同。R. Lozano 和 B. Brogliato 针对低刚度柔性关节协作机器人提出了自适应轨迹跟踪控制器<sup>[47][48]</sup>。在[3]中，针对低刚度柔性关节协作机器人提出了一种自适应神经网络轨迹跟踪控制器。对于高刚度柔性关节，应变片传感器安装在柔性结构上，可测量的量是柔性结构的扭转形变。扭转形变乘以柔性结构的刚度系数，近似等于柔性结构转矩。因此，电机轴角位移和角速度信号实际上不可测得。此外，现有的许多针对柔性关节协作机器人提出的轨迹跟踪控制器相对复杂，仅停留在理论层面。为了解决这些问题，M. W. Spong 基于奇异摄动理论，使用 J.-J. E. Slotine 和 W. Li<sup>[49][50]</sup>提出的刚体关节机器人自适应轨迹跟踪控制器，并添加一个小的修正项抑制柔性关节弹性震动来控制柔性关节协作机器人<sup>[51]</sup>。整体复合控制器并不比刚体关节机器人控制器复杂很多，仅需连杆角位移、连杆角速度和柔性结构转矩反馈信号。Y.-Z. Chang 和 R. W. Daniel 讨论了[51]，并调整了复合控制器<sup>[52]</sup>。M. W. Spong 讨论了这两个工作<sup>[52]</sup>和<sup>[53]</sup>，并澄清了两个工作的贡献<sup>[54]</sup>。然而，基于 H. K. Khalil<sup>[54]</sup>考虑无限时间间隔的复合控制器稳定性分析仍然存在一些小缺陷。S. S. Ge 在[54]的基础上，提出了一种新型柔性关节协作机器人自适应轨迹跟踪控制器<sup>[55]</sup>。他修改了[54]中的小缺陷，但只通过一些简单数值仿真测试了控制效果<sup>[56][57]</sup>。直到 S. S. Ge 提出了基于 Euler-Lagrange 形式动力学模型的刚体关节机器人自适应神经网络轨迹跟踪控制器<sup>[58][59][60]</sup>，这才有合适的方法来处理高自由度柔性关节协作机器人动力学中的不确定性。Z. Li 使用自适应神经网络轨迹跟踪控制器控制外骨骼协作机器人<sup>[61][62][63]</sup>。同时，C. Yang 使用自适应神经网络轨迹跟踪控制器控制协作机器人进行避障实验以及人与协作机器人物理交互实验等<sup>[64][65][66][67]</sup>。虽然自适应神经网络轨迹跟踪控制算法已经被深入地研究<sup>[68][69]</sup>，但稳定性分析只停留在一致最终有界，这不足以应对高刚度柔性关节协作机器人系统<sup>[70]</sup>，控制器须要保证降阶系统可达到指数稳定<sup>[55]</sup>。因此，基于 J.-J. E. Slotine 和 W. Li<sup>[49][50]</sup>提出的刚体关节机器人自适应轨迹跟踪控制器，重新设计了自适应神经网络轨迹跟踪控制器，并提出了一种 ANN-F 控制器。对于医疗康复领域中的康复协作机器人<sup>[71][72][73][74]</sup>，使用障碍 Lyapunov 函数处理输出约束问题<sup>[75][76]</sup>。本文利用障碍 Lyapunov 函数实现了高刚度柔性关节协作机器人的输出约束，进一步提高了协作机器人轨迹跟踪控制的安全性和精度。

### 1.2.3 人与协作机器人双臂交接系统研究现状

交接操作是协作机器人在协作任务中与人类互动的基本能力，例如照顾老人和协助制造车间的工人。在人与人自然交接操作中，双方有不同的目标。给予者想要安全地释放物体，而接收者想要建立稳定的抓取以安全地获得物体。依靠丰富的感官反馈和长时间的训练，人类可以自然地掌控完整的交接过程，在时间和空间上精确协调。由于人与人交接操作几乎完美无缺，因此人与协作机器人交接操作的复杂性被严重低估，许多关键问题目前尚未解决。W. P. Chan 等人分别以给予者为中心和以接收者为中心，面向二十种常见物体，研究了人与人自然交接位型<sup>[77][78]</sup>。S. Parastegari 等人研究了人与人自然交接位型和交接轨迹<sup>[79][80]</sup>。K. Strabala 等人<sup>[81]</sup>在人与人自然交接研究的基础上，提出了人与协作机器人交接的协调策略。该研究可以同时识别交接对象，协调交接时间，确定交接位型。G. Maeda 等人通过预测人的运动轨迹实现了快速、流畅的人与协作机器人交接<sup>[82][83][84]</sup>，即使人被遮挡。一般来说，对于必须用双手搬运的大型物体来说，取得的研究成果有限<sup>[85]</sup>。在之前的工作中<sup>[86]</sup>，设计了一个用于大板型物体的双臂双向交接系统。虽然此研究成功地实现了人与协作机器人双臂交接操作，但交接操作的效率仍不够高，而且人类给予者的交接操作不够自然。

因此，进一步研究了人与协作机器人双臂大箱型物体交接系统。为了提高交接效率和自然性，模仿人与人双臂自然交接策略，发展协作技术（响应协作），使协作机器人能够实时响应人类意图，并研究了基于模仿学习运动规划算法的协作机器人接收技能学习算法，以像人类一样用双臂抓取大箱形物体。应该指出的是，协作机器人和人类之间仍有很大差距，协作机器人在许多方面不能盲目模仿人类。许多人与人交接操作策略须要调整和简化。交接系统应该以人为中心，协作机器人应该配合人类。为了保证交接操作的效率，人类接收者通常会提前朝物体移动。因此，预测交接任务的开始和交接位置应该是研究的重点。利用人类给予者在大多数情况下运动轨迹相似的特点，使用基于概率模型的模仿学习运动规划算法，如高斯过程回归（Gaussian Process Regression, GPR）算法和 GMR 算法，可有效地建模和预测人类运动轨迹。这类方法可以准确地预测一个人的运动轨迹。在<sup>[87]</sup>中，J. M. Wang 等人利用 GPR 从收集的运动轨迹中学习人类运动模型。在<sup>[88]</sup>中，F. Zhang 提出了一种高斯过程潜在变量模型（Gaussian Process Latent Variable Models, GP-LVM）来跟踪用户位型。GPR 可以处理均值估计的不确定性，但很难计算高维状态变量之间的协方差。它依赖于许多过去的数据集，这导致计算成

本增加。因此,很难作为在线预测算法应用。GMR 算法可以计算编码高维状态变量之间相关性的全协方差矩阵,并根据当前模型对异常状态变量进行合理预测<sup>[89]</sup>。在[90]中,A. Kanazawa 等人根据具有不确定性的工人运动的概率模型,提出了面向装配过程的自适应最优轨迹运动规划系统。由于实际交接操作中经常存在小的差异,期望预测算法仍然可以对人类给予者行为的微小变化进行合理的运动预测。考虑到在线预测算法的计算成本和对异常状态变量的预测灵活性,选择使用 GMR 算法对人类给予者的运动进行在线预测。具体来说,使用 GMR 算法来建模和在线预测人类给予者双手的运动轨迹,并应用高斯模型(Gaussian Model, GM)算法建模交接位置。然后,可以预测交接任务的开始时间和交接位置,以提高交接操作的效率。此外,在人与协作机器人的交接操作中,由于人类给予者的习惯不同,重复的人类运动逐渐发生变化。GMR 算法参数应根据人类运动的变化自适应更新。使用在线学习算法扩展了 GMR 算法,不仅可以处理人类给予者的规则运动模式,还可以处理他们的不规则运动模式。

为了提高人与协作机器人交接过程中人类给予者的流畅性和自然性,使用基于模仿学习运动规划算法实现协作机器人接收技能的学习。模仿学习 DMP 算法<sup>[91][92][93]</sup>和概率运动基元(Probabilistic Movement Primitives, ProMP)算法<sup>[94]</sup>可以生成期望轨迹。然而,由于对轨迹动力学的确切描述,这类算法除了基函数及其权重系数外,还引入了许多开放参数<sup>[95]</sup>。因此,这类算法很难处理高维状态变量。GMR 算法不需要具体函数,因此它可以回归出高维状态变量期望轨迹<sup>[96]</sup>。但它不能很好地满足时变约束的需求(例如,时变经过点和终点)。为了满足时变约束的需求,DMP 算法可以调整轨迹以满足终点约束,但是,经过点约束仍然不能得到有效解决。此外,强化学习(Reinforcement Learning, RL)算法可以处理时变约束<sup>[97][98][99][100][101]</sup>。然而,这种方法的缺点是学习最优策略耗费大量时间<sup>[102][103][104]</sup>。近年来,基于概率模型的模仿学习 KMP 算法<sup>[105]</sup>被提出。KMP 算法该算法保留了专家轨迹的概率特性,使得协作机器人能够更准确的学习运动技能。与依赖基函数的方法相比,模型具有更少的开放参数,能够处理高维输入。保证协作机器人能够动态、快速地响应实时变化的起止点并通过相应的经过点。因此,采用提出的 DS-KMP 算法来学习接收技能,解决 KMP 算法难以进行整体轨迹调制的问题。该算法根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能,并满足安全约束,保证人类给予者可以自然地进行交接操作。

对于双臂抓取操作,根据人与人双臂自然交接研究,设计了双臂抓取策

略和控制, 以确保稳定抓取。此外, 扩展了协作机器人的夹持器, 使其更适合交接任务。在预抓取过程中, 双臂协作机器人须要跟踪接收技能的运动规划结果<sup>[106] [107] [108]</sup>。使用提出的 ANN-R 控制器来处理双臂协作机器人动力学中的不确定性, 并实现协作机器人高精轨迹跟踪控制<sup>[109] [110] [111]</sup>。对于抓取过程, 物体和协作机器人没有刚体连接<sup>[112] [113]</sup>。提出了一种控制器, 用于维持期望的“挤压”力, 以实现稳定抓取<sup>[114]</sup>。

#### 1.2.4 智能化化学合成协作机器人系统研究现状

树脂材料被广泛应用于在口腔医学中, 例如充填修复材料、洞衬材料以及牙科修复中的粘接剂和粘固剂等牙科材料。其主要优势在于, 树脂材料硬度较高, 具有良好的机械性能, 可以胜任牙齿的咀嚼功能。其具有良好的可操作性能, 便于打磨和整型。而且其还与牙齿颜色相近, 因此具有良好的美观性。但是, 此类树脂材料在使用中存在收缩应力的问题。收缩应力的产生来源于树脂聚合过程中的体积收缩, 在聚合过程中的体积收缩可达 21%。而在牙洞中发生聚合时, 树脂发生凝胶化, 产生了收缩应力, 无法释放的收缩应力就会与粘接面作用, 导致填充材料与牙齿的粘接力下降, 进而导致填充界面出现间隙。在电镜下, 可以观察到由于收缩应力导致的填充材料与牙齿的充填边缘缺口可以达到 10-20 $\mu\text{m}$ , 而缺口可能诱发包括牙齿敏感、牙尖变形、釉质微裂、继发性龋齿等一系列的临床问题。为解决此问题, 选择的策略是在聚合体系中加入加成-碎裂化链转移试剂推迟聚合体系的凝胶点从而使应力充分释放, 并且不会影响合成树脂的机械强度。对于树脂材料收缩应力或凝胶点的测定, 通常采用的方法是在力学万能试验机上测量聚合过程的收缩应力, 或是用流变仪测定凝胶点, 二者都面临着测试过程复杂和仪器成本高的问题。为了克服这些问题, 选用合适的相机, 依靠计算机视觉技术, 对体系的反应进行监测, 节省了不必要的人力成本, 更为简洁与低成本的测定树脂聚合的凝胶点。此外, 相机采集的数据相较人类观察者会具有更高的平行性。

近年来, 许多自动化化学合成系统被研发出来<sup>[14] [15] [16]</sup>。2019 年, Jensen 等人设计并改造流动反应装置成为能够自动决定原料进样和流动路径的全自动流动合成仪。同年, Cronin 等人结合流动管路与改造的常见实验室仪器, 实现了实验室内分子制备自动化。2020 年, Cooper 等人通过向实验室中引入一个可移动的协作机器人, 配合多种自动化仪器实现了完整的光反应分析-筛选-优化过程。另外, Leibfarth 和 Hein 等人在近年也分别将自动化系统运用到了无机材料以及高分子领域的智能化筛选过程中。然而, 这些自动化化学

合成操作平台的通用性和扩展性仍然不足。为了使只能进行某个或某类化学反应的专一系统发展到能够自主完成实验设计-化合物合成-产物表征的闭环系统，设计了一个基于视觉辅助的智能化化学合成协作机器人系统。其中，设计并搭建了以 UR3 协作机器人作为中心配备双目 RGB 相机的通用的、可扩展的自动化化学合成硬件平台，实现树脂材料筛选。为了提高系统性能，还设计并搭建了用于模仿学习运动规划算法训练的虚拟仿真平台，以及基于分步控制方案（环境感知层、运动规划层和控制执行层）的软件系统，以确保智能性、准确性和实时性。在运动规划层，考虑使用模仿学习运动规划算法来实现复杂任务的高效、合理的运动规划。

模仿学习运动规划算法主要分为三类<sup>[115][116]</sup>：BC 严重依赖专家数据去训练从状态到动作的策略网络，从而让策略网络去模仿专家行为，获得再现专家行为的能力<sup>[117][118]</sup>。BC 算法将完全复制专家的行为，即使这是专家本身的习惯，而不是必要的。IRL 希望通过学习得到一个奖励函数去解释专家的行为，在这个过程中，不断对当前得到的奖励函数进行优化，最终从专家的行为中反推出一个最合理的结果<sup>[119][120]</sup>。IRL 算法可用于根本无法给予 RL 奖励的任务。然而，它计算量大，学习过程长，在一定程度上限制了 IRL。GAIL 利用 GANs 的对抗训练来生成专家数据分布。利用 GAIL 可以直接显式的得到决策，更高效。然而，假设模仿学习基于单一模态策略，当专家轨迹具有多个模态策略分布时，很容易导致模态崩塌。为了解决这个问题，结合 GAIL 和辅助分类器 GANs 的思想，提出了 ACGAIL 算法，以从多个模态中学习。辅助分类器的作用是协助对抗网络重建有关多个潜在模态的辅助信息。在基于标签条件的模仿学习场景中，ACGAIL 算法可以表现出比现有方法更好的性能，例如 GAIL 和 Info-GAIL。因此，在运动规划层，使用改进的 ACGAIL 算法，实现复杂任务的高效、合理的运动规划。

### 1.3 本文的组织结构




图 1-3 本文整体研究思路与框架

图 1-3 展示了本文整体研究思路和框架。本文主要分为以下几个章节：



第一章：引言，介绍了本文的研究背景与研究意义，研究内容的国内外研究现状以及本文的组织结构。

第二章：介绍协作机器人模仿学习运动规划相关算法，并对两种算法提出改进。首先规范了专家轨迹数据集的构建方法。将 DMP 算法的拓扑等价性引入 KMP 算法，提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法，解决 KMP 算法难以进行整体轨迹调制的问题。以及，提出了改进的 ACGAIL 算法，解决生成式对抗模仿学习算法存在的模态崩塌、梯度消失与专家轨迹利用效率低等问题。

第三章：介绍柔性关节协作机器人轨迹跟踪控制算法相关研究。针对高刚度柔性关节协作机器人提出了一种 ANN-F 控制器，以实现高精轨迹跟踪。根据奇异摄动理论，它只需要关节角位移、关节角速度和柔性结构转矩的反馈信号，具有很高的实用性。其使用神经网络处理协作机器人动力学中的不确定性问题。为了进一步保证协作机器人轨迹跟踪控制的安全性和精度，在满足输出约束的同时，其通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。通过李雅普诺夫稳定性分析，所提出的 ANN-F 控制器还可保证系统达到指数稳定。除了一些必要的仿真之外，还基于 Baxter 协作机器人自主抓取摆放系统进行了一系列轨迹跟踪实验，以评估 ANN-F 控制器的性能。结果表明，所提出的 ANN-F 控制器对高刚度柔性关节协作机器人轨迹跟踪具有更好的控制性能。为后面章节协作机器人系统设计提供了理论依据。

第四章：介绍人与协作机器人双臂交接系统相关研究。交接操作的效率以及自然性须要被提高，就像在两个人之间进行交接一样。首先，研究了人与双臂自然交接大箱型物体过程来指导本研究。然后为了提高效率，使用模仿学习高斯混合回归算法与在线学习算法相结合来预测交接任务的开始和交接位置。在线更新概率模型不仅可以处理人类给予者的规则运动模式，还可以处理他们的不规则运动模式。然后，为了保证人类给予者可以自然地执行交接操作，使用提出的模仿学习运动规划 DS-KMP 算法，根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能，并满足安全约束。此外，还设计了双臂抓取策略和控制，以保证稳定的抓取。最后，将此交接系统装备在 Baxter 协作机器人上，并扩展了夹持器，使其更适合双臂交接操作。实验结果表明，所提出的交接系统可以自然、高效地解决大箱型物体的人机双臂交接操作。

第五章：介绍智能化化学合成协作机器人系统相关研究。设计了一个基于视觉辅助的智能化化学合成协作机器人系统。其中，设计了一个基于 UR3 协作机器人和双目 RGB 相机的通用、可扩展的自动化化学合成硬件平台。为

了提高系统性能，还设计并搭建了用于模仿学习运动规划算法训练的虚拟仿真平台，以及基于分步控制方案（环境感知层、运动规划层和控制执行层）的软件系统，以确保智能性、准确性和实时性。对于运动规划层，利用改进的 ACGAIL 算法实现对一些复杂任务的高效、合理的运动规划。进一步地，通过一系列实验对所提出的自动化化学合成硬件平台和改进的 ACGAIL 算法进行了测试。实验结果表明，该硬件平台和改进的 ACGAIL 算法具有优秀的性能。最后，部署所设计的基于视觉辅助的智能化化学合成协作机器人系统，进行高分子聚合体系实验研究。

第六章：结论与展望，对本文工作进行了总结，并对未来工作进行了展望。

## 2 协作机器人模仿学习运动规划算法研究

模仿学习运动规划算法是当下协作机器人运动规划领域的先进算法。其根据专家轨迹学习，并模仿专家策略进行运动规划，使得协作机器人可以更高效、直接地学习技能。

### 2.1 预备知识

#### 2.1.1 动态运动基元算法

1) 动态运动基元算法动力学模型：

动态运动基元（Dynamic Movement Primitives, DMP）算法是一种基于非线性动态系统的协作机器人模仿学习运动规划算法。其依靠由点吸引子模型与非线性函数构造的非线性动态系统来生成一条复杂的协作机器人运动轨迹。点吸引子模型能确保所生成的运动轨迹最终一定收敛于目标位置，而非线性函数使得运动轨迹在到达目标位置过程中发生形变。

非线性动态系统的数学表达式为：

$$\ddot{y} = \alpha_y (\beta_y (g - y) - \dot{y}) + f \quad (2-1)$$

其中  $y, \dot{y}, \ddot{y}$  分别为运动轨迹的位置、速度和加速度， $g$  为运动轨迹最终须要到达的目标位置， $\alpha_y$  和  $\beta_y$  为比例系数， $f$  为调整运动轨迹的非线性强迫函数：

$$f(x, g) = \frac{\sum_{i=1}^N \psi_i \omega_i}{\sum_{i=1}^N \psi_i} x (g - y_0) \quad (2-2)$$

其中， $\psi_i = \exp(-h_i (x - c_i)^2)$  为高斯基函数， $h_i$ ， $c_i$  和  $\omega_i$  为第  $i$  个高斯核的带宽、中心和权重， $N$  表示基函数的个数。 $(g - y_0)$  表示比例项，当轨迹起始位置或终止位置改变时，能够实现运动轨迹的缩放。为了提高鲁棒性，设计强迫函数  $f$  为基于指数衰减的正则系统：

$$\dot{x} = -\alpha_x x \quad (2-3)$$

其中， $\alpha_x$  为比例系数。

2) 动态运动基元算法参数学习：

当轨迹起始位置或终止位置改变时，DMP 算法可稳定生成运动轨迹。而在运动生成过程中，可通过权重  $\omega_i$  改变轨迹的形状，从而实现模仿学习运动规划的目的。假设专家轨迹的位置、速度和加速度为  $(y_{demo}(t), \dot{y}_{demo}(t), \ddot{y}_{demo}(t))$ ，

其中  $t \in [1, \dots, N]$ ,  $N$  为专家轨迹时长, 可得非线性强迫函数  $f_{target}$  为:

$$f_{target} = \ddot{y}_{demo} - \alpha_y (\beta_y (g - y_{demo}) - \dot{y}_{demo}) \quad (2-4)$$

于是, 对专家轨迹的学习问题被转化为非线性强迫函数  $f_{target}$  的拟合问题。本文采用经典的局部加权回归算法快速求解基函数权重。局部加权回归算法的损失函数为:

$$J(\omega) = \sum_t \psi_i(t) (f_{target}(t) - \omega_i(x(t)(g - y_0)))^2 \quad (2-5)$$

使用最小二乘法可得其解为:

$$\omega_i = \frac{s^T \Gamma_i f_{target}}{s^T \Gamma_i s} \quad (2-6)$$

其中:

$$s = \begin{pmatrix} x(t_0)(g - y_0) \\ \dots \\ x(t_N)(g - y_0) \end{pmatrix}, \quad \Gamma_i = \begin{pmatrix} \psi_i(t_0) & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \psi_i(t_N) \end{pmatrix} \quad (2-7)$$

通过局部加权回归算法简单、快速解得权重  $\omega_i$  后, 非线性动态系统在强迫函数  $f_{target}$  的作用下即可生成与专家轨迹类似的运动轨迹。总而言之, DMP 算法具有学习简单、吸引点处可保证全局稳定、学习和泛化效率高等特点。

### 2.1.2 高斯混合回归算法

高斯混合模型 (Gaussian Mixture Model, GMM) 算法是一种机器学习聚类算法, 可用于对运动轨迹进行建模。其与 DMP 算法的最大区别在于, GMM 算法可以处理高维输入, 并从概率分布的角度对运动轨迹进行编码, 进而可以提取多组专家轨迹中的概率属性。GMM 算法常用于专家轨迹建模。本文中, 也使用了 GMM 算法对任务中人手运动轨迹进行建模, 使用 GMR 算法回归出一条带有概率信息的专家轨迹, 并基于期望最大化 (Expectation-Maximization, EM) 算法估计 GMM 算法参数。

#### 1) GMM 算法:

对于高维样本数据的高斯分布 (Gaussian Distribution, GD) 的概率密度函数表达式为:

$$\mathcal{N}(x) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{(x-\mu)^T \Sigma^{-1} (x-\mu)}{2}} \quad (2-8)$$

其中  $\mu \in R^d$  和  $\Sigma \in R^{d \times d}$  分别为数据的均值和协方差矩阵,  $d$  为数据维度,  $e$  为

指数函数。

当单个 GD 无法准确地描述数据分布时，通常引入多个 GD 的加权平均来拟合多峰数据，解决 GD 的单峰性问题。这就是 GMM 算法，其函数表达式为：

$$P(x) = \sum_{k=1}^K \alpha_k \mathcal{N}(x) \quad (2-9)$$

其中  $\alpha_k$  是混合系数，它表示选择第  $k$  个分模型的概率，满足  $\alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1$ ， $\mathcal{N}(x)$  是第  $k$  个分模型，为式(2-8)所示 GD 概率密度函数。

2) GMM 算法参数估计的 EM 算法：

假设观测数据为  $x_j, j=1,2,\dots,N$  由 GMM 算法生成：

$$P(x) = \sum_{k=1}^K \alpha_k \mathcal{N}(x) \quad (2-10)$$

其中参数为  $\{\alpha_1, \alpha_2, \dots, \alpha_K; \mu_1, \mu_2, \dots, \mu_K; \Sigma_1, \Sigma_2, \dots, \Sigma_K\}$ 。使用 EM 算法估计 GMM 算法参数。

第一步：确定隐变量，然后写出完全数据的对数似然函数：

可设想观测数据  $x_j, j=1,2,\dots,N$  的产生步骤：1) 依据概率  $\alpha_k$  选择第  $k$  个分模型；2) 根据第  $k$  个分模型的概率分布  $\mathcal{N}(x)$  生成观测数据  $x_j, j=1,2,\dots,N$ 。这时观测数据  $x_j, j=1,2,\dots,N$  是已知的；反映观测数据  $x_j, j=1,2,\dots,N$  来自第  $k$  个分模型的数据是未知的，以隐变量  $\gamma_{jk}$  表示， $\gamma_{jk}$  是 0-1 随机变量，其定义如下：

$$\gamma_{jk} = \begin{cases} 1, & \text{第 } j \text{ 个观测来自第 } k \text{ 个分模型} \\ 0, & \text{否则} \end{cases} \quad (2-11)$$

$j=1,2,\dots,N; k=1,2,\dots,K$

GMM 算法的完全数据由观测数据  $x_j$  和未观测数据  $\gamma_{jk}$  组成：

$$(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jK}), j=1,2,\dots,N \quad (2-12)$$

于是，完全数据的似然函数为：

$$\begin{aligned}
 P(x, \gamma) &= \prod_{j=1}^N P(x_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jk}) \\
 &= \prod_{k=1}^K \prod_{j=1}^N [\alpha_k \mathcal{N}(x_j)]^{\gamma_{jk}} = \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N [\mathcal{N}(x_j)]^{\gamma_{jk}} \\
 &= \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N \left[ \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_k|^{\frac{1}{2}}} e^{-\frac{(x_j - \mu_k)^T \Sigma_k^{-1} (x_j - \mu_k)}{2}} \right]^{\gamma_{jk}}
 \end{aligned} \quad (2-13)$$

其中,  $n_k = \sum_{j=1}^N \gamma_{jk}$ ,  $\sum_{k=1}^K n_k = N$ 。

那么, 完全数据的对数似然函数为:

$$\begin{aligned}
 \log P(x, \gamma) &= \sum_{k=1}^K n_k \log \alpha_k \\
 &+ \sum_{j=1}^N \gamma_{jk} \left[ -\log(2\pi)^{\frac{d}{2}} - \log |\Sigma_k|^{\frac{1}{2}} - \frac{(x_j - \mu_k)^T \Sigma_k^{-1} (x_j - \mu_k)}{2} \right]
 \end{aligned} \quad (2-14)$$

第二步: E 步的目的实际上是最大化函数  $Q(\theta, \theta^{(i)})$  下界:

$$\begin{aligned}
 Q(\theta, \theta^{(i)}) &= \sum_{k=1}^K n_k \log \alpha_k \\
 &+ \sum_{j=1}^N \hat{\gamma}_{jk} \left[ -\log(2\pi)^{\frac{d}{2}} - \log |\Sigma_k|^{\frac{1}{2}} - \frac{(x_j - \mu_k)^T \Sigma_k^{-1} (x_j - \mu_k)}{2} \right]
 \end{aligned} \quad (2-15)$$

其中,  $n_k = \sum_{j=1}^N E\gamma_{jk}$ ,  $\hat{\gamma}_{jk} = E\gamma_{jk}$ ,  $\hat{\gamma}_{jk}$  是基于当前模型参数, 分模型  $k$  对观测数据  $x_j$  的响应度, 即当前模型参数下第  $j$  个观测数据来自第  $k$  个分模型的概率:

$$\hat{\gamma}_{jk} = \frac{\alpha_k \mathcal{N}(x_j)}{\sum_{k=1}^K \alpha_k \mathcal{N}(x_j)}, j=1, 2, \dots, N; k=1, 2, \dots, K \quad (2-16)$$

第三步: M 步是在固定好这个下界的条件下, 去最优化估计参数  $\theta$ :

最优化参数  $\theta$  把下界函数  $Q(\theta, \theta^{(i)})$  推向一个更优的方向, 接着又在这个最优的方向上再估计一个下界函数  $Q(\theta, \theta^{(i)})$ , 以此类推迭代下去。如果目标函数是一个凸函数, 随着迭代的进行, 每次进步一点, 最终就可以到达那个最优解, 即随机初始化 GMM 算法的参数, 然后迭代 E 步与 M 步, 直到其迭代后参数的变化量小于阈值, 模型收敛。M 步计算新一轮迭代的模型参数:

---

**算法 2-1 GMM 参数估计算法**


---

**Input:** 专家轨迹数据集  $x_j$ ,  $j=1,2,\dots,N$ , GD 个数  $K$

**Start:** 初始化 GMM 算法参数  $\{(\hat{\alpha}_k, \hat{\mu}_k, \hat{\Sigma}_k) | k=1,2,\dots,K\}$

**Repeat:**

For  $j=1,2,\dots,N$  do

根据当前模型参数, 计算分模型  $k$  对观测数据  $x_j$  的响应度:

$$\hat{\gamma}_{jk} = \frac{\alpha_k \mathcal{N}(x_j)}{\sum_{k=1}^K \alpha_k \mathcal{N}(x_j)}, k=1,2,\dots,K$$

End for

For  $k=1,2,\dots,K$  do

计算新一轮迭代的模型参数:

$$\text{混合系数: } \hat{\alpha}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}, k=1,2,\dots,K$$

$$\text{均值向量: } \hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} x_j}{\sum_{j=1}^N \hat{\gamma}_{jk}}, k=1,2,\dots,K$$

$$\text{协方差矩阵: } \hat{\Sigma}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (x_j - \mu_k)(x_j - \mu_k)^T}{\sum_{j=1}^N \hat{\gamma}_{jk}}, k=1,2,\dots,K$$

End for

更新模型参数  $\{(\hat{\alpha}_k, \hat{\mu}_k, \hat{\Sigma}_k) | k=1,2,\dots,K\}$

**Until:** 模型参数收敛或达到预设的迭代次数

**Output:** GMM 算法参数  $\{(\hat{\alpha}_k, \hat{\mu}_k, \hat{\Sigma}_k) | k=1,2,\dots,K\}$

---

$$\hat{\alpha}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}, k=1,2,\dots,K \quad (2-17)$$

$$\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} x_j}{\sum_{j=1}^N \hat{\gamma}_{jk}}, k=1,2,\dots,K \quad (2-18)$$

$$\hat{\Sigma}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (x_j - \mu_k)(x_j - \mu_k)^T}{\sum_{j=1}^N \hat{\gamma}_{jk}}, k=1,2,\dots,K \quad (2-19)$$

GMM 算法  $\theta^{(i+1)}$  的各个参数可以表示为  $\{(\hat{\alpha}_k, \hat{\mu}_k, \hat{\Sigma}_k) | k=1,2,\dots,K\}$ ，使用 EM 算法对 GMM 算法参数进行估计的流程如下算法 2-1 所示：

### 3) 高斯混合回归算法：

GMR 算法是一种基于概率模型的协作机器人模仿学习运动规划算法。GMR 算法首先使用 GMM 算法建立数据的联合概率密度函数，然后得到回归函数。因此，GMR 算法同时具备了参数模型的紧凑结构和非参数模型的灵活性，目前在协作机器模仿学习运动规划领域应用较多。

首先，使用 GMM 算法建立专家轨迹的联合概率密度函数，输入时间  $\{t_i\}_{i=1}^N$ ，输出协作机器人末端执行器六维位姿  $\{a_i\}_{i=1}^N$ 。其中  $\{t_i\}_{i=1}^N$  和  $\{a_i\}_{i=1}^N$  的联合概率分布如下：

$$P(t, a) = \sum_{k=1}^K \alpha_k \mathcal{N}(t, a | \mu_k, \Sigma_k) \quad (2-20)$$

$$\mu_k = \begin{bmatrix} \mu_k^t \\ \mu_k^a \end{bmatrix} \quad (2-21)$$

$$\Sigma_k = \begin{bmatrix} \Sigma_k^{tt} & \Sigma_k^{ta} \\ \Sigma_k^{at} & \Sigma_k^{aa} \end{bmatrix} \quad (2-22)$$

其中  $\alpha_k$ ， $\mu_k$  和  $\Sigma_k$  分别表示第  $k$  个分模型的概率、均值和协方差矩阵， $K$  表示 GD 的数量。对于 GMM 算法参数通常采用 EM 算法进行迭代优化求解。

在得到 GMM 算法参数后，通过 GMR 算法回归生成概率轨迹  $D$ ，则输入时间  $\{t_i\}_{i=1}^N$  对应的输出协作机器人末端执行器六维位姿  $\{a_i\}_{i=1}^N$  的均值矢量和方差矢量由如下公式计算：

$$\hat{\mu}_i = \mathbb{E}(\hat{a}_i | t_i) = \sum_{k=1}^K h_k(t_i) \mu_k(t_i) \quad (2-23)$$

$$\hat{\Sigma}_i = \mathbb{D}(\hat{a}_i | t_i) = \sum_{k=1}^K h_k(t_i) \left( \Sigma_k + \mu_k(t_i) \mu_k(t_i)^T \right) - \hat{\mu}_i \hat{\mu}_i^T \quad (2-24)$$



$$h_k(t_i) = \frac{\pi_k \mathcal{N}(t_i | \mu_k', \Sigma_k'')}{\sum_{k=1}^K \pi_k \mathcal{N}(t_i | \mu_k', \Sigma_k'')} \quad (2-25)$$

$$\mu_k(t_i) = \mu_k^a + \Sigma_k^{aa} (\Sigma_k'')^{-1} (t_i - \mu_k') \quad (2-26)$$

$$\Sigma_k = \Sigma_k^{aa} - \Sigma_k^{aa} (\Sigma_k'')^{-1} \Sigma_k^{ia} \quad (2-27)$$

经过 GMR 算法回归得到专家轨迹  $D = \{t_i, \hat{\mu}_i, \hat{\Sigma}_i\}_{i=1}^N$ 。

### 2.1.3 逆强化学习算法

#### 1) 强化学习算法

马尔可夫决策过程 (Markov Decision Process, MDP) 是对强化学习问题的数学描述与理论基础。MDP 是指智能体未来状态只与当前状态和动作有关, 与历史信息无关。MDP 定义为一个元组  $\langle S, A, P, r, \gamma \rangle$ , 其中:

- (1)  $S$  为有限数量状态集合,  $s_t \in S$  为智能体当前时刻  $t$  所处的状态;
- (2)  $A$  为有限数量动作集合,  $a_t \in A$  为智能体当前时刻  $t$  所执行的动作;
- (3)  $P$  为状态转移概率矩阵, 即智能体在状态  $s_t$  采取动作  $a_t$  并转移到一个状态  $s_{t+1}$  的概率, 即  $s_{t+1} \sim P(s_t, a_t)$ ;
- (4)  $r$  为奖励函数, 表示智能体在状态  $s_t$  选择动作  $a_t$ , 进入到下一个时刻  $(t+1)$  能获得的奖励值;
- (5)  $\gamma \in [0, 1)$  为折扣因子, 用以控制未来奖励值对累积奖励值的作用效果。

强化学习问题可以描述为, 智能体在时刻  $t$  时处于状态  $s_t$ , 要学习一个策略  $\pi$ , 使该策略选择动作  $a_t$  后, 获得尽可能的高回报期望。其中回报定义为:

$$R_t = \sum_{i=0}^{\infty} \gamma^i r_{t+i+1} \quad (2-28)$$

其中, 当  $\gamma=0$  时, 智能体只关心当前奖励, 当  $\gamma=1$  时, 智能体将充分考虑未来奖励对于回报值的影响。可将智能体从状态  $s_t$  到交互完全结束所得到的所有回报期望定义为状态值函数  $V^\pi(s)$ :

$$V^\pi(s) = \mathbb{E}_\pi [R_t | s_t = s] = \mathbb{E}_\pi \left[ \sum_{i=0}^{\infty} \gamma^i r_{t+i+1} | s_t = s \right] \quad (2-29)$$

同样, 可定义智能体在状态  $s_t$  得到的回报期望为状态-动作值函数

$Q^{\pi}(s, a):$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} [R_t | s_t = s, a_t = a] \quad (2-30)$$

在强化学习算法中，基于策略梯度的强化学习算法可用神经网络结构将策略参数化为可微的  $\pi(a|s, \theta)$ 。于是便可通过最大化目标函数  $J(\theta)$  的方法计算策略梯度  $\nabla_{\theta} \pi(a|s, \theta)$ ，优化策略网络参数。目标函数可定义为策略回报期望：

$$J(\theta) = \mathbb{E}_{\pi} \left[ \sum_{i=0}^{\infty} \gamma^i r_{t+i+1} \right] \quad (2-31)$$

策略参数可以用如下公式更新：

$$\theta = \theta + \alpha \frac{\partial J}{\partial \theta} \quad (2-32)$$

策略梯度算法是一种直接学习策略的算法，它的目标是通过优化策略来最大化预期累积回报，如图 2-1-(a)所示。J. Schulman 等人提出了信赖域策略优化（Trust Region Policy Optimization, TRPO）算法<sup>[36]</sup>，对策略进行学习。而后，基于此算法，提出了改进的近端策略优化（Proximal Policy Optimization, PPO）算法，它降低了计算开销，并使得策略优化更加容易，更易于实际应用。

## 2) 逆强化学习算法

IRL 前提假设专家行为是（近似）最优的。希望通过逆向强化学习得到一个奖励函数去解释专家行为，换言之，马尔可夫决策过程的奖励函数被认为是未知的，须要从专家轨迹数据集中恢复，从而避免人为设定奖励函数，然后通过强化学习从该奖励函数中提取策略。首先，初始化一个奖励函数，通过强化学习算法可以得到当前奖励函数下最优的一组策略，并根据假设专家策略是最优奖励函数下的最优解，优化奖励函数使得专家策略获得更高的奖励值，再由强化学习算法得到最新奖励函数下的最优策略，不断迭代上述过程至收敛，最终根据得到的奖励函数下的最优策略应该与专家策略一致，说明专家行为已经可以被很好地解释，如图 2-1-(b)所示。因此，IRL 的优点是马尔可夫决策，能够探索整个空间，对专家轨迹数据集的要求比 BC 算法要低。缺点是对专家轨迹数据集的使用是间接的，在每一轮内循环中都包含强化学习过程，可能导致训练速度慢，时间成本高，一定程度上限制了 IRL 的发展和实际的应用。




图 2-1 强化学习算法与 IRL 算法对比

IRL 定义为一个元组  $\langle S, A, P, \tau_E, \pi_E \rangle$ ，其中：

- (1)  $S$  为有限数量状态集合， $s_t \in S$  为智能体当前时刻  $t$  所处的状态；
- (2)  $A$  为有限数量动作集合， $a_t \in A$  为智能体当前时刻  $t$  所执行的动作；
- (3)  $P$  为状态转移概率矩阵，即智能体在状态  $s_t$  采取动作  $a_t$  并转移到下一个状态  $s_{t+1}$  的概率，即  $s_{t+1} \sim P(s_t, a_t)$ ；
- (4)  $\tau_E$  为根据专家策略  $\pi_E$  得到的专家轨迹数据集。

在基于最大边际 IRL 中，定义根据专家策略  $\pi_E$  得到的专家轨迹数据集为：

$$\tau_E = \{\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_i, \dots, \hat{\tau}_N | \pi_E\} \quad (2-33)$$

而每一条轨迹可以进一步表示为时间序列上的状态-动作对：

$$\hat{\tau}_i = \{(s_0, \hat{a}_0), (s_1, \hat{a}_1), \dots, (s_i, \hat{a}_i), \dots\} \quad (2-34)$$

使用  $k$  个已知的、固定的和有界的基函数  $\phi$  的线性组合拟合奖励函数：

$$r(s) = \sum_{i=1}^K w_i \phi_i(s) \quad (2-35)$$

策略  $\pi$  定义为将状态映射到动作，值函数  $V_\pi$  定义为：

$$V_{\pi}(s) = \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_t) | \pi \right] = \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t w^T \phi(s_t) | \pi \right] = w^T \mu_{\pi} \quad (2-36)$$

将折扣累积特征值的期望定义为  $\mu_{\pi} = \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t \phi(s_t) | \pi \right]$ 。认为最优专家策略  $\pi_E$  总是产生比任何其它策略  $\hat{\pi}$  更高的值函数  $V_{\pi_E}(s)$ 。因此，将找到一个策略  $\hat{\pi}$  使得  $\|\mu_E - \mu_{\hat{\pi}}\|_2 \leq \varepsilon$ 。对于这样的  $\hat{\pi}$ ，在任何  $\|w\|_2 \leq 1$  下，都有：

$$\begin{aligned} & \left| \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_t) | \pi_E \right] - \mathbb{E} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_t) | \hat{\pi} \right] \right| \\ &= |w^T \mu_E - w^T \mu_{\hat{\pi}}| \leq \|w\|_2 \|\mu_E - \mu_{\hat{\pi}}\|_2 \leq \varepsilon \end{aligned} \quad (2-37)$$

其中，根据专家轨迹  $\tau_E$ ，计算专家的特征期望  $\mu_E = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{\infty} \gamma^t \phi(s_t^{(i)})$ 。还通过探索随机策略  $\hat{\pi}$  来估计特征期望  $\mu_{\hat{\pi}}$ 。并令  $\varepsilon$  是一个很小的阈值。因此，问题被简化为找到一个策略  $\hat{\pi}$ ，它会导致特征期望  $\mu_{\hat{\pi}}$  接近  $\mu_E$ 。再确定  $w$  的值，通过最大化专家的特征期望与估计的特征期望之间的距离：

$$t_{(i)} = \max_{w: \|w\|_2 \leq 1} \min_{j \in \{0 \dots (i-1)\}} w^T (\mu_E - \mu_{(j)}) \quad (2-38)$$

基于最大边际 IRL 算法的算法流程如下：

- (1) 回报函数初始化，随机选择一些策略  $\pi_{(0)}$ ，计算  $\mu_{(0)} = \mu(\pi_{(0)})$ ，并设置  $i = 1$ ；
- (2) 计算  $t_{(i)} = \max_{w: \|w\|_2 \leq 1} \min_{j \in \{0 \dots (i-1)\}} w^T (\mu_E - \mu_{(j)})$ ，令  $w_{(i)}$  为使  $t$  达到最大值的  $w$  值；
- (3) 当  $t_{(i)} \leq \varepsilon$ ，则意味着该集合中至少有一个策略的性能与专家策略的性能近似，然后终止；
- (4) 使用 RL 算法，基于奖励  $r = w_{(i)}^T \phi$  计算 MDP 的最优策略  $\pi_{(i)}$ ；
- (5) 计算  $\mu_{(i)} = \mu(\pi_{(i)})$ ；
- (6) 设  $i = i + 1$ ，然后回到第 2 步。

在第  $i$  次迭代中，已经找到了一些策略  $\{\pi_{(0)}, \dots, \pi_{(i-1)}\}$ 。步骤 2 中的优化可以看作是一个逆向强化学习步骤，该步骤尝试估计被专家优化的奖励函数。终止后，算法返回  $\{\pi_{(i)} : i = 0 \dots n\}$ 。

基于最大边际 IRL 算法存在的一大问题是不安定问题，即或许存在很多不同的回报函数导致相同的专家策略。B. D. Ziebart 等人使用最大熵原理来解决该问题。最大熵原理是指，在约束条件下，真实回报函数的最优策略的

熵最大。最大熵 IRL 算法就是在目标函数中额外引入  $\lambda_H H(\pi)$  项， $H(\pi)$  表示为策略的熵， $\lambda_H$  为调节系数。于是，有 IRL 框架：

$$\max_r \left( \min_{\pi} -\mathbb{E}_{\pi} [r(s,a)] - \lambda_H H(\pi) \right) + \mathbb{E}_{\pi_E} [r(s,a)] \tag{2-39}$$

其中， $H(\pi) \triangleq \mathbb{E}_{\pi} [-\log \pi(a|s)]$  为策略  $\pi$  的  $\gamma$  折扣因果熵。在实际问题中， $\pi_E$  是没法直接获取的，只能使用专家数据的采样来估计。最大因果熵 IRL 的  $\min_{\pi} -\mathbb{E}_{\pi} [r(s,a)] - \lambda_H H(\pi)$  可以通过强化学习的过程来得到，使策略  $\pi$  的因果熵和期望奖励函数最大化。

除了不适定问题，回报函数的表征能力也是约束 IRL 问题的一大瓶颈。引入正则化器  $\psi(r)$ ，可以解决 IRL 回报函数表征能力不足的问题。进一步，有 IRL 框架：

$$\max_r \psi(r) + \left( \min_{\pi} -\mathbb{E}_{\pi} [r(s,a)] - \lambda_H H(\pi) \right) + \mathbb{E}_{\pi_E} [r(s,a)] \tag{2-40}$$

2.1.4 生成对抗式模仿学习算法

1) 生成对抗网络：

GANs 是一种生成式模型，其基于神经网络通过对抗式的策略学习数据特征。其由生成器（Generator, G）和判别器（Discriminator, D）两部分组成。GANs 通过生成器生成数据与专家数据之间的差异来引导生成器的学习，擅长于无监督学习，其模型如图 2-2 所示。




图 2-2 GANs 模型框架

$G$  和  $D$  通过博弈相互优化提升, 最终达到最优, 优化目标函数如下:

$$\min_G \max_D L_{GANs}(D, G) = \mathbb{E}_x [\log D(x)] + \mathbb{E}_z [\log(1 - D(G(z)))] \quad (2-41)$$

其中  $x$  表示专家样本,  $z$  表示随机噪声输入,  $G(z)$  表示智能体策略与环境交互产生样本,  $D(x)$  表示判别器  $D$  判别样本为专家样本的概率 (因为  $x$  就是真实的, 所以对于  $D$  来说, 这个值越接近 1 越好)。  $D(G(z))$  表示判别器  $D$  判断  $G$  生成样本为专家样本的概率。  $G$  希望自己生成的样本越接近专家样本越好, 即  $G$  的能力越强,  $D(G(z))$  应该越大。  $D$  希望自己能很好地区分生成样本与专家样本, 即  $D$  的能力越强,  $D(x)$  应该越大,  $D(G(z))$  应该越小。因此  $L_{GANs}(D, G)$  对于  $D$  来说是求最大, 对于  $G$  来说是求最小。为了前期加快训练, 生成器  $G$  的训练可以把  $\log(1 - D(G(z)))$  换成  $-\log(D(G(z)))$  损失函数。

GANs 的算法流程如下:

- (1) 训练  $D$ , 使其能最大化优化目标  $L_{GANs}(D, G)$ , 即能准确区分来自生成器的样本和专家样本;
- (2) 训练  $G$ , 最小化优化目标  $L_{GANs}(D, G)$ , 即产生逼真样本欺骗  $D$ ;
- (3) 重复步骤(1)(2), 直到达到一定迭代次数;
- (4) 最终得到能生成完美拟合专家样本的  $G$ , 而  $D$  以无法辨别两者差别, 此时博弈达到纳什均衡, 算法结束。

GANs 的优化目标是最小化智能体交互样本分布和专家样本分布之间的 Jensen-Shannon (JS) 散度。模态崩塌是指随着输入的变化, 对应的  $G(z)$  并没有变化, 从而导致模态单一。梯度消失是指当两个分布之间完全没有重叠部分时, 损失函数为常数, 梯度为零或很小, 即损失函数失去衡量两种分布靠近程度的能力。造成这两个问题的主要原因是 JS 散度无法衡量不重叠分布之间的散度, 且不具有对称性。

## 2) 生成对抗式模仿学习算法

GAIL 算法可以绕过 IRL 算法的中间步骤, 直接从专家行为学习到策略, 明确地告诉模仿者如何行动。其基本思想是将 GANs 引入 IRL, 利用 GANs 的对抗训练来生成专家数据分布。根据 GANs 包含生成模型  $G$  和判别模型  $D$ , GAIL 使用强化学习策略梯度算法来更新生成模型  $G$  中的策略网络。生成模型  $G$  根据输入当前状态输出动作。判别模型  $D$  判断输入动作的来源是生成模型  $G$  还是专家轨迹数据集, 以此来使生成模型学习的策略逼近专家策略。该算法与现有的无模型方法相比, 在大型、高维环境中, 模仿复杂行为的能

力获得了显著的提升。

设计新的正则化器  $\psi_{GA}(c)$  来构建目标函数，定义为如下形式：

$$\psi_{GA}(c) = \begin{cases} \mathbb{E}_{\pi_E} [g(c(s, a))], & \text{if } c < 0 \\ +\infty, & \text{else} \end{cases} \quad (2-42)$$

其中  $g(x)$  可表示为：

$$g(x) = \begin{cases} -x - \log(1 - e^x), & \text{if } x < 0 \\ +\infty, & \text{else} \end{cases} \quad (2-43)$$

该形式鼓励损失函数  $c$  分配给专家策略较小的惩罚，如果损失函数  $c$  分配给专家策略较大的惩罚（接近于 0，这是  $\psi_{GA}(c)$  可行域的上限），那么  $\psi_{GA}(c)$  将重重惩罚  $c$ 。 $\psi_{GA}^*$  满足：

$$\psi_{GA}^*(\rho_\pi - \rho_{\pi_E}) = \max_{\omega} \mathbb{E}_{\pi} [\log D(s, a)] + \mathbb{E}_{\pi_E} [\log(1 - D(s, a))] \quad (2-44)$$

其中， $\pi_E$  表示专家策略， $\pi_\theta$  表示生成策略， $D(s, a)$  表示判别器，输出的最大范围为  $(0, 1)$ 。

$$\min_{\theta} \psi_{GA}^*(\rho_\pi - \rho_{\pi_E}) - \lambda_H H(\pi) = D_{JS}(\rho_\pi, \rho_{\pi_E}) - \lambda_H H(\pi) \quad (2-45)$$

接着，通过最小化智能体策略生成的样本分布  $\rho(s, a)$  与专家策略的样本分布  $\rho_E(s, a)$  之间的 JS 散度，从而使  $\pi$  产生的样本分布最终能拟合  $\pi_E$  的样本分布。GAIL 算法适用于大环境下的无模型模仿学习，其目标函数定义如下：

$$\min_{\theta} \max_{\omega} L_{GAIL}(\pi, D) = \mathbb{E}_{\pi_\theta} [\log D(s, a)] + \mathbb{E}_{\pi_E} [\log(1 - D(s, a))] - \lambda_H H(\pi) \quad (2-46)$$

其中， $\pi_\theta$  为基于参数  $\theta$  的策略网络， $D_\omega$  为基于参数  $\omega$  的判别器网络。使用 Adam 梯度步长调整  $\omega$ ，增加(2-46)，进而更新  $D_\omega$ 。使用 PPO 步长调整  $\theta$ ，减小(2-46)，进而更新  $\pi_\theta$ 。这两步交替进行。PPO 步长防止由于策略梯度中的噪声而导致策略过度变化。判别器网络通过最优化二分类交叉熵目标函数区别来自  $\pi_E$  还是  $\pi_\theta$  的状态-动作对  $(s, a)$ ，它可以解释为向生成模块策略网络提供学习信号的局部目标函数。GAN 算法的算法结构相当于该算法结构  $c(s, a) = \log D(s, a)$  时的情形。GAIL 算法框架如图 2-3 所示。

GAIL 算法的算法流程如下所示：

- (1) 使用 ADAM 等梯度优化算法训练  $D$ ，使  $D$  对  $\pi_E$  尽可能小的惩罚而给  $\pi$  尽可能大的惩罚；

- (2) 使用 TRPO、PPO 等梯度优化算法训练  $\pi$ ，使其向最小化累计惩罚值方向梯度更新；
- (3) 重复(1)(2)步骤，使得惩罚函数不断接近真实惩罚函数并引导  $\pi$  接近  $\pi_E$ ；

虽然 GAIL 算法有效解决了 IRL 计算开销大与表征能力较差等缺陷，但由于使用了 GANs 的思想，同时也引入了 GANs 的不足，即模态崩塌与梯度消失的问题。另外，GAIL 算法还存在与环境交互生成样本利用效率低的问题。智能体与环境交互的成本很高，而与环境交互所生成的样本却只会被使用一次。




图 2-3 GAIL 算法模型框架

## 2.2 模仿学习运动规划框架与专家轨迹数据集的建立

### 2.2.1 模仿学习运动规划框架

模仿学习运动规划算法框架分为示教、学习和生成三个部分，如图 2-4 所示。示教部分的任务是建立专家轨迹数据集，供模仿学习运动规划算法学习与模仿。针对高自由度协作机器人提出通过规划算法构造专家轨迹的方法。学习部分的任务是对输入到输出之间的映射进行学习，即学习专家策略。生成部分的任务是根据协作机器人当前运动状态对所模仿的专家技能进行复现与泛化。针对两种模仿学习运动规划算法提出改进结合动态运动基元与核化运动基元的 DS-KMP 算法和改进的带有辅助分类器的生成式对抗模仿学习算法。






图 2-4 模仿学习运动规划算法框架

2.2.2 专家轨迹数据集建立

首先，需要建立一个专家轨迹数据集，以供模仿学习运动规划算法进行学习。建立专家轨迹数据集通常采用示教的方式获取专家轨迹。有两种简单的获取方法：一种是通过安装在示教者身上的定位传感器采集专家轨迹，再将其映射到协作机器人上；另一种方法是拖动示教，记录的专家轨迹可以直接用于模仿学习运动规划算法的学习。当协作机器人自由度过高时，很难通过人工示教方法获取高质量的专家轨迹数据，故介绍一种通过规划算法构造专家轨迹的方法。以构造一条先曲线运动再直线运动的位姿轨迹，并保证两个阶段位姿轨迹连续为例。

首先，进行路径规划，为了使两个阶段位置轨迹连续，设计曲线位置轨迹为一条贝塞尔曲线。N 阶贝塞尔曲线的参数表达如式(2-47)与(2-48)：

$$B_j(t) = c_j^0 b_n^0(t) + c_j^1 b_n^1(t) + \cdots + c_j^n b_n^n(t) = \sum_{i=0}^n c_j^i b_n^i(t) \tag{2-47}$$

$$b_n^i(t) = \binom{n}{i} t^i (1-t)^{n-i} \tag{2-48}$$

其中  $c_j^0, c_j^1, \dots, c_j^n$  为生成 N 阶贝塞尔曲线的 N+1 个位置控制点，下标 j 代表控制点矢量的维度，t 为归一化参数，取值范围为[0,1]。在这个例子中，使用二阶贝塞尔曲线来构造曲线位置轨迹。三个位置控制点分别是曲线起始位置点，中间经过位置点和曲线终止位置点。中间经过位置点与曲线终止位置点连线的延长线为直线位置轨迹。图 2-5 所示为通过二阶贝塞尔曲线构造的先曲线再直线的位置轨迹。



图 2-5 协作机器人末端执行器位置轨迹与四元数球面线性插值示意图

在曲线运动阶段结束时，需要到达目标姿态，并在直线运动阶段保持此目标姿态不变。本文使用球面线性插值建立从起始姿态到终止姿态的姿态变化轨迹。根据球面线性插值得到的中间姿态与初始姿态间的夹角  $\theta$  是线性变化的，从而实现曲线运动阶段姿态的连续。球面线性插值的计算公式如下：

$$\text{Slerp}(p_0, p_1; t) = \frac{\sin[(1-t)\Omega]}{\sin \Omega} p_0 + \frac{\sin[t\Omega]}{\sin \Omega} p_1 \quad (2-49)$$

其中  $p_0, p_1$  分别为以四元数形式表达的起始姿态与终止姿态， $\Omega$  为  $p_0, p_1$  之间的夹角， $t$  为归一化参数，取值范围为  $[0, 1]$ 。

然后，基于路径规划结果，可通过三次样条插值路径参数化算法或是时间最优路径参数化(Time-Optimal Path Parameterization, TOPP)算法进行轨迹规划。于是，便构造出一条完整专家轨迹。




图 2-6 建立专家轨迹数据集框架

接着，假设有一个  $n$  个任务的集合  $\{c_1, c_2, \dots, c_m, \dots, c_n\}$ ， $c_m$  是任务编号，服从先验概率  $c_m \sim p(c)$ 。在实际应用中，以六自由度 UR3 协作机器人为例，当通过规划算法构造出专家轨迹路径之后，使用 ur-rtde 1.5.1 控制接口跟踪专家轨迹的路径，同时使用 ur-rtde 1.5.1 接收接口固定频率采样得到当前 UR3 协作机器人关节角状态  $q_E^i = (\theta_1^i, \theta_2^i, \theta_3^i, \theta_4^i, \theta_5^i, \theta_6^i)$  和下一个时刻 UR3 协作机器人关节角状态  $\bar{q}_E^{i+1}$ 。专家轨迹中的状态-动作-模态对的状态可以表示为  $s_E^i = (q_E^i; c_m^i; q_E^o)^T$ ，其中  $q_E^o$  是 UR3 协作机器人在关节空间下的目标状态， $c_m^i$  是任务编号。专家轨迹中的状态-动作-模态对的动作可以表示为  $a_E^i = (q_E^{i+1}; c_m^{i+1})^T$ 。一条完整专家轨迹可以表示为

$\{(s_E^1, a_E^1, t^1), \dots, (s_E^i, a_E^i, t^i), \dots, (s_E^T, a_E^T, t^T)\}$ 。同理也可以得到以协作机器人末端执行器位姿  $x_E^i = (x^i, y^i, z^i, \delta_1^i, \delta_2^i, \delta_3^i)$  来表述的专家轨迹。大量的专家轨迹组成专家轨迹数据集  $D$ ，整个框架如图 2-6 所示。

以化学合成实验中的 UR3 协作机器人转运试管任务为例，假定试管被放置在试管架的随机位置上，UR3 协作机器人首先运动到固定的起始位置  $A$ ，通过相机识别目标试管在试管架上的位置编号。通过查表的方法匹配对应的协作机器人末端执行器目标位姿  $x_E^o$ ，将该点记录为  $B$ 。接下来 UR3 协作机器人通过规划算法构造出一条从位置  $A$  到位置  $B$  的安全合理的运动轨迹，并令  $A \rightarrow B$  的动作为模式  $c_1$ 。接着，抓取物体，构造出一条垂直向上拿起试管到位置  $C$ ，再将试管运送到磁力搅拌器上的指定位置  $D$  的安全合理的运动轨迹，并令  $B \rightarrow C \rightarrow D$  的动作为模式  $c_2$ 。通过 UR3 协作机器人的 ur-rtde 1.5.1 控制接口控制运动，并同时使用 ur-rtde 1.5.1 接收接口固定频率采样记录下完整的专家轨迹  $d$ ，多次采集专家轨迹，得到实验所需的专家轨迹数据集  $D$ ，该过程具体情况将在第五章详细介绍。

2.3 核化运动基元算法及改进

首先，介绍 KMP 算法的原理和特性。然后，将 DMP 算法的拓扑等价性引入 KMP 算法，提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法，解决 KMP 算法难以进行整体轨迹调制的问题。进一步，通过手写字母轨迹学习实验，证明 DS-KMP 算法的优越性。




图 2-7 KMP 算法流程

### 2.3.1 核化运动基元算法

KMP 算法作为一种基于概率模型的模仿学习运动规划算法,其核心思想是首先通过 GMM 算法对多条专家轨迹进行建模。然后,通过 GMR 算法回归出一条带有概率信息的专家轨迹  $E$ 。接着,可对专家轨迹  $E$  进行局部轨迹调制。最后,再根据相对熵(Kullback-Leible 散度, KL 散度)对这条调整后的专家  $E$  轨迹进行拟合,以得到 KMP 模型,用于轨迹输出,如图 2-7 所示。

以协作机器人接收技能学习为例,通过 GMM 算法得到专家接收轨迹的概率分布,输入时间为  $\{t_n\}_{n=1}^N$ ,输出协作机器人末端执行器在笛卡尔空间下 6-D 位姿  $\{\xi_n\}_{n=1}^N$ 。 $t$  和  $\xi$  的联合概率分布由下式给出:

$$\mathcal{P}(t, \xi) = \sum_{c=1}^C \pi_c \mathcal{N}(t, \xi | \mu_c, \Sigma_c) \quad (2-50)$$

其中  $\pi_c$ 、 $\mu_c$  和  $\Sigma_c$  分别表示第  $c$  个高斯分布的先验概率、均值和协方差,而  $C$  表示高斯分布的数量。此外,可以通过 GMR 算法生成概率专家轨迹  $\{\hat{\xi}_n\}_{n=1}^N$ ,其中每个点  $\hat{\xi}_n$  由均值  $\hat{\mu}_n$  和协方差  $\hat{\Sigma}_n$  的条件概率分布来描述:

$$\mathcal{P}_r(\hat{\xi}_n | t_n) = \mathcal{N}(\hat{\mu}_n, \hat{\Sigma}_n) \quad (2-51)$$

然后,进行轨迹调制以通过新的经过点和终点。将  $M$  个新的期望点定义为  $\bar{E} = \{\bar{t}_m, \bar{\xi}_m\}_{m=1}^M$ ,每个点满足条件概率分布  $\bar{\xi}_m | \bar{t}_m \sim \mathcal{N}(\bar{\mu}_m, \bar{\Sigma}_m)$ 。将专家轨迹  $E$  与期望点集  $\bar{E}$  连接起来。对于新终点  $x_{end} = \{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\}$ ,直接替换终点  $\{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}$ :

$$E \leftarrow \{E / \{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}\} \cup \{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\} \quad (2-52)$$

其中符号 “/” 和 “ $\cup$ ” 分别代表排除和联合操作。

对于新的经过点  $x_{via} = \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$ ,首先将其位置  $x_{via}$  与专家轨迹  $E$  进行比较,从而找到最近的数据点  $\{x_r, \hat{\mu}_r, \hat{\Sigma}_r\}$  满足  $d(\bar{t}_2, t_r) \leq d(\bar{t}_2, t_n)$ ,  $\forall n \in \{1, 2, \dots, N\}$ ,其中  $d(\cdot)$  可以是任意 2 范数距离度量。如果最近距离  $d(\bar{t}_2, t_r)$  小于预定义的阈值  $\zeta_0 > 0$ ,替换  $\{x_r, \hat{\mu}_r, \hat{\Sigma}_r\}$  与  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$ 。否则,将  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$  插入专家轨迹  $E$ 。更新专家轨迹  $E$  根据:

$$\begin{cases} E \leftarrow \{E / \{x_r, \hat{\mu}_r, \hat{\Sigma}_r\}\} \cup \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}, & \text{if: } d(\bar{t}_2, t_r) < \zeta_0 \\ E \leftarrow E \cup \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}, & \text{else} \end{cases} \quad (2-53)$$

对于专家轨迹  $E$  在  $\{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}$  和  $\{x_r, \hat{\mu}_r, \hat{\Sigma}_r\}$  间的点,用基于  $\{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\}$  和  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$  的等量点替换它们。

接着，基于概率参数轨迹  $\{\xi_n'\}_{n=1}^N$  学习 KMP 算法参数：

$$\xi_n' = \Theta^T w \quad (2-54)$$

其中矩阵  $\Theta \in \mathbb{R}^{6B \times 6}$  定义为  $\Theta = \text{diag}(\varphi(t_n), \varphi(t_n), \dots, \varphi(t_n))$ ， $\varphi(t_n) \in \mathbb{R}^B$  表示  $B$  维基函数，权重矢量  $w \in \mathbb{R}^{6B}$ 。此外，假设权重矢量  $w$  是正态分布，即  $w \sim \mathcal{N}(\mu_w, \Sigma_w)$ ，其中均值  $\mu_w$  和协方差  $\Sigma_w$  是未知的。因此，参数轨迹满足：

$$\mathcal{P}_p(\xi_n' | t_n) = \mathcal{N}(\Theta^T \mu_w, \Theta^T \Sigma_w \Theta) \quad (2-55)$$

这样做的目的是模仿概率专家轨迹  $\{\hat{\xi}_n\}_{n=1}^N$ 。因此，目标是匹配参数轨迹分布(2-55)与专家轨迹分布。为了解决这个问题，考虑最小化两个轨迹分布之间的 KL-散度：

$$J_{ini}(\mu_w, \Sigma_w) = \sum_{n=1}^N D_{KL}(\mathcal{P}_p(\xi_n' | t_n) \| \mathcal{P}_r(\hat{\xi}_n | t_n)) \quad (2-56)$$

其中  $D_{KL}(\cdot \| \cdot)$  表示概率分布  $\mathcal{P}_p$  和  $\mathcal{P}_r$  之间的 KL 散度。随后，可以推导出  $\mu_w$  和  $\Sigma_w$  的最优解。

KMP 算法在新输入  $t^*$  处预测新的高斯分布， $\mathbb{E}(\xi_n'(t^*))$  和  $\mathbb{D}(\xi_n'(t^*))$  可以导出为：

$$\mathbb{E}(\xi_n'(t^*)) = k^*(K + \lambda_1 \Sigma)^{-1} \mu \quad (2-57)$$

$$\mathbb{D}(\xi_n'(t^*)) = \frac{N}{\lambda_2} (k^{**} - k^*(K + \lambda_2 \Sigma)^{-1} k^{*T}) \quad (2-58)$$

其中  $\mu = [\hat{\mu}_1^T, \dots, \hat{\mu}_N^T]^T$ ， $\Sigma = \text{diag}(\hat{\Sigma}_1, \dots, \hat{\Sigma}_N)$ ， $K = \begin{bmatrix} k(t_1, t_1) & \dots & k(t_1, t_N) \\ \dots & \ddots & \dots \\ k(t_N, t_1) & \dots & k(t_N, t_N) \end{bmatrix}$ ，

$k^* = [k(t^*, t_1), \dots, k(t^*, t_N)]$  和  $k^{**} = k(t^*, t^*)$ 。此外，

$k(t_i, t_j) = \Theta(t_i)^T \Theta(t_j) = k(t_i, t_j)I$ ，其中  $I$  是单位矩阵。此外，令核函数为：

$$k(t_i, t_j) = \sigma_f^2 \exp(-\frac{1}{l} \|t_i - t_j\|^2) \quad (2-59)$$

并定义 KMP 算法所需的四个超参数  $\{\lambda_1, \lambda_2, l, \sigma_f^2\}$ 。然后，使用内核技术来得到 KMP 算法模型。算法流程如算法 2-2 所示。

## 算法 2-2 KMP 算法

### 1: 初始化

定义核函数  $k(\cdot, \cdot)$  和超参数  $\lambda_1, \lambda_2$

### 2: 从专家轨迹数据集中学习

收集专家轨迹数据集  $D = \left\{ \left\{ t_{n,h}, \xi_{n,h} \right\}_{n=1}^N \right\}_{h=1}^H$

通过 GMM/GMR 算法生成专家轨迹  $E = \{t_n, \hat{\mu}_n, \hat{\Sigma}_n\}_{n=1}^N$

增减起止点/经过点到专家轨迹  $E$  中，进行轨迹调制

### 3: 得到 KMP 算法模型

输入: 查询点  $t^*$

使用公式计算  $\Sigma$ ,  $\mu$ ,  $K$  和  $k^*$

输出:  $\mathbb{E}(\xi'_n(t^*)) = k^*(K + \lambda_1 \Sigma)^{-1} \mu$  和

$$\mathbb{D}(\xi'_n(t^*)) = \frac{N}{\lambda_2} (k^{**} - k^*(K + \lambda_2 \Sigma)^{-1} k^{*T})$$

## 2.3.2 结合动态运动基元与核化运动基元的 DS-KMP 算法

该算法保留了专家轨迹的概率特性，使得协作机器人能够更准确的学习运动技能。与依赖基函数的方法相比，模型具有更少的开放参数，能够处理高维输入。保证协作机器人能够动态、快速地响应实时变化的起止点并通过相应的经过点。难以根据实际情况进行整体轨迹调制。不具备拓扑等价性，仅适用于相对简单的协作机器人运动规划任务。将 DMP 算法的拓扑等价性引入 KMP 算法，提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法，解决 KMP 算法难以进行整体轨迹调制的问题。

首先，根据 KMP 算法可以生成基于时间  $\{t_i^*\}_{i=1}^N$  的均值轨迹  $y_{demo}(t) = \left\{ \mathbb{E}(\xi'_n(t_i^*)) \right\}_{i=1}^N$ ，即 DMP 算法的专家轨迹的位置、速度和加速度为  $(y_{demo}(t), \dot{y}_{demo}(t), \ddot{y}_{demo}(t))$ ，其中  $t \in [1, \dots, N]$ ， $N$  为专家轨迹时长。可得非线性强迫函数  $f_{target}$  为：

$$f_{target} = \ddot{y}_{demo} - \alpha_y (\beta_y (g - y_{demo}) - \dot{y}_{demo}) \quad (2-60)$$

于是，对专家轨迹的学习问题被转化为非线性强迫函数的拟合问题。本文采用经典的局部加权回归算法快速求解基函数权重。局部加权回归算法的



损失函数为：

$$J(\omega) = \sum_i \psi_i(t)(f_{target}(t) - \omega_i(x(t)(g - y_0)))^2 \tag{2-61}$$

使用最小二乘法可得其解为：

$$\omega_i = \frac{s^T \Gamma_i f_{target}}{s^T \Gamma_i s} \tag{2-62}$$

其中

$$s = \begin{pmatrix} x(t_0)(g - y_0) \\ \cdots \\ x(t_N)(g - y_0) \end{pmatrix}, \quad \Gamma_i = \begin{pmatrix} \psi_i(t_0) & \cdots & 0 \\ 0 & \ddots & 0 \\ 0 & \cdots & \psi_i(t_N) \end{pmatrix} \tag{2-63}$$

通过局部加权回归算法简单、快速解得权重后，非线性动态系统在强迫函数的作用下即可生成与专家轨迹类似的运动轨迹。至此，可以通过 KMP 算法来学习得到轨迹特征，并通过 DMP 算法来生成轨迹，其算法流程如算法 2-3 所示。

表 2-1 DS-KMP 算法与其它算法优劣对比

|       | DMP | GMR | KMP | DS-KMP |
|-------|-----|-----|-----|--------|
| 概率性   | -   | √   | √   | √      |
| 经过点   | -   | -   | √   | √      |
| 终止点   | √   | -   | √   | √      |
| 轨迹调制  | -   | -   | √   | √      |
| 拓扑等价性 | √   | -   | -   | √      |

备注 2-1：为了拓展 DMP 算法，以实现多自由度的模仿学习，需要耦合多个 DMP 系统。在保证各个自由度的 DMP 系统的强迫函数  $f$  和动力学系统  $y$  是相互独立的，同时将正则系统  $x$  设为相同，即各个维度的 DMP 系统目标值  $g$  和起点值  $y_0$ 、基函数  $\psi_i$  和对应权重  $\omega_i$  都能单独设定。由于各个自由度的 DMP 系统共享了同一个正则系统  $x$ ，可保证各个自由度的运动节奏保持一致与运动特性不变。

备注 2-2：需要说明的是：在 DS-KMP 算法中使用到了两种轨迹调制方法。一种方法是在 GMR 算法生成概率专家轨迹后，直接对轨迹进行局部调制。此方法适用于小范围局部轨迹调制，比如起止点，经过点轨迹约束，以

及轨迹特征增删。另一种则是通过调节 DMP 系统参数来实现轨迹在时间和空间尺度上的缩放。由于其具有良好的拓扑等价性，此方法更适用于大范围轨迹调制。

### 算法 2-3 DS-KMP 算法

#### 1: 初始化

定义 GMM 算法的 GD 个数  $K$ ，随机初始化 GD 均值  $\mu_k$  和协方差  $\Sigma_k$

定义 KMP 算法的核函数  $k(\cdot, \cdot)$  和超参数  $\lambda_1, \lambda_2$

定义 DMP 算法的超参数  $\alpha_x, \alpha_y, \beta_y$

#### 2: 从专家轨迹数据集中学习

收集专家轨迹数据集  $D = \left\{ \left\{ t_{n,h}, \xi_{n,h} \right\}_{n=1}^N \right\}_{h=1}^H$

通过 GMM/GMR 算法生成专家轨迹  $E = \{t_n, \hat{\mu}_n, \hat{\Sigma}_n\}_{n=1}^N$

增减起止点/经过点到专家轨迹  $E$  中，进行轨迹调制

#### 3: 得到 KMP 算法模型

输入：时间  $t^*$

使用公式计算  $\Sigma, \mu, K$  和  $k^*$

输出：  $\mathbb{E}(\xi'_n(t^*)) = k^*(K + \lambda_1 \Sigma)^{-1} \mu$  和

$$\mathbb{D}(\xi'_n(t^*)) = \frac{N}{\lambda_2} (k^{**} - k^*(K + \lambda_2 \Sigma)^{-1} k^{*T})$$

#### 4: 使用 DMP 算法进行轨迹生成

输入：时间序列  $\{t_i^*\}_{i=1}^N$ ，均值轨迹序列  $y_{demo}(t) = \left\{ \mathbb{E}(\xi'_n(t^*)) \right\}_{t=1}^N$

计算  $f_{target} = \ddot{y}_{demo} - \alpha_y (\beta_y (g - y_{demo}) - \dot{y}_{demo})$

$$\text{计算 } s = \begin{pmatrix} x(t_0)(g - y_0) \\ \cdots \\ x(t_N)(g - y_0) \end{pmatrix}, \quad \Gamma_i = \begin{pmatrix} \psi_i(t_0) & \cdots & 0 \\ 0 & \ddots & 0 \\ 0 & \cdots & \psi_i(t_N) \end{pmatrix}$$

$$\text{计算 } \omega_i = \frac{s^T \Gamma_i f_{target}}{s^T \Gamma_i s}$$

根据实际起止点和时间空间关系调整  $\alpha_x, \alpha_y, \beta_y$ ，进行轨迹缩放

输出：DMP 参数用于轨迹生成

DS-KMP 算法其既保留了专家轨迹的概率特性，使得协作机器人能够更



准确的学习运动技能。与依赖基函数的方法相比,模型具有更少的开放参数,能够处理高维输入。保证协作机器人能够动态、快速地响应实时变化的起止点并通过相应的经过点,又结合了 DMP 算法的动态调整能力和拓扑等价性,具有更高的实际应用价值。表 2-1 详细对比了 DS-KMP 算法与各种传统算法的优劣。


### 2.3.3 算法实验设计与结果分析

本节设计了一个手写字母轨迹学习实验,该实验旨在通过对专家手写字母轨迹数据集进行学习,实现不同字母的手写轨迹复现。


通过 MATLAB 绘制二维手写字母轨迹,分别使用手写字母‘G’、‘a’和手写数字‘2’各五条轨迹来评估 DS-KMP 算法。首先,使用 GMM 算法对多条专家轨迹进行建模,得到专家轨迹的概率分布。然后,通过 GMR 算法回归出一条带有概率信息的专家轨迹。GMM 算法的 GD 个数选定为 10 个,核函数选择高斯核  $k(t_i, t_j) = \sigma_f^2 \exp(-\frac{1}{l} \|t_i - t_j\|^2)$ , 其中  $l=2, \lambda_1 = \lambda_2 = 1$ 。接着,通过对专家轨迹进行局部调制。进一步,根据 KL 散度对这条调制后的专家轨迹进行拟合,以得到 KMP 模型,时间序列  $\{t_n\}_{n=1}^N$ , 均值轨迹序列  $y(t) = \{\mathbb{E}(\xi(t_n))\}_{n=1}^N$ 。最后,通过 DMP 算法来生成轨迹。DMP 的基函数个数  $BFs = 500$ 。

图 2-8-(a)和图 2-8-(b)展示了 DS-KMP 算法和 KMP 算法在轨迹调制方面的性能效果,在图 2-8-(a)中增加了一个经过点和终止点约束,而在图 2-8-(b)中增加了起始点和一个经过点约束。可以见得在增加约束方面,DS-KMP 算法和 KMP 算法在性能上并没有明显的差别,都能生成满足要求的轨迹。而对于图 2-8-(c)中展现的轨迹缩放情况。可以很明显的看到,在改变轨迹终止点后,KMP 算法并不能根据改变的终止点位置,合理地调整整个轨迹的运动趋势。这便是 KMP 算法在整体轨迹调制上的缺陷所在。而由于 DS-KMP 算法使用了动态系统进行大范围轨迹调制,引入拓扑等价性,能够根据终止点或起始点的不同调整整体轨迹的缩放,并保证轨迹的特征不变。图 2-8-(d)展示的是 DS-KMP 算法对于轨迹局部的特征调整能力。该算法能在原本的专家轨迹‘2’上加入额外的特征,这是 DMP 算法所无法实现的。


通过将 DS-KMP 算法与其它算法进行对比实验,验证了 DS-KMP 算法能够实现轨迹起始点、经过点、终止点约束,拓扑不变性,以及轨迹特征调整。因此,证明了该算法性能的优越。



(a) 轨迹的起始点与经过点约束



(b) 轨迹的终止点与经过点约束



(c) 轨迹调制的拓扑等价性




图 2-8 手写字母轨迹模仿学习实验结果

2.4 带有辅助分类器的生成式对抗模仿学习算法及改进

针对 GAIL 算法存在的一些问题，本节介绍改进的 ACGAIL 算法。ACGAIL 算法是一种多模态 GAIL 算法，特别适用于处理协作机器人复杂非结构化环境下的高难度任务。并且，对 ACGAIL 算法提出三点改进，解决 GAIL 算法存在的模态崩塌、梯度消失与专家轨迹利用效率低等问题。

2.4.1 带有辅助分类器的生成式对抗模仿学习算法

当专家数据包含多个不同的策略模态时，GAIL 算法基于单一策略模态进行训练，而忽略了其他策略模态的存在，很容易导致模态崩塌。因此，考虑使用多模态 GAIL 算法。通过给专家数据添加模态标签，能够帮助模型更好地理解多策略模态专家数据中的模态特征，从而更加准确地学到多策略模态下的专家策略。ACGAIL 算法在 GAIL 算法的基础上引入了辅助分类网络，简称  $C$ ，通过模态标签对多策略模态专家数据进行分类与学习。




图 2-9 ACGAIL 算法框架

这里假设专家数据  $T_E = \{\tau_{E_{c_1}}, \dots, \tau_{E_{c_i}}, \dots, \tau_{E_{c_n}}\}$  具有  $n$  种有限的模态  $C = \{c_1, \dots, c_i, \dots, c_n\}$ , 所对应的专家策略  $\pi_E = \{\pi_{E_{c_1}}, \dots, \pi_{E_{c_i}}, \dots, \pi_{E_{c_n}}\}$ 。为了仅使用一个策略网络  $\pi$  从多策略模态专家数据中准确模仿学习专家策略, 不仅仅通过状态  $s$  学习策略网络  $\pi(a|s)$ , 在策略网络中引入模态标签变量  $c$ , 即  $\pi(a|s, c)$ 。引入辅助分类网络到 GAIL 算法中, 即 ACGAIL, 通过模态标签  $c$  对多策略模态专家数据进行分类和学习, 提高了策略网络  $\pi$  的学习效率。如果没有模态标签  $c$  的辅助分类, 只用 GAIL 算法可能无法区分多策略模态专家数据中存在的不同模态特征, 因此很容易导致模态崩塌。

具体来说, 生成模块是一个策略网络, 定义为  $\pi_\theta$ , 参数为  $\theta$ 。 $\pi_\theta$  的输入是当前状态  $s$  和模态  $c$ , 输出是动作  $a = \pi_\theta(s, c)$ 。进一步地, 向判别模块中添加了一个辅助分类器, 它现在由两个模型组成: 一个是判别器, 定义为  $D_\omega$ , 参数为  $\omega$ ; 一个是辅助分类器, 定义为  $C_\psi$ , 参数为  $\psi$ 。 $D_\omega$  和  $C_\psi$  的输入都是协作机器人根据生成模块策略网络与环境交互采样得到的在模态  $c$  下的状态-动作-模态对  $(s, a, c)$ , 以及根据专家策略  $\pi_E$  与环境交互采样得到的在模态  $c$  下的状态-动作-模态对  $(s_E, a_E, c)$ 。 $D_\omega$  的输出是  $(s, a, c)$  不是来自专家策略  $\pi_{E_c}$  的代价。 $C_\psi$  的输出是  $(s, a, c)$  是模态  $c$  下的概率。此外, 它们都由深度神经网络表示。判别模块的目标函数现在由来自判别器和分类器的目标函数组合而成  $L_{\text{adversary}} = L_D + L_C$ , 其中:

$$L_D = \max_{\omega} \mathbb{E}_{\pi_\theta} [\log(D_\omega(s, a))] + \mathbb{E}_{\pi_E} [\log(1 - D_\omega(s, a))] \quad (2-64)$$

$$L_C = \max_{\psi} \mathbb{E}_{\pi_\theta} [\log(C_\psi(c|s, a))] + \mathbb{E}_{\pi_E} [\log(C_\psi(c|s, a))] \quad (2-65)$$

判别模块被训练以最大化目标函数  $L_{\text{adversary}}$ 。判别模块中的判别器和分类器分别通过解二分类交叉熵和稀疏分类交叉熵目标函数区别状态-动作-模态对  $(s, a, c)$  的来源是  $\pi_E$  还是  $\pi_\theta$  和对模态标签更加准确的分类。它们可以解释为共同向生成模块策略网络提供学习信号的局部目标函数。

此外, 可以获得生成模块的目标函数, 如下所示:

$$L_{\pi_\theta} = \min_{\pi_\theta} \mathbb{E}_{\pi_\theta} [\log(D_\omega(s, a))] - \lambda_c \mathbb{E}_{\pi_\theta} [\log(C_\psi(c|s, a))] - \lambda_H H(\pi_\theta) \quad (2-66)$$

其中, 超参数  $\lambda_c$  用于权衡判别器和分类器对生成模块的影响。判别器试图使生成模块生成样本的分布接近专家样本的分布。与此同时, 辅助分类器能对生成模块生成的样本模态标签更加准确的分类。在这样的组合中, 判别模块引导策略迷惑判别器以及减少分类器的分类错误, 从而得到面向多模态的策

略。

#### 算法 2-4 ACGAIL 算法

**输入:** 专家轨迹  $T_E = \{\tau_{E_{c_1}}, \dots, \tau_{E_{c_i}}, \dots, \tau_{E_{c_n}}\}$ 。

**初始化:** 初始化判别模块和生成模块的网络参数为  $\omega$ 、 $\psi$ 、 $\theta$ ，批大小为  $B$ ，判别模块和生成模块的自循环次数为  $M$  次和  $N$  次。

**输出:** 生成策略  $\pi_\theta$ 。

```

1  for  $i = 0, 1, 2, \dots$  do
2      根据当前生成策略  $\pi_\theta$  与环境交互采样轨迹  $\tau_i \sim \pi_\theta(c_i)$ 
3      根据批大小  $B$ ，采样生成模块产生样本  $\chi_i \sim \tau_i$  和专家样本  $\chi_E \sim T_E$ 
4      for  $i = 0, 1, \dots, M$  do
5          更新判别器参数:

$$\Delta_\omega = \mathbb{E}_{\chi_i} [\nabla_\omega \log D_\omega(s, a)] + \mathbb{E}_{\chi_E} [\nabla_\omega \log(1 - D_\omega(s, a))]$$

6          更新分类器参数:

$$\Delta_\psi = \mathbb{E}_{\chi_i} [\nabla_\psi \log(C_\psi(c|s, a))] + \mathbb{E}_{\chi_E} [\nabla_\psi \log(C_\psi(c|s, a))]$$

7      end for
8      for  $i = 0, 1, \dots, N$  do
9          利用 PPO 算法根据以下目标函数更新生成模块参数:

$$-\mathbb{E}_{\chi_i} [\log D_\omega(s, a)] + \lambda_c \mathbb{E}_{\chi_i} [\log(C_\psi(c|s, a))] + \lambda_H H(\pi_\theta)$$

10     end for
11 end for

```

综上所述，ACGAIL 中判别模块和生成模块之间总的极大极小博弈可以总结为：

$$\begin{aligned}
 \min_{\theta, \psi} \max_{\omega} L_{ACGAIL} = & \min_{\theta, \psi} \max_{\omega} \mathbb{E}_{\pi_\theta} [\log(D_\omega(s, a))] \\
 & + \mathbb{E}_{\pi_E} [\log(1 - D_\omega(s, a))] - \mathbb{E}_{\pi_\theta} [C_\psi(c|s, a)] \quad (2-67) \\
 & - \lambda_c \mathbb{E}_{\pi_E} [C_\psi(c|s, a)] - \lambda_H H(\pi_\theta)
 \end{aligned}$$

因此，ACGAIL 能够有效学习多模态策略。基于带辅助分类器的生成式对抗模仿学习算法的整体架构和流程如图 2-9 和算法 2-4 所示。首先，随机初始化网络参数，并设置批大小，各模块自循环次数：判别模块自循环  $M$  次，生成模块自循环  $N$  次，以及一些超参数。根据当前策略与环境交互采集样本。判别器和分类器网络使用 ADAM 算法更新  $M$  次。策略网络使用 PPO 算法更

新  $N$  次。由于判别器和分类器联系紧密，共同组成了判别模块，判别器和分类器参数是共享的。在判别模块的目标函数中使用超参数来平衡判别器和分类器的更新。

## 2.4.2 改进的带有辅助分类器的生成式对抗模仿学习算法

虽然 ACGAIL 算法可以解决模态崩塌问题，但它仍面临梯度消失和样本利用率不足的挑战。本节将提出三种改进方法来解决这些问题。

### 1) 奖励增强

强化学习在与环境交互时，通常只获得稀疏的奖励信号，这导致协作机器人无法有效地学习。为了解决这个问题，可以使用奖励增强方法，即在判别器和分类器给出的奖励值之外，人为设定奖励增强函数。这种方法可以提高网络模型的学习效率，使其能够更快地学习到比专家策略更好的策略。具体来说，奖励增强函数可以提供除了专家轨迹之外的先验知识，从而克服模仿学习运动规划算法最终能力受限于专家行为能力的问题。最终，这种方法可以使机器人学习到一个比专家策略更好的策略。可以将当前位置与目标位置的累积距离和等作为奖励增强函数：

$$\min_{q_c^{1:N}} R_1 = \min_{q_c^{1:N}} \sum_{i=1}^N \|q_c^i - q_o\|_Q^2, \quad q_{c\min} < q_c < q_{c\max} \quad (2-68)$$

$$\min_{u_c^{0:N}} R_2 = \min_{u_c^{0:N}} \sum_{i=0}^N \|\Delta u_c^i\|_R^2, \quad u_{c\min} < u_c < u_{c\max} \quad (2-69)$$

其中  $Q$ ,  $R$  是正定加权矩阵， $i$  是当前时刻， $q_c$  是协作机器人当前的位姿， $q_o$  是任务的目标位姿。通过奖励增强，可以在机器人的早期训练阶段鼓励其快速接近目标位姿，从而提高训练效率。在实际应用中，可能会存在多个不同的奖励增强函数，这些函数各自对协作机器人的训练效果产生积极影响，最终形成一个总的奖励增强函数  $R = R_1 + R_2 + \dots$ 。

### 2) WGANs-GP

KL 散度和 JS 散度都是用于度量两个分布之间差异的常用方法，但它们都有缺点：当两个分布的差异较大时，KL 散度会失去数学意义，而 JS 散度则会变成常数  $\log 2$ 。此外，当判别模块训练得比生成模块强时，JS 散度也会变成一个常数  $\log 2$ ，这对于那些依赖于判别模块梯度进行更新的生成模块来说是非常不利的。这也是 GANs 网络难以训练的重要原因之一。

WGANs 引入了 Wasserstein 距离。与 KL 散度和 JS 散度相比，即使两个分布位于没有重叠的低维流形中，Wasserstein 距离仍然可以提供一個有意义

且平滑的距离表示，表示如下：

$$W(p_{\pi_E}, p_{\pi}) = \inf_{\gamma \in \Pi(p_{\pi_E}, p_{\pi})} \mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|] \quad (2-70)$$

其中  $\inf$  表示最大下界， $\Pi(p_{\pi_E}, p_{\pi})$  是  $p_{\pi_E}$  和  $p_{\pi}$  之间所有可能的联合概率分布的集合。 $\gamma \in \Pi(p_{\pi_E}, p_{\pi})$  是一个联合概率分布。 $(x, y)$  是采样数据， $x$  是专家数据， $y$  是生成数据。当以  $x$  为起点，以  $y$  为终点时，移动的泥土总量为  $\gamma(x, y)$ ，移动距离为  $\|x - y\|$ ，因此  $\mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|]$  是所有  $(x, y)$  对的平均期望损失。

针对 Wasserstein 距离难以直接求解的问题，常常引入 Lipschitz 限制来限制函数每次更新的变化范围。Lipschitz 限制是指梯度的大小不超过某个常数。然而，这种方法会将参数限制在一个范围内，导致参数直接达到该范围的最大值和最小值，从而削弱算法的性能。因此，引入 GP 项来代替参数限制：

$$\lambda \mathbb{E}_{x \sim \mathbb{P}_x} [\|\nabla_x D(x)\|_2 - 1]^2 \quad (2-71)$$

其中  $x$  表示在  $x_{\pi_E}$  和  $x_{\pi}$  的连接线上随机插值采样，即  $x = \epsilon x_{\pi} + (1 - \epsilon)x_{\pi_E}$ 。

GP 项的思想是将梯度的范数限制在 1 附近，这相当于变相地限制了梯度的范围。最后，WGANs-GP 的判别器  $D$  的损失函数如下：

$$L = \mathbb{E}_{x \sim \mathbb{P}_{\pi}} [D(x)] - \mathbb{E}_{x \sim \mathbb{P}_{\pi_E}} [D(x)] + \lambda \mathbb{E}_{x \sim \mathbb{P}_x} [\|\nabla_x D(x)\|_2 - 1]^2 \quad (2-72)$$

WGANs-GP 不仅保留了 WGANs 能够解决梯度消失问题，提高稳定性优势，而且显著提高了训练速度，解决了 WGANs 训练难的问题。

### 3) 经验重放池

GAIL 算法无法重用对象与环境交互产生的样本，因此需要与环境进行大量交互才能获得足够数量的样本，以满足学习所需，这使得 GAIL 算法难以被实际应用。本节创建了一个经验回放池，用于存储和重用对象过去与环境交互产生的样本，以缓解样本利用率不足的问题，如图 2-10 所示。在实际中，经验重放池通常使用栈结构来实现。在数据采集过程中，协作机器人与环境交互，获取一系列由状态-动作-奖励对组成的采样轨迹。然后将这些数据逐个压入并存储到经验栈中。在采样时，从经验栈中随机抽取批大小数量的数据，用于后续模仿学习运动规划算法学习。需要注意的是，在采样过程中需要从经验重放池中进行均匀采样，以确保采样数据的多样性。






图 2-10 经验重放池原理

4) 改进的 ACGAIL 算法

提出了一种改进的 ACGAIL 算法，该算法结合了以上三种改进方案。算法的整体架构如图 2-11 所示，算法流程如算法 2-5 所示。首先，随机初始化网络参数，并设置批大小、经验重放池大小，各模块自循环次数：判别模块为  $M$  次，生成模块为  $N$  次，以及一些超参数。使用初始化策略  $\pi_\theta$  进行任务，采集得到轨迹并将其压栈入经验重放池中（第 2-4 行）。从经验重放池中均匀采样生成样本，并用来更新判别器和分类器参数（第 5-8 行）。接下来，固定判别器参数和分类器参数，并使用 PPO 算法更新生成模块（第 9-11 行）。




图 2-11 改进的 ACGAIL 算法框架



---

**算法 2-5 改进的 ACGAIL 算法**


---

**输入：** 专家轨迹  $T_E = \{\tau_{E_{c_1}}, \dots, \tau_{E_{c_i}}, \dots, \tau_{E_{c_n}}\}$

**初始化：** 初始化判别模块和生成模块的网络参数  $\omega$ 、 $\psi$ 、 $\theta$ ，批大小为  $B$ ，判别模块和生成模块的自循环次数分别为  $M$  次和  $N$  次；初始化经验重放池大小，并将栈设为空  $C = \emptyset$ ；设置超参数  $\lambda$ 、 $\lambda_c$ 、 $\lambda_H$ 、 $\lambda_R$

**输出：** 生成策略  $\pi_\theta$ 。

**1 for**  $i = 0, 1, 2, \dots$  **do**

**2**        根据当前生成策略  $\pi_\theta$  与环境交互采样轨迹  $\tau_i \sim \pi_\theta(c_i)$

**3**        将采样得到的轨迹压入经验重放池中  $C \leftarrow C \cup \tau_i$

**4**        根据批大小  $B$ ，采样生成模块产生样本  $\chi_i \sim \tau_i$  和专家样本  $\chi_E \sim T_E$

**5 for**  $i = 0, 1, \dots, M$  **do**

**6**        更新判别器参数：

$$\Delta_\omega = \mathbb{E}_{\chi_i} [D(s, a)] - \mathbb{E}_{\chi_E} [D(s, a)] + \lambda \mathbb{E}_{\hat{\chi}} \left[ \left( \|\nabla_\omega D(s, a)\|_2 - 1 \right)^2 \right]$$

**7**        更新分类器参数：

$$\Delta_\psi = \mathbb{E}_{\chi_i} \left[ \nabla_\psi \log(C_\psi(c|s, a)) \right] + \mathbb{E}_{\chi_E} \left[ \nabla_\psi \log(C_\psi(c|s, a)) \right]$$

**8 end for**

**9 for**  $i = 0, 1, \dots, N$  **do**

**10**        利用 PPO 算法根据以下目标函数更新生成模块参数：

$$-\mathbb{E}_{\chi_i} [\log D_\omega(s, a)] + \lambda_c \mathbb{E}_{\chi_i} [\log(C_\psi(c|s, a))] + \lambda_H H(\pi_\theta) - \lambda_R R$$

**11 end for**

**12 end for**

---

### 2.4.3 算法实验设计与结果分析

在本节中，将同样使用手写字母轨迹生成实验来验证改进的 ACGAIL 算法的可行性。首先，需要采集大量手写字母专家轨迹，并建立一个手写字母专家轨迹数据集。然后，为每个任务设定一个专家奖励函数。根据这些专家奖励函数，使用 PPO 算法生成多模态专家策略。在本实验中，考虑两个潜在的专家策略模态。使用所生成多模态专家策略采集 100 条手写字母 ‘G’ 和 100 条手写字母 ‘a’ 的专家轨迹，每条轨迹采样 100 个数据点，并对任务轨

迹的模式进行标注。其中字母 ‘G’ 设置为模态 1，字母 ‘a’ 设置为模态 2。

生成模块是一个包含两层隐层的神经网络，每一层隐层有 100 个神经元，它的输入是当前轨迹的模式  $c$ 、二维坐标  $\xi(t)=[x(t), y(t)]^T$  以及目标结束位置  $\xi^e(t)=[x^e(t), y^e(t)]^T$ ，输出为下一时刻的二维坐标  $\xi(t+1)=[x(t+1), y(t+1)]^T$ ；判别模块中的判别器和分类器共享隐层参数，这也是两层隐层，每一层隐层包含有 100 个神经元。神经网络的激活函数是非线性的  $\tanh$  函数。判别模块中的判别器和分类器输入均为状态-动作对  $(s, a)=[x(t), y(t), x(t+1), y(t+1)]^T$ ，判别器输出当前策略不是专家策略的代价  $p \in [0, 1]$ ，分类器经过 softmax 层输出当前策略的策略模态  $c_i$ 。设定经验重放池大小为 1024，批大小设置为 32，判别模块和生成模块的自循环次数分别为  $M=4$  次和  $N=1$  次，超参数设定为  $\lambda=0.03, \lambda_c=0.5, \lambda_H=0.008, \lambda_R=0.1$ ，其中奖励增强函数  $R$  设定为轨迹移动的速度  $R=\|v\|_2-1=\|a-s\|_2-1$ ，这个奖励增强函数用于限制轨迹的匀速运动，从而在一定程度上防止了轨迹的突变。




图 2-12 ACGAIL 在手写字母轨迹模仿实验上的性能

图 2-12 展示了基于改进的 ACGAIL 算法在手写字母轨迹模仿上进行了 5000 次迭代训练后的实验结果。图中纵坐标为平均奖励回报，横坐标为迭代训练步数。虚线代表专家样本的平均奖励回报，实线代表改进的 ACGAIL 算法生成的样本的回报。在该图中，可以看出的是在训练的初期，两种模式下的学习策略是大致相同。然而，随着时间的推移，不同的模式逐渐向相应的

专家策略靠近。在 1000 次训练迭代之后，两种模态都基本收敛到了专家策略。值得注意的是，模态 2 的收敛速度比模态 1 慢。这可能的解释是手写字母 ‘a’ 比手写字母 ‘G’ 的特征更加复杂，因此算法需要更多的迭代步数来拟合这些特征。

图 2-13 展示了在 5000 次迭代训练过程中，生成模块 loss 值随迭代步数的变化情况。可以看出的是在迭代训练的初期，loss 值非常大，且存在较大的波动，然后迅速下降，并在迭代训练 200 次左右下降到一定的数值。之后，loss 值保持稳定状态，这表明生成模块和判别模块在不断学习的过程中相互促进，性能得到了提升，逐渐达到了纳什均衡，并维持在稳定状态。




图 2-13 生成模块 Loss 值随迭代步数变化

为了比较三种改进策略在改进的 ACGAIL 算法中所起到的效果，保留最终判别器和分类器参数作为真实奖励函数，并在训练过程中分别去掉奖励增强、经验重放池和 WGANs-GP 三种技术。可通过比较它们的收敛步数和平均奖励回报值来了解这些技术在实际应用中发挥的功效，结果如图 2-14、图 2-15 以及表 2-2 所示。图中展示了各种技术组合的收敛步数和平均奖励回报值，可以看到去掉经验重放池之后的 ACGAIL 算法其平均奖励回报减小的最多，可见该技术对与整体算法的性能提升有着十分重要的作用。去掉奖励增强的平均奖励回报只有略微减小，但其收敛步数显著增加，说明该项技术能有效加速算法收敛，但并无法证明该项技术能使得生成策略超越专家策略。而去掉 WGANs-GP 技术的 ACGAIL 算法无论是从平均奖励回报上还是从收敛速度上都有所下降，说明该项技术能少量提升算法性能。




图 2-14 ACGAIL 算法性能对比：平均奖励回报




图 2-15 ACGAIL 算法性能对比：收敛步数

综上所述，改进的 ACGAIL 算法能够有效地学习到多种模态专家策略，并复现出类似于专家轨迹的手写字母轨迹。三项改进策略均对算法性能提升做出了不同程度的贡献。其中，经验重放池对于算法性能的提升是最为显著的。在实验中，奖励增强技术虽然能够有效加速算法收敛，但并无法证明能够指导生成策略超越专家策略。因此，需要进一步的实验来证明这一点。

表 2-2 不同技巧对 ACGAIL 算法的影响

|                 | 平均奖励回报（模态 1/2） | 收敛步数 |
|-----------------|----------------|------|
| 改进的 ACGAIL      | 3592/6302      | 105  |
| ACGAIL（去除奖励增强）  | 3530/6203      | 217  |
| ACGAIL（去除 W-GP） | 3452/6014      | 185  |
| ACGAIL（去除经验重放池） | 2803/5423      | 124  |
| ACGAIL（原始算法）    | 2593/5212      | 230  |
| 专家轨迹            | 3601/6293      | -    |

2.5 本章小结

随着协作机器人从简单环境与低难度任务转向复杂非结构化环境与高难度任务，协作机器人面临着运动规划难的问题。因此，本章重点研究了协作机器人的模仿学习运动规划技术。将 DMP 算法的拓扑等价性引入 KMP 算法，提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法，以解决 KMP 算法难以进行整体轨迹调制的问题。通过对比实验，验证了 DS-KMP 算法能实现轨迹起始点、经过点、终止点约束，拓扑不变性，以及轨迹特征调整。因此，证明了该算法性能的优越。

此外，还提出了改进的 ACGAIL 算法，以解决生成式对抗模仿学习算法存在的模态崩塌、梯度消失和专家轨迹利用效率低等问题。实验证明，改进的 ACGAIL 算法能够有效地学习到多种模态专家策略，并复现出类似于专家轨迹的手写字母轨迹。三项改进策略均对算法性能提升做出了不同程度的贡献。其中，经验重放池对于算法性能的提升是最为显著的。在实验中，奖励增强技术虽然能够有效加速算法收敛，但并无法证明能够指导生成策略超越专家策略。因此，需要进一步的实验来证明这一点。



### 3 协作机器人自适应神经网络轨迹跟踪控制算法研究

在引言中,已经详细介绍了柔性关节对于协作机器人的必要性,以及目前亟待解决的问题。尽管柔性关节协作机器人具有上述优点,但柔性结构也会给协作机器人带来不希望的弹性震动。因此,协作机器人高精轨迹跟踪控制器的设计难度大大增加,成为一个亟待解决的问题。柔性关节根据柔性结构刚度的不同可大致分为两类:高刚度柔性关节与低刚度柔性关节。在之前的工作中,针对低刚度柔性关节协作机器人提出了一种自适应神经网络轨迹跟踪控制器。此工作保证了柔性关节满足输出约束,提高了柔性关节协作机器人的安全性,但该控制器不仅需要连杆角位移和角速度的反馈信号,还需要电机轴角位移和角度速度的反馈信号。本章中,提出了一种针对高刚度柔性关节协作机器人的 ANN-F 控制器,以实现高精轨迹跟踪。根据奇异摄动理论,ANN-F 控制器只需要连杆角位移、连杆角速度和柔性结构扭矩的反馈信号。ANN-F 控制器具有很高的实用性。其使用神经网络处理协作机器人动力学中的不确定性问题。为了进一步保证协作机器人轨迹跟踪控制的安全性和精度,在满足输出约束的同时,其通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。通过李雅普诺夫稳定性分析,所提出的 ANN-F 控制器还可保证系统达到指数稳定。除了一些必要的仿真之外,还基于 Baxter 协作机器人自主抓取摆放系统进行了一系列轨迹跟踪实验,以评估 ANN-F 控制器的性能。结果表明,所提出的 ANN-F 控制器对高刚度柔性关节协作机器人轨迹跟踪具有更好的控制性能。

#### 3.1 问题描述

图 3-1 为柔性关节的局部放大图。柔性关节协作机器人动力学模型是:

$$\begin{aligned} D(q_1)\ddot{q}_1 + C(q_1, \dot{q}_1)\dot{q}_1 + G(q_1) &= K(q_2 - q_1) \\ J\ddot{q}_2 + K(q_2 - q_1) &= u + d \end{aligned} \quad (3-1)$$

其中  $q_1$  为连杆的  $n \times 1$  角位移矢量,  $q_2$  为电机轴的  $n \times 1$  角位移矢量,  $u$  为  $n \times 1$  输入转矩矢量,  $d$  为  $n \times 1$  外部扰动转矩矢量,  $D(q_1)$  为连杆的  $n \times n$  对称正定惯性矩阵,  $C(q_1, \dot{q}_1)\dot{q}_1$  为  $n \times 1$  科氏力和离心力矢量,  $G(q_1)$  为  $n \times 1$  重力矢量,  $J$  为电机轴的  $n \times n$  对角正定惯性矩阵,  $K$  为  $n \times n$  对角正定柔性结构刚度矩阵。





图 3-1 基于应变片传感器的高刚度柔性关节协作机器人示意图

假设 3-1: 对于基于应变片传感器的高刚度柔性关节协作机器人, 电机轴的角位移矢量  $q_2$  和角速度矢量  $\dot{q}_2$  不可测, 也就是说所提出的控制器须要仅依赖于连杆的角位移矢量  $q_1$ , 连杆的角速度矢量  $\dot{q}_1$  和柔性结构转矩矢量  $z = K(q_2 - q_1)$ 。

假设 3-2: 由于外部扰动能量有限, 外部扰动转矩矢量  $d$  是有界的, 即存在未知正常数  $d_i \in \mathbb{R}^+$ , 使得  $|d_i(t)| \leq d_i, \forall t \in [0, \infty), i = 1, 2, \dots, n$ 。

本章中, 目标是在假设 3-1 和假设 3-2 下, 面向基于应变片传感器的高刚度柔性关节协作机器人提出一个 ANN-F 控制器  $u$ 。ANN-F 控制器应保证协作机器人精准轨迹跟踪, 具有较高的实用性。而且, 使用神经网络处理协作机器人动力学中的不确定性。为了进一步提高协作机器人轨迹跟踪控制的安全性和精度, 在保证输出约束的同时, 通过自适应方法同时消除神经网络的近似误差和外部扰动转矩。此外, 所提出的 ANN-F 控制器还可保证系统达到指数稳定, 即  $\tilde{q}$  和  $\dot{\tilde{q}}$  可以指数收敛到零, 其中  $\tilde{q}$  是连杆角位移的跟踪误差矢量。

## 3.2 控制设计和稳定性分析

在控制设计之前, 对一些必要的定义和引理做简要的介绍:

定义 3-1: 动力学系统的奇异摄动模型定义为:

$$\begin{aligned}\dot{x} &= f(t, x, z, \epsilon) \\ \epsilon \dot{z} &= g(t, x, z, \epsilon)\end{aligned}\quad (3-2)$$

其中  $f$  和  $g$  是连续可微函数,  $x \in \mathbb{R}^n$  和  $z \in \mathbb{R}^m$  是动力学系统状态矢量,  $\epsilon$  是摄动参数。

当  $\epsilon$  定义为 0 时, (3-2) 可以退化为:

$$0 = g(t, x, z, 0) \quad (3-3)$$

如果(3-3)有  $k \geq 1$  个孤立的实根, 模型(3-2)就是标准奇异摄动模型:

$$z = h_i(t, x), i = 1, 2, \dots, k \quad (3-4)$$

定义 3-2: 假设(3-2)是标准奇异摄动模型。将(3-4)代入(3-2), 当  $\epsilon = 0$  时, 可以得到降阶模型(慢模型)为:

$$\dot{x} = f(t, x, h(t, x), 0) \quad (3-5)$$

可以得到边界层模型(快模型)为:

$$\frac{d\eta}{d\tau} = g(t, x, \eta + h(t, x), 0) \quad (3-6)$$

引理 3-1: 假设(3-2)是标准奇异摄动模型, 满足[54] 中定理 11.2 和定理 11.4 的条件列表, 主要包括: 原点是降阶系统(3-5)的指数稳定平衡点, 且原点是边界层系统(3-6)的指数稳定平衡点, 那么, 存在一个极小正常数  $\epsilon$ , 使得对于所有  $t_0 \geq 0$ , 奇异摄动系统在  $[t_0, \infty)$  上有唯一解  $x(t)$  和  $z(t)$ , 且当  $t \in [t_0, \infty)$  时:

$$\begin{aligned}x(t) &= \bar{x}(t) + O(\epsilon) \\ z(t) &= h(t, \bar{x}(t)) + \eta(\tau) + O(\epsilon)\end{aligned}\quad (3-7)$$

一致成立, 其中  $\bar{x}(t)$  和  $\eta(\tau)$  分别是降阶系统和边界层系统的解。此外, 还可保证标准奇异摄动系统在原点处指数稳定。

引理 3-2: 对于任何正常数  $k_a \in \mathbb{R}$ , 对于区间  $|x| < k_a$  中的  $x \in \mathbb{R}$ , 以下不等式成立:

$$\ln \frac{k_a^2}{k_a^2 - x^2} \leq \frac{x^2}{k_a^2 - x^2} \quad (3-8)$$

### 3.2.1 动力学模型转换

根据奇异摄动理论设计控制器, 来解决基于应变片传感器的高刚度柔性关节协作机器人电机轴角位移矢量  $q_2$  和角速度矢量  $\dot{q}_2$  不可测问题。首先, 将



柔性关节协作机器人动力学模型(3-1)转换为标准的奇异摄动模型。

设计刚度矩阵  $K = \frac{K_1}{\epsilon^2}$ ，其中  $K_1$  是对角正定矩阵，摄动参数  $\epsilon$  是极小正常数。此外， $z = K(q_2 - q_1) = \frac{K_1}{\epsilon^2}(q_2 - q_1)$ 。那么，高刚度柔性关节协作机器人的模型可以表示为：

$$\begin{aligned} D(q_1)\ddot{q}_1 + C(q_1, \dot{q}_1)\dot{q}_1 + G(q_1) &= z \\ \epsilon^2 J\ddot{z} + K_1 z &= K_1(u + d - J\dot{q}_1) \end{aligned} \quad (3-9)$$

在(3-9)中求解  $\ddot{q}_1$ ：

$$\ddot{q}_1 = D^{-1}(q_1)[z - C(q_1, \dot{q}_1)\dot{q}_1 - G(q_1)] \quad (3-10)$$

为了将(3-9)转换为标准的奇异摄动模型定义 3-1，将(3-10)代入(3-9)，乘以  $J^{-1}$  并得到：

$$\begin{aligned} \epsilon^2 \ddot{z} &= K_1 D^{-1}(q_1)[C(q_1, \dot{q}_1)\dot{q}_1 + G(q_1)] - K_1[J^{-1} + D^{-1}(q_1)]z \\ &\quad + J^{-1}K_1(u + d) \end{aligned} \quad (3-11)$$

降阶系统状态矢量的选择是  $[q_1, \dot{q}_1]^T$ ，边界层系统状态矢量的选择是  $[z, \epsilon\dot{z}]^T$ 。(3-10)和(3-11)是标准的奇异摄动模型。

### 3.2.2 降阶系统和边界层系统

然后，将标准奇异摄动模型(3-10)和(3-11)分为降阶系统和边界层系统。假设原点是降阶系统的指数稳定平衡点，且原点是边界层系统的指数稳定平衡点，可以根据定义 3-2 得到降阶系统和边界层系统。

在(3-2)中设置  $\epsilon = 0$  可以得到  $\bar{z}$ ：

$$\bar{z} = \bar{u} + d - J\dot{\bar{q}}_1 \quad (3-12)$$

其中，上划线表示变量在  $\epsilon = 0$  时。在  $\epsilon = 0$  时，将(3-12)代入(3-2)得到降阶系统为：

$$[D(\bar{q}_1) + J]\ddot{\bar{q}}_1 + C(\bar{q}_1, \dot{\bar{q}}_1)\dot{\bar{q}}_1 + G(\bar{q}_1) = \bar{u} + \bar{d} \quad (3-13)$$

这与刚体关节协作机器人动力学模型相同。

备注 3-1：降阶系统(3-10)是柔性关节协作机器人的动力学模型忽略了关节弹性项。它被认为等同于刚体关节协作机器人动力学模型。

另一方面，在(3-11)中，令  $\epsilon = 0$  得到：

$$K_1[J^{-1} + D^{-1}(\bar{q}_1)]\bar{z} = J^{-1}K_1(\bar{u} + \bar{d}) + K_1 D^{-1}(\bar{q}_1)[C(\bar{q}_1, \dot{\bar{q}}_1)\dot{\bar{q}}_1 + G(\bar{q}_1)] \quad (3-14)$$

根据引理 3-1, 在快速时间尺度  $\tau = \frac{t}{\epsilon}$  下,  $\bar{z}$  是一个常数。更改为快速时间尺度  $\tau$ , 并替换(3-11)中  $z = \eta + \bar{z}$ , 其中  $\epsilon = 0$  得到:

$$\begin{aligned} \frac{d^2\eta}{d\tau^2} + K_1[J^{-1} + D^{-1}(\bar{q}_1)](\eta + \bar{z}) &= J^{-1}K_1(u + d) \\ &+ K_1D^{-1}(\bar{q}_1)[C(\bar{q}_1, \dot{\bar{q}}_1)\dot{\bar{q}}_1 + G(\bar{q}_1)] \end{aligned} \quad (3-15)$$

在(3-14)的基础上, 可以从(3-15)推出边界层系统为:

$$\frac{d^2\eta}{d\tau^2} + K_1[J^{-1} + D^{-1}(\bar{q}_1)]\eta = J^{-1}K_1u_f \quad (3-16)$$

其中  $u_f = u - \bar{u}$  称为快速反馈。

显然, 系统(3-1)的控制器是以下形式的:

$$u = \bar{u}(\bar{q}_1, \dot{\bar{q}}_1, t) + u_f(\eta, \dot{\eta}) \quad (3-17)$$

其中  $\bar{u}$  应设计保证降阶系统(3-10)达到指数稳定,  $u_f$  应设计保证边界层系统(3-11)达到指数稳定。

### 3.2.3 降阶系统控制设计 (ANN-R 控制器)

对于降阶系统, 提出了一种新的针对刚体关节协作机器人的 ANN-R 控制器, 通过神经网络解决协作机器人动力学中的不确定性。为了进一步提高协作机器人轨迹跟踪控制的安全性和精度, 在保证输出约束的同时, 采用自适应方法同时消除神经网络的近似误差和外部扰动转矩。此外, 还应保证降阶系统达到指数稳定。

降阶系统模型是:

$$H(\bar{q}_1)\ddot{\bar{q}}_1 + C(\bar{q}_1, \dot{\bar{q}}_1)\dot{\bar{q}}_1 + G(\bar{q}_1) = \bar{u} + d \quad (3-18)$$

其中  $H(\bar{q}_1) = D(\bar{q}_1) + J$ 。

设计  $\dot{q}_r$  和  $\ddot{q}_r$  如下:

$$\begin{aligned} \dot{q}_r &= \dot{q}_{1d} - \Lambda \tilde{q} \\ \ddot{q}_r &= \ddot{q}_{1d} - \Lambda \dot{\tilde{q}} \end{aligned} \quad (3-19)$$

其中  $q_{1d}(t)$  是期望连杆角位移矢量,  $\tilde{q} = \bar{q}_1(t) - q_{1d}(t)$  是跟踪误差矢量,  $\Lambda$  是对角正定矩阵。

还定义:

$$s = \dot{\bar{q}}_1 - \dot{q}_r = \dot{\tilde{q}} + \Lambda \tilde{q} \quad (3-20)$$

备注 3-2: 对于传统自适应神经网络轨迹跟踪控制器<sup>[63]</sup> 定义的闭环系统

状态变量形式不够正式问题，将稳态跟踪误差限制在滑模面上，使所提出的控制器在形式上更加正式。

然后，降阶模型(3-10)可以转换如下：

$$H(\bar{q}_1)\dot{s} + C(\bar{q}_1, \dot{\bar{q}}_1)s = \bar{u} + d - H(\bar{q}_1)\ddot{q}_r - C(\bar{q}_1, \dot{\bar{q}}_1)\dot{q}_r - G(\bar{q}_1) \quad (3-21)$$

由于协作机器人动力学中的不确定性存在于  $H(\bar{q}_1)$ ,  $C(\bar{q}_1, \dot{\bar{q}}_1)$ ,  $G(\bar{q}_1)$ ，基于神经网络，假设：

$$H(\bar{q}_1)\ddot{q}_r + C(\bar{q}_1, \dot{\bar{q}}_1)\dot{q}_r + G(\bar{q}_1) = w^{*T}h(x) + \psi \quad (3-22)$$

其中  $x_i = [\bar{q}_{1i}, \dot{\bar{q}}_{1i}, \dot{q}_{ri}, \ddot{q}_{ri}]^T$  是第  $i$  个关节对应的输入矢量， $i=1,2,\dots,n$ ， $w_i^*$  是  $w_i$  的理想常数近似矢量，它对于所有输入矢量  $x_i$  能最小化  $|\psi_i|$ ， $w^{*T}h(x) = [w_1^{*T}h(x_1), w_2^{*T}h(x_2), \dots, w_n^{*T}h(x_n)]^T$  是  $H(\bar{q}_1)\ddot{q}_r + C(\bar{q}_1, \dot{\bar{q}}_1)\dot{q}_r + G(\bar{q}_1)$  的一个  $n \times 1$  理想神经网络近似矢量，以及  $\psi$  是一个  $n \times 1$  极小的神经网络近似误差矢量，它非常小，有界，并且一定存在于神经网络近似过程中，即存在一个未知的正常数  $\Psi_i \in \mathbb{R}^+$ ， $|\psi_i| \leq \Psi_i$ 。 $\psi$  的影响应与外部干扰同时消除。外部干扰被重新定义为：

$$k_i = d - \psi \quad (3-23)$$

其中  $k_i$  是有界的，即存在一个未知的正常数  $k_i = \bar{d}_i + \Psi_i$ ， $k_i \in \mathbb{R}^+$ ， $|k_{ii}| \leq k_i$ 。

ANN-R 控制器可以设计为：

$$\bar{u} = -\Phi - K_D s + \hat{w}^T h(x) - \text{sgn}(s)\hat{k} \quad (3-24)$$

其中  $\Phi = \left[ \frac{\tilde{q}_1}{k_{a1}^2 - \tilde{q}_1^2}, \frac{\tilde{q}_2}{k_{a2}^2 - \tilde{q}_2^2}, \dots, \frac{\tilde{q}_n}{k_{an}^2 - \tilde{q}_n^2} \right]^T$ ， $K_D$  是对角正定矩阵，

$\hat{w}^T h(x) = w^{*T} h(x) + \tilde{w}^T h(x)$ ， $\hat{w}^T h(x)$  是  $w^{*T} h(x)$  的估计值， $\tilde{w}^T h(x)$  是估计误差， $\hat{k}$  是  $k_i$  的上界  $k$  的估计值， $\text{sgn}(\cdot)$  返回一个对角矩阵，其中包含矢量  $(\cdot)$  对应元素的符号。

设计神经网络权重的新自适应律为：

$$\dot{\hat{w}}_i = -p_i h(x_i) s_i \quad (3-25)$$

其中  $h(x_i)$  是一个由高斯函数组成的  $m \times 1$  矢量， $m$  是神经网络中隐层节点数， $p_i$  应该满足：

$$\frac{d}{dt} \left( \frac{1}{p_i} \right) = -\frac{\lambda_i}{p_i} \quad (3-26)$$

设计变遗忘因子  $\lambda_i$  为：

$$\lambda_i = \lambda_{0i} (1 - \frac{p_i}{k_{0i}}) \quad (3-27)$$

其中  $\lambda_{0i}$  和  $k_{0i}$  是两个正常数, 指定最大遗忘率和  $p_i$  的上限。

定理 3-1: 对于神经网络权重的新自适应律(3-25)和(3-26)与变遗忘因子(3-27), 如果  $\lambda_{0i}$  和  $k_{0i}$  是正常数, 则  $\frac{1}{p_i}$ 、 $p_i$  和  $\lambda_i$  有一致的上界和下界, 且是正数。

证明:

为了得到  $\frac{1}{p_i}$  的表达式, 将(3-27)代入(3-26)可以得到:

$$\frac{d}{dt}(\frac{1}{p_i}) = -\frac{\lambda_{0i}}{p_i} + \frac{\lambda_{0i}}{k_{0i}} \quad (3-28)$$

然后, 求解(3-26)可以得到:

$$\frac{1}{p_i} = [\frac{1}{p_i(0)} - \frac{1}{k_{0i}}] e^{-\lambda_{0i}t} + \frac{1}{k_{0i}} \quad (3-29)$$

通过设定合适的初始值, 很容易保证  $[\frac{1}{p_i(0)} - \frac{1}{k_{0i}}] > 0$ 。因此对于所有  $t \geq 0$ ,  $\frac{1}{k_{0i}} < \frac{1}{p_i} \leq \frac{1}{p_i(0)}$ 。然后, 有  $p_i(0) \leq p_i < k_{0i}$  和  $0 < \lambda_i \leq \lambda_{0i} [1 - \frac{p_i(0)}{k_{0i}}]$ 。因此,  $\frac{1}{p_i}$ 、 $p_i$  和  $\lambda_i$  是一致的上界、一致的下界和正数。

对于自适应神经网络近似误差和外部扰动转矩  $\bar{k}_i$  的上界  $\bar{k}$ , 设计  $\bar{k}$  的自适应律为:

$$\dot{\bar{k}}_i = \text{sgn}(s_i) s_i \Gamma_i \quad (3-30)$$

其中  $\text{sgn}(\cdot)$  返回  $(\cdot)$  的符号,  $\Gamma_i$  应满足:

$$\frac{d}{dt}(\frac{1}{\Gamma_i}) = -\frac{\gamma_i}{\Gamma_i} \quad (3-31)$$

设计变遗忘因子  $\gamma_i$ :

$$\gamma_i = \lambda_{1i} (1 - \frac{\Gamma_i}{k_{1i}}) \quad (3-32)$$

其中  $\lambda_{1i}$  和  $k_{1i}$  是两个正常数, 指定最大遗忘率和  $\Gamma_i$  的上限。

定理 3-2: 对于  $k$  的新自适应律(3-30)、(3-31)与变遗忘因子(3-32)。如果  $\lambda_{1i}$  和  $k_{1i}$  是正常数, 则  $\frac{1}{\Gamma_i}$ 、 $\Gamma_i$  和  $\gamma_i$  有一致的上界和下界, 且是正数。证明过程

与定理 3-1 的证明相同。

定理 3-3: 考虑由(3-18)描述的降阶系统, 通过 ANN-R 控制器(3-24), 神经网络权重(3-25)、新自适应律(3-26)与变遗忘因子(3-27), 以及  $k$  的新自适应律(3-30)、(3-31)与变遗忘因子(3-32), 只要保证所有初始条件都是有界的, 可使降阶系统达到指数稳定, 即降阶系统状态误差  $\tilde{q}$ ,  $\dot{\tilde{q}}$ ,  $\tilde{w}_i$  和  $\tilde{k}_i$  可以指数地收敛到零。 $\tilde{q}$  不违反约束, 即在  $-k_{ai} \leq \tilde{q}_i(0) \leq k_{ai}$  前提条件下,  $\tilde{q}_i$  保持在区间  $-k_{ai} \leq \tilde{q}_i \leq k_{ai}$ ,  $\forall t > 0$ 。

证明: 为了解决输出约束问题, 设计了一个障碍 Lyapunov 函数:

$$V_1 = \frac{1}{2} \sum_{i=1}^n \ln \frac{k_{ai}^2}{k_{ai}^2 - \tilde{q}_i^2} \quad (3-33)$$

其中  $\ln(\cdot)$  表示  $(\cdot)$  的自然对数。 $-k_{ai} < \tilde{q}_i < k_{ai}$ ,  $\forall t > 0$ ,  $i=1,2,\dots,n$ 。

$V_1$  关于时间的微分为:

$$\dot{V}_1 = \frac{1}{2} \sum_{i=1}^n \frac{k_{ai}^2 - \tilde{q}_i^2}{k_{ai}^2} \frac{2k_{ai}^2 \tilde{q}_i \dot{\tilde{q}}_i}{(k_{ai}^2 - \tilde{q}_i^2)^2} = \sum_{i=1}^n \frac{\tilde{q}_i \dot{\tilde{q}}_i}{k_{ai}^2 - \tilde{q}_i^2} = \sum_{i=1}^n \frac{\tilde{q}_i (s_i - h_i \tilde{q}_i)}{k_{ai}^2 - \tilde{q}_i^2} \quad (3-34)$$

其中  $\Lambda = \text{diag}(h_1, h_2, \dots, h_n)$ 。

随后, Lyapunov 函数被提出为:

$$V_2 = V_1 + \frac{1}{2} s^T H s + \frac{1}{2} \sum_{i=1}^n \frac{\tilde{w}_i^T \tilde{w}_i}{p_i} + \frac{1}{2} \sum_{i=1}^n \frac{\tilde{k}_i^2}{\Gamma_i} \quad (3-35)$$

其中  $\tilde{w}_i = \hat{w}_i - w_i^*$ ,  $\tilde{w}_i$ ,  $\hat{w}_i$  和  $w_i^*$  分别是神经网络权重估计误差、估计值和实际值。同理,  $\tilde{k}_i = \hat{k}_i - k_i$ ,  $\tilde{k}_i$ ,  $\hat{k}_i$  和  $k_i$  分别是上限  $k_i$  的估计误差、估计值和真实值。

把(3-35)对时间进行微分:

$$\begin{aligned} \dot{V}_2 = & \sum_{i=1}^n \frac{\tilde{q}_i (s_i - h_i \tilde{q}_i)}{k_{ai}^2 - \tilde{q}_i^2} + s^T H \dot{s} + \frac{1}{2} s^T \dot{H} s + \sum_{i=1}^n \frac{\tilde{w}_i^T \dot{\tilde{w}}_i}{p_i} \\ & + \frac{1}{2} \sum_{i=1}^n \tilde{w}_i^T \frac{d}{dt} \left( \frac{1}{p_i} \right) \tilde{w}_i + \sum_{i=1}^n \frac{\tilde{k}_i \dot{\tilde{k}}_i}{\Gamma_i} + \frac{1}{2} \sum_{i=1}^n \tilde{k}_i^2 \frac{d}{dt} \left( \frac{1}{\Gamma_i} \right) \end{aligned} \quad (3-36)$$

然后, 将(3-21)和自适应律(3-25)、(3-30)代入(3-36)可以得到:

$$\begin{aligned} \dot{V}_2 = & s^T (\bar{u} + d - H\ddot{q}_r - C\dot{q}_r - G) + \sum_{i=1}^n \frac{\tilde{q}_i s_i}{k_{ai}^2 - \tilde{q}_i^2} - \sum_{i=1}^n \frac{h_i \tilde{q}_i^2}{k_{ai}^2 - \tilde{q}_i^2} \\ & - \sum_{i=1}^n \tilde{w}_i^T h(x_i) s_i - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{w}_i^T \lambda_i \tilde{w}_i}{p_i} + \sum_{i=1}^n \text{sgn}(s_i) s_i \tilde{k}_i - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{k}_i^2 \gamma_i}{\Gamma_i} \end{aligned} \quad (3-37)$$

此外, 代入 ANN-R 控制器(3-24)可以得到:

$$\dot{V}_2 \leq -\sum_{i=1}^n \frac{h_i \tilde{q}_i^2}{k_{ai}^2 - \tilde{q}_i^2} - s^T K_D s - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{w}_i^T \lambda_i \tilde{w}_i}{p_i} - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{k}_i^2 \gamma_i}{\Gamma_i} \quad (3-38)$$

根据引理 3-2 可以得到:

$$\dot{V}_2 \leq -\sum_{i=1}^n h_i \ln \frac{k_{ai}^2}{k_{ai}^2 - \tilde{q}_i^2} - s^T K_D s - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{w}_i^T \lambda_i \tilde{w}_i}{p_i} - \frac{1}{2} \sum_{i=1}^n \frac{\tilde{k}_i^2 \gamma_i}{\Gamma_i} \leq -\rho_0 V_2 \quad (3-39)$$

其中  $\rho_0 = \min[2 \min(h_i), 2 \frac{\lambda_{\min}(K_D)}{\lambda_{\max}(H)}, \min(\lambda_i), \min(\gamma_i)]$ , 它是严格的正常数。

$\lambda_{\min}(\cdot)$  和  $\lambda_{\max}(\cdot)$  分别是矩阵  $(\cdot)$  的最小和最大特征值。

将(3-39)乘以  $e^{\rho_0 t}$  得到:

$$\frac{d}{dt}(V_2 e^{\rho_0 t}) \leq 0 \quad (3-40)$$

对上述不等式进行积分, 得到:

$$V_2 \leq V_2(0) e^{-\rho_0 t} \leq V_2(0) \quad (3-41)$$

对于  $\tilde{q}$  有:

$$\frac{1}{2} \sum_{i=1}^n \ln \frac{k_{ai}^2}{k_{ai}^2 - \tilde{q}_i^2} \leq V_2(0) \quad (3-42)$$

对不等式两边取指数得到:

$$\tilde{q}_i^2 \leq k_{ai}^2 (1 - e^{-2V_2(0)}) \quad (3-43)$$

因此, 根据障碍 Lyapunov 函数,  $\tilde{q}_i$  收敛到小范围  $\Omega_{\tilde{q}_i}$ ,  $\tilde{q}_i$  保持在区间  $-k_{ai} \leq \tilde{q}_i \leq k_{ai}, \forall t > 0$ , 前提是  $-k_{ai} \leq \tilde{q}_i(0) \leq k_{ai}$ 。闭环系统状态误差  $\tilde{q}, \dot{\tilde{q}}, \tilde{w}_i, \tilde{k}_i$  可以指数地收敛到零。

备注 3-3: 为保证降阶系统(3-18)可以达到指数稳定, 须要解决两个关键问题: 对于常规自适应神经网络轨迹跟踪控制器所使用的神经网络权重的自适应律, 它只能保证闭环系统的状态变量最终一致有界。这对于 ANN-R 控制设计来说是不够的。与传统自适应神经网络轨迹跟踪控制器使用的自适应律不同, 考虑了基于变遗忘因子  $\lambda_i$  的神经网络权重(3-25)的新自适应律。第二个关键问题是同时消除神经网络近似误差和外部干扰的影响。为了自适应  $\tilde{k}$ , 考虑了基于变遗忘因子  $\gamma_i$  的自适应律(3-30)。然后, 就很容易保证闭环系统状态误差  $\tilde{q}, \dot{\tilde{q}}, \tilde{w}_i, \tilde{k}_i$  可以指数地收敛到零。

### 3.2.4 边界层系统设计

在本小节中，还应保证边界层系统可以达到指数稳定。

边界层系统模型描述为：

$$\frac{d^2\eta}{d\tau^2} + K_1[J^{-1} + D^{-1}(\bar{q}_1)]\eta = J^{-1}K_1u_f \quad (3-44)$$

为了给边界层系统提供足够的阻尼，边界层系统的控制器  $u_f$  被设计为：

$$u_f = -K_2 \frac{d\eta}{d\tau} \quad (3-45)$$

由于  $\bar{z}$  在边界层系统中被认为是一个常数，可以重写为：

$$u_f = -\epsilon K_2 \dot{z} \quad (3-46)$$

其中  $\dot{z}$  是柔性结构的转矩矢量  $z$  与时间的比值。

定理 3-4：考虑由(3-44)描述的边界层系统，通过控制器为(3-46)，只要保证  $K_1$  和  $K_2$  是对角正定矩阵，可使边界层系统达到指数稳定。

备注 3-4：将控制器 (3-45) 代入边界层系统 (3-44) 可以得到  $\frac{d^2\eta}{d\tau^2} + J^{-1}K_1K_2 \frac{d\eta}{d\tau} + K_1[J^{-1} + D^{-1}(\bar{q}_1)]\eta = 0$ 。对于这个边界层系统，如果这个闭环系统的特征多项式满足 Hurwitz 的稳定性判据，则边界层系统可以达到指数稳定。由于  $D(q_1)$  是刚体连杆的对称正定惯性矩阵， $J$  是柔性结构的对角正定惯性矩阵，只要系数矩阵  $K_1$  和  $K_2$  是对角正定矩阵，该边界层系统的特征多项式满足 Hurwitz 稳定判据，即边界层系统可以达到指数稳定。

备注 3-5：根据假设 3-1，带有应变片传感器的高刚度柔性关节协作机器人可以准确地反馈柔性结构的转矩矢量  $z$ 。 $\dot{z}$  是柔性结构转矩矢量  $z$  与时间的比值，可以通过数值微分计算。但是，数值微分会产生误差。可以考虑一种类似于同时消除神经网络近似误差和外部干扰影响的方法。可以设计类似于基于变遗忘因子的自适应项和自适应律来消除数值微分误差的影响。很容易确保数值微分误差可以指数收敛到零。

因此，控制器(3-46)可以保证边界层系统可以达到指数稳定。

### 3.2.5 复合控制设计（ANN-F 控制器）

可以得到复合 ANN-F 控制器：

$$u = \bar{u} + u_f = -\Phi - K_D s + \hat{w}^T h(x) - \text{sgn}(s) \hat{k} - \epsilon K_2 \dot{z} \quad (3-47)$$

备注 3-6：通过 Lyapunov 稳定性分析，提出的新型 ANN-R 控制器(3-24)

可以保证降阶系统达到指数稳定。对于边界层系统, (3-46)可以保证系统达到指数稳定。因此, 根据引理 3-1, 提出的 ANN-F 控制器(3-47), 如图 3-2 所示, 可以保证高刚度柔性关节协作机器人系统达到指数稳定。

备注 3-7: 在假设 3-1 和假设 3-2 下, 对于基于应变片传感器的高刚度柔性关节协作机器人, 所提出的 ANN-F 控制器(3-47)不需要任何系统参数, 具有很高的实用性。所提出的 ANN-F 控制器可以保证系统达到指数稳定。此外, 在保证输出约束的同时, 通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。因此, ANN-F 控制器可以保证协作机器人精确的轨迹跟踪。




图 3-2 ANN-F 控制系统框图

为了有效地避免不希望的控制抖动并尽可能保证控制性能, 在工程中, 可以使用饱和函数  $\tanh(\delta s_i)$  代替控制器中的符号函数  $\text{sgn}(s_i)$ , 其中,  $\delta$  是一个很大的正数。

因此, 提出的 ANN-F 控制器(3-47)被调整为:

$$u = -\Phi - K_D s + \hat{w}^T h(x) - \tanh(\delta s) \hat{k} - \epsilon K_2 \dot{z} \quad (3-48)$$

$k$  的自适应律(3-30)调整为:

$$\dot{\hat{k}}_i = \tanh(\delta s_i) s_i \Gamma_i \quad (3-49)$$

备注 3-8:  $\tanh(\delta \cdot)$  是一个基于可调饱和因子的单调递增平滑饱和函数, 它经过坐标原点, 并连续可微。重要的是, 平滑饱和函数  $\tanh(\delta \cdot)$  在原点附近保留了常见符号函数  $\text{sgn}(\cdot)$  的快速响应特性, 以确保足够的鲁棒性。理论上, 通过调整饱和因子可以无限接近符号函数  $\text{sgn}(\cdot)$ , 但避免在切换过程中出现不连续过渡, 导致抖动。当  $\delta$  足够大, 但饱和函数  $\tanh(\delta \cdot)$  几乎可以等于符号函数  $\text{sgn}(\cdot)$ 。



### 3.2.6 轨迹跟踪控制算法数值仿真

对自适应轨迹跟踪控制器和 ANN-R 控制器(3-24)进行数值仿真。使用 MATLAB 符号计算建立 7 自由度刚体关节协作机器人的动力学模型（基于 Baxter 协作机器人的 DH 参数表）。模型的初始值，如连杆质量、长度和惯量，均参考 Baxter 协作机器人的 URDF 文件。为了获得可比较的数值仿真结果，考虑使用相同的期望轨迹。七个关节的期望轨迹都是  $\sin(2\pi t)$ 。

#### 1) 刚体关节协作机器人自适应轨迹跟踪控制算法数值仿真

设定自适应轨迹跟踪控制器的控制增益分别为  $\Lambda_a$  和  $K_a$  分别为 **diag**(30.2,15.2,20.0,15.3,20.0,10.5,10.5) 和 **diag**(30.2,30.2,5.0,15.5,2.2,2.2,0.2)。自适应轨迹跟踪控制算法的数值仿真结果如图 3-3 所示。协作机器人可以在自适应轨迹跟踪控制器的作用下很好地跟踪期望轨迹。

#### 2) 刚体关节协作机器人自适应神经网络轨迹跟踪控制算法数值仿真

对于 ANN-R 控制器，选择的控制增益  $\Lambda$  和  $K_D$  与自适应轨迹跟踪控制器的相同。神经网络节点的数量为 35。将径向基函数的中心和展开常数分别定义为从  $-3\pi/5$  到  $3\pi/5$  中均匀选择和 0.25。 $w_{i,j=1,2,\dots,7}$  的初始值为  $\text{node} \times 1$  矩阵，每个矩阵由来自  $[-1,1]$  的随机数组成。

ANN-R 控制器的数值仿真结果如图 3-4 所示。协作机器人也可以在 ANN-R 控制器的作用下很好地跟踪期望轨迹。ANN-R 控制器和自适应轨迹跟踪控制器的性能是相近的。总之，考虑到不确定的动力学模型  $D(q_1)$ ， $C(q_1, \dot{q}_1)$  和  $G(q_1)$ ，ANN-R 控制器在 7 自由度刚体关节协作机器人控制中表现出更好的性能。此外，对于 7 自由度协作机器人，所提出的 ANN-R 控制器的计算成本低于自适应轨迹跟踪控制器。

备注 3-9：自适应轨迹跟踪控制器可以在线调整动力学模型参数，使动力学补偿更加准确。对于高自由度的协作机器人，比如 7 自由度的协作机器人，动力学模型非常复杂，可使用 MATLAB 符号计算得到。为了保证高控制频率，协作机器人需要超高计算能力。相比之下，对于高自由度协作机器人来说，使用 RBF 神经网络学习动力学模型将比自适应轨迹跟踪控制器的计算开销更少。此外，在动力学模型不确定  $D(q_1)$ ， $C(q_1, \dot{q}_1)$  和  $G(q_1)$  的条件下，而不仅仅是模型参数的不确定，ANN-R 控制器可以很好地实现高自由度刚体关节协作机器人控制。根据数值仿真结果，ANN-R 控制器和自适应轨迹跟踪控制器的性能是基本相同的。因此，ANN-R 控制器对于高自由度协作机器人控制具有更大的优势。




图 3-3 自适应跟踪控制算法仿真结果




图 3-4 ANN-R 控制算法仿真结果

### 3.3 轨迹跟踪控制算法实验设计与结果分析




图 3-5 基于 Baxter 协作机器人自主抓取摆放系统轨迹跟踪控制实验

#### 3.3.1 实验设计

基于 Baxter 协作机器人自主抓取摆放系统进行了一系列轨迹跟踪实验，以评估 ANN-F 控制器的性能。具体任务是自主地从桌子上拾取散落的苹果并将其放入分格托盘中。协作机器人微小的位置偏差很可能导致抓取摆放操作失败，因此柔性关节协作机器人抓取摆放系统需要协作机器人精准运动控制。为了更好地展示 ANN-F 控制器的性能，本实验聚焦在目标物体转运过程。Baxter 协作机器人将目标物体从位置 A 转运到位置 B，如图 3-5 所示。三种控制器用于比较：传统的比例微分控制器(PD 控制器)、提出的新型 ANN-R 控制器和提出的 ANN-F 控制器。使用 MoveIt! 来规划末端执行器轨迹并将它们从笛卡尔空间映射到关节空间。然后，使用三次样条插值方法获得足够的连杆角期望角位移、角速度和角加速度。插值节点的数量由规划时间和控制频率决定。将控制频率设置为 200Hz。由于 MoveIt! 的规划时间约为 2.06s，因此样条插值节点的数量应为 412 个左右。与传统的 PD 控制器相比，ANN-R 控制器需要更多的时间用于神经网络的计算，即(3-24)。为了保证控制性能，在这些实验中，须要保证神经网络的计算速度至少与 200Hz 的控制频率相匹配。因此，设置了适当数量的神经网络隐层节点。需要注意的是，在三个实验过程中保持所有期望轨迹和初始条件相同，以获得可比较的实验结果。






图 3-6 Baxter 协作机器人各关节命名

表 3-1 轨迹跟踪控制实验中使用的参数总结

|           | $W_0$ | $W_1$ | $W_2$ | $E_0$ | $E_1$ | $S_0$ | $S_1$ |
|-----------|-------|-------|-------|-------|-------|-------|-------|
| $K_D$     | 2.2   | 2.2   | 5.1   | 5.0   | 5.5   | 15.2  | 22.2  |
| $\Lambda$ | 18.0  | 25.5  | 10.5  | 20.1  | 15.3  | 30.2  | 15.2  |

选择的七组控制增益如图 3-6 和表 3-1 所示。为了更好地比较三种控制器的控制效果，绘制了它们的跟踪效果。图 3-7，图 3-8 和图 3-9 是它们在机械臂关节空间下的跟踪效果。期望轨迹是通过 MoveIt! 和三次样条插值法获得的。输出约束定义为  $-k_{ai} \leq \tilde{q}_i \leq k_{ai}$ ， $k_{ai} = 0.02\text{rad}$ 。还计算了一些性能指标以更好地说明控制效果，包括上升时间 (RT)、稳态时间 (ST)、超调 (OS)、均方误差 (MSE) 和稳态误差 (SSE)，如表 3-2 所示。这些实验中的 ST 定义为系统瞬态衰减到  $\pm 2\%$  内的时间。三种控制器在 RT 的比较中均表现出优异的性能，均趋于零。因此，不再关注 RT。

3.3.2 实验结果分析

1) PD 轨迹跟踪控制算法结果分析

由于 PD 控制器是目前应用最广泛的控制算法，首先进行 PD 控制实验。尽管尽最大努力调整合适的控制器参数，但仍然不能得到非常优秀的跟踪效果。选择的七组 PD 控制增益如表 3-1 所示。根据表 3-2，ST、OS、MSE 和 SSE 较大。这些也可以在图 3-7 中清楚地看到。不能保证输出约束。图 3-10 中，末端执行器的最终跟踪误差为 8.02 mm，是最大的。总体而言，PD 控制

器的控制性能是这三个控制器中最差的。

## 2) 刚体关节协作机器人自适应神经网络轨迹跟踪控制算法结果分析

对于高刚度柔性关节协作机器人,许多研究人员直接将其视为刚体关节机器人,并使用常规的自适应神经网络轨迹跟踪控制器对其进行控制。在这里,也将其视为刚体关节机器人并测试所提出的新型 ANN-R 控制器的性能。等式(3-24)是提出的新型 ANN-R 控制器。实际上,(3-24)的第一项是 PD 控制器,使用神经网络来逼近不确定的动力学模型作为控制系统的前馈补偿。选择的七组控制增益  $\Lambda$  和  $K_D$  如表 3-1 所示。神经网络节点的数量为 35。将径向基函数的中心和展开常数分别定义为从  $-3\pi/5$  到  $3\pi/5$  中均匀选择和 0.25。 $w_{i,j=1,2,\dots,7}$  的初始值为  $\text{node} \times 1$  矩阵,每个矩阵由来自  $[-1,1]$  的随机数组成。设定初始值  $p_{i,j=1,2,\dots,7}(0)$  分别为 (0.2, 0.2, 0.2, 5.0, 5.0, 5.0, 5.0) 和  $\Gamma_{i,j=1,2,\dots,7}(0)$  分别为 (0.2, 0.2, 0.2, 4.0, 4.0, 4.0, 4.0)。定义变遗忘因子  $\lambda$  的参数  $\lambda_{0i,j=1,2,\dots,7}$  和  $k_{0i,j=1,2,\dots,7}$  分别为 (10.0, 10.0, 6.0, 0.5, 0.5, 0.5, 0.5) 和 (0.4, 0.4, 0.5, 10.0, 10.0, 10.0, 10.0)。定义变遗忘因子  $\gamma$  的参数  $\lambda_{1i,j=1,2,\dots,7}$  和  $k_{1i,j=1,2,\dots,7}$  分别为 (8.0, 8.0, 4.0, 0.5, 0.5, 0.5, 0.5) 和 (0.4, 0.4, 0.5, 8.0, 8.0, 8.0, 8.0)。

根据表 3-2,几乎所有的指标 ST、OS、MSE 和 SSE 都降低了,控制效果被提高了。这些也可以在图 3-8 中清楚地看到。可以保证输出约束。在图 3-10 中,末端执行器的最终跟踪误差为 6.04mm,优于 PD 控制的跟踪性能。因此,可以得出结论,所提出的新型 ANN-R 控制器(3-24)的控制性能优于 PD 控制器的。

## 3) 高刚度柔性关节协作机器人自适应神经网络轨迹跟踪控制算法结果分析

最后,测试了提出的 ANN-F 控制器(3-47)。定义  $\epsilon = 0.005$ ,这是一个极小值。七组控制增益  $\Lambda$ 、 $K_D$  与神经网络参数与提出的新型 ANN-R 控制器相同,并且  $K_2 = \text{diag}(0.1, 0.1, 0.1, 0.3, 0.2, 0.7, 0.7)$ 。

根据表 3-2,几乎所有的指标 ST、OS、MSE 和 SSE 都有降低,控制效果显著提高。这些也可以在图 3-9 中清楚地看到。可以保证输出约束。在图 3-10 中,末端执行器的最终跟踪误差为 2.76mm,提出的 ANN-F 控制器的性能为这三种控制器中最好的。因此,所提出的 ANN-F 控制器(3-47)可以很好地用于高刚度柔性关节协作机器人轨迹跟踪。




图 3-7 PD 控制算法实验结果




图 3-8 ANN-R 控制算法实验结果






图 3-9 ANN-F 控制算法实验结果




表 3-2 控制器性能比较：PD、ANN-R 与 ANN-F

| Joints | ST(s)          | OS(%)             | MSE( $10^{-5}$ )  | SSE( $10^{-3}$ rad) |
|--------|----------------|-------------------|-------------------|---------------------|
| $W_0$  | 5.00/5.00/5.00 | 17.49/14.10/13.00 | 6.98/6.05/5.04    | 6.64/8.04/3.67      |
| $W_1$  | 5.00/5.00/2.20 | 3.71/3.27/2.70    | 11.20/10.88/10.16 | 4.23/3.85/1.10      |
| $W_2$  | 3.15/1.94/1.90 | 1.27/1.16/0.88    | 3.55/2.68/1.68    | 5.53/4.38/0.60      |
| $E_0$  | 2.24/2.22/2.19 | 2.81/2.81/2.41    | 10.65/8.15/7.85   | 2.50/0.30/0.00      |
| $E_1$  | 0.78/0.02/0.02 | 1.89/1.80/1.73    | 5.84/4.81/4.63    | 2.51/2.01/2.31      |
| $S_0$  | 3.69/3.26/2.61 | 2.76/2.55/2.45    | 4.29/3.97/3.45    | 4.96/4.87/3.42      |
| $S_1$  | 1.94/1.80/1.79 | 2.76/2.56/2.40    | 4.80/3.79/3.71    | 5.58/5.57/5.50      |

4) 讨论

根据性能指标 RT、ST、OS、MSE 和 SSE，传统的 PD 控制性能一般，但提出的新型 ANN-R 控制性能良好。所提出的 ANN-F 控制对高刚度柔性关节协作机器人的控制性能优于传统的 PD 控制和提出的新型 ANN-R 控制。此外，ANN-F 控制器可以很容易地部署。它还可以有效地使用神经网络处理协作机器人动力学中的不确定性。因此，具有很高的实用性。可以保证输出约束，进一步提高协作机器人轨迹跟踪控制的安全性和精度。

3.4 本章小结

由于现有的高刚度柔性关节大多基于应变片传感器，这种高刚度柔性关节只能反馈连杆角位移、连杆角速度和柔性结构转矩。为了解决这些问题，在本章中，提出了一种 ANN-F 控制器来实现高刚度柔性关节协作机器人的高精轨迹跟踪。根据奇异摄动理论，它只需要关节角位移、关节角速度和柔性结构转矩的反馈信号。ANN-F 控制器具有很高的实用性。其使用神经网络处理协作机器人动力学中的不确定性问题。为了进一步保证协作机器人轨迹跟踪控制的安全性和精度，在满足输出约束的同时，其通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。通过李雅普诺夫稳定性分析，所提出的 ANN-F 控制器可以保证系统达到指数稳定。除了一些必要的仿真之外，还基于 Baxter 协作机器人自主抓取摆放系统进行了一系列轨迹跟踪实验，以评估 ANN-F 控制器的性能。结果表明，所提出的 ANN-F 控制器对高刚度柔性关节协作机器人轨迹跟踪具有更好的控制性能。

## 4 人与协作机器人双臂交接系统研究

设计人与双臂协作机器人大箱型物体交接系统，实现人与双臂协作机器人高效地、自然地交接大箱物体。将概率模型算法与在线学习算法相结合，使用 GMR 算法建模和预测人手运动轨迹；使用 GM 算法建模交接位置，预测交接任务开始时间和交接位置，提高交接效率。在预测结果的基础上，采用基于概率模型的模仿学习运动规划 DS-KMP 算法，根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能，并满足安全约束，保证了人的自动交接操作能够顺利、自然地进行。设计双臂协作机器人精准轨迹跟踪控制器以及双臂物体抓取力控制器。改进双臂协作机器人夹爪，集成多种传感器，针对板型和箱型两类交接物体设计不同的抓取策略。最后，基于 Baxter 机器人建立完整的、能快速响应人类运动意图的、自然的人与双臂协作机器人大箱型物体交接系统，完成对多种类物体的人机交接。交接成功率接近 99.3%（受限于机器人性能）。

### 4.1 人与人双臂交接大箱型物体研究

凭借丰富的感官反馈、灵活的肢体和长期的练习，人类可以轻松完成对多种形状、大小和重量物体的交接操作。对于人与协作机器人双臂大箱型物体交接系统的设计，有必要先对人与人双臂自然交接过程（特别是对人类接收者的行为）进行研究，以指导系统设计。

#### 4.1.1 实验设计

在本研究中，主要关注的是人类接收者的行为。本研究共有 10 名参与者（5 名男性和 5 名女性）参与，他们都是本校 21 岁至 30 岁的学生。将 10 名参与者分成五组，每组两人。在人类给予者准备好之前，要求接收者背朝给予者，这样可以避免从准备过程中给予者的行为中获取信息。交接对象为 40cm×30cm×20cm 箱子和 50cm×30cm×40cm 箱子。此外，物体的重量分为两类，轻（0.4/0.6kg）和重（1.0/1.2kg），即 4 种箱子。接收者无法从箱子的外观获得任何关于重量的线索。每次试验开始时，给予者和接收者之间的距离约为 2-3 米。

#### 4.1.2 实验结果分析与交接系统设计

图 4-1 显示了人与人双臂自然交接的过程。人类接收者从身体两侧伸出



双手，提前向物体移动，根据对交接位置的预测，自适应调整其运动，并准备好从给予者手中拿过物体，这可以大大提高交接操作的效率。协作机器人模仿人类接收者来实现自然交接是合理的。接收者实际上从给予者手中抓取物体。根据相互作用力的变化，给予者可以有效地协调释放时间。

此外，还得到了双臂大箱型物体接收者动作的统计结果。根据表 4-1 中显示的统计结果，对于多尺寸的箱型对象，尤其是大型对象，图 4-1 中所示的双手托底边是最常见的接收方式。当接收者不知道大箱型物体的重量和其它属性时，这是接收此类对象最稳妥的方式。



图 4-1 人与人双臂自然交接过程




图 4-2 大型箱型物体人机双臂交接系统策略

表 4-1 人与人双臂交接大箱型物体接收动作统计

|       | 40cm×30cm×20cm |       | 50cm×30cm×40cm |       |
|-------|----------------|-------|----------------|-------|
|       | 0.4kg          | 1.0kg | 0.6kg          | 1.2kg |
| 双手托底边 | 70%            | 90%   | 100%           | 100%  |
| 其它    | 30%            | 10%   | 0%             | 0%    |

基于人与人双臂自然交接过程，提出了人与协作机器人双臂大箱型物体交接策略，如图 4-2 所示。由于人类给予者手的运动规律高度相似，首先，使用在线学习算法改进 GMR 算法，以预测交接任务的开始和交接位置。在线更新概率模型不仅要能处理人类给予者的规则运动模式，还要能处理他们的不规则运动模式，也就是说，须要区分规则和不规则运动模式，并根据规则运动模式的数据更新人手运动轨迹模型和交接位置模型。此外，基于双臂大箱型物体接收者动作的统计结果，应用基于概率模型的模仿学习运动规划 DS-KMP 算法，根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能，并满足安全约束，以确保人类给予者能够在与协作机器人交接操作中流畅自然地工作。最后，提出了双臂抓取策略，设计了双臂抓取控制，并扩展了夹持器以实现稳定抓取。




图 4-3 人手运动轨迹的建模与预测示意图

4.2 给予者运动轨迹预测算法研究

在本节中，使用概率模型算法估计给予者规则与不规则运动模式下的交接任务开始时间和交接位置，以提高交接操作的效率。首先，使用 GMR 算

法来建模和预测人手运动轨迹，并应用 GM 算法在线建模交接位置。其次，可以预测交接任务的开始时间和交接位置，以保证交接操作的效率。接着，使用在线学习算法改进 GMR 算法，不仅可以处理人类给予者的规则运动模式，还可以处理他们的不规则运动模式。图 4-3 展示了人与协作机器人双臂交接大箱型物体操作中的人类运动轨迹预测算法。

#### 4.2.1 运动轨迹建模与预测

使用 GMR 算法对手运动轨迹进行建模和预测。由于微分会导致误差，只使用人手位置进行建模。令  $x_c = x_{hand}^{(t)} \in \mathbb{R}^n$  为当前人手位置， $x_h = (x_{hand}^{(t-1)}, x_{hand}^{(t-2)}, \dots, x_{hand}^{(t-d)}) \in \mathbb{R}^{n \times d}$  是历史人手位置，其中  $d$  是自回归模型的阶数。 $x_c$  和  $x_h$  的联合分布由下式给出：

$$p(x_h, x_c) = \sum_{m=1}^M \pi_m \mathcal{N}(x_h, x_c | \mu_m, \Sigma_m) \quad (4-1)$$

$$\mu_m = \begin{bmatrix} \mu_m^{x_h} \\ \mu_m^{x_c} \end{bmatrix}, \Sigma_m = \begin{bmatrix} \Sigma_m^{x_h x_h} & \Sigma_m^{x_h x_c} \\ \Sigma_m^{x_c x_h} & \Sigma_m^{x_c x_c} \end{bmatrix} \quad (4-2)$$

其中  $M$  是混合数， $\mathcal{N}(x_h, x_c | \mu_m, \Sigma_m)$  是第  $m$  个多元正态分布，均值矢量  $\mu_m$  和协方差矩阵  $\Sigma_m$ ， $\pi_m$  是混合系数，必须满足  $0 \leq \pi_m \leq 1$  和  $\sum_{m=1}^M \pi_m = 1$ 。

根据联合分布，期望矢量和方差-协方差矩阵计算为：

$$E[x_c | x_h] = \sum_{m=1}^M h^m(x_h) \mu_m' \quad (4-3)$$

$$V[x_c | x_h] = \sum_{m=1}^M h^m(x_h) \Sigma_m' + \sum_{m=1}^M h^m(x_h) (\mu_m' - E[x_c | x_h]) (\mu_m' - E[x_c | x_h])^T \quad (4-4)$$

其中：

$$h^m(x_h) = \frac{\pi_m \mathcal{N}(x_h | \mu_m^{x_h}, \Sigma_m^{x_h x_h})}{\sum_{k=1}^M \pi_k \mathcal{N}(x_h | \mu_k^{x_h}, \Sigma_k^{x_h x_h})} \quad (4-5)$$

$$\mu_m' = \mu_m^{x_c} + \Sigma_m^{x_c x_h} (\Sigma_m^{x_h x_h})^{-1} (x_h - \mu_m^{x_h}) \quad (4-6)$$

$$\Sigma_m' = \Sigma_m^{x_c x_c} - \Sigma_m^{x_c x_h} (\Sigma_m^{x_h x_h})^{-1} \Sigma_m^{x_h x_c} \quad (4-7)$$

然后，在  $t+1$  时刻的当前人手位置  $x_c^{(t+1)}$  可以预测为：

$$x_c^{(t+1)} = E[x_c^{(t+1)} | x_h^{(t+1)}] \quad (4-8)$$

$$x_h^{(t+1)} = (x_c^{(t)}, x_c^{(t-1)}, \dots, x_c^{(t+1-d)})^T \quad (4-9)$$



重复使用(4-8)和(4-9)进行预测，直到预测步长大于最大预测步长 $T_p$ 。这样，人手预测轨迹就表示为一组高斯分布，在 $t$ 时刻预测的人手位置为：

$$\mathcal{N}^{(t)} = \mathcal{N}(\mu_{hand}^{(t)}, \Sigma_{hand}^{(t)}) \quad (4-10)$$

其中 $\mu_{hand}^{(t)}$ 和 $\Sigma_{hand}^{(t)}$ 分别是 $t$ 时刻人手位置预测的均值矢量和协方差矩阵。算法流程显示在算法 4-1 中。

---

#### 算法 4-1 基于高斯混合回归算法预测人手运动轨迹

---

**Input:** 当前时刻 $t$ ，当前人手位置 $x_c^{(t)}$ ，历史人手位置 $x_h^{(t)}$

**Start:**

**While**  $k=1$  to  $T_p$

$$x_h^{(t+k)} = (x_c^{(t+k-1)}, x_c^{(t+k-2)}, \dots, x_c^{(t+k-d)})^T$$

$$\mu_{hand}^{(t)} = E[x_c^{(t+k)} | x_h^{(t+k)}]$$

$$\Sigma_{hand}^{(t)} = V[x_c^{(t+k)} | x_h^{(t+k)}]$$

$$x_c^{(t+k)} = E[x_c^{(t+k)} | x_h^{(t+k)}]$$

**End while**

**Output:** 人手运动轨迹 $(\mathcal{N}^{(t)}, \mathcal{N}^{(t+1)}, \dots, \mathcal{N}^{(t+T_p)})$

---

### 4.2.2 预测交接任务开始和交接位置

首先，使用 GM 算法将交接位置建模为 $\mathcal{N} = (\mu_{task}, \Sigma_{task})$ ，它遵循正态分布。 $\mu_{task}$ 和 $\Sigma_{task}$ 分别是该模型的均值矢量和协方差矩阵。其次，可以利用 Hotelling 的 T 平方法来确定交接的开始和交接位置。马氏距离 $D_M(x_{hand}^{(t)}, \mu_{task}, \Sigma_{task})$ 可以通过下式计算：

$$D_M = \sqrt{(x_{hand}^{(t)} - \mu_{task})^T \Sigma_{task}^{-1} (x_{hand}^{(t)} - \mu_{task})} \quad (4-11)$$

其中 $x_{hand}^{(t)}$ 是 $t$ 时刻人手位置。马氏距离的平方 $D_M(x_{hand}^{(t)}, \mu_{task}, \Sigma_{task})^2$ 遵循 $\chi^2$ 分布。 $T_a$ 是预测的最新人手位置满足以下条件的时刻：

$$\begin{cases} D_M(x_{hand}^{(t+T_a)}, \mu_{task}, \Sigma_{task})^2 < a_{th} \\ \frac{x_{hand}^{(t+T_a)} - x_{hand}^{(t+T_a-1)}}{\Delta t} < v_{th} \end{cases} \quad (4-12)$$

其中 $\Delta t$ 是人手位置的更新周期，在 3 维情况下第 95 个百分位数 $a_{th} = 7.815$ ， $v_{th}$ 是人手运动速度阈值。 $T_a$ 满足 $T_a \leq T_p$ 。一旦满足条件，协作机器人立即开始交接操作。

备注 4-1：应该注意的是，人类运动模式可大致分为两类：规则的和不规则

则的。规则的运动模式是指给予者径直走向协作机器人，并直接完成物体交接。不规则运动模式是指给予者可以在工作区域内自由移动，只要最终到达交接位置，完成物品交接即可。

第三，一旦交接操作完成，通过计算预测误差的均方根误差（RMSE）来判断给予者的运动模式是规则的还是不规则的。预测误差的 RMSE 可以通过以下等式计算：

$$e_{RMSE} = \sqrt{\frac{1}{T} \sum_{k=1}^T (x_p^{(k)} - x_r^{(k)})^T (x_p^{(k)} - x_r^{(k)})} \quad (4-13)$$

其中  $x_p^{(k)}$  是  $t$  时刻的预测位置， $x_r^{(k)}$  是  $t$  时刻的真实位置。如果  $e_{RMSE} \leq b_{th}$ ，则该运动将被识别为规则运动，其中  $b_{th}$  是 RMSE 的阈值。保存规则运动模式下的人手运动轨迹和交接位置，以在线更新人手运动轨迹模型和交接位置模型。

### 4.2.3 模型在线更新

通常情况下，使用 EM 算法更新 GMM 算法未知参数。为了使模型具有在线更新能力，使用增量式 EM 算法在线更新模型：

- 1) 使用步骤  $k$  的参数，响应度  $\gamma_{lm}$  计算为：

$$\gamma_{lm} = \frac{\mathcal{N}(x_l | \mu_m^{(k)}, \Sigma_m^{(k)})}{\sum_{m=1}^M \pi_m^{(k)} \mathcal{N}(x_l | \mu_m^{(k)}, \Sigma_m^{(k)})} \pi_m^{(k)} \quad (4-14)$$

- 2) 根据响应度  $\gamma_{lm}$ ，估计每个参数为：

$$\pi_{est,m} = \frac{S_{\gamma,m}}{N_s} \quad (4-15)$$

$$\mu_{est,m} = \frac{1}{S_{\gamma,m}} \sum_{l=1}^{N_s} \gamma_{lm} x_l \quad (4-16)$$

$$\Sigma_{est,m} = \frac{1}{S_{\gamma,m}} \sum_{l=1}^{N_s} \gamma_{lm} (x_l - \mu_m^{(k)}) (x_l - \mu_m^{(k)})^T \quad (4-17)$$

其中  $N_s$  是样本数据的总数， $S_{\gamma,m} = \sum_{l=1}^{N_s} \gamma_{lm}$ 。

- 3) 使用遗忘因子  $\eta(k)$  更新参数为：

$$\pi_m^{(k+1)} = (1 - \eta(k)) \pi_m^{(k)} + \eta(k) \pi_{est,m} \quad (4-18)$$

$$\mu_m^{(k+1)} = (1 - \eta(k)) \mu_m^{(k)} + \eta(k) \mu_{est,m} \quad (4-19)$$

$$\Sigma_m^{(k+1)} = (1 - \eta(k)) \Sigma_m^{(k)} + \eta(k) \Sigma_{est,m} \quad (4-20)$$

其中  $\eta(k) = (k+2)^{-\beta}$ ,  $\beta$  是一个常数, 表示相对于过去参数的更新程度。

### 4.3 接收者模仿学习运动规划 DS-KMP 算法应用

在本节中, 首先, 通过 GMR 算法从大量专家轨迹中生成概率专家轨迹, 以保留概率属性。然后, 为了解决适应性问题, 考虑新的终点来更新原始概率专家轨迹。为了尽量避免协作机器人与物体之间的碰撞, 考虑轨迹调制以通过新的经过点。进一步地, 应用基于概率模型的模仿学习运动规划 DS-KMP 算法, 根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能, 并满足安全约束, 实现如图 4-4 所示的类人抓取, 以保证人类给予者在人类与协作机器人的交接操作中能够柔顺、自然地工作。算法 2-3 中总结了具有新经过点/终点的 DS-KMP 算法过程。




图 4-4 基于概率模型的模仿学习运动规划 DS-KMP 算法示意图

#### 4.3.1 从专家轨迹中学习

通过 GMM 算法得到专家接收轨迹的概率分布, 输入时间为  $\{t_n\}_{n=1}^N$ , 输出协作机器人末端执行器在笛卡尔空间下 6-D 位姿  $\{\xi_n\}_{n=1}^N$ 。  $t$  和  $\xi$  的联合概率分布由下式给出:

$$\mathcal{P}(t, \xi) = \sum_{c=1}^C \pi_c \mathcal{N}(t, \xi | \mu_c, \Sigma_c) \quad (4-21)$$

其中  $\pi_c$ 、 $\mu_c$  和  $\Sigma_c$  分别表示第  $c$  个高斯分布的先验概率、均值和协方差, 而  $C$  表示高斯分布的数量。此外, 可以通过 GMR 算法生成概率专家轨迹  $\{\hat{\xi}_n\}_{n=1}^N$ , 其中每个点  $\hat{\xi}_n$  由均值  $\hat{\mu}_n$  和协方差  $\hat{\Sigma}_n$  的条件概率分布来描述:

$$\mathcal{P}_r(\hat{\xi}_n | t_n) = \mathcal{N}(\hat{\mu}_n, \hat{\Sigma}_n) \quad (4-22)$$

### 4.3.2 概率专家轨迹调制与轨迹生成




图 4-5 双臂协作机器人坐标系定义图

预测的人双手位置  $x_{hand,l}^{(t+T_o)}$ ,  $x_{hand,r}^{(t+T_o)}$  是独立的。图 4-5 定义了双臂协作机器人坐标系。为了保证双臂抓取过程中的稳定性, 规定两个末端执行器的最终方向始终彼此相对, 最终位置分别关于协作机器人基坐标系的  $XOZ$  平面对称。可以根据人双手在协作机器人基坐标系  $Y$  方向上的位置预测结果来预测交接对象的近似大小。协作机器人交接操作末端执行器位置可通过下式计算:

$$\begin{cases} x_{end,l} = (x_{hand,r}^{(t+T_o)} - x_{hand,l}^{(t+T_o)}) / 2 - x_{offset,x} \\ x_{end,r} = (x_{hand,l}^{(t+T_o)} - x_{hand,r}^{(t+T_o)}) / 2 - x_{offset,x} \end{cases} \quad (4-23)$$

备注 4-2: 需要注意的是, DS-KMP 算法根据最新的终点(协作机器人交接操作末端执行器位置)实时生成 DS-KMP 算法学习轨迹, 以解决适应性问题。

由于微小的位置误差就会使协作机器人双臂之间产生很大的内力, 可能会损坏交接物体甚至协作机器人本身, 要求协作机器人通过  $Y$  方向距离目标  $x_{offset,y}$  的经过点:

$$\begin{cases} x_{via,l} = x_{end,l} + x_{offset,y} \\ x_{via,r} = x_{end,r} - x_{offset,y} \end{cases} \quad (4-24)$$

然后, 进行轨迹调制以通过新的经过点和终点。将  $M$  个新的期望点定义为  $\bar{D} = \{\bar{t}_m, \bar{\xi}_m\}_{m=1}^M$ , 每个点满足条件概率分布  $\bar{\xi}_m | \bar{t}_m \sim \mathcal{N}(\bar{\mu}_m, \bar{\Sigma}_m)$ 。将专家轨迹  $D$  与期望点集  $\bar{D}$  连接起来。对于新终点  $x_{end} = \{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\}$ , 直接替换终点  $\{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}$ :

$$D \leftarrow \{D / \{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}\} \cup \{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\} \quad (4-25)$$

其中符号“/”和“ $\cup$ ”分别代表排除和联合操作。

对于新的经过点  $x_{via} = \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$ ，首先将其位置  $x_{via}$  与专家轨迹  $\bar{D}$  进行比较，从而找到最近的数据点  $\{x_r, \hat{\mu}_r, \hat{\Sigma}_r\}$  满足  $d(\bar{t}_2, t_r) \leq d(\bar{t}_2, t_n)$ ， $\forall n \in \{1, 2, \dots, N\}$ ，其中  $d(\cdot)$  可以是任意 2 范数距离度量。如果最近距离  $d(\bar{t}_2, t_r)$  小于预定义的阈值  $\zeta_0 > 0$ ，替换  $\{\bar{t}_r, \bar{\mu}_r, \bar{\Sigma}_r\}$  与  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$ ；否则，将  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$  插入专家轨迹。更新专家轨迹  $\bar{D}$  根据：

$$\begin{cases} D \leftarrow \{D / \{t_r, \hat{\mu}_r, \hat{\Sigma}_r\}\} \cup \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}, & \text{if } d(\bar{t}_2, t_r) < \zeta_0 \\ D \leftarrow D \cup \{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}, & \text{otherwise} \end{cases} \quad (4-26)$$

对于专家轨迹  $\bar{D}$  在  $\{t_e, \hat{\mu}_e, \hat{\Sigma}_e\}$  和  $\{\bar{t}_r, \bar{\mu}_r, \bar{\Sigma}_r\}$  间的点，用基于  $\{\bar{t}_1, \bar{\mu}_1, \bar{\Sigma}_1\}$  和  $\{\bar{t}_2, \bar{\mu}_2, \bar{\Sigma}_2\}$  的等量点替换它们。然后，使用 DS-KMP 算法得到协作机器人期望轨迹  $x_{kmp,l}$  和  $x_{kmp,r}$ 。令  $J_l$  和  $J_r$  是  $6 \times 7$  Jacobian 矩阵，将 7DOF 关节速度映射到两个末端执行器的 6DOF 空间速度：

$$\dot{q}_{dl} = J_l^\dagger \dot{x}_{kmp,l}, \quad \dot{q}_{dr} = J_r^\dagger \dot{x}_{kmp,r} \quad (4-27)$$

其中  $J_l^\dagger$  和  $J_r^\dagger$  分别是  $J_l$  和  $J_r$  的伪逆矩阵。

## 4.4 双臂精准轨迹跟踪控制与力控制研究

在本节中，模仿人手扩展双指电动平行夹持器，模仿人类双臂抓取行为提出了控制策略，并设计了一些控制器，以显著提高抓取过程的安全性和效率。

### 4.4.1 夹持器设计

模仿人类托着一个大箱型物体时手的姿态来扩展 Rethink Robotics 双指电动平行夹持器。在左夹持器的一个指上安装一个光电传感器，以有效测量夹持器与物体之间的相对位移。ATI Nano 17 力/转矩传感器安装在左夹持器的另一个指上，以测量夹持力。Robotiq FT-300 力/转矩传感器安装在右侧手腕上，用于测量“挤压”力和手腕转矩。为了获得更可靠的信号，使用卡尔曼滤波算法对所有传感器数据进行预处理。此外，低刚度使人类擅长力控制。在夹持器中添加了一些柔性结构，以降低其刚度，有效提高其力控制性能。

### 4.4.2 双臂抓取策略设计

为了保证双臂抓取过程中的稳定性，规定两个末端执行器的最终方向始终彼此相对，最终位置分别关于协作机器人基坐标系的  $XOZ$  平面对称。在预抓取过程中，使用所提出的 ANN-R 控制器来跟踪在线规划 (DS-KMP 算法) 结果，可以实现对具有动力学模型不确定性的双臂协作机器人的高精轨迹跟踪。

然后，为了与物体建立接触并防止物体滚落，沿着接触点之间的连线移动协作机器人两个手臂以满足“挤压”力的阈值  $F_0^d$ ，如图 4-6 所示。为了保持稳定的抓取，必须控制两个协作机器人手臂沿接触点间连线相向连续施加“挤压”力。在这里，只须要关注沿投影在接触点间连线方向上的接触力。使用右手腕上的 Robotiq 力/转矩传感器来测量右侧的“挤压”力  $F_R$ 。左侧的“挤压”力为  $F_L \approx -F_R$ 。

给予者很难依靠视觉和触觉的方式来确定“挤压”力是否达到阈值，即给予者不确定释放时间。根据人类交接研究，交接是一种从给予者手中抓住运动物体的过程。根据物体的运动和相互作用力的变化，给予者可以有效地确定释放时间。当“挤压”力达到阈值时，协作机器人将会把物体抓起来。

### 4.4.3 双臂抓取控制设计

其一，双臂精准轨迹跟踪控制设计：为了跟踪在线规划结果 (DS-KMP 算法学习轨迹) 并处理双臂协作机器人动力学中的不确定性，使用提出的 ANN-F 控制器来实现协作机器人的高精轨迹跟踪。

其二，双臂力控制设计：针对这个操作过程，如图 4-6 所示，进行了受力分析，包括：沿投影在接触点间连线方向上的“挤压”力  $F_L$ 、 $F_R$ ，物体重力  $G$ ，支持力  $N_L$ ， $N_R$  和摩擦力  $f_L$ ， $f_R$ 。可以使用右手腕上的 Robotiq 力/转矩传感器来测量右侧“挤压”力  $F_R$ 、支持力  $N_R$  和摩擦力  $f_R$ 。左侧的“挤压”力是  $F_L \approx -F_R$ 。通过调整两个手臂的相对位置来调节“挤压”力：

$$v_{F_R} = \zeta K_s g(F_0^d - F_R) \quad (4-28)$$

$$v_{F_L} = -v_{F_R} \quad (4-29)$$

其中  $g(\cdot)$  可以过滤掉过大的力偏差 (可能是力传感器测量误差引起的)。为了确保安全，较高的“挤压”力通常比较低的“挤压”力更可取，尽管过大的力会导致物体产生不必要的形变甚至损坏。因此，使用  $\zeta$ ，来避免接触断开，

它会导致用力推入但缓慢后退。

$$\zeta = \begin{cases} 1 & , F < F_0^d \\ \frac{F_1^d - \zeta_f F_0^d - (1 - \zeta_f) F}{F_1^d - F_0^d} & , F_0^d \leq F < F_1^d \\ \zeta_f & , F \geq F_1^d \end{cases} \quad (4-30)$$

其中常数  $\zeta_f$  必须在  $[0,1)$  和  $F_0^d < F_1^d$  范围内。稳定性分析类似于[114]。

令  $J_l$  和  $J_r$  是  $6 \times 7$  Jacobian 矩阵，将 7DOF 关节速度映射到两个末端执行器的 6DOF 空间速度：

$$\dot{q}_{dl} = J_l^+ v_{F_L}, \quad \dot{q}_{dr} = J_r^+ v_{F_R} \quad (4-31)$$

其中  $J_l^+$  和  $J_r^+$  分别是它们的伪逆矩阵。当“挤压”力达到阈值时，给协作机器人末端执行器额外的垂直向上速度分量  $v_{v_l}$  和  $v_{v_r}$  片刻，并使用(4-31)得到关节速度。




图 4-6 双臂抓取过程受力分析

## 4.5 系统实施、实验设计与结果分析

在本节中，将大物体交接系统部署到 Baxter 协作机器人上，以测试所设计的系统性能。

### 4.5.1 系统实施

人机双臂交接系统的硬件如图 4-7 所示。两个 Kinect V2 深度相机固定在工作区的两侧，用于定位人手位置。须要提前计算出协作机器人和 Kinect V2



深度相机坐标系之间的两个变换矩阵。由于 Baxter 协作机器人的负载非常有限，因此在本次交接实验中使用的箱子尺寸为 40cm×30cm×20cm，重量为 0.6kg。首先，进行人手运动轨迹预测实验，以验证人类给予者的规则运动模式及其不规则运动模式下的预测性能。还验证了所提出的在线学习算法可以在一定程度上提高预测性能。此外，评估了所提出的模仿学习接收技能算法的性能。最后，验证了所提出的双臂抓取控制性能，包括双臂精准轨迹跟踪控制实验和双臂力控制实验。




图 4-7 双臂人机大箱型物体交接系统硬件组成

4.5.2 给予者运动轨迹预测算法实验

实验参与者 4 名，模式 2 个：给予者规则和不规则运动模式。首先，要求每个参与者用规则运动模式进行 5 次试验，以初始化人手运动轨迹模型和交接位置模型。然后，他们进一步被要求使用规则运动模式进行 10 次试验，通过增量式 EM 算法更新模型。在模型的学习过程中，时刻关注模型预测性能的变化。模型学习完成后，使用模型进行 5 次不规则运动模式试验，以测试模型应对不规则运动模式的能力。

预测过程中使用的关键参数汇总在表 4-2 中。将“等待时间”定义为人类和协作机器人到达交接位置的时间间隔。对于给予者规则运动模式试验，参与者 1 从起始位置到交接位置的第 10 次试验预测结果如图 4-8 所示。最终预测误差小于 0.015m，可以有效证明该运动预测算法可以对人类给予者规则运动模式进行有效预测。此外，计算了从起始位置到交接位置的实际轨迹和

预测轨迹之间的 RMSE，以及每个参与者每次试验的“等待时间”，如图 4-9-(a)和图 4-9-(b)所示，以测试所提出的在线学习算法的效果。在图 4-9-(a)和图 4-9-(b)，图中横坐标为模型在线更新的次数，而虚线和实线分别代表参与者左手和右手的结果。预测误差的 RMSE 和每个参与者的“等待时间”都显著降低到小于 0.04m 和 1.3s。可以看出，在一定范围内，试验次数越多，RMSE 和“等待时间”越小。因此，这两个指标可以有效地说明所提出的在线学习算法可以在一定程度上提高运动预测算法性能。

对于不规则运动模式试验，预测过程如图 4-10 所示。图 4-10-(a)表明当参与者没有交接意图时，预测结果不满足条件。如图 4-10-(b)所示，一旦参与者有交接意图，预测结果将满足条件，协作机器人将快速响应参与者。综上所述，实验结果证实，该系统可以基于相同的参数响应多个给予者的规则和不规则运动模式。

表 4-2 人手运动轨迹预测相关参数汇总

| 参数名                   | 参数值     |
|-----------------------|---------|
| 测量采样时间间隔 $\Delta t$   | 0.1 秒   |
| 预测时间步长上限 $T_p$        | 40      |
| GMM 算法成分数 $M$         | 15      |
| 任务空间维度 $n$            | 3       |
| GMR 算法自回归阶数 $d$       | 3       |
| 人手运动速度阈值 $v_{th}$     | 0.1 米/秒 |
| 预测 RMSE 误差阈值 $b_{th}$ | 0.15 米  |
| EM 算法遗忘因子 $\beta$     | 0.8     |




图 4-8 参与者 1 规则运动模式下左右手从开始位置到交接位置的第 10 次试验预测结果




图 4-9 参与者规则运动模式轨迹预测




图 4-10 参与者不规则运动模式轨迹预测




图 4-11 接收者模仿学习运动规划算法实验结果

### 4.5.3 接收者模仿学习运动规划算法实验

在协作机器人抓取大箱型物体的过程中, 预先收集了 50 组末端执行器专家轨迹。使用 DS-KMP 算法生成两个末端执行器的期望轨迹。其中 DS-KMP 算法的关键参数总结在表 4-3 中。图 4-11-(a)展示了协作机器人接收操作两个末端执行器的专家轨迹, “•”和“\*”分别标记了专家轨迹的起点和终点。图 4-11-(b)展示了 GMR 算法生成的两个末端执行器的概率专家轨迹和两个末端执行器的 DS-KMP 算法学习轨迹, 其中“•”、“\*”和“×”分别标记了各种轨迹的起点、终点和经过点。可以看出, DS-KMP 算法学习轨迹到达了交接操作的新终点, 并且保持了专家轨迹的形状。此外, DS-KMP 算法学习轨迹通过了新的经过点。因此, 可以证明 DS-KMP 算法可以以时间作为输入自适应地模仿学习技能。需要说明的是, DS-KMP 算法接收技能学习系统根据最新预测的交接位置, 实时生成 DS-KMP 算法学习轨迹。

表 4-3 DS-KMP 算法接收技能学习相关参数汇总

| 参数名            | 参数值                                                    |
|----------------|--------------------------------------------------------|
| 测量采样时间间隔       | 0.001 秒                                                |
| 模仿轨迹时间步长       | 5000                                                   |
| 模仿轨迹时间间隔       | 0.001 秒                                                |
| 任务空间维度         | 3                                                      |
| GMM 算法成分数量 $K$ | 4                                                      |
| EM 算法遗忘因子      | 0.8                                                    |
| DS-KMP 算法核函数   | 高斯核 $K(t_i, t_j) = \exp\left(-l\ t_i - t_j\ ^2\right)$ |
| DS-KMP 算法超参数   | $l = 2, \lambda_1 = \lambda_2 = 1$                     |

4.5.4 双臂抓取控制算法实验

表 4-4 轨迹跟踪控制相关参数汇总

|       | Left arm |           |             |       | Right arm |           |             |       |
|-------|----------|-----------|-------------|-------|-----------|-----------|-------------|-------|
|       | $K_D$    | $\Lambda$ | $\lambda_0$ | $k_0$ | $K_D$     | $\Lambda$ | $\lambda_0$ | $k_0$ |
| $W_0$ | 2.2      | 18.0      | 10.0        | 0.4   | 2.5       | 18.1      | 10.0        | 0.4   |
| $W_1$ | 2.2      | 25.5      | 10.0        | 0.4   | 2.4       | 25.2      | 10.0        | 0.4   |
| $W_2$ | 5.1      | 10.5      | 6.0         | 0.5   | 5.6       | 10.4      | 6.0         | 0.5   |
| $E_0$ | 5.0      | 20.1      | 0.5         | 10.0  | 5.3       | 20.1      | 0.5         | 10.0  |
| $E_1$ | 5.5      | 15.3      | 0.5         | 10.0  | 5.3       | 15.3      | 0.5         | 10.0  |
| $S_0$ | 15.2     | 30.2      | 0.5         | 10.0  | 15.1      | 30.4      | 0.5         | 10.0  |
| $S_1$ | 22.2     | 15.2      | 0.5         | 10.0  | 22.3      | 15.3      | 0.5         | 10.0  |

在预抓取过程中，使用提出的 ANN-F 控制器来跟踪在线规划结果（DS-KMP 算法模仿学习轨迹）。对于提出的 ANN-F 控制器(3-47)的第一项是 PD 控制器，使用神经网络来学习不确定动力学模型，并作为控制系统的前馈补



偿。选择的控制增益  $K_D$ 、 $\Lambda$  以及神经网络参数  $\lambda_0$ 、 $k_0$  如表 4-4 所示。确定了合适的神经网络隐层节点数 35。径向基函数的中心和展开常数分别定义为从  $-3\pi/5$  到  $3\pi/5$  中均匀选择和 0.25。 $w_{i,i=1,2,\dots,7}$  的初始值为  $\text{node} \times 1$  矩阵，每个矩阵由来自  $[-1,1]$  的随机数组成。初始值  $p_{i,i=1,2,\dots,7}(0)$  分别为 (0.2, 0.2, 0.2, 5.0, 5.0, 5.0, 5.0)。

为了比较 ANN-F 控制器和 PD 控制器的性能，保持所有的期望轨迹和初始条件相同。图 4-12-(a)和图 4-12-(c)是在关节空间中的跟踪性能。虚线是期望轨迹 (DS-KMP 算法学习轨迹)。实线是实际轨迹。尽管尽最大努力调整合适的参数，仍然无法通过 PD 控制器实现很好地跟踪。基于 PD 控制器的双臂跟踪误差如图 4-12-(b)所示，小于 0.075rad。然而，基于 ANN-F 控制器的双臂跟踪误差如图 4-12-(d)所示，小于 0.04rad。因此，可以得出结论，所提出的 ANN-F 控制器(3-47)的性能优于 PD 控制器的性能。可以确认 ANN-F 控制器可以更好地实现轨迹跟踪。




图 4-12 ANN-F 控制器与 PD 控制器的性能比较

在双臂抓取控制过程中，设置  $\zeta_f = 0.15$ ，期望的“挤压”力  $F_0^d = 7N$ 。

图 4-13 显示了所提出的控制器可以将“挤压”力稳定地保持在期望力左右。




图 4-13 “挤压”力稳定跟踪效果

4.5.5 讨论

人类运动预测的实验结果证实，在相同参数下，该系统可以同时响应多个给予者的规则和不规则运动模式，提出的在线学习算法可以在一定程度上提高预测性能。因此，可以显著提高交接操作的效率。基于接收技能模仿学习实验可以看出，DS-KMP 算法可以以时间作为输入自适应地模仿学习技能。而且，DS-KMP 算法学习轨迹可以根据最新预测的交接位置进行实时轨迹调制，并保证通过新的经过点。这确保了人类给予者可以在人对协作机器人的交接操作中柔顺、自然地工作。在双臂抓取控制实验中，实验结果可以证实所提出的 ANN-F 控制器可以更好地实现协作机器人轨迹跟踪。它还证明了所提出的双臂抓取策略、双臂抓取控制和扩展的夹持器可以实现稳定的抓取。完整的实验证实了所提出的物体交接系统可以自然高效地完成人对协作机器人的大箱型物体交接任务，如图 4-14 所示。



图 4-14 完整的人对协作机器人的大箱型物体交接实验过程

还应该注意的是，Baxter 协作机器人的负载非常有限，这使无法基于



Baxter 交接更大、更重的物体。在这些交接实验中，还发现，在协作机器人切换控制模式（轨迹跟踪控制模式切换到速度控制模式）的那一刹那，Baxter 会出现一次抖动。为了更好地发挥系统的性能，将在性能更优的双臂协作机器人（例如 Universal Robot）上部署该系统。

## 4.6 本章小结

本章将改进的协作机器人模仿学习运动规划与轨迹跟踪控制算法应用于人与协作机器人双臂大箱型物体交接任务中。参考人与人双臂自然交接过程，研究并设计了高效、自然的人与协作机器人双臂大箱型物体交接系统。人类研究的结果包括人与人双臂交接过程和人类接收者的接收动作统计。将概率模型算法与在线学习算法相结合来预测交接任务的开始和交接位置。实验结果证实，该系统可以响应给予者的规则和不规则交接运动模式，提出的在线学习算法可以在一定程度上提高预测性能，显著提高交接操作的效率。应用基于概率模型的模仿学习 DS-KMP 算法，根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能，并满足安全约束，以确保人类给予者能够在人与协作机器人的交接操作中柔顺自然地工作。然后，使用提出的 ANN-F 控制器来跟踪在线运动规划结果（DS-KMP 算法）。实验结果可以证实，所设计的在线运动规划 DS-KMP 算法具有优秀的性能，提出的 ANN-F 控制器可以更好地实现协作机器人轨迹跟踪。此外，提出了双臂抓取策略，设计了双臂抓取控制，并扩展了 Baxter 协作机器人的末端执行器以实现稳定的抓取。实验结果表明，所提出的分步控制方案（感知决策层、运动规划层、控制执行层）和基于 Baxter 协作机器人硬件平台可以实现人对协作机器人大箱型物体的自然、高效的交接任务。

## 5 智能化化学合成协作机器人系统研究

本章设计了一个基于视觉辅助的智能化化学合成协作机器人系统。系统包括了一个基于 UR3 协作机器人和双目 RGB 相机的通用、可扩展的自动化化学合成硬件平台，一个用于模仿学习运动规划算法训练的虚拟仿真平台，以及一个基于分步控制方案（环境感知层、运动规划层和控制执行层）的软件系统。对于运动规划层，利用改进的 ACGAIL 算法避免模态崩塌。通过 WGANs-GP 算法用于解决梯度消失问题。通过经验重放池来提高历史样本的利用率。引入奖励增强项，引导生成策略超越专家策略。从而实现对一些复杂任务的高效、合理的运动规划。进一步地，通过一系列实验对所提出的智能化化学合成系统和改进的 ACGAIL 算法进行了测试。最后，部署所设计的基于视觉辅助的协作机器人智能化化学合成系统，进行高分子聚合体系实验研究，为化学合成智能化奠定基础。

### 5.1 智能化化学合成协作机器人系统设计

近年来，自动化化学合成系统有了新的发展，由只能进行某个或某类化学反应的专一系统发展到能够自主完成实验设计-化合物合成-产物表征的闭环系统。设计了一个基于视觉辅助的智能化化学合成协作机器人系统，如图 5-1 所示。其中，设计并搭建了以 UR3 协作机器人为中心配备双目 RGB 相机的通用的、可扩展的自动化化学合成硬件平台，实现树脂材料筛选。为了提高系统性能，还设计并搭建了用于模仿学习运动规划算法训练的虚拟仿真平台，以及基于分步控制方案（环境感知层、运动规划层和控制执行层）的软件系统，以确保智能性、准确性和实时性。在运动规划层，使用改进的 ACGAIL 算法，实现复杂任务的高效、合理的运动规划。

设计的智能化化学合成系统流程可分为准备阶段、监测阶段以及处理阶段。在准备阶段，协作机器人通过末端相机识别并抓取实验台试管架上的装有反应体系的试管，移至泵阀系统添加反应催化剂再转运至磁力搅拌器上，之后，协作机器人打开磁力搅拌器以开始聚合反应；在聚合过程中，凝胶化的树脂会使磁子运动受限，使用相机采集聚合过程中监测区域的图像，再根据图像像素变化，判断是否到达了聚合反应凝胶点。通过监测，发现在到达聚合反应凝胶点时，磁子会因受到不平衡的外力发生无规则的剧烈运动，在该阶段图像像素同样会发生剧烈波动，以此作为凝胶点的信号，对凝胶点采集的误差可以在满足条件的时间范围内。因此，在监测阶段，当视觉识别算法监测

到开始搅拌时，蓝光 LED 被打开并开始计时。当视觉识别算法监测到体系凝胶化时，停止计时，关闭蓝光 LED 并识别记录所得凝胶的颜色信息。利用计算机视觉监测智能地判断体系凝胶化的发生并记录凝胶点，从而避免了人的观察，大大提高了判断的准确性和实验的可重复性。然后，将反应后的试管转运至试管回收架；在处理阶段，机器学习算法根据凝胶时间和颜色信息推荐配比。




图 5-1 智能化化学合成协作机器人系统

### 5.1.1 硬件平台设计

设计了自动化化学合成硬件平台。UR3 协作机器人非常适合自动化作业台等应用场合。其编程简单、安装快捷、部署灵活、可与人协同工作、协作性与安全性高。因此，本研究选用 UR3 协作机器人，并在末端加装 Robotiq 2F-85 二指自适应夹持器，该二指夹持器可以轻松对位置、速度和力度进行编程。UR3 协作机器人的末端执行器配备了 500 万像素 720P 分辨率双目 RGB 相机。最终整个化学合成实验平台如图 5-2 所示。在实验台上，部署了两组试管架，并放置着若干试管。试管架 1 主要用于各种溶液试剂的混合，当溶液混合完成后，试管被从试管架 1 转运到试管架 2。在试管架 2 下，放置着一台磁力搅拌器，它主要用于搅拌混合的溶液试剂，以促进化学合成反应的

进行。该平台可以完成多种化学操作，包括：在 UR3 协作机器人末端携带移液枪，实现液体试剂混合，更换移液枪头、实现试管转运等，具有很强的扩展性。




图 5-2 自动化化学合成硬件平台

5.1.2 仿真平台设计

由于基于生成模型的模仿学习运动规划算法在学习阶段表现不佳，因此，如果直接使用协作机器人去训练算法，可能会对协作机器人造成损伤。故设计了一个如图 5-3 所示的试管转运仿真平台，用于训练基于生成模型的模仿学习运动规划算法，该算法在虚拟仿真平台中训练到接近最优策略时应用于真实物理系统。仿真平台基于 MuJoCo 200。相关环境相关配置为 Python 3.7、TensorFlow 1.14、MuJoCo-py 1.50，计算机系统版本为 Ubuntu 18.04。在仿真平台中，使用所提出的 ANN-R 控制器实现 UR3 协作机器人高精度轨迹跟踪。

5.1.3 软件系统设计

软件系统框架主要分为三个部分：环境感知层、运动规划层和控制执行层。环境感知层确定 UR3 协作机器人在任务空间中的目标状态  $\bar{q}_E^o$ 。试管难以识别和定位。由于试管是透明的，且试管中的液体大多是透明的，导致深度信息无法获得，因此 RGB-D 相机不适用。故该系统考虑了 RGB 双目像机。



由于试管架和 UR3 协作机器人之间的位置是相对固定的，且试管孔的位置是固定的。试管定位可以通过图像识别出目标试管所处试管架的位置编号，再通过对对应表查询得到目标位置。这可以降低管道识别和定位的难度。检测结果如图 5-4 所示。试管位置检测算法流程：拍摄 10 张不含试管的试管架图片用作模板，并对十张模板图片取均值得到均值模板图片。基于高斯滤波算法对均值模板图片滤波处理，并转换成灰度图像。基于 OTSU 自适应二值化算法对滤波后的均值模板图片进行二值化。读取相机视频流中的一帧目标图像，重复上述预处理过程，得到滤波后的二值图像。对二值化后的模板图像和二值化后的目标图像进行求差处理，得到差值图。基于图像形态学算法对差值图进行处理，去除噪声和修复差值图中的缺陷。基于轮廓检测算法，检测差值图中的目标试管轮廓，并过滤掉噪声轮廓。根据轮廓检测结果，进行位置匹配，最终得到试管的位置。




图 5-3 自动化化学合成仿真平台




图 5-4 RGB 像机图像识别目标试管，判断目标试管所处试管架的位置编号

并且, 选用合适的相机对反应体系进行监测, 测定体系凝胶化的发生并记录凝胶点的成本低, 相机采集的数据相较人类观察者会具有更高的平行性, 提高了信息采集准确性和效率, 如图 5-5 所示。




图 5-5 视觉检测反应体系

对于运动规划层, 首先, 使用传统的运动规划算法来规划生成专家轨迹, 并用这些轨迹训练改进的 ACGAIL 算法, 实现 UR3 协作机器人模仿学习运动规划。

控制执行层是为了跟踪运动规划层的结果以完成任务。在本系统中, 使用 ur-rtde 1.5.1 控制接口来完成对 UR3 协作机器人的控制。试管和试管架之间有很强的约束。如果 UR3 协作机器人仅跟踪轨迹, 则不足以完成高精度试管传输任务。插拔试管的过程要求高精度, 一旦出现小误差, 任务就会失败。须要通过在 UR3 协作机器人的末端安装一个高精度六轴力传感器, 根据导纳控制器校正和协调试管与试管架之间的相对位置。

## 5.2 改进的带有辅助分类器的生成式对抗模仿学习算法应用

针对 GAIL 算法的不足, 提出 ACGAIL 算法, 基于专家轨迹学习专家策略, 避免模态崩塌, 实现一些复杂任务的运动规划功能。此外, 还提出了改进策略: 使用 WGANs-GP 算法避免梯度消失, 使用经验重放池提高过去样本的利用率, 引入奖励增强项来引导生成策略超越专家策略。

### 5.2.1 专家轨迹数据集建立

专家轨迹的收集对于模仿学习十分重要。专家轨迹数据集的质量将直接影响算法训练。假设有一组  $n$  个意图  $C = \{c_1, \dots, c_m, \dots, c_n\}$ ,  $c_m$  表示第  $m$  个专家意图, 它服从先验概率  $c_m \sim p(c)$ 。在本文中, 任务集为  $C = \{c_1, c_2\}$ , 即抓取试管并运送试管。采用传统的运动规划算法, 规划生成专家轨迹。然后, 使用 `ur-rtde 1.5.1` 控制接口跟踪专家轨迹, 同时使用接收接口在固定频率下采样 UR3 关节角度  $q_E^i$ 。专家轨迹的每个状态-动作对的状态可以表示为  $s_E^i = (q_E^i; c_m^i; q_E^o)^T$ , 其中  $q_E^o$  是 UR3 协作机器人在关节空间的目标状态,  $c_m^i$  是任务编号。专家轨迹的每个状态-动作对的动作可以表示为  $a_E^i = (q_E^{i+1}; c_m^{i+1})^T$ 。于是, 一条完整专家轨迹数据可表示为  $\{(s_E^1, a_E^1, t^1), \dots, (s_E^i, a_E^i, t^i), \dots, (s_E^T, a_E^T, t^T)\}$ 。大量得专家轨迹数据构成了专家轨迹数据集。

### 5.2.2 改进的带有辅助分类器的生成式对抗模仿学习算法实现

提出了一种改进的 ACGAIL 算法。该算法的整体架构如图 2-11 所示。首先, 随机初始化网络参数, 并设置批大小、经验重放池大小, 各模块自循环次数: 判别模块为  $M$  次, 生成模块为  $N$  次, 以及一些超参数。使用初始化策略  $\pi_\theta$  进行任务, 采集得到轨迹并将其压栈入经验重放池中 (第 2-4 行)。从经验重放池中均匀采样生成样本, 并用来更新判别器和分类器参数 (第 5-8 行)。接下来, 固定判别器参数和分类器参数, 并使用 PPO 算法更新生成模块 (第 9-11 行)。

## 5.3 实验设计与结果分析

### 5.3.1 实验设计

为了验证改进的 ACGAIL 算法的性能, 本节设计了一个基于自动化化学合成硬件平台的专家轨迹模仿学习运动规划实验, 实验过程如图 5-6 所示。混合液体试剂后, UR3 首先从初始位置  $Q$  开始移动到位置  $A$  进行试管目标位置识别, 并在那里停留 10s, 等待图像识别程序完成。试管定位可以通过 RGB 双目相机图像识别出目标试管所处试管架上的位置编号, 然后通过查询表的方式得到目标位置。当 UR3 接收到识别完成信号后, 会回到初始位置  $Q$ ,



然后再移动到识别出的目标位置 B，抓取反应试管，并将其从试管架 1 位置 B 转运到试管架 2 位置 C。接着，UR3 会打开磁力搅拌器，以开始聚合反应。利用计算机视觉监测智能地判断体系凝胶化的发生并记录凝胶点。然后，将反应后的试管转运回位置 B。

在第二章中，介绍过模仿学习运动规划算法框架。在本任务中，采集专家轨迹，并将其分为两种模态，如图 5-7 所示。模态 1 是试管抓取过程。协作机器人从初始位置 Q 移动到目标试管位置 B。在此过程中，由于试管位置的不同，每次实验将随机设定不同的终止点 B。模态 2 是试管转运过程。试管被从位置 B 转运到位置 C。每次开始点 B 也不同。

此外，共设置了四个不同的位置 B，即试管 5-8。对于不同的位置 B 与不同模态，分别采集了 10 条轨迹，每条轨迹的采样间隔为 0.002s，以满足 500Hz 的控制频率。专家轨迹总数量为  $2 \times 4 \times 10 = 80$  条。每条轨迹包括了当前协作机器人六自由度关节角状态、当前协作机器人末端执行器六自由度位姿状态、下一时刻协作机器人六自由度关节角动作、当前任务模态以及当前任务目标位置信息，这六种数据。之后的专家轨迹模仿学习运动规划实验可以根据所需从中提取需要的信息。



图 5-6 基于自动化化学合成硬件平台的模仿学习运动规划实验流程




图 5-7 采集的两种模态的专家轨迹

5.3.2 实验结果分析

采用改进的 ACGAIL 算法实现专家轨迹模仿学习运动规划。该算法的生成模块根据当前协作机器人六自由度关节角状态生成下一时刻协作机器人六自由度关节角动作。具体参数设置如表 5-1 所示。需要特别说明的是奖励增强项，最终选择了包括：距离惩罚、转矩惩罚和任务失败惩罚。任务失败惩罚意味着在任务失败后，将受到很大的惩罚。在表 5-1 中，当任务失败时，惩罚值为[1000]，当任务成功时，惩罚值为[0]。

表 5-1 ACGAIL 轨迹学习相关参数表

| 参数名                                            | 参数值                                              |
|------------------------------------------------|--------------------------------------------------|
| 生成模块隐层                                         | 2 层×100 个神经元                                     |
| 判别器/分类器隐层                                      | 2 层×100 个神经元                                     |
| 判别器/分类器自循环次数 M                                 | 4                                                |
| 生成模块自循环次数 N                                    | 1                                                |
| 激活函数                                           | tanh 函数                                          |
| 经验重放池大小                                        | 1024                                             |
| 超参数 $\lambda, \lambda_c, \lambda_H, \lambda_R$ | 0.04, 0.5, 0.005, 0.6                            |
| 奖励增强函数 R                                       | $R = R_1 + R_2 + R_3, R_3 = \lambda_3 [0; 1000]$ |

首先，在 MuJoCo 仿真平台中训练所提出的改进的 ACGAIL 算法。经过 5000 次训练，使得平均奖励回报值稳定以及损失值收敛后，将算法模型移植到实际环境中。这时，损失值会有一个较大的提升，随后再逐渐降低。

图 5-8 显示了改进的 ACGAIL 算法在关节空间中的性能，虚线左侧是模态 1 的轨迹，右侧是模态 2 的轨迹。可以看出，改进的 ACGAIL 算法实现了对专家轨迹的模仿学习，具有很好的轨迹特征保持特性。





图 5-8 改进的 ACGAIL 算法在关节空间的模仿学习性能

与传统 ACGAIL 算法相比，改进的 ACGAIL 算法提升了 9.6%的任务成功率，任务成功率达到到了 99.1%。造成任务失败的主要原因是将试管插入试管架，由于将试管插入试管架的过程需要很高的精度，在这个过程中，试管和试管架之间有一个很强的约束，而一旦有微小的误差，都会导致试管无法插入试管架。如果 UR3 协作机器人仅跟踪轨迹，则不足以完成高精度试管传输任务。所以，校正和协调试管与试管架之间的相对位置是十分有必要。由



于采用了分步控制方案,可以通过在控制执行层 UR3 协作机器人的末端安装高精度六轴力传感器来使用导纳控制器。

5.4 智能化化学合成协作机器人系统实施








图 5-9 基于视觉的协作机器人 10 管 1 组自动化闭环的树脂材料筛选系统运行过程

在本工作中，设计并搭建了一个以协作机器人为中心的自动化实验平台，结合计算机视觉监测，首次实现了对光引发共聚体系凝胶化时间点及凝胶体系状态的智能识别。在机器学习算法的帮助下，该系统可实现闭环的聚合条件筛选以得到具有特定凝胶点和颜色的凝胶材料。

该系统包含协作机器人、2 套 10 管 1 组试管架、泵阀系统、磁力搅拌台、相机以及蓝光 LED。在软件上，协作机器人和相机均与电脑直接连接，而泵阀系统和蓝光 LED 则通过 Arduino 板与电脑连接。通过 Python 程序，这些组件均可实现独立的操控，进而可以组合实现特定的实验流程。图 5-9 展示了基于视觉的协作机器人 10 管 1 组自动化闭环的树脂材料筛选系统运行过程。为实现自动化的聚合条件筛选，为该系统制定了一个工作流程。图 5-9-(1)到图 5-9-(11)展示了一个反应体系试管的完整实验操作流程。该流程主要分为三个部分：准备、监测以及处理。在准备阶段，图 5-9-(1)到图 5-9-(6)，

协作机器人通过末端相机识别并抓取实验台 10 管 1 组试管架上的装有反应体系的试管，移至泵阀系统添加反应催化剂再转运至磁力搅拌器上，之后，协作机器人打开磁力搅拌器以开始聚合反应；在监测阶段，图 5-9-(7)到图 5-9-(11)，当视觉识别算法监测到开始搅拌时，蓝光 LED 被打开并开始计时。当视觉识别算法监测到体系凝胶化时，停止计时，关闭蓝光 LED 并识别记录所得凝胶的颜色信息，将反应后的试管转运至 10 管 1 组试管回收架；在处理阶段，机器学习算法根据凝胶时间和颜色信息推荐配比。图 5-9-(12)到图 5-9-(30)展示了 1 组 10 管中剩余 9 管的完整实验操作流程。

利用该平台，自动筛选了一类具有特定凝胶化时间和颜色的牙科树脂材料。在控制聚合单体浓度，引发条件及环境因素不变的条件下，针对两种加成-碎裂化链转移试剂的加入浓度进行条件筛选，发现，对于合计超过 650 种聚合条件的反应空间，该系统能够在少于 30 次的条件筛选中得到符合要求的，具有特定凝胶化时间和颜色的聚合体系。在改变初始反应条件和时间颜色目标的控制组中，该系统仍然能够实现相同的筛选效率和优化结果。另外，利用相同的工作循环，成功收集了 8 种具有类似结构的加成-碎裂化链转移试剂对于相同聚合体系凝胶点的推迟效果，时间结果显示出的试剂分子结构与作用功效之间的关系与此前文献报道的结果吻合。

## 5.5 本章小结

为了实现化学合成智能化目标，减少化学家繁重的人力劳动，本章设计了一个基于视觉辅助的智能化化学合成协作机器人系统。其中，设计并搭建了一个通用、可扩展的自动化化学合成硬件平台，该平台基于 UR3 协作机器人和双目 RGB 相机，可以完成多种化学操作，包括：在 UR3 协作机器人末端装配移液枪实现液体试剂混合、实现移液枪枪头更换、转运试管等操作。然后，设计并搭建了一个试管转运仿真平台，用于基于生成模型的模仿学习运动规划算法的训练，该算法在虚拟仿真平台中训练到接近最优策略时应用于真实物理系统。在仿真平台中，使用所提出的刚体关节协作机器人自适应神经网络轨迹跟踪控制器（ANN-R 控制器）实现 UR3 高精度轨迹跟踪。接着，提出了一种分步控制方案，主要分为三个部分：环境感知层、运动规划层和控制执行层。在化学合成操作中，对于包含多个步骤和意图的化学合成任务来说，单模态模仿学习运动规划算法性能不足，当专家轨迹具有多个模态分布时，很容易导致模态崩塌。因此，对于运动规划层，使用改进的 ACGAIL 算法学习专家轨迹，并模仿专家策略进行运动规划。进一步地，通过一系列实验对所提出的自动化化学合成硬件平台和改进的 ACGAIL 算法进行了测



试。实验结果表明,该硬件平台和改进的 ACGAIL 算法具有优秀的性能。

最后,部署所设计的基于视觉辅助的协作机器人智能化化学合成系统,进行高分子聚合体系实验研究。目前已实现包括移液、装换枪头、试管抓取及试管转运等多种操作。任务成功率接近 99.1%,满足北京大学化学系的日常实验需求,为化学合成智能化奠定基础。该工作是国内首个利用协作机器人自动化平台通过视觉辅助的方法对高分子聚合体系的探索研究。利用视觉检测,该平台能够智能的判断体系凝胶化的发生并记录凝胶点,从而避免了人的观察,提高了准确性和可重复性。通过引入机器学习算法,能够在尽可能少的条件筛选中进行条件优化,从而节省了实验的试剂和时间成本。该平台仍具有很强的拓展性,可以用于其它类似的反应场景,如催化剂降解,聚合发光体系等可以借助或依赖视觉辅助的研究中。该工作是由北京科技大学与北京大学合作完成的。该系统的设计为今后开发类似的以协作机器人为中心的智能化化学合成实验系统积累了宝贵经验。

## 6 结论与展望

### 6.1 论文工作总结

本文针对协作机器人的模仿学习运动规划与轨迹跟踪控制展开了深入的研究,取得了以下创造性研究成果,包括:

1) 提出了两种改进的模仿学习运动规划算法。将 DMP 算法的拓扑等价性引入 KMP 算法,提出了将 KMP 算法与 DMP 算法相结合的 DS-KMP 算法,以解决 KMP 算法难以进行整体轨迹调制的问题。通过对比实验,验证了 DS-KMP 算法能实现轨迹起始点、经过点、终止点约束,拓扑不变性,以及轨迹特征调整。因此,证明了该算法性能的优越。此外,还提出了改进的 ACGAIL 算法,以解决生成式对抗模仿学习算法存在的模态崩塌、梯度消失和专家轨迹利用效率低等问题。实验证明,改进的 ACGAIL 算法能够有效地学习到多种模态专家策略,并复现出类似于专家轨迹的手写字母轨迹。解决了协作机器人复杂非结构化环境下,高难度任务中,面临的运动规划难的问题。

2) 提出了针对高刚度柔性关节协作机器人的一种自适应神经网络高精度轨迹跟踪控制器(ANN-F 控制器)。根据奇异摄动理论,ANN-F 控制器只需要连杆角位移、连杆角速度和柔性结构扭矩的反馈信号,因此具有很高的实用性。其使用神经网络处理协作机器人动力学中的不确定性问题。为了进一步保证协作机器人轨迹跟踪控制的安全性和精度,在满足输出约束的同时,其通过自适应方法同时消除了神经网络的近似误差和外部扰动转矩。通过李雅普诺夫稳定性分析,所提出的 ANN-F 控制器还可保证系统达到指数稳定。通过轨迹跟踪实验结果表明,所提出的 ANN-F 控制器对高刚度柔性关节协作机器人轨迹跟踪具有更好的控制性能。解决了由于高刚度柔性关节协作机器人关节刚性较低导致重复定位精度较差,所面临的高精度轨迹跟踪控制的难题。

3) 设计人与协作机器人双臂交接系统。交接操作的效率及自然性须被提高,就像在两个人之间进行交接一样。为了提高效率,将基于概率模型的模仿学习运动规划 GMR 算法与在线学习算法相结合来预测交接任务的开始和交接位置。在线更新概率模型不仅可以处理人类给予者的规则运动模式,还可以处理他们的不规则运动模式。然后,为了保证人类给予者可以自然地执行交接操作,应用基于概率模型的模仿学习运动规划 DS-KMP 算法,根据人类给予者运动轨迹的在线预测结果来自适应地学习物体接收技能,并满足安

全约束。此外,还设计了双臂抓取策略和控制,以保证稳定的抓取。最后,将此交接系统装备在 Baxter 协作机器人上,并扩展了夹持器,使其更适合双臂交接操作。实验结果表明,所提出的交接系统可以自然地、高效地解决人与协作机器人双臂交接操作。

4) 设计了一个基于视觉辅助的智能化化学合成协作机器人系统。其中,设计并搭建了一个通用、可扩展的自动化化学合成硬件平台,该平台基于 UR3 协作机器人和双目 RGB 相机,可以完成多种化学操作。然后,设计并搭建了一个试管转运仿真平台,用于基于生成模型的模仿学习运动规划算法的训练,该算法在虚拟仿真平台中训练到接近最优策略时应用于真实物理系统。进一步,提出了一种分步控制方案,主要分为三个部分:环境感知层、运动规划层和控制执行层。对于运动规划层,使用改进的 ACGAIL 算法学习专家轨迹,并模仿专家策略进行运动规划。最后,部署所设计的基于视觉辅助的协作机器人智能化化学合成系统,使用改进的 ACGAIL 算法进行化学合成协作机器人运动规划,进行高分子聚合体系实验研究。目前已实现包括移液、装换枪头、试管抓取及试管转运等多种操作。任务成功率接近 99.1%,满足北京大学化学系的日常实验需求,为化学合成智能化奠定基础。

虽然本文取得了一些研究成果,但是本文的研究尚有一些有待完善与提升的空间,需要进一步的研究,包括:

1) 本文虽然提出了 DS-KMP 算法,在很大程度上改善了 KMP 算法在整体轨迹调制方面的算法性能。但是,由于算法流程冗长,可能会导致累积误差和数据失真,影响算法的性能。因此,如何在有效缩减算法处理流程的基础上确保算法性能,是之后研究的重点。

2) 本文对模仿学习运动规划算法的性能评估是通过实验结果图做了定性的分析,而没有提出一些性能指标对其做定量的分析。对模仿学习运动规划算法的性能做定量分析是一个有意义的研究方向。在未来工作中,会考虑对模仿学习运动规划算法的性能做定量分析与评估。

3) 在实验中,虽然奖励增强技术能够加速模仿学习运动规划算法收敛,但未能证明能够指导生成策略超越专家策略。因此,未来需要进一步的实验来证明这一点。

4) 在实际应用中,插拔试管的过程要求高精度,一旦出现小误差,任务就会失败。须要通过在 UR3 协作机器人的末端安装一个高精度六轴力传感器,根据导纳控制器校正和协调试管与试管架之间的相对位置。未来会在 UR3 协作机器人的末端安装一个高精度六轴力传感器,根据导纳控制器校正和协调试管与试管架之间的相对位置,进一步提高任务成功率。

## 6.2 论文工作展望

展望未来，将进一步地与北京科技大学新材料技术研究院深度合作，应用所研究协作机器人运动规划与控制算法于材料制备智能化协作机器人系统中。现阶段已完成部分工作，包括：设计并部署了北科大材料制备智能化协作机器人基础硬件平台（如图 6-1 所示）、仿真平台以及软件系统。协作机器人系统所选用的主要设备及具体参数如下：工作台尺寸：1400mm\*1400mm；选用 UR3 协作机器人，其有效负载 3kg，工作半径 500mm；在 UR3 协作机器人末端加装了 Robotiq 2F-85 二指自适应夹持器，该二指夹持器可以轻松对位置、速度和力度进行编程。面向材料样品涂层制备与转运任务，针对小且薄金属基材夹取与防水问题，设计并研发了一款柔性二指夹持器。基材制备实验完成后，将制备好的金属基材放置于水滴角检测平台上进行后续检测实验。材料样品疏水角检测（难点在于：液滴小且透明，平台需要调水平等）。设计并研发了金属基材表面疏水角检测装置，最终版本基于工业显微摄像头（高清 CCD 相机）配合亮度可调补光灯与水平调整台，解决液滴小且透明，平台需要调水平等难题，通过视觉反馈测量金属基材的亲疏水角，指导新材料制备。研究并部署了水滴角视觉检测算法，识别精度在正负 2 度左右。




图 6-1 北科大材料制备智能协作机器人总体硬件平台






图 6-2 基于 UR3 协作机器人基材表面聚电解质涂层制备层层自组装闭环方案

研究并设计材料制备智能机器人系统闭环方案。理论上实现通过 UR3 协作机器人基材表面聚电解质涂层制备层层自组装闭环方案。实验过程如图 6-2 所示。在实验过程中, 协作机器人首先确定目标金属基材位置, 通过研发的柔性二指夹持器柔性抓取目标金属基材。图 6-2-(b)左上角为高清显微相机拍摄画面。然后, 机械臂进行基材制备操作, 将金属基材浸入聚阳离子溶液中,

沉积一段时间后取出，完成聚阳离子材料在金属基材表面的镀膜。图 6-2-(c)与图 6-2-(d)左上角显示的为该系统仿真平台。接着，机械臂将金属基材浸入去离子水中，将金属基材表面残留的聚阳离子溶液清洗后取出。进一步地，将金属基材浸入聚阴离子溶液中，沉积一段时间后取出，完成聚阴离子材料在金属基材表面的镀膜。而后，机械臂将金属基材浸入去离子水中，将表面残余的聚阴离子溶液清洗干净后取出。基材制备实验完成后，将制备好的金属基材放置于水滴角检测平台上进行后续检测实验。图 6-2-(g)左上角为高清显微相机检测画面。

进一步地，还研究并设计了泵阀液体试剂混合系统，为材料制备智能机器人系统闭环奠定基础。





## 参考文献

- [1] Wensing P M, Wang A, Seok S, et al. Proprioceptive actuator design in the mit cheetah: Impact mitigation and high-bandwidth physical interaction for dynamic legged robots[J]. IEEE Transactions on Robotics, 2017, 33(3): 509-522.
- [2] Tsagarakis N G, Caldwell D G, Negrello F, et al. Walk-man: A high-performance humanoid platform for realistic environments[J]. Journal of Field Robotics, 2017, 34(7): 1225-1259.
- [3] He W, Yan Z, Sun Y, et al. Neural-learning-based control for a constrained robotic manipulator with flexible joints[J]. IEEE Transactions on Neural Networks and Learning Systems, 2018, 29(12): 5993-6003.
- [4] Ling S, Wang H, Liu P X. Adaptive fuzzy dynamic surface control of flexible-joint robot systems with input saturation[J]. IEEE/CAA Journal of Automatica Sinica, 2019, 6(1): 97-107.
- [5] Sun T, Peng L, Cheng L, et al. Composite learning enhanced robot impedance control[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31(3): 1052-1059.
- [6] Zhang Y, Cheng L, Li H, et al. Learning accurate and stable point-to-point motions: A dynamic system approach[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 1510-1517.
- [7] 刘乃军, 鲁涛, 蔡莹皓, 等. 机器人操作技能学习方法综述[J]. 自动化学报, 2019, 45(3): 458-470.
- [8] 曾超, 杨辰光, 李强, 等. 人-机器人技能传递研究进展[J]. 自动化学报, 2019, 45(10): 1813-1828.
- [9] Pratt G A, Williamson M M. Series elastic actuators[C]//Proceedings 1995 IEEE/RSJ International Conference on Intelligent Robots and Systems. Human Robot Interaction and Cooperative Robots. IEEE, 1995, 1: 399-406.
- [10] Cao R, Cheng L. Distributed dynamic event-triggered control for Euler-Lagrange multiagent systems with parametric uncertainties[J]. IEEE Transactions on Cybernetics, 2023, 53(2): 1272-1284.
- [11] Li G, Cheng L, Gao Z, et al. Development of an untethered adaptive thumb exoskeleton for delicate rehabilitation assistance[J]. IEEE Transactions on Robotics, 2022, 38(6): 3514-3529.
- [12] Wang D, Cheng L, Yan J. Self-learning robust control synthesis and trajectory tracking of uncertain dynamics[J]. IEEE Transactions on Cybernetics, 2020,

- 52(1): 278-286.
- [13] Yan Z, He W, Wang Y, et al. Probabilistic motion prediction and skill learning for human-cobot dual-arm handover control[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, in press. DOI: 10.1109/TNNLS.2022.3182973.
  - [14] Coley C W, Thomas III D A, Lummiss J A M, et al. A robotic platform for flow synthesis of organic compounds informed by AI planning[J]. Science, 2019, 365(6453): eaax1566.
  - [15] Steiner S, Wolf J, Glatzel S, et al. Organic synthesis in a modular robotic system driven by a chemical programming language[J]. Science, 2019, 363(6423): eaav2211.
  - [16] Burger B, Maffettone P M, Gusev V V, et al. A mobile robotic chemist[J]. Nature, 2020, 583(7815): 237-241.
  - [17] He W, Xue C, Yu X, et al. Admittance-based controller design for physical human-robot interaction in the constrained task space[J]. IEEE Transactions on Automation Science and Engineering, 2020, 17(4): 1937-1949.
  - [18] Yang C, Zeng C, Liang P, et al. Interface design of a physical human-robot interaction system for human impedance adaptive skill transfer[J]. IEEE Transactions on Automation Science and Engineering, 2017, 15(1): 329-340.
  - [19] Li Z, Huang B, Ye Z, et al. Physical human-robot interaction of a robotic exoskeleton by admittance control[J]. IEEE Transactions on Industrial Electronics, 2018, 65(12): 9614-9624.
  - [20] Osa T, Pajarinen J, Neumann G, et al. An algorithmic perspective on imitation learning[J]. Foundations and Trends® in Robotics, 2018, 7(1-2): 1-179.
  - [21] Kober J, Bagnell J A, Peters J. Reinforcement learning in robotics: A survey[J]. The International Journal of Robotics Research, 2013, 32(11): 1238-1274.
  - [22] Joshi S, Kumra S, Sahin F. Robotic grasping using deep reinforcement learning[C]//2020 IEEE 16th International Conference on Automation Science and Engineering (CASE). IEEE, 2020: 1461-1466.
  - [23] Quillen D, Jang E, Nachum O, et al. Deep reinforcement learning for vision-based robotic grasping: A simulated comparative evaluation of off-policy methods[C]//2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018: 6284-6291.
  - [24] Deng Y, Guo X, Wei Y, et al. Deep reinforcement learning for robotic pushing and picking in cluttered environment[C]//2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2019: 619-626.
  - [25] Fu J, Luo K, Levine S. Learning robust rewards with adversarial inverse

- reinforcement learning[J]. arXiv preprint arXiv:1710.11248, 2017.
- [26] Arora S, Doshi P. A survey of inverse reinforcement learning: Challenges, methods and progress[J]. Artificial Intelligence, 2021, 297: 103500.
  - [27] Ziebart B D, Maas A L, Bagnell J A, et al. Maximum entropy inverse reinforcement learning[C]//Proceedings of the Twenty-Third AAAI Conference on Artificial Intelligence. AAAI, 2008, 8: 1433-1438.
  - [28] You C, Lu J, Filev D, et al. Advanced planning for autonomous vehicles using reinforcement learning and deep inverse reinforcement learning[J]. Robotics and Autonomous Systems, 2019, 114: 1-18.
  - [29] Ho J, Ermon S. Generative adversarial imitation learning[J]. Advances in Neural Information Processing Systems, 2016, 29.
  - [30] Song J, Ren H, Sadigh D, et al. Multi-agent generative adversarial imitation learning[J]. Advances in Neural Information Processing Systems, 2018, 31.
  - [31] Fang B, Jia S, Guo D, et al. Survey of imitation learning for robotic manipulation[J]. International Journal of Intelligent Robotics and Applications, 2019, 3: 362-369.
  - [32] Choi S, Kim J, Yeo H. TrajGAIL: Generating urban vehicle trajectories using generative adversarial imitation learning[J]. Transportation Research Part C: Emerging Technologies, 2021, 128: 103091.
  - [33] Tai L, Zhang J, Liu M, et al. Socially compliant navigation through raw depth inputs with generative adversarial imitation learning[C]//2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018: 1111-1117.
  - [34] Chi W, Dagnino G, Kwok T M Y, et al. Collaborative robot-assisted endovascular catheterization with generative adversarial imitation learning[C]//2020 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2020: 2414-2420.
  - [35] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
  - [36] Schulman J, Levine S, Abbeel P, et al. Trust region policy optimization[C]//International Conference on Machine Learning. PMLR, 2015: 1889-1897.
  - [37] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International Conference on Machine Learning. PMLR, 2017: 214-223.
  - [38] Lin J, Zhang Z. Acgail: Imitation learning about multiple intentions with auxiliary classifier gans[C]//Pacific Rim International Conference on Artificial Intelligence. Springer, Cham, 2018: 321-334.

- [39] Odena A, Olah C, Shlens J. Conditional image synthesis with auxiliary classifier gans[C]//International Conference on Machine Learning. PMLR, 2017: 2642-2651.
- [40] Chen X, Duan Y, Houthoofd R, et al. Infogan: Interpretable representation learning by information maximizing generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2016, 29.
- [41] Li Y, Song J, Ermon S. Infogail: Interpretable imitation learning from visual demonstrations[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [42] Roozing W, Malzahn J, Kashiri N, et al. On the stiffness selection for torque-controlled series-elastic actuators[J]. IEEE Robotics and Automation Letters, 2017, 2(4): 2255-2262.
- [43] Oh S, Kong K. High-precision robust force control of a series elastic actuator[J]. IEEE/ASME Transactions on Mechatronics, 2016, 22(1): 71-80.
- [44] Liu Y, Chen X, Mei Y, et al. Observer-based boundary control for an asymmetric output-constrained flexible robotic manipulator[J]. Science China Information Sciences, 2022, 65: 1-3.
- [45] Spong M W. Modeling and control of elastic joint robots[J]. Mathematical and Computer Modelling, 1989, 12(7): 912.
- [46] Spong M W, Hutchinson S, Vidyasagar M. Robot modeling and control[M]. John Wiley & Sons, 2020.
- [47] Lozano R, Brogliato B. Adaptive control of robot manipulators with flexible joints[J]. IEEE Transactions on Automatic Control, 1992, 37(2): 174-181.
- [48] Brogliato B, Ortega R, Lozano R. Global tracking controllers for flexible-joint manipulators: a comparative study[J]. Automatica, 1995, 31(7): 941-956.
- [49] Slotine J J E, Li W. On the adaptive control of robot manipulators[J]. The International Journal of Robotics Research, 1987, 6(3): 49-59.
- [50] Slotine J J E, Li W. Composite adaptive control of robot manipulators[J]. Automatica, 1989, 25(4): 509-519.
- [51] Spong M W. Adaptive control of flexible joint manipulators[J]. Systems & Control Letters, 1989, 13(1): 15-21.
- [52] Chang Y Z, Daniel R W. On the adaptive control of flexible joint robots[J]. Automatica, 1992, 28(5): 969-974.
- [53] Spong M W. Adaptive control of flexible joint manipulators: Comments on two papers[J]. Automatica, 1995, 31(4): 585-590.
- [54] Khalil H K. Nonlinear control[M]. New York: Pearson, 2015.
- [55] Shuzhi S G. Adaptive controller design for flexible joint manipulators[J]. Automatica, 1996, 32(2): 273-278.

- [56] Lee T H, Harris C J. Adaptive neural network control of robotic manipulators[M]. World Scientific, 1998.
- [57] Ge S S, Hang C C, Lee T H, et al. Stable adaptive neural network control[M]. Springer Science & Business Media, 2013.
- [58] Zeng C, Su H, Li Y, et al. An approach for robotic learning inspired by biomimetic adaptive control[J]. IEEE Transactions on Industrial Informatics, 2021, 18(3): 1479-1488.
- [59] Luo J, Huang D, Li Y, et al. Trajectory online adaption based on human motion prediction for teleoperation[J]. IEEE Transactions on Automation Science and Engineering, 2021, 19(4): 3184-3191.
- [60] Li Z, Li J, Zhao S, et al. Adaptive neural control of a kinematically redundant exoskeleton robot using brain-machine interfaces[J]. IEEE Transactions on Neural Networks and Learning Systems, 2018, 30(12): 3558-3571.
- [61] Yu X, He W, Li Q, et al. Human-robot co-carrying using visual and force sensing[J]. IEEE Transactions on Industrial Electronics, 2020, 68(9): 8657-8666.
- [62] Li Z, Huang B, Ajoudani A, et al. Asymmetric bimanual control of dual-arm exoskeletons for human-cooperative manipulations[J]. IEEE Transactions on Robotics, 2017, 34(1): 264-271.
- [63] 葛泉波, 王贺彬, 杨秦敏, 等. 基于改进高斯混合模型的机器人运动状态估计[J]. 自动化学报, 2022, 48(8): 1972-1983.
- [64] Yang C, Wang X, Li Z, et al. Teleoperation control based on combination of wave variable and neural networks[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2016, 47(8): 2125-2136.
- [65] Liu Y, Chen X, Wu Y, et al. Adaptive neural network control of a flexible spacecraft subject to input nonlinearity and asymmetric output constraint[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 33(11): 6226-6234.
- [66] Yang C, Chen C, Wang N, et al. Biologically inspired motion modeling and neural control for robot learning from demonstrations[J]. IEEE Transactions on Cognitive and Developmental Systems, 2018, 11(2): 281-291.
- [67] Chen Z, Li Z, Chen C L P. Adaptive neural control of uncertain MIMO nonlinear systems with state and input constraints[J]. IEEE Transactions on Neural Networks and Learning Systems, 2016, 28(6): 1318-1330.
- [68] Li Z, Zhao K, Zhang L, et al. Human-in-the-loop control of a wearable lower limb exoskeleton for stable dynamic walking[J]. IEEE/ASME Transactions on Mechatronics, 2020, 26(5): 2700-2711.
- [69] Yang H, Liu J. An adaptive RBF neural network control method for a class of



- nonlinear systems[J]. IEEE/CAA Journal of Automatica Sinica, 2018, 5(2): 457-462.
- [70] 秦方博, 徐德. 机器人操作技能模型综述[J]. 自动化学报, 2019, 45(8): 1401-1418.
- [71] Dong Y, He W, Kong L, et al. Impedance control for coordinated robots by state and output feedback[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2019, 51(8): 5056-5066.
- [72] He W, Sun Y, Yan Z, et al. Disturbance observer-based neural network control of cooperative multiple manipulators with input saturation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31(5): 1735-1746.
- [73] He W, Li Z, Chen C L P. A survey of human-centered intelligent robots: Issues and challenges[J]. IEEE/CAA Journal of Automatica Sinica, 2017, 4(4): 602-609.
- [74] Ding L, Li S, Liu Y J, et al. Adaptive neural network-based tracking control for full-state constrained wheeled mobile robotic system[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, 47(8): 2410-2419.
- [75] Yu X, He W, Li H, et al. Adaptive fuzzy full-state and output-feedback control for uncertain robots with output constraint[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 51(11): 6994-7007.
- [76] Yu X, He W, Li Y, et al. Bayesian estimation of human impedance and motion intention for human-robot collaboration[J]. IEEE Transactions on Cybernetics, 2019, 51(4): 1822-1834.
- [77] Chan W P, Pan M K X J, Croft E A, et al. Characterization of handover orientations used by humans for efficient robot to human handovers[C]//2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2015: 1-6.
- [78] Chan W P, Parker C A C, Van der Loos H F M, et al. A human-inspired object handover controller[J]. The International Journal of Robotics Research, 2013, 32(8): 971-983.
- [79] Parastegari S, Abbasi B, Noohi E, et al. Modeling human reaching phase in human-human object handover with application in robot-human handover[C]//2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2017: 3597-3602.
- [80] Parastegari S, Noohi E, Abbasi B, et al. Failure recovery in robot-human object handover[J]. IEEE Transactions on Robotics, 2018, 34(3): 660-673.
- [81] Strabala K, Lee M K, Dragan A, et al. Toward seamless human-robot

- handovers[J]. *Journal of Human-Robot Interaction*, 2013, 2(1): 112-132.
- [82] Maeda G, Ewerton M, Neumann G, et al. Phase estimation for fast action recognition and trajectory generation in human-robot collaboration[J]. *The International Journal of Robotics Research*, 2017, 36(13-14): 1579-1594.
- [83] 胡晋. 机械臂运动的示教学习方法与应用研究[D]. 浙江大学, 2018.
- [84] 刘成菊, 林立民, 刘明, 等. 一种基于 DTW-GMM 的机器人多机械臂多任务协同策略[J]. *自动化学报*, 2022, 48(9): 2187-2197.
- [85] Raessa M, Chen J C Y, Wan W, et al. Human-in-the-loop robotic manipulation planning for collaborative assembly[J]. *IEEE Transactions on Automation Science and Engineering*, 2020, 17(4): 1800-1813.
- [86] He W, Li J, Yan Z, et al. Bidirectional human-robot bimanual handover of big planar object with vertical posture[J]. *IEEE Transactions on Automation Science and Engineering*, 2021, 19(2): 1180-1191.
- [87] Wang J M, Fleet D J, Hertzmann A. Gaussian process dynamical models for human motion[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2007, 30(2): 283-298.
- [88] Zhang F, Cully A, Demiris Y. Probabilistic real-time user posture tracking for personalized robot-assisted dressing[J]. *IEEE Transactions on Robotics*, 2019, 35(4): 873-888.
- [89] Khansari-Zadeh S M, Billard A. Learning stable nonlinear dynamical systems with gaussian mixture models[J]. *IEEE Transactions on Robotics*, 2011, 27(5): 943-957.
- [90] Kanazawa A, Kinugawa J, Kosuge K. Adaptive motion planning for a collaborative robot based on prediction uncertainty to enhance human safety and work efficiency[J]. *IEEE Transactions on Robotics*, 2019, 35(4): 817-832.
- [91] Ijspeert A J, Nakanishi J, Hoffmann H, et al. Dynamical movement primitives: learning attractor models for motor behaviors[J]. *Neural Computation*, 2013, 25(2): 328-373.
- [92] Colomé A, Torras C. Dimensionality reduction for dynamic movement primitives and application to bimanual manipulation of clothes[J]. *IEEE Transactions on Robotics*, 2018, 34(3): 602-615.
- [93] 孙宁, 程龙. 串联弹性驱动器设计, 建模及在机器人上的应用[J]. *自动化学报*, 2021, 47(7): 1467-1483.
- [94] Gomez-Gonzalez S, Neumann G, Schölkopf B, et al. Adaptation and robust learning of probabilistic movement primitives[J]. *IEEE Transactions on Robotics*, 2020, 36(2): 366-379.
- [95] Kulvicius T, Ning K J, Tamosiunaite M, et al. Joining movement sequences: Modified dynamic movement primitives for robotics applications

- exemplified on handwriting[J]. IEEE Transactions on Robotics, 2011, 28(1): 145-157.
- [96] Yang C, Luo J, Liu C, et al. Haptics electromyography perception and learning enhanced intelligence for teleoperated robot[J]. IEEE Transactions on Automation Science and Engineering, 2018, 16(4): 1512-1521.
- [97] Buchli J, Stulp F, Theodorou E, et al. Learning variable impedance control[J]. The International Journal of Robotics Research, 2011, 30(7): 820-833.
- [98] 罗彪, 欧阳志华, 易昕宁, 等. 基于自适应动态规划的移动机器人视觉伺服跟踪控制[J]. 自动化学报, 2022, 48: 1-11.
- [99] Huang H, Zhang T, Yang C, et al. Motor learning and generalization using broad learning adaptive neural control[J]. IEEE Transactions on Industrial Electronics, 2019, 67(10): 8608-8617.
- [100] 王坤峰, 苟超, 段艳杰, 等. 生成式对抗网络 GAN 的研究进展与展望[J]. 自动化学报, 2017, 43(3): 321-332.
- [101] 于欣波, 贺威, 薛程谦, 等. 基于扰动观测器的机器人自适应神经网络跟踪控制研究[J]. 自动化学报, 2019, 45(7): 1307-1324.
- [102] 贺威, 丁施强, 孙长银. 扑翼飞行器的建模与控制研究进展[J]. 自动化学报, 2017, 43(5): 685-696.
- [103] 孙长银, 吴国政, 王志衡, 等. 自动化学科面临的挑战[J]. 自动化学报, 2021, 47(2): 464-474.
- [104] 孙长银, 穆朝絮. 多智能体深度强化学习的若干关键科学问题[J]. 自动化学报, 2020, 46(7): 1301-1312.
- [105] Huang Y, Rozo L, Silvério J, et al. Kernelized movement primitives[J]. The International Journal of Robotics Research, 2019, 38(7): 833-852.
- [106] 文天赐, 方勇纯, 卢彪. 采用神经网络的双吊车自适应防摆控制[J]. 自动化学报, 2023, 49(1): 111-121.
- [107] Zeng C, Yang C, Chen Z. Bio-inspired robotic impedance adaptation for human-robot collaborative tasks[J]. Science China Information Sciences, 2020, 63: 1-10.
- [108] 金哲豪, 刘安东, 俞立. 基于 GPR 和深度强化学习的分层人机协作控制[J]. 自动化学报, 2022, 48(9): 2352-2360.
- [109] Li Z, Li X, Li Q, et al. Human-in-the-loop control of soft exosuits using impedance learning on different terrains[J]. IEEE Transactions on Robotics, 2022, 38(5): 2979-2993.
- [110] Yu X, He W, Li Y, et al. Adaptive NN impedance control for an SEA-driven robot[J]. Sci. China Inf. Sci., 2020, 63(5): 159207.
- [111] Dong Y, Ren B, Zhong Q C. Bounded universal droop control to enable the

- operation of power inverters under some abnormal conditions and maintain voltage and frequency within predetermined ranges[J]. IEEE Transactions on Industrial Electronics, 2021, 69(11): 11633-11643.
- [112] Yu X, Liu S, He W, et al. A Hybrid Visual-Haptic Framework for Motion Synchronization in Human-Robot Cotransporting: A Human Motion Prediction Method[J]. IEEE Robotics & Automation Magazine, 2022, 29(4): 25-35.
- [113] Yu X, Li B, He W, et al. Adaptive-constrained impedance control for human-robot co-transportation[J]. IEEE transactions on cybernetics, 2021, 52(12): 13237-13249.
- [114] Kruse D, Wen J T, Radke R J. A sensor-based dual-arm tele-robotic system[J]. IEEE Transactions on Automation Science and Engineering, 2014, 12(1): 4-18.
- [115] 徐璠, 王贺升. 软体机械臂水下自适应鲁棒视觉伺服[J]. 自动化学报, 2020, 46: 1-10.
- [116] Yu X, Liu P, He W, et al. Human-robot variable impedance skills transfer learning based on dynamic movement primitives[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 6463-6470.
- [117] Li Z, Zhao T, Chen F, et al. Reinforcement learning of manipulation and grasping using dynamical movement primitives for a humanoidlike mobile manipulator[J]. IEEE/ASME Transactions on Mechatronics, 2017, 23(1): 121-131.
- [118] 于欣波,王远航,闫子晨等. 基于多分类生成对抗模仿学习算法的化学合成机器人系统[P]. 北京市: CN114779661B,2023-03-24.
- [119] 施伟, 冯旻赫, 程光权, 等. 基于深度强化学习的多机协同空战方法研究[J]. 自动化学报, 2021, 47(7): 1610-1623.
- [120] 齐志刚, 黄攀峰, 刘正雄, 等. 空间冗余机械臂路径规划方法研究[J]. 自动化学报, 2019, 45(6): 1103-1110.



学位论文数据集

|                                                |                |                  |                |           |
|------------------------------------------------|----------------|------------------|----------------|-----------|
| 关键词*                                           | 密级*            | 中图分类号*           | UDC            | 论文资助      |
| 协作机器人，模仿学习，运动规划，柔性关节，自适应神经网络控制，人机物理交互          | 公开             | TP18             | 621.3          |           |
| 学位授予单位名称*                                      |                | 学位授予单位代码*        | 学位类别*          | 学位级别*     |
| 北京科技大学                                         |                | 10008            | 工学             | 博士        |
| 论文题名*                                          |                | 并列题名             | 论文语种*          |           |
| 协作机器人模仿学习运动规划与轨迹跟踪控制研究                         |                |                  | 中文             |           |
| 作者姓名*                                          | 闫子晨            |                  | 学号*            | B20180303 |
| 培养单位名称*                                        |                | 培养单位代码*          | 培养单位地址         | 邮编        |
| 北京科技大学                                         |                | 10008            | 北京市海淀区学院路 30 号 | 100083    |
| 学科专业*                                          |                | 研究方向*            | 学制*            | 学位授予年*    |
| 控制科学与工程                                        |                | 协作机器人运动规划与轨迹跟踪控制 | 4 年            | 2023      |
| 论文提交日期*                                        | 2023 年 6 月 1 日 |                  |                |           |
| 导师姓名*                                          | 贺威             |                  | 职称*            | 教授        |
| 评阅人                                            | 答辩委员会主席*       |                  | 答辩委员会成员        |           |
|                                                | 吴淮宁            |                  |                |           |
| 电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） |                |                  |                |           |
| 推荐格式：application/msword； application/pdf       |                |                  |                |           |
| 电子版论文出版（发布）者                                   |                | 电子版论文出版（发布）地     |                | 权限声明      |
|                                                |                |                  |                |           |
| 论文总页数*                                         | 123            |                  |                |           |
| 共 33 项，其中带*为必填数据，为 22 项。                       |                |                  |                |           |