

学校代码: 10255
学 号: 2222032
中图分类法: TP242.6



学术学位硕士学位论文

基于“视觉—语言—动作”模型的机器人抓取与投掷技能学习

学 位 申 请 人: 梁浩天

指 导 教 师: 刘华山

一 级 学 科: 控制科学与工程

研 究 方 向: 复杂系统建模、控制与优化

所 在 学 院: 信息科学与技术学院

提 交 日 期: 2025 年 4 月

University Code: 10255

Student ID: 2222032

CLC Index: TP242.6



ACADEMIC MASTER DISSERTATION

Robot Grasping and Throwing Skill Learning Based on a Vision-Language-Action Model

Author:	Haotian Liang
Supervisor:	Huashan Liu
First-level Discipline:	Control Science and Engineering
Research Field:	Modeling, Control, and Optimization of Complex Systems
College:	College of Information Science and Technology
Date of Submission:	April, 2025

硕士学位论文答辩委员会名单

姓名	职称	单位	备注
曾令斌	研究员	上海霄元创新中心	主席
高鲲鹏	讲师	东华大学	委员
宫晓蕙	讲师	东华大学	委员
李晓丽	副教授	东华大学	秘书

答 辩 人：梁浩天

答辩地点：东华大学 2 号楼 220

答辩日期：2025 年 5 月 14 日

基于“视觉—语言—动作”模型的机器人抓取与投掷技能学习

摘要

随着人工智能与机器人技术的快速发展，机器人的技能学习在制造业、医疗服务和日常生活等领域的应用需求日益凸显。其中，抓取与投掷作为机器人核心操作技能，要求机器人具备精确的物体交互能力和环境动态适应能力。尽管传统解析方法在已知条件下表现稳定，但其在面对未知物体时的泛化能力、鲁棒性以及交互性仍存在局限。针对现有方法的局限，本研究创新性地提出了基于视觉-语言-动作模型的机器人技能学习框架。

首先，针对传统抓取质量评估方法指标单一、无法全面反映抓取稳定性的问题，本研究建立了多维度的抓取质量评估体系，从扭矩平衡、质心距离、接触点分布和平面性等维度对抓取性能进行综合评价。同时，设计了基于通道交互注意力机制的抓取网络 (CIAR-Grasp)，利用稀疏卷积编码和多尺度特征融合，有效提升了对点云数据中几何细节与全局特征的提取能力。实验结果表明，CIAR-Grasp 网络在 GraspNet-1Billion 基准测试中表现优异，在实际机械臂抓取任务中显著提升了操作稳定性和定位精度。

其次，为实现机器人对投掷任务的自主学习，研究采用了基于软演员-评论家算法的强化学习策略，并引入了面向目标的条件策略，使机器人能针对不同目标区域精确调整投掷动作。通过精心设计状态空间、动作空间和奖励函数，机器人可在仿真环境中自主学习和优化面向多目标区域的投掷策略，并有效迁移至真实机器人平台。实验验证表明，该方法在仿真与实体环境中对不同目标区域均能保持较高的投掷成功率，展现出良好的泛化性与环境自适应能力。

最后，本研究进一步提出融合大语言模型的视觉-语言-动作任务规划系统，将开放性词汇检测、抓取预测与投掷策略进行有效协同，使机器人能够根据自然语言指令自主理解并执行复杂任务。实验表明，所提出的 VLA 框架成功实现了对复杂语言指令的准确理解与执行，顺利完成了抓取-投掷的连贯操作任务，为机器人自主决策提供了理论支撑与技术方案。

关键词：视觉-语言-动作模型；抓取位姿估计；强化学习；注意力机制

Robot Grasping and Throwing Skill Learning Based on a Vision-Language-Action Model

ABSTRACT

With the rapid advancement of artificial intelligence and robotics, skill learning for robots has become increasingly critical across applications such as manufacturing, medical services, and daily living tasks. In particular, grasping and throwing, as essential robotic manipulation skills, demand high precision in object interaction and dynamic environmental adaptability. Although traditional analytical methods perform reliably under known conditions, they often exhibit limitations in generalization, robustness, and interaction capabilities when encountering unseen objects. To address these limitations, this research proposes an innovative robotic skill-learning framework grounded in a vision-language-action (VLA) model.

Firstly, to overcome the limitations of traditional grasp evaluation metrics—which typically rely on single-dimensional assessments insufficient for comprehensively reflecting grasp stability—a multi-dimensional grasp quality evaluation system is established. This system assesses grasp performance through multiple criteria, including torque balance, centroid distance, distribution balance, and planarity of contact points. Additionally, a grasp pose estimation network named Channel Interaction Attention Refinement (CIAR-Grasp) is developed, leveraging sparse convolution encoding and multi-scale feature fusion techniques to effectively extract both geometric details and global semantic features from point-cloud data. Experimental results demonstrate that the CIAR-Grasp network achieves superior performance on the GraspNet-1Billion benchmark and significantly enhances the stability and positioning accuracy in real robotic grasping tasks.

Secondly, for the autonomous learning of robotic throwing tasks, a reinforcement learning framework based on the Soft Actor-Critic (SAC) algorithm with goal-conditioned strategies is developed. By carefully designing the state space, action space, and reward functions, the robot is enabled to autonomously learn optimized throwing actions toward different target regions in simulation, with effective transferability to a physical robotic platform. Experimental evaluations confirm that the proposed approach maintains high throwing accuracy across various target regions in both simulated and real environments, exhibiting strong generalization capability and environmental adaptability.

Finally, this study introduces a comprehensive vision-language-action task-planning framework integrated with a large language model, effectively combining open-vocabulary object detection, grasp pose estimation, and throwing strategies. This enables robots to autonomously interpret and execute complex tasks described by natural language instructions. Experiments validate that the proposed VLA framework successfully accomplishes sequential grasp-throw operations guided by intricate linguistic commands, providing robust theoretical

support and practical technological solutions for robotic autonomous decision-making.

KEY WORDS: Robot Manipulation; Vision-Language-Action Model; Grasp Pose Estimation;
Reinforcement Learning; Channel Interaction Attention Mechanism

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	1
1.2.1 传统基于力闭合准则的抓取方法.....	1
1.2.2 基于物理模型的传统投掷方法.....	3
1.2.3 视觉-语言-动作模型.....	3
1.3 论文主要研究内容.....	5
1.4 论文组织结构.....	6
第二章 机器人抓取和投掷任务技能学习的相关理论基础.....	7
2.1 抓取任务与投掷任务分析.....	7
2.1.1 抓取任务传统力闭合准则分析.....	7
2.1.2 机器人投掷任务分析.....	9
2.2 机器人抓取位姿估计任务的深度学习基础.....	12
2.2.1 点云学习技术.....	12
2.2.2 注意力机制的引入.....	13
2.2.3 端到端抓取姿态预测.....	14
2.2.4 结合大模型辅助的抓取检测.....	15
2.3 深度强化学习基础.....	16
2.3.1 马尔可夫决策过程.....	16
2.3.2 贝尔曼方程及其推导.....	17
2.3.3 基于价值函数的强化学习方法.....	18
2.3.4 基于策略的方法.....	19
2.3.5 值函数近似与深度神经网络.....	19
2.3.6 DQN 及其改进.....	20
2.3.7 基于策略梯度的先进算法.....	22
2.3.8 基于 Actor-Critic 的离线策略方法.....	23
2.4 本章小结.....	25
第三章 基于多维度指标的抓取质量评估与优化.....	26
3.1 抓取质量综合评价指标体系设计.....	26
3.1.1 扭矩平衡指标.....	26
3.1.2 质心距离指标.....	27
3.1.3 接触点分布平衡性指标.....	27
3.1.4 接触点非共面指标.....	27
3.1.5 综合评分公式构建.....	28

3.2 通道交互注意力抓取网络	29
3.2.1 网络架构与稀疏卷积编码器设计	29
3.2.2 多尺度通道交互注意力机制	30
3.2.3 损失函数	32
3.3 实验验证与分析	32
3.3.1 GraspNet-1Billion 数据集实验	32
3.3.2 真实环境抓取实验	35
3.4 本章小结	39
第四章 “视觉—语言—动作”模型的抓取与投掷任务规划	41
4.1 系统总体架构设计	41
4.2 开放词汇抓取检测模块实现	42
4.3 基于 SAC 的机器人投掷技能学习	43
4.3.1 状态空间与动作空间设计	44
4.3.2 奖励函数构建与策略学习	44
4.3.3 仿真平台搭建与实验	47
4.4 大语言模型驱动的任务规划	50
4.4.1 LLM API 集成与 Prompt 设计	50
4.4.2 LLM 任务规划与执行	50
4.5 物理平台实验分析	51
4.5.1 投掷任务实验与分析	51
4.5.2 基于“视觉—语言—动作”模型的抓取与投掷任务实验与分析	57
4.6 本章小结	58
第五章 总结与展望	59
5.1 总结	59
5.2 展望	60
参考文献	61

第一章 绪论

1.1 研究背景与意义

随着人工智能与机器人技术的飞速进步，机器人已在制造业、医疗服务和家居生活等多个领域得到广泛应用，这使得对机器人灵巧操控与动作智能的需求日益迫切。抓取与投掷作为机器人操控技能的核心组成部分，不仅体现了机器人在与物体交互中的精准性与灵活性，更考验了其在动态场景下感知、理解与执行任务的综合能力。

传统方法虽然通过精确的物体定位、运动规划与控制策略实现了一定程度的可靠性，但在面对复杂环境或未知物体时，其泛化能力与鲁棒性却受到严重限制。近年来，大语言模型的崛起为机器人技能学习开辟了崭新的研究方向。通过跨模态的语义理解，机器人能够深入解析场景并执行复杂任务，这不仅推动了机器人技术的革新发展，同时也极大拓展了机器人在实际应用中的潜力，具有重大的理论与实践研究价值。

1.2 国内外研究现状

1.2.1 传统基于力闭合准则的抓取方法

根据夹爪姿态的不同，机器人抓取可主要分为平面抓取和六自由度抓取两种范式。平面抓取方法通常假设夹爪从固定方向接近目标物体，从而将复杂的三维抓取问题简化为二维图像中抓取位姿的检测。尽管这种简化使算法实现更为便捷，但在处理姿态多变或物体复杂堆叠的场景时，其固有的维度约束导致了较大的应用局限性。

相比之下，六自由度抓取允许夹爪从空间中任意方向接近物体，充分利用了机械臂的灵活性，能更有效地适应物体的几何特性和空间位置关系。这种方法显著提升了抓取系统处理复杂、多变实际场景的能力，使机器人能够应对更广泛的

抓取任务，特别是在非结构化环境或需要精确操作的情境中表现出明显优势。六自由度抓取表示如图 1-1。




图 1-1 六自由度抓取表示

Fig 1-1 6-degree-of-freedom grasping representation

无论是平面抓取还是六自由度抓取，都强调抓取必须实现力闭合或形闭合的条件^[1]。当夹爪在物体表面有足够的摩擦力时，能抵消重力等外力，即满足力闭合条件^[2]；而形闭合则要求夹爪或灵巧手的接触点分布，即使是在无摩擦条件下也能锁定物体的位置^[3]。然而，这类解析方法对物体的几何形状、摩擦系数等参数有较强的依赖性，在处理实际抓取任务时缺乏灵活性。此外，为了确定合适的接触点组合，传统方法常采用凸包近似等策略，计算复杂度较高，进一步限制了实际应用。

近年来，随着深度学习技术的发展，机器人抓取策略正逐渐从传统解析方法转向数据驱动的学习方法。Dex-Net^[4]利用合成点云和抓取质量标签训练卷积神经网络，从单帧深度图像中预测平行夹爪抓取成功率，其在处理未知物体时表现出了较高的鲁棒性。GraspNet-1Billion^[5]等大规模数据集的出现，使得抓取策略在不同场景、不同物体的学习能力进一步提升。此外，为了应对更复杂的抓取需求，一些研究引入强化学习的方法来完成六自由度抓取任务，并不断优化抓取策略^[6]。

为了进一步提升抓取的准确性，研究者们利用 RGB-D 摄像头获取的彩色图像与深度信息重建物体的三维点云，为抓取任务提供详细的物体形状与位姿信息。Ten Pas 等^[7]提出的抓取姿态检测算法，通过点云信息，在无需预先识别物体的情

况下获取一系列候选抓取姿态，并通过评分函数进行筛选，从而取得较高的抓取成功率。

1.2.2 基于物理模型的传统投掷方法

早期机器人投掷研究主要采用刚体动力学模型，对投掷物体的抛物线轨迹进行规划。典型做法是根据目标位置利用弹道方程计算机械臂末端需要施加的初始速度和角度，从而令物体沿预定轨迹飞行落入目标。然而，这类纯解析方法需要精确的物理模型和参数。投掷结果受多种因素影响，如物体的质量分布、摩擦特性、形状、空气动力学以及初始的抓取姿态等，而其中一些难以被精确建模^[8]。为保证投掷精度，必须假设物体形状均匀、握持姿态固定等理想化条件，而这限制了传统的机器人投掷方法的适用范围^[9]。此外，如空气阻力等不确定性，复杂物体的动力学建模难题，使得基于刚体模型的方法在现实中精度有限。Okada 等针对这一问题进行了敏感度分析，评估了机器人动力学参数误差对着陆点偏差的影响，并提出通过优化释放姿态来提高投掷准确率^[10]。总体而言，传统物理建模方法在处理非结构化环境和多变物体方面存在较大局限。

近年来，深度学习和强化学习为机器人投掷任务提供了全新思路。通过让机器人从大量试投中学习，数据驱动方法能够在未知物体和环境自动调整投掷策略。谷歌推出的 TossingBot 是该方向的代表性成果之一^[11]。该系统采用端到端深度神经网络，从 RGB-D 视觉观测直接预测抓取与投掷的动作参数，并结合抛物线模型进行残差学习。这种“学习”+“物理”的融合策略使机器人能够在训练后，以超过 85% 的投掷准确率将任意物品快速投向指定目标。除了深度学习，强化学习也被用于发展投掷策略。Kasaei 等利用深度强化学习，使机器人学会将物体精准投掷进移动篮筐并躲避途中障碍^[12]。通过在仿真环境反复训练，并且进行真机部署，他们的系统可以使物体投掷并目标。

1.2.3 视觉-语言-动作模型

视觉-语言-动作（Vision-Language-Action, VLA）模型指同时以视觉感知和语言指令为输入，直接输出机器人动作的多模态模型，由谷歌在 RT-2^[13]中提出，用

于解决具身智能领域的任务。与 ChatGPT 等大语言模型不同，VLA 模型需要“读懂”且“看懂”物理世界，既要可以理解人类语言，又能够感知环境状态，并生成合适的动作以实现机器人与环境的交互。相比单纯的强化学习策略，融入视觉和语言的 VLA 策略在复杂环境下展现出更高的多样性、灵活性和泛化性，使其应用场景能够从工业场景拓展到日常生活场景，因而成为机器人自主决策的新范式^[14]。VLA 模型主要包括三种模式，显式、隐式和分层。

显式 VLA 模型，指的是机器人直接将视觉信息和语言指令编码成抽象表示，再从抽象表示映射到动作空间^[15]。常用的方法是利用如 Resnet^[16]的视觉编码器提取图像特征，再通过自然语言编码器提取指令信息编码，将二者通过特征融合或交叉注意力机制^[17]融合后，通过一个策略网络生成控制指令。这种端到端的训练方式简单且高效，能够充分利用现有的感知和语言模型成果。

隐式 VLA 模型关注决策过程的可解释性，其主要特点是在生成动作之前先预测出机器人未来的观测，再根据观测来推断动作^[18]。这种方法通过如扩散模型^[19]等生成模型，对未来的视觉观测预测。根据当前的图像信息、指令信息以及机器人的状态信息等，生成未来若干步的预期图像帧，再通过逆运动学计算出机器人的关节空间的动作序列。通过生成未来的观测，隐式 VLA 使得决策过程更加透明，便于检查机器人“预想”执行后的结果是否符合预期，从而减少不安全或不合理动作的发生。隐式 VLA 方法将回归问题转化为生成问题。

分层 VLA 模式通过层次化的模块设计，将复杂任务拆分为高层和低层两个部分，以同时兼顾全局推理能力和局部执行效率。该方法的高层决策利用大语言模型，根据指令和视觉信息来规划子任务序列；低层采用如强化学习的策略网络或运动控制等执行各个子任务。PaLM-SayCan^[20]是典型的分层 VLA 模型，其中 PaLM^[21]模型负责生成上层的决策方案，而下层则通过强化学习中的策略网络采取动作。它可以将整理房间这类长程任务分解为抓起物体与分类放置等可易于执行的动作。分层 VLA 已成为当前研究热点，其优化层次划分和信息传递的策略将有助于提升机器人在复杂任务中的表现。

“视觉-语言-动作”模型正推动机器人迈向更加智能自主的阶段。通过 VLA

机器人不仅能“看懂”场景、“听懂”指令，更能融合多模态信息，像人一样理解任务并规划行动，为家庭服务、工业生产乃至外星探索等领域带来了突破性进展。

1.3 论文主要研究内容

基于上述研究背景与国内外研究现状，本研究围绕多维度抓取质量评估、机器人抓取与投掷任务建模以及“视觉-语言-动作”模型等关键技术展开深入研究，力求在理论与实践层面为复杂场景下的高精度抓取和灵活投掷提供有效解决方案。本研究受国家自然科学基金面上项目，62373095，面向连续多工步自主作业的冗余自由度机器人运动规划技能学习支持，主要研究内容如下：

(1) 多维度抓取质量评估体系构建与 CIAR-Grasp 网络设计

针对传统力闭合准则难以全面评估抓取稳定性的问题，本文在第三章提出了多维度抓取质量评价指标体系。通过综合扭矩平衡、质心距离、接触点分布平衡性和非共面性等多个力学与几何指标，建立了精细的抓取位姿综合评分方法，为后续的抓取检测与优化提供可靠依据。此外，本文进一步提出通道交互注意力抓取网络 (CIAR-Grasp)，利用稀疏卷积编码器-解码器结构高效处理点云或 RGB-D 数据，结合多尺度通道交互注意力机制动态捕捉跨尺度特征关联，显著提升了对几何细节与全局语义的特征表达能力，在 GraspNet-1Billion 数据集上取得了优异的性能表现。

(2) 机器人投掷任务建模与强化学习策略优化

在第四章，本文针对机器人投掷任务，设计了明确的状态空间、动作空间与奖励函数，并采用 Soft Actor-Critic (SAC) 强化学习算法，使机器人能在仿真环境中自主优化投掷动作。通过学习面向目标区域的条件策略，机器人能够精确调整动作参数以满足多目标区域的投掷需求，并最终将优化后的策略有效迁移到真实机器人平台，实验验证了所提方法在实际场景中的高成功率与泛化能力。

(3) 基于视觉-语言-动作协同规划与系统实现验证

为进一步提高机器人系统的交互能力与任务泛化能力，本文第四章提出了一种融

合视觉、语言与动作的协同规划方法。通过将开放词汇目标检测、CIAR-Grasp 抓取技能、强化学习投掷技能与大语言模型 (LLM) 的推理与规划能力有效结合, 实现了机器人基于自然语言指令的自主目标识别与任务执行规划。此外, 本文分别在仿真与真实机械臂平台上开展抓取与投掷综合实验, 成功完成了由语言指令驱动的“抓取-投掷”连贯操作任务, 验证了所提出方法在不同环境下的实用性与有效性。

1.4 论文组织结构

本文共分为五章, 各章节的内容安排如下:

第一章为绪论。主要阐述本文的研究背景和研究意义, 回顾机器人的抓取任务、投掷任务以及“视觉-语言-动作”模型的研究现状并, 提出论文的研究内容与结构。

第二章为相关技术与理论基础。首先分析了传统抓取方法中的力闭合准则和投掷任务基础, 介绍了本研究涉及的深度学习、强化学习基础知识, 为后续章节提供理论基础。

第三章提出了多维度抓取质量评估与综合评分体系与通道交互注意力抓取网络的设计。详细介绍了抓取评估的各类新指标, 网络结构设计, 训练细节以及数据集实验、消融实验与真实机械臂抓取实验。

第四章围绕“视觉-语言-动作”模型的机器人抓取与投掷任务规划进行研究, 给出了系统总体设计架构, LLM 驱动的任务规划方法, 投掷动作的强化学习训练过程, 以及物理平台实验验证的结果与分析。

第五章对全文的研究工作进行总结, 并对未来可能的研究方向进行了展望。

第二章 机器人抓取和投掷任务技能学习的相关理论基础

2.1 抓取任务与投掷任务分析

2.1.1 抓取任务传统力闭合准则分析

抓取中的力闭合和形闭合是评估抓取稳定性的两个基本概念。形式闭合指纯几何约束下物体被完全固定，物体在接触约束下无法发生任何运动，不需要摩擦力；力闭合则允许利用摩擦力，当手指施加适当的力时，即使物体存在受力扰动也能保持稳定。直观来说，形式闭合要求手指位置本身就能完全束缚物体（如夹持在虎钳中），而力闭合意味着通过足够大的夹持力和摩擦力，抓取可以抵抗各个方向的一定范围外力扰动。实际机械手通常依赖摩擦提供抓取稳定性，因此力闭合是更常用的准则。

在基于力闭合的分析方法中，抓取任务的力学模型包括摩擦模型和抓取矩阵等。通常假设夹爪的指尖与物体为点接触并存在摩擦，此时接触力由法向力和切向摩擦力组成，摩擦力必须满足库仑摩擦锥约束，即切向力的大小不超过法向力与摩擦系数的乘积^[22]。用几何语言描述，摩擦力矢量必须位于以法向为轴的摩擦锥。在计算中，连续的圆锥通常用多面体近似，以方便线性处理^[23]。

抓取矩阵则用于将各接触点的力映射为该物体所受到的合力和合力矩。对于一个具有 n 个手指的抓取，可建立 $6 \times f_n$ 维的抓取矩阵 G ，使得 $w = Gf$ ，其中 f 是所有接触力构成的向量， w 为作用在物体上的六维力/力矩向量^[24]。这里 $w = (F, M)$ 包含合力 F 和力矩 M ，而 G 由各接触点的位置和法向方向决定。当 f 在各接触的摩擦锥约束内且满足非负等条件时，称 f 属于可行力集合 F_C 。力闭合的本质是通过选择合适的接触力 $f \in F_C$ ， Gf 可以产生抵消任意外力的合力 w 。

判断一个抓取是否达到力闭合，经典判据是看抓取所能产生的力-力矩空间是否覆盖了所有方向。严格地说，当且仅当原点位于抓取所能产生的六维力/力矩空间的内部时，抓取是力闭合的。等价地，如果将每个接触的摩擦锥通过抓取矩阵

映射到物体受力空间, 得到一组原始螺旋力 w_{ij} , 表示第 i 个接触摩擦锥近似的第 j 条极边缘向量所产生的力/力矩。这些 w_{ij} 的凸包应包含原点^[25]。这是力闭合的充要条件, 也称抓取力-力矩空间 (Grasp Wrench Space, GWS) 的原点判定法。在满足该条件时, 存在一组接触力可以平衡任意施加在物体上的外力或力矩。

在实际计算中, 由于原点恰好在凸包内部时可能需要无限大的力, 通常引入定量度量来表征力闭合的“裕度”。Ferrari-Canny 度量就是常用的指标之一^[26]。该度量将抓取品质定义为抓取能够抗拒的最大无方向偏好的扰动力或力矩, 数值上等于原点到 GWS 凸包最近边界的距离。从几何上看, 这相当于在 GWS 中以原点为中心能够内切于 GWS 的最大超球半径, 又称 ϵ 度量或“最大内切球”准则。如果该半径 $\epsilon > 0$, 则说明原点在凸包内部, 即抓取达到力闭合; ϵ 值越大, 抓取对各方向扰动的抵抗力越强。Ferrari-Canny 度量被广泛用于评估抓取质量, 并在优化抓取规划中用作目标函数。除了 ϵ 指标外, 抓取质量还可使用其他量化方式衡量, 例如 GWS 体积、最小奇异值等^[27]。抓取矩阵 G 的最小奇异值可表示抓取接近失去某方向抗扰能力的程度。

针对力闭合性质, 不同研究提出了多种判别和度量方法。基于物体和手指接触几何关系的分析判据, 寻找对握接触作为抓取点。对于平面中的两指抓取, 一个充分条件是两接触点连线落在双方摩擦锥内, 这意味着两指作用力方向相对, 能形成对向夹持。这一对向条件保证只要存在足够摩擦系数, 抓取即为力闭合。Nguyen 等^[3]早期工作提出了多指形式闭合的几何条件, 通过分析接触法线方向组合实现对物体所有自由度的约束。几何方法直观高效, 对于简单物体, 通过对称点抓取通常会满足力闭合。

随着数据驱动技术的发展, 出现了采用机器学习预测抓取是否力闭合或预测一个抓取质量评分, 以替代显式的解析判定的方法。最早是利用神经网络或 SVM 根据物体形状特征判断抓取稳定性的方法, 近些年更涌现出基于深度学习的抓取检测方法, 将力闭合作为学习目标之一。Dex-Net^[28]等方法生成海量仿真抓取数据, 标注每个抓取的力闭合度量, 然后训练卷积神经网络从物体的点云或深度图像直

接预测抓取成功率。这类几何+学习混合的方法在未知物体上表现出色，可实时给出抓取方案。融合了大数据和学习的策略有望提高抓取稳定性和力闭合判别的鲁棒性。总之，机器学习方法能够在复杂环境下处理高维感知输入，弥补解析模型难以覆盖的不确定性，但其结果往往缺乏显式物理意义，需要与力学模型结合以保证可靠性。

2.1.2 机器人投掷任务分析

机器人投掷任务指机械手臂将物体加速后释放，使物体在空中飞行并落向目标的操作。相比保持物体稳定不动的抓取，投掷具有明显不同的特征和挑战，具体包括如下。

(1) 动力学开放环节：在抓取中，机械手始终控制物体并可通过力反馈调整，而投掷一旦释放物体后，物体运动不再受机器人直接控制。因此，投掷成功取决于释放瞬间赋予物体的初始速度和角速度，要求机器人精确地控制释放条件。

(2) 利用动力扩大能力范围：投掷利用物体的弹道飞行将其送达远超机械手工作空间范围的地点^[29]。通过抛掷，机器人可以在更短时间内将物体置入目标，显著提高操作效率。抓取则通常用于短距离精确放置，无法实现这样的远距离高速操作。

(3) 任务成功判据不同：抓取任务关注抓稳抓牢（避免滑落）的二元判定，而投掷任务往往以命中目标与否或误差大小来衡量。投掷的评价指标通常包括命中精度，如命中率或落点与目标的距离误差、投掷距离、飞行时间等。机器人投掷需要在速度与精度之间权衡，通常既要满足有足够快的释放初速度，又要能确保落点准确。

(4) 外部扰动影响：投掷物体在空中运动会受到重力和环境阻力等影响，物体自身的质量分布、形状、空气阻力、弹性碰撞等都会改变飞行轨迹。这些因素对投掷结果影响显著，但在抓取静态保持中通常不是考虑重点。因此，投掷任务的动力学不确定性更强，建立精确模型更为困难。

为了分析和规划投掷动作，需要对物体被抛出后的运动进行建模。基础模型

是假设物体可视为仅受重力作用的质点。从释放点以初速度 v_0 抛出。则物体的抛物线运动可用经典力学公式描述: 例如在竖直平面内, 水平位移 $x(t) = v_0 \cos \theta \cdot t$, 竖直位移 $y(t) = v_0 \sin \theta \cdot t - \frac{1}{2}gt^2$, 其中 θ 为释放仰角, g 为重力加速度。该模型表明落点距离取决于初速度大小和角度等, 当忽略空气阻力时, 存在优化的 45° 左右仰角可最大化投掷距离。对于空间中的一般抛掷, 物体位置 $\mathbf{p}(t)$ 满足二阶常微分方程 $\ddot{\mathbf{p}} = -[0, 0, g]^T$, 解为抛物轨迹。

除此之外, 对于需要考虑物体的朝向和自旋的情况, 则需要加入刚体的角运动方程。旋转投掷是指在物体被抛出时赋予其一定角速度, 导致物体在飞行中自旋。在理想情况下, 物体的自旋角速度在飞行中保持恒定, 物体将持续旋转并在落地前后的姿态可能产生影响。例如, 投掷飞盘时通过高速自旋来稳定其姿态和产生升力。旋转投掷的动力学需要结合欧拉方程来描述物体姿态随时间的演变。如果计及空气动力学, 旋转还可能引起 Magnus 效应等, 使轨迹偏移。但在许多机器人投掷研究中, 模型会简化假设无空气阻力且物体近似对称, 从而使用理想抛物线模型评估落点。这种模型虽然理想化, 但提供了规划初始速度的第一近似。为了实际应用, 需根据物体特性对模型进行校正。

机器人投掷的关键在于确定包括释放速度的大小、方向, 以及物体旋转等合适的释放条件, 以及实现这些条件的机械臂的运动规划。传统方法往往分两步, 首先根据目标位置反解所需的初始速度, 然后规划机械臂动作产生该速度并准确释放。对于给定目标位置 $(x_{target}, y_{target}, z_{target})$, 可从抛物线方程反推出所需初速度 v_0 和角度 θ 解运动学方程。再通过机器人逆运动学和动力学, 求解机械手关节的加速度/轨迹, 使末端在释放时刻达到所需速度和姿态。

然而, 这一过程复杂且对模型精度依赖高; 例如, 机械手的弹性、物体在手中滑动等都会造成偏差。因此, 优化投掷策略时除了理想解, 还需考虑误差补偿和鲁棒性。一种思路是将投掷规划作为优化问题求解。以落点误差最小或命中概率最大为目标, 对机械手的运动参数进行优化。使用数值优化方法在仿真中反复

迭代，以找到能命中目标的投掷姿势。优化过程中引入多目标函数，既要求命中目标，又惩罚过于剧烈的动作或超出模型有效性的动作，以提高解的可行性。还有一些研究关注最大投掷距离的问题，通过优化机械手的加速路径使物体以最大速度抛出，从而在给定初始高度下实现最远的落点。这涉及分析机器人动力学极限，以找到最优的释放角度和时机。

由于精确建模投掷行为非常困难，近年来大量工作引入强化学习（RL）和数据驱动方法来让机器人通过试验改进投掷表现。在强化学习框架下，将投掷结果的成功与否作为奖励信号。命中目标得正奖励、偏离则按误差给负分，机器人反复尝试不同投掷策略并更新策略参数。相比于依赖模型的预测方法，RL 能够直接基于真实反馈优化投掷策略，可以取得更高的命中率。然而，纯粹的强化学习来优化投掷任务的方法也存在难点。对每一种新物体或初始条件都需要大量试投训练，而且如果不加入物理知识约束，学习过程可能样本效率低下。为此，近期研究倾向于模型+学习相结合的混合方法。例如，Google 和普林斯顿提出的“TossingBot^[11]”系统中，先利用物理仿真计算出初步的投掷参数，再用卷积神经网络学习残差修正，实时补偿模型未涵盖的动力学因素。这种方法等价于提供一个物理先验，然后让 RL 或监督学习只学习剩余误差，大大加快了收敛速度。TossingBot 在真实机器人上通过自我试验训练，实现了从抓取到投掷的端到端策略，能将各种形状的物品精准抛入箱中。其投掷命中精度达到 85%以上，平均每小时可完成 500 次以上的抓取-投掷操作。

对于投掷任务效果的评估，常用指标有：命中准确率、位置误差等。在定点投掷场景中，命中率和平均误差是核心衡量标准；在要求高速操作的场景，单位时间内的投掷数量也很重要。对于现在的投掷任务，不仅要追求高准确率，也关注如何以最少的试投达到高性能，即提高学习和优化的效率。通过这种模型与数据融合的方法，机器人已能够在不同环境下高精度地完成投掷任务，展示了在物流分拣、家务等领域的应用前景。

2.2 机器人抓取位姿估计任务的深度学习基础

在机器人抓取任务中，深度学习技术提供了强大的感知和决策能力支撑。近年来的研究从多方面推动了机器人抓取性能，包括针对点云数据的特征学习、引入注意力机制增强特征提取、采用端到端模型直接从视觉输入预测抓取姿态，以及探索将大语言模型融入抓取任务以处理高层次指令和复杂任务分解等。下面将分别介绍这些方面的进展及其在机器人抓取中的作用。

2.2.1 点云学习技术

针对机器人抓取所需的三维信息，学者们提出了能够直接处理点云的深度网络以提取物体几何特征。经典的 PointNet 网络开创了直接以无序点集为输入进行学习的先河^[30]。PointNet 通过对每个点独立提取特征并采用对称函数，如最大池化来聚合，实现了对输入点顺序不变的全局特征学习。这种方法能够高效提取物体的全局形状特征，但对局部细节的刻画有限。为增强对局部几何的表征，PointNet++在 PointNet 基础上引入分层聚类^[31]，对点云进行分块采样和分级特征提取，从而捕捉细粒度的局部结构信息。这使得网络可以识别物体表面的局部形状（如凸缘、凹槽），对抓取相关的细节更加敏感。Pointnet++结构如图 2-1。




图 2-1 Pointnet++结构图示意

Fig 2-1 Schematic diagram of the structure of PointNet++

除了分层采样，也有方法通过构建点云的局部邻接图来提取特征。代表性工

作是动态图卷积网络 DGCNN^[32]。DGCNN 引入了 EdgeConv 模块，在网络每一层动态计算点的邻居并对邻域进行卷积运算。这种 EdgeConv 操作捕获了点与其邻居之间的局部几何关系，同时通过每层重新建立邻接关系实现对全局形状的逐步理解。换言之，DGCNN 既获得了局部邻域信息，又能通过多层次特征空间的邻接使远距离的点产生关联，从而编码物体的全局语义结构。在机器人抓取中，这类点云学习的 Backbone 网络常被用来提取物体表面的三维特征，用以判断哪些区域适合放置机械手抓取。

上述点云学习技术已被成功应用于抓取姿态检测和抓取质量评估等任务中。例如，基于 PointNet 的抓取评估网络 PointNetGPD 直接利用抓取夹爪空间内的局部点云来预测抓取的成功率^[33]。这种方法避免了人工设计特征，能够从稀疏点云中捕捉手爪与物体接触区域的复杂 3D 几何结构，从而可靠地评估抓取质量。

此外还有结合 PointNet++ 架构的方法，实现了从完整点云中端到端地直接回归出候选抓取姿态。例如 Graspnet^[5]模型，它无需预先生成抓取候选，直接以稀疏点云为输入输出所有抓取位姿及其评分，在计算效率和抓取多样性上有了很大改进。使用点云深度学习 Backbone 能有效提取物体三维形状特征，显著提升机器人在未知物体上的抓取成功率。

2.2.2 注意力机制的引入

为了进一步增强深度网络对抓取相关特征的提取能力，注意力机制近年来被广泛引入机器人抓取领域。注意力机制通过自适应地强调重要特征、抑制次要特征，使模型更聚焦于与抓取决策密切相关的信息。

在抓取检测中加入注意力模块可以引导网络关注图像或点云中最可能抓取的区域^[34]。Hu 等人将通道注意力融入残差网络，用于抓取特征提取，证明了强调不同特征通道的重要性有助于提升网络对抓取区域的关注^[35]。然而，仅有通道加权可能不足以定位抓取部位，因此为了进一步结合空间注意力，可以使用卷积块注意力模块 (CBAM)，同时在空间和通道维度生成注意力图，能够引导模型在特征图的空间维度上聚焦于与抓取相关的区域^[36]。

Transformer 中的自注意力机制也被用于机器人视觉抓取检测领域^[37]。它能赋予模型全局信息整合能力，使得网络能够同时考虑场景中不同物体和部位间的关联，从而在杂乱环境下正确判断可抓取区域。此外，为兼顾不同尺度下的抓取线索，注意力机制还与多尺度特征融合相结合。一些抓取检测网络融合同步的空间和通道注意力，有效提升了网络对抓取区域的响应^[38]。总体而言，注意力机制帮助抓取模型突出关键的如物体边缘、可接近区域等感知要素，在复杂场景下提高了抓取检测的准确性。自注意力机制如图 2-2。




图 2-2 自注意力机制
Fig 2-2 Self-attention mechanism

2.2.3 端到端抓取姿态预测

传统机器人抓取通常将感知与规划分开，而深度学习的发展使得端到端地从传感器输入直接输出抓取决策成为可能。这样的端到端学习模型避免了中间手工设计模块，利用数据驱动的方法学习最优的抓取策略。

在 2D 平面抓取的场景下，通常采用卷积神经网络直接从相机图像或深度图预测抓取矩形或抓取概率分布。例如，Redmon 和 Angelova 提出了单阶段的 CNN 抓取检测模型，只需一次前向传播即可在 RGB-D 图像中定位多个抓取矩形，实现了约 13 帧每秒的实时性能且在 Cornell 抓取数据集上达到 88% 的检测准确率^[39]。随着更深的骨干网络以及全卷积网络结构的出现，可以对每个像素进行抓取位姿

的预测，提高了精度和效率^[40]。

除了 2D 图像，端到端方法也扩展到 RGB-D、点云等多模态感知输入以预测 6-DOF 抓取姿态^[41]。使用深度网络直接处理传感器的原始输出，例如将摄像头捕获的深度图转换为点云输入网络，直接回归笛卡尔空间的抓取位姿。总体来说，端到端学习使机器人能够“从感知直接到行动”，通过大量数据训练，模型学会了从视觉输入中自动提取与抓取相关的特征并输出最优抓取决策。这极大地简化了抓取系统的流水线，并在实验中展示出对新物体和复杂场景的良好泛化能力。

2.2.4 结合大模型辅助的抓取检测

随着大语言模型（LLM）的飞速发展，机器人研究开始探索将其强大的语言理解和推理能力用于指导和丰富抓取任务。大语言模型可以帮助机器人理解高层指令、推理复杂任务步骤，从而将抓取动作置于更智能的决策框架下。

大型语言模型蕴含了海量的世界知识和常识，这对于抓取这样的任务也有潜在帮助。LLM 可以根据物体的语义描述推测适当的抓取方式，若指令涉及易碎物品，模型可能推断需要更温柔的抓取姿态；对于重物，则需稳固的抓取。研究表明，将 LLM 生成的知识融入抓取决策能够提升机器人在复杂情境下的表现。此外，利用大模型还可以让机器人从隐含的人类意图中推断抓取目标^[42]。当人类给出间接指令，如“我有点渴”暗示需要递上一瓶水时，模型能够理解意图并引导机器人选择正确的物体进行抓取。

大语言模型还可以辅助机器人进行更复杂的长时间序列操作和人机对话。在长程任务中，抓取往往只是整个操作链的一步。LLM 可以通过对话形式与人确认任务需求，动态规划抓取顺序和条件。例如，“先拿起 A 物体，再去抓 B”这样的复合指令，LLM 能够解析先后关系并指导机器人合理执行^[43]。

此外，LLM 与机器人的结合需要解决语言描述与视觉感知的对齐问题。利用多模态模型将图像、点云等感知信息嵌入语言模型的决策过程，使得模型对环境有了感知能力，从而在规划抓取等操作时考虑实时的环境状态。

总体而言，将大语言模型引入机器人抓取为高层语义与低层动作架起了桥梁。

语言模型提供了强大的推理和计划能力，而机器人本体的视觉和操控能力则为语言模型的输出提供了执行基础。这种结合使机器人可以在复杂开放的环境中，根据模糊甚至口语化的指令，自主完成包括抓取在内的复杂操作任务。

在机器人抓取领域，深度学习技术的应用已经实现了从低级感知特征提取到高级语义理解与任务规划的演进。点云学习技术为机器人系统提供了对三维环境的精确感知能力，而注意力机制的引入则使模型更聚焦于与抓取决策密切相关的信息。端到端的抓取位姿估计模型实现了感知-动作决策的一体化，消除了传统流水线方法中的信息瓶颈。同时，大型语言模型的集成正在为机器人系统带来前所未有的语义理解与意图推理能力。这些深度学习技术范式的融合构成了当代机器人抓取研究的理论基础，并持续推动自主机器人系统向更高通用性与智能水平迈进。

2.3 深度强化学习基础

在机器人控制问题中，系统通常面临如传感器数据、位姿信息等高维状态空间和多变量耦合控制，这对传统控制方法构成巨大挑战。强化学习正是以其基于试错、直接从交互中获取最优策略的特点，在解决高维非线性控制问题上展现出巨大潜力。

随着深度神经网络的发展，深度强化学习 (Deep Reinforcement Learning, DRL) 应运而生。它将深度学习强大的函数逼近能力引入 RL 中，既突破了传统表格方法在高维状态空间中的局限，又为机器人自主决策提供了全新的解决方案，从而在无人驾驶、机械臂操作、仿生机器人等领域产生了深远影响。

2.3.1 马尔可夫决策过程

强化学习问题通常形式化为马尔可夫决策过程^[44] (MDP)，其定义为五元组：

$$\langle S, A, P, R, \gamma \rangle \quad (2-1)$$

式中, S 表示状态空间; A 表示动作空间; 状态转移概率 $P(s_{t+1}/s_t, a_t)$ 描述了在状态 s_t 下采取动作 a_t 后转移到下一个状态 s_{t+1} 的概率; 即时奖励函数 $R(s_t, a_t)$ 表征在状态-动作对 (s_t, a_t) 下所获得的即时反馈; 折扣因子 $\gamma \in [0, 1)$ 则用于平衡未来奖励与即时奖励的重要性。

马尔可夫性假设要求满足于:

$$P(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1} | s_t, a_t) \quad (2-2)$$

式中, s_t 表示时刻 t 的状态, a_t 表示时刻 t 的动作, s_{t+1} 表示下一个状态。

在机器人控制领域, MDP 的建模通常需要考虑包括传感器信号、末端执行器的位置与速度、环境地图等的状态表示; 关节力矩、速度、加速度以及移动平台的运动参数以及不仅需要反映任务成功率, 还要考虑能耗、安全性、平滑性等多方面的奖励函数。

此外, 虽然传统 MDP 多采用有限离散状态与动作空间, 但机器人系统大多涉及连续状态与连续动作, 因此在建模时需要引入连续型 MDP。

2.3.2 贝尔曼方程及其推导

在 MDP 框架下, 强化学习的核心在于寻找最优策略, 而价值函数和动作价值函数为此提供了度量标准^[45]。

状态价值函数:

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R(s_{t+k}, a_{t+k}) | s_t = s \right] \quad (2-3)$$

式中, $V^\pi(s)$ 表示在状态 s 下, 按照策略能够获得的累计折扣奖励的期望值; $\mathbb{E}_\pi[\cdot]$ 表示对按照策略 π 生成的状态和动作序列的期望; γ^k 表示第 k 步的折扣因子; $R(s_{t+k}, a_{t+k})$ 表示在时刻 $t+k$ 获得的即时奖励。

动作价值函数:

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R(s_{t+k}, a_{t+k}) \middle| s_t = s, a_t = a \right] \quad (2-4)$$

式中 $Q^\pi(s, a)$ 表示在状态 s 下采取动作 a 后, 按照策略 π 继续执行时能够获得

的累计折扣奖励的期望值, 衡量了在状态 s 下采取动作 a 后, 按策略 π 继续执行时所获得的累计奖励。

贝尔曼期望方程可以推导为:

$$V^{\pi}(s) = \sum_{a \in A} \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi}(s') \right] \quad (2-5)$$

类似地, 动作价值函数满足:

$$Q^{\pi}(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q^{\pi}(s', a') \quad (2-6)$$

最优值函数和最优动作价值函数分别由贝尔曼最优方程描述:

$$V^*(s) = \max_{a \in A} \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right] \quad (2-7)$$

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a'} \quad (2-8)$$

基于上述方程, 常用的求解方法包括值迭代 (不断更新 $V(s)$ 直至收敛) 和策略迭代, 交替进行策略评估与策略提升, 为后续算法设计提供了理论基础。

2.3.3 基于价值函数的强化学习方法

Q-Learning^[46]是最典型的基于价值函数的方法, 其离线更新特性使得能够利用离线采样数据进行学习。更新公式为:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right] \quad (2-9)$$

式中, $Q(s_t, a_t)$ 表示在时刻 t 状态 s_t 下采取动作 a_t 时的当前估计价值; α 表示学习率, 控制每次更新的步长; r_t 表示在时刻 t 获得的即时奖励; γ 为折扣因子; $\max_{a'} Q(s_{t+1}, a')$ 表示在下一个状态 s_{t+1} 中所有可能动作 a' 中所对应的最大估计价值。

另一种方法 SARSA^[45]则采用在线更新的方法。

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)] \quad (2-10)$$

式中, a_{t+1} 表示在下一个状态 s_{t+1} 下实际采取的动作; 该公式直接利用当前

策略生成的数据更新 Q 值，更贴近实际执行情况。

不同于 Q-Learning 的离线性质，SARSA 直接利用当前策略生成的数据更新值函数，从而更能反映策略的即时行为。

2.3.4 基于策略的方法

基于策略的方法直接对策略参数化，例如令策略表示为 $\pi_\theta(a|s)$ 。根据策略梯度定理，目标函数 $J(\theta)$ 关于参数 θ 的梯度为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{s \sim d^\pi, a \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) Q^\pi(s, a)] \quad (2-11)$$

式中， θ 表示策略参数； $J(\theta)$ 表示策略的目标函数（通常为期望累计奖励）； d^π 表示按照策略 π 产生的状态分布； $\nabla_\theta \log \pi_\theta(a|s)$ 是对策略概率对数的梯度，用于指导参数更新； $Q^\pi(s, a)$ 表示状态 s 下采取动作 a 的动作价值函数。

这种方法特别适用于连续动作空间下的控制问题，因为策略输出可以直接对应连续控制量。通过优化目标函数，能够直接提升策略性能。

Actor-Critic 方法将策略（Actor）和值函数（Critic）结合起来，既利用了策略梯度直接优化策略的优势，又利用值函数降低梯度估计的方差。通常引入优势函数：

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (2-12)$$

其中， $A^\pi(s, a)$ 表示在状态 s 下采取动作 a 相对于平均水平的优势； $Q^\pi(s, a)$ 为动作价值函数； $V^\pi(s)$ 为状态价值函数。

该函数用来刻画在状态 s 下，采取动作 a 相对于平均水平的增益。通过使用优势函数，Actor 更新时能够更加关注那些比基准更优的动作，从而实现更高效的策略改进。在机器人连续控制任务中，Actor-Critic 方法能够有效平衡采样效率与稳定性。

2.3.5 值函数近似与深度神经网络

在马尔可夫决策过程中，可以通过状态价值函数与动作价值函数来度量在给定策略 π 下的长期回报。具体定义如下：

$$V^{\pi}(s) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right] \quad (2-13)$$

其中 τ 表示按照策略 π 采样得到的一条状态-动作序列, γ 是折扣因子 ($0 < \gamma < 1$), $R(s_t, a_t)$ 是在状态 s_t 采取动作 a_t 时得到的即时奖励。

$$Q^{\pi}(s, a) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s, a_0 = a \right] \quad (2-14)$$

当状态空间和动作空间高维、连续时, 传统表格方法难以对所有状态进行价值估计, 也难以快速更新。为此, 通常采用函数近似的方式, 用深度神经网络来逼近价值函数或策略函数, 从而在高维场景下保持良好的泛化能力。

在训练过程中, 最常见的是通过最小化时序差分误差来更新价值函数网络参数 θ 。例如, 在 Q-learning 中, 其损失函数可表示为:

$$\mathcal{L}(\theta) = E_{(s, a, r, s') \sim \mathcal{D}} [(y - Q(s, a; \theta))^2] \quad (2-15)$$

其中, $y = r + \gamma \max_{a'} Q(s', a'; \theta^-)$, θ^- 表示目标网络的参数, 通常通过固定间隔或指数滑动平均更新, $\mathcal{D}$ 表示从经验回放中采样到的小批量数据。

这里, 经验回放和目标网络是提高训练稳定性的重要技术。经验回放通过随机抽取小批量数据进行梯度下降, 打破了训练数据的相关性; 目标网络则使用固定间隔或指数滑动平均更新参数, 避免预测网络的频繁变化。此外, 正则化技术如权重衰减和 dropout 被广泛用于增强模型的泛化能力。

2.3.6 DQN 及其改进

深度 Q 网络^[47] (DQN) 将 Q-learning 与深度神经网络相结合, 在离散动作空间的多种任务中取得了突破性进展。在计算目标 Q 值时, 使用一段时间内固定的网络参数或通过指数滑动平均得到的目标网络参数, 从而降低由于目标值和预测值相互耦合引起的训练震荡。此外还采用了经验回放, 将历史交互数据以随机批量的形式进行离线学习, 有效减少样本相关性并提高数据利用效率。DQN 结构如图 2-3。




图 2-3 DQN 算法
Fig 2-3 DQN

然而, DQN 也会面临过估计问题和收敛速度等方面的挑战, 故提出了以下改进算法。

一种方法是 Double DQN, 通过将“选择动作”和“计算 Q 值”分离到不同网络, 缓解 DQN 中的过估计问题^[48]。

其目标值变为:

$$y = r + \gamma Q\left(s', \arg \max_{a'} Q(s', a'; \theta^-); \theta^-\right) \quad (2-16)$$

其中 θ 和 θ^- 分别是在线和目标网络的参数, 动作由在线网络选择, 再由目标网络进行价值估计。

还有一种是 Dueling DQN 算法, 它在网络结构上, 将 Q 函数拆分为状态价值函数 $V(s)$ 和动作优势函数 $A(s, a)$, 再合并为

$$Q(s, a) = V(s) + A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a' \in \mathcal{A}} A(s, a') \quad (2-17)$$

式中, $Q(s, a)$ 表示状态-动作值函数, 即在状态 s 下执行动作 a 后所能获得的期望长期回报; $V(s)$ 表示状态值函数, 即状态 s 本身的价值, 不涉及具体动作; $A(s, a)$ 表示优势函数, 用来衡量选择动作相对于在该状态下平均所有动作而言的优势或劣势程度; $\frac{1}{|\mathcal{A}|} \sum_{a' \in \mathcal{A}} A(s, a')$ 是对所有动作优势函数的均值, 用于归一化

优势函数，使其均值为零。该结构更有利于学习状态价值，提升策略评估精^[49]。

根据 TD 误差大小为经验样本分配优先级，能让误差更大的样本被采样到的概率更高，从而加速训练收敛速度，但需要额外引入重要性采样来降低训练偏差。

2.3.7 基于策略梯度的先进算法

在策略梯度算法中，直接对参数化的策略 $\pi_\theta(a|s)$ 进行优化，而非像 Q-learning 那样先学习 Q 函数。对于高维连续动作空间，策略梯度方法更具优势^[50]。

策略梯度定理可以表示为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{s \sim d^\pi, a \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) \cdot Q^\pi(s, a)], \quad (2-18)$$

其中 d^π 为在策略 π 下的状态分布， $Q^\pi(s, a)$ 为相应的动作价值函数。在实际中，会用优势函数 $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ 来替代 $Q^\pi(s, a)$ 减少方差。

TRPO^[51]通过在更新策略时加入信赖域（Trust Region）的 KL 散度约束，保证新旧策略不会偏离太远，从而在训练中保持稳定。其优化目标可表述为：

$$\max_{\theta} \mathbb{E}[r(\theta) A^\pi(s, a)], \quad \text{s.t.} \quad D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_\theta) \leq \delta. \quad (2-19)$$

其中 $r(\theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}$ ， δ 为限制更新幅度的常数。该约束避免一次更新步幅过大导致策略性能骤降，尤其适合复杂机器人控制任务。但 TRPO 的计算代价相对较高。

PPO 在 TRPO 的基础上做了改进，通过裁剪方式来替代二阶近似和复杂约束^[52]。其核心目标函数为：

$$L^{\text{CLIP}}(\theta) = E[\min(r(\theta) A^\pi(s, a), \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon) A^\pi(s, a))] \quad (2-20)$$

其中 $r(\theta) = \frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}$ 。若概率比 $r(\theta)$ 偏离区间 $[1 - \epsilon, 1 + \epsilon]$ 太多，则会切断梯度，从而保证更新稳定，又简化了算法实现和计算量。PPO 广泛应用于机器人操作和控制领域，兼具稳定与高效等优点。PPO 结构如图 2-4。




图 2-4 PPO 结构图
Fig 2-4 Structural diagram of PPO

A3C (Asynchronous Advantage Actor-Critic) 采用多线程并发的方式来提高采样效率^[53]。每个线程在本地环境中并行与环境交互，周期性地将梯度发送到全局网络进行异步更新。异步机制在一定程度上还可降低梯度估计方差，促进策略收敛。

后续也出现了 A2C (Advantage Actor-Critic) 作为其同步版本，将多条并行环境的采样结果在一个时间步后统一收集，再一起做梯度更新，简化并行实现，依然能享受并行采样优势。

2.3.8 基于 Actor-Critic 的离线策略方法

对于机器人等真实环境，采样成本往往十分高昂，离线策略学习能在更灵活的环境下使用历史数据进行更新，因而在最近几年受到广泛关注。

DDPG 将确定性策略梯度理论和深度网络结合，擅长在连续动作空间任务中实现高效学习^[54]。其主要思想是维护一个 Actor 网络 $\mu_\theta(s)$ 和一个 Critic 网络 $Q(s, a; \theta^Q)$ ，近似 $Q^\mu(s, a)$ ，使用 TD 误差最小化：

$$\mathcal{L}(\theta^Q) = E[(r + \gamma Q(s', \mu_\theta(s'); \theta^{Q^-}) - Q(s, a; \theta^Q))^2] \quad (2-21)$$

利用确定性策略梯度定理，梯度为：

$$\nabla_\theta J \approx E[\nabla_a Q(s, a; \theta^Q)|_{a=\mu_\theta(s)} \cdot \nabla_\theta \mu_\theta(s)] \quad (2-22)$$

DDPG 同样结合了目标网络和经验回放等手段来降低训练震荡。DDPG 结构

如下图 2-5。




图 2-5 DDPG 结构图
Fig 2-5 DDPG structure diagram

TD3 针对 DDPG 中常见的 Q 值过估计与训练不稳定问题，采用类似 Double DQN 的思路[55]，如下使用两个 Critic 网络分别估计 Q 值，计算目标值时取最小值，从而降低过估计风险。

$$y = r + \gamma \min_{i=1,2} Q_i(s', \tilde{a}'; \theta_i^{Q-}) \quad (2-23)$$

其中 $\tilde{a}'$ 在 Actor 输出的动作上加一定高斯噪声并进行裁剪。TD3 结构如图 2-6。




图 2-6 TD3 结构图
Fig 2-6 TD3 structure diagram

此外还使用了延迟更新的方法：每隔固定的更新步数后才对 Actor 及目标网

络进行更新，使策略的学习更加平稳。

2.4 本章小结

本章首先分析了机器人抓取和投掷任务的理论基础。针对抓取任务，介绍了传统力闭合判据，包括形式闭合与力闭合的区别、力闭合条件的几何解释、以及 Ferrari-Canny 度量等抓取质量评估指标。此外，还讨论了基于优化方法的抓取分析与规划。对于投掷任务，分析了其动力学特性与抓取任务的显著差异，包括开放环控制、对初始条件的高精度要求、外界扰动的影响等。进一步阐述了经典投掷轨迹模型及其逆向规划方法，以及近年来兴起的强化学习与数据驱动方法在提高投掷精准性和鲁棒性方面的方法。

其次，介绍了机器人抓取任务的深度学习基础。从点云特征学习技术、注意力机制、端到端抓取姿态预测，以及结合大语言模型的机械臂抓取等角度，总结了深度学习方法如何有效提升机器人对复杂环境的感知和操作能力。

随后概述了深度强化学习的理论框架，包括马尔可夫决策过程、贝尔曼方程及相关推导，并详细介绍了基于价值函数、策略梯度以及 Actor-Critic 等典型方法的基本原理和算法特征。这些方法在高维连续动作空间中的高效性和鲁棒性，为机器人控制任务提供了强大的工具。

第三章 基于多维度指标的抓取质量评估与优化

3.1 抓取质量综合评价指标体系设计

在机器人抓取任务中，抓取质量的准确评价直接影响机器人对物体抓取的成功率与稳定性。现有的传统评价方法往往仅基于单一的力闭合准则，未能全面地反映抓取过程中可能出现的多维因素。为全面提高抓取位姿预测的准确性与鲁棒性，本节提出一种综合评价指标体系，从扭矩平衡性、质心距离、接触点分布平衡性、接触点非共面性和传统力闭合指标等多个维度对抓取质量进行评价。

3.1.1 扭矩平衡指标

在分析机器人抓取的整体稳定性时，除了需满足力闭合外，还应重点考察各接触点处所施加力与物体表面法向量之间的关系。如果接触力过于接近摩擦锥的极限，稍有外界干扰便可能引起滑动；反之，若接触力与法线方向更为对齐，则在承受扰动力时具备更大的可调范围。为量化这一“力矩均衡”程度，引入第二章所提的摩擦锥指标，用以衡量接触力相对于摩擦锥极限的“余量”：当某一接触点力越贴近摩擦锥极限时，指标值趋于无穷大，意味着抓取所能容忍的干扰更小，整体稳定性更差；反之，较小的值表明接触力与法线方向更为对齐，抓取对外界干扰的适应性更强。

为更直观地度量接触力对扭矩平衡的贡献，可引入如下“扭矩平衡指标”，对上述指标进行了简化：

$$Q_{\tau} = \frac{1}{2} \|\cos(\theta_1), \cos(\theta_2)\|_1 \quad (3-1)$$

式中， θ_1 为 $\vec{n}_1$ 与 $\vec{c}$ 的夹角， θ_2 为 $\vec{n}_2$ 与 $\vec{c}$ 的夹角， $\|\cdot\|_1$ 表示向量的 L1 范数。

若两法向量与连线向量平行，则 $\cos\theta_i \approx 1$ ， Q_{τ} 取最大值，说明施力方向对称且更易保持扭矩平衡；若二者近乎垂直，则 $\cos\theta_i \approx 0$ ，表明此时手指难以提供足

够的正压力组件去平衡外界扰动，抓取的稳定性较低。

3.1.2 质心距离指标

为了最小化抓取过程中惯性和重力力量的影响，关键在于减小物体的质心与接触形状的质心之间的距离——无论是对于二维对象的多边形还是三维对象的多面体。因此，这段距离成为了评估 2D 和 3D 对象抓取质量的一个关键指标。

本研究采用的二指平行夹爪，质心距离指标用于评估平行夹爪的 2 个抓取点与物体质心之间的空间距离。首先确定夹爪接触点 C 的中心坐标与物体质心坐标 O ，质心距离指标 (3-2) 定义为两点间的欧氏距离：

$$Q_D = -\|CO\|_2 \quad (3-2)$$

式中， C 为接触点中心坐标， O 为物体质心坐标。较大的 Q_D 表示抓取位置接近物体质心，有利于提高抓取的稳定性。

3.1.3 接触点分布平衡性指标

为刻画质心 O 在两接触点连线 $c_1 c_2$ 上的对称性，定义 θ 为向量 $\overrightarrow{OC}$ 与 $\overrightarrow{C_1 C_2}$ 之间的夹角，并将公式 (3-3) 作为衡量分布均衡程度的指标：

$$Q_E = -|\cos(\theta)| \quad (3-3)$$

当 Q_E 越大（即 θ 越接近 90° ）时，说明质心与该连线分布更为对称； Q_E 越小则表示质心分布越不均衡。换言之， $|\cos(\theta)| \approx 0$ ，对应 $\|C_1 C\|_2 \approx \|C_2 C\|_2$ ，是最理想的均衡情形。

3.1.4 接触点非共面指标

在实际两指或多指抓取中，通常希望接触点不在同一个平面上，也尽可能不选在两个接触点所在曲面的外法向量夹角过小的相邻面上。如果两个接触点接近共面，或者位于两个几乎平行的面上，那么两指作用力几乎在同一个方向或夹角太小，难以形成对物体的“包夹”效果，这类似用筷子夹东西时，筷子几乎是平行且紧贴物体同一表面，就很难把它夹住。接触点同面或夹角过小，想实现稳固

抓取，尤其是需要满足力封闭 force-closure 或形封闭 form-closure 会非常困难。

对于简单的二指夹爪，如果要抓住一个有厚度、同时表面相互垂直的棱柱形物体，平行夹爪的两指可能无法对物体施加足够的包围，导致抓取“不封闭”，在无其他辅助力/摩擦力的情况下难以稳固抓取。

因此，从几何和力学的角度，希望两个接触点分布在物体曲面或多面体表面上时，接触法线方向能相互对立，即夹角接近 180° ，以达到更好的力封闭条件。

非共面性评分 (Non-Coplanarity Score) 如下：

$$Q_{NC} = - \frac{\mathbf{n}_1 \cdot \mathbf{n}_2}{\|\mathbf{n}_1\| \|\mathbf{n}_2\|} \quad (3-4)$$

式中， $\mathbf{n}_1$ ， $\mathbf{n}_2$ 分别表示下物体与夹爪的两个接触点 c_1 ， c_2 在物体表面的外法向量。

分数高即法线夹角大意味着抓取点较为对立，能提供对合力；分数低则意味着抓取点在几何上相对“邻近”或“共面”，抓取稳定性也随之降低。

当法向量呈对向时，意味着两个接触点分布在几何上更“对称”或“对立”的位置，不仅避开了“共面”或“微小夹角”的情况，也使得物体在两指之间具有更好的支撑与包夹效果。

3.1.5 综合评分公式构建

为了更全面、准确地评估机器人抓取姿态的质量，本研究综合考虑了力闭合指标、扭矩平衡指标、质心距离指标、接触点分布平衡性指标和接触点非共面指标，将其统一到一个综合评分体系中。具体公式如下：

$$Q = w_1 Q_{fc} + w_2 Q_\tau + w_3 Q_D + w_4 Q_E + w_5 Q_{nc} \quad (3-5)$$

式中 w_1 ， w_2 ， w_3 ， w_4 ， w_5 ，为权重系数； Q_{fc} 表示力闭合指标，用于衡量抓取是否达到力闭合条件，满足闭合条件时该指标取较大值，否则取值较小； Q_τ 表示扭矩平衡指标， Q_D 表示质心距离指标， Q_E 表示接触点分布平衡性指标 Q_{nc} 表示接触点非共面指标，各权重系数根据实际应用场景与需求进行调整，以获得最优的抓取位姿评价结果。

3.2 通道交互注意力抓取网络

为有效提升机器人抓取位姿预测的准确性与鲁棒性，本研究设计了一种基于通道交互注意力机制的抓取网络。该网络采用了编码器-解码器架构，结合稀疏卷积技术及多尺度特征融合方法，能够高效地从点云数据中提取丰富的空间特征。

3.2.1 网络架构与稀疏卷积编码器设计

基于通道交互注意力机制的抓取网络(CIAR-Grasp)整体网络结构如图 3-1 所示。




图 3-1 CIAR-Grasp 整体结构图
Fig 3-1 Overall structure of CIAR-Grasp

网络采用稀疏卷积编码器，以输入的原始点云为基础进行多尺度特征抽取。稀疏卷积网络能够有效处理高维且稀疏的点云数据，通过逐层卷积操作捕获全局与局部的上下文信息。

编码器首先对点云数据进行下采样，形成多个不同尺度的特征映射，以获得更具区分度的多尺度特征表示。随后通过特征融合和上采样模块逐步提升特征的语义表达能力，为解码器提供高质量的特征输入。

3.2.2 多尺度通道交互注意力机制

点云数据通常呈现出高维度、稀疏性强及缺乏显式空间结构等特点，这给基于空间注意力的方法带来了挑战，点云中不同特征之间的复杂关系往往难以通过传统的空间注意力机制进行充分建模。相比之下，通道建模在应对点云的几何变化，如旋转、平移等方面更具鲁棒性，同时能够更为有效地关注不同通道特征的重要程度，从而在高维度特征融合时减少冗余，并突出对语义信息具有关键贡献的通道。

为此，本研究提出了多尺度通道交互注意力机制，该机制能有效捕获不同特征通道之间的非相似性关系，显著提高特征表示能力。

CIAR 机制如图 3-2 所示。




图 3-2 CIAR 示意图
Fig 3-2 CIAR schematic diagram

受 Qiu[56]的启发，本研究提出的 CIAR 模块旨在通过学习通道间的亲和关系来重构高层语义表示，提高对点云中复杂特征的表达能力。与传统的自注意力方法不同，CIAR 更关注不同通道之间的互补与非相似度，通过自适应地加权各通道特征，得到更具判别力与上下文感知能力的特征表示。

为了进一步提升对点云特征的捕捉能力，CIAR 模块在通道注意力的基础上，额外整合了多尺度信息。在点云任务中，多尺度信息能够帮助模型在不同的感受野下捕捉到既具有全局语义、又蕴含局部结构的特征，从而更好地应对点云内部

显著尺度差异和密度变化所带来的挑战。

CIAR 模块首先将上述已融合的多尺度特征组合成统一的表示, 然后利用卷积层将其投影至 Q 、 K 和 V 三个空间, 用于计算特征间的注意力权重。不同于传统自注意力常用的相似度矩阵, CIAR 引入了通道非相似性来刻画通道之间的差异性并指导特征融合, 具体包括以下步骤:

首先, 设当前特征张量在通道维度上有 S 个通道, $\mathbf{S} \in \mathbb{R}^{S \times S}$ 表示通道间的相似度矩阵, 其中, $\mathbf{S}_{ij}$ 表示第 i 个通道与第 j 个通道之间的相似度。该相似度通常可通过 Q 与 K 的点积或卷积操作获得;

其次, 为进一步突出不同通道的互斥或差异程度, CIAR 利用非相似性矩阵来对通道间的关系进行加权。具体地, 给定相似度矩阵 $\mathbf{S}$, 不相似度 $\mathbf{A}_{ij}$ 的计算方式如下:

$$\mathbf{A}_{ij} = \max(\mathbf{S}_{i, \cdot}) - \mathbf{S}_{ij} \quad (3-6)$$

其中 $\max(\mathbf{S}_{i, \cdot})$ 表示第 i 个通道在所有与之相关的相似度中的最大值。通过这种方式, 若两条通道间相似度较高, 则其非相似度就低; 反之, 则非相似度越高。为便于后续的注意力分配, $\mathbf{A}$ 会通过 *softmax* 操作进行归一化。

再次, 基于非相似度矩阵 $\mathbf{A}$, CIAR 动态地融合不同通道的特征, 让在通道上差异显著的通道获得更高的权重, 从而在整体表示中占据更重要的地位。与此同时, 为了防止特征精炼过程过度抹去原始信息, CIAR 在通道加权的同时引入了残差连接, 将初始的特征直接与注意力加权后的特征相加, 以保留原有特征中的关键信息。

最后, 在完成通道不相似度加权后, CIAR 还通过若干非线性映射, 如激活函数与卷积层组合等来提升特征的表达能力。最终, 通过对各通道进行自适应缩放, CIAR 能够根据通道间的亲和或差异程度, 在输出特征中动态分配不同通道的贡献权重, 从而得到更精细、更多样化且对上下文更敏感的特征表示。

3.2.3 损失函数

CIAR-Grasp 的损失函数采用多任务联合优化策略，包括对象分割损失、点级抓取可能性损失、视图级抓取可能性损失、抓取得分回归损失和夹爪宽度回归损失。具体损失函数定义如下：

$$L = \lambda_1 L_o + \lambda_2 L_g + \lambda_3 L_v + \lambda_4 L_{rd} + \lambda_5 L_w \quad (3-7)$$

其中，对象分割损失 L_o 采用交叉熵损失；点级抓取可能性损失 L_g 、视图级抓取可能性损失 L_v 、抓取得分回归损失 L_{rd} 和夹爪宽度回归损失 L_w 均采用 Smooth L1 损失。模型训练过程中，损失函数各项权重系数设定为 $\lambda_1 = 1$ ， $\lambda_2 = 10$ ， $\lambda_3 = 100$ ， $\lambda_4 = 15$ ， $\lambda_5 = 10$ 。此外，训练采用 Adam 优化器，初始学习率为 0.001，每个 epoch 后乘以 0.95 进行衰减。交叉熵损失与 Smooth L1 见公式 3-8，3-9。

$$\mathcal{L}_{\text{smooth-L1}}(x, y) = \begin{cases} 0.5(x - y)^2 / \beta, & \text{if } |x - y| < \beta \\ |x - y| - 0.5\beta, & \text{otherwise} \end{cases} \quad (3-8)$$

式中， x 为模型预测值， y 为真实值， β 为阈值参数。

$$\mathcal{L}_{\text{CE}}(\mathbf{p}, \mathbf{y}) = - \sum_{i=1}^C y_i \log(p_i) \quad (3-9)$$

式中， p_i 为预测概率， y_i 为真实标签， C 表示类别数。

3.3 实验验证与分析

3.3.1 GraspNet-1Billion 数据集实验

本研究的实验部分在公开的 GraspNet-1Billion 数据集上开展，该数据集涵盖多种物体和抓取场景，提供超过十亿个合成抓取位姿，能有效评估抓取算法性能。评估采用平均精度（Average Precision, AP）指标，同时引入不同摩擦系数下的 AP_μ 指标，评估抓取位姿在不同场景条件下的性能。

本研究实验采用 Ubuntu 20.04 系统，编程语言为 Python 3.8，利用 PyTorch

1.11.0 和 CUDA 11.3 实现深度学习网络的训练与测试。硬件平台为配备 NVIDIA RTX 4090 显卡与 Intel Xeon Platinum 8352V 处理器的计算机。模型训练的初始学习率设定为 0.001, 采用 Adam 优化器, 并在每个 epoch 结束后以 0.95 的比例衰减学习率。

本研究方法 (CIAR-Grasp) 与多种主流抓取方法进行了对比, 包括 PointnetGPD、graspnet-baseline、RGBD-Grasp、Gsnet、DGCAN、Ma、Qiu、HGGD 和 Liu 等, 实验结果如下表。在已见物体数据集的结果如表 3-1, 相似物体数据集如表 3-2, 未见过物体数据集表现如表 3-3。实验结果表明, CIAR-Grasp 在 mAP 指标上达到了 53.29 (Realsense) 和 45.01 (Kinect), 明显优于现有的主流方法, 尤其在 Seen 和 Similar 类别的物体中表现突出。

表 3-1 已见物体数据集对比实验结果

Table 3-1 Comparison of experimental results on seen object datasets

方法	AP	AP _{0.8}	AP _{0.4}
PointnetGPD ^[33]	25.96/27.59	33.01/34.21	15.37/17.83
graspnet-baseline ^[5]	47.47/42.02	55.90/49.91	41.33/35.34
RGBD-Grasp ^[57]	27.98/32.08	33.47/39.46	17.75/20.85
Gsnet ^[58]	67.12/61.19	78.46/71.46	60.90/56.04
DGCAN ^[59]	49.85/47.32	59.67/57.27	42.24/38.55
Ma ^[60]	63.83/-	74.25/-	58.66/-
Qiu ^[61]	70.46/62.28	82.42/73.34	64.85/55.13
HGGD ^[62]	59.36/60.26	-/-	-/-
Liu ^[63]	67.90/64.41	78.30/73.89	63.34/58.24
ours	71.59/62.61	83.36/74.12	65.78/54.57

表 3-2 相似物体数据集对比实验结果

Table 3-2 Comparison of experimental results on similar object datasets

方法	AP	AP _{0.8}	AP _{0.4}
PointnetGPD ^[33]	22.68/24.38	29.15/30.84	10.76/12.83
graspnet-baseline ^[5]	42.27/37.35	51.01/44.82	35.40/30.40

表 3-2 相似物体数据集对比实验结果 (续)

方法	AP	AP _{0.8}	AP _{0.4}
RGBD-Grasp ^[57]	27.23/30.40	36.34/37.87	15.60/18.72
Gsnet ^[58]	54.81/47.39	66.72/56.78	46.17/40.43
DGCAN ^[59]	41.46/35.73	50.31/44.22	33.69/26.99
Ma ^[60]	58.46/-	70.05/-	51.32/-
Qiu ^[61]	61.63/51.38	74.80/62.40	52.53/42.39
HGGD ^[62]	51.20/48.59	-/-	-/-
Liu ^[63]	57.67/53.79	68.47/62.84	51.53/45.17
ours	62.01/52.15	74.74/63.55	53.42/42.45

表 3-3 未见物体数据集对比实验结果

Table 3-3 Comparison of experimental results on unseen object datasets

方法	AP	AP _{0.8}	AP _{0.4}
PointnetGPD ^[33]	9.23/10.66	9.89/11.24	2.74/3.21
graspnet-baseline ^[5]	16.61/12.17	20.84/15.17	8.30/5.51
RGBD-Grasp ^[57]	12.25/13.08	12.45/13.79	5.62/6.01
Gsnet ^[58]	24.31/19.01	30.52/23.73	14.23/10.60
DGCAN ^[59]	17.48/16.10	21.83/20.01	7.90/7.81
Ma ^[60]	24.63/-	31.05/-	12.85/-
Qiu ^[61]	26.30/19.66	33.00/24.50	13.70/10.88
HGGD ^[62]	22.17/18.13	-/-	-/-
Liu ^[63]	25.41/21.37	31.74/25.61	14.83/12.01
ours	26.26/20.28	32.92/25.40	14.05/10.70

通过消融实验进一步验证了通道交互注意力机制 (CIAR) 的有效性。实验结果见表 3-4, 加入 CIAR 后, 各类物体的抓取精度均有明显提高, 其中 Seen 和 Similar 类别的提升尤为显著, 表明 CIAR 在捕获通道间的复杂关系和优化特征表示方面的突出贡献。

表 3-4 CIAR 在 Graspnet 数据集消融实验
Table3-4 Ablation study of CIAR on the GraspNet dataset

方法	已见数据集			相似数据集			未见数据集		
	AP	AP _{0.8}	AP _{0.4}	AP	AP _{0.8}	AP _{0.4}	AP	AP _{0.8}	AP _{0.4}
ours-baseline	68.16	78.70	63.71	58.42	70.73	32.03	26.14	32.63	14.44
ours+CIAR	71.79	83.36	65.78	62.01	74.74	53.42	26.26	32.92	14.05

CIAR-Grasp 的抓取估计结果如图 3-3。




图 3-3 抓取结果示意图
Fig 3-3 Visualization of grasp results

综上，实验验证了本研究方法的有效性与优越性，证明了 CIAR-Grasp 模型在不同环境条件下具有稳定且优于现有技术的抓取性能。

3.3.2 真实环境抓取实验

本实验在实验室环境中的桌面抓取平台进行。使用一台 6 自由度机械臂 (Universal Robots UR5) 执行抓取动作，末端安装两指平行夹爪 (Robotiq 2f-140 型) 用于夹取物体。工作台尺寸约为 $0.8\text{m} \times 0.8\text{m}$ ，机械臂安装在桌面一侧。Intel RealSense D435 RGB-D 深度摄像头固定在机械臂末端上方约 15cm 处，俯视覆盖整个工作区域。通过手眼标定，摄像头坐标系与机械臂坐标系对齐，以确保能将相机获取的点云转换到机器人坐标系用于抓取姿态计算。实验过程中，机械臂以单视角点云为输入进行抓取决策，不进行额外的视角切换或调整。抓取实验的机器人平台与实验场景见图 3-4。



眼在手上的机械臂-相机抓取平台

抓取实验场景

图 3-4 眼在手上的机械臂-相机抓取平台与实验场景

Fig 3-4 Eye-in-hand robotic arm-camera grasping platform and scene

测试物体选自日常物品，共 23 种，涵盖不同大小和形状，以考察算法对不同尺度目标的适应性。其中包括玩具模型和车厘子等小型物体，水果和洗漱用品中型物体，纸盒和打气筒等以及较大型物体。在实验中，本研究设计两种复杂程度不同的场景：(1)单目标抓取场景：在约 $40\text{cm} \times 40\text{cm}$ 的区域内随机放置 1 个物体；(2)杂乱场景：在约 $40\text{cm} \times 40\text{cm}$ 的区域内随机放置多个物体，物体彼此有少许间隔，避免完全覆盖。每种场景下，物体的初始姿态和摆放位置均随机变化，以增加实验多样性和挑战性。

对于单个物体采用抓取成功率 (Success Rate, SR)作为评估指标：定义为成功抓取并拿起物体的次数占总尝试抓取次数的比例。成功抓取的判断标准是机械臂按规划姿态夹持物体并将其从桌面提起，无掉落滑落现象。

对于多个物体场景成功率 (Scene Completion Rate, SCR)：定义为在限定的抓取尝试次数内清空整个场景的情况比例。SCR 以百分比表示,表示场景中待抓取物体数/抓取次数。

为充分比较 3.1 节方法的效果，本研究将在单物体场景中分别测试基线算法和使用了本研究提出的多维度指标的抓取算法。基线选择目前通用的 3.2 节所提出的端到端抓取网络。两种方法在相同条件下分别执行实验，以抓取成功率作为

主要评价指标，每种方法对单个物体抓取各进行 10 次，共 23 个物体，进行 230 次抓取。实验结果如表 3-5 所示。

表 3-5 机械臂抓取实验结果
Table 3-5 Robotic grasping experiment results

序号	物体类别	抓取次数	基线/基线+多维度指标
1	橙子 (中)	10	8/9
2	香蕉 (中)	10	9/10
3	梨 (中)	10	8/9
4	柠檬 (中)	10	10/9
5	桃子 (中)	10	9/10
6	小苏打牙膏 (中)	10	8/10
7	黑人牙膏 (中)	10	9/10
8	大宝洗面奶 (中)	10	10/10
9	大宝 sod (中)	10	10/10
10	小球 (小)	10	9/8
11	瓶子 (中)	10	7/9
12	狮子 (小)	10	9/10
13	猩猩 (小)	10	10/10
14	斑马 (小)	10	9/10
15	大象 (小)	10	10/10
16	河马 (小)	10	9/10
17	cheezit 盒子(大)	10	10/10
18	盘子 (大)	10	7/9
19	打气筒 (大)	10	7/10
20	dove 沐浴露 (大)	10	5/3
21	车厘子 (小)	10	8/10
22	三角柱 (大)	10	4/6
23	运动水壶 (大)	10	5/7

从单目标抓取实验的结果来看，本文提出的基于多维度指标的抓取方法较没有使用多维度指标优化的基线方法 CIAR-GRASP 展现出了更好的整体性能，平均抓取成功率 (SR) 由基线的 82.61%提升至 90.87%，提高了约 8 个百分点，体现了本方法在单一物体抓取任务中对多种尺度和形状的物体具有更高的适应性与鲁

棒性。

对于场景级别抓取，对每个方法设置了 5 个场景，每个场景中各布置了 5-9 种物体。结果如表 3-6 所示。

表 3-6 场景级物体抓取实验结果
Table 3-6 Scene-level object grasping experiment results

实验序号	物体数量	单物体抓取次数		场景级成功抓取率	
		Graspnet	Ours	Graspnet	Ours
1	5	8	6	62.50%	83.33%
2	6	8	6	75.00%	100.00%
3	7	11	8	63.64%	87.50%
4	8	10	8	80.00%	100.00%
5	9	15	9	60.00%	100.00%

对场景级别的抓取，选取 Graspnet 与本文提出的方法作为对比算法。从实验数据来看，Graspnet 方法的抓取成功率在多个场景中成功率为 60%-80%左右。而本研究的方法则在大部分场景中均实现了 80%到 100%的成功率。这表明，本研究提出的方法在处理多物体场景以及抓取顺序规划上更鲁棒，能够在限定次数内以更少的抓取尝试清空工作区域的物体。抓取执行的流程以及抓取位姿估计如图 3-5 与图 3-6。




图 3-5 抓取动作流程
Fig 3-5 Grasping procedure




图 3-6 场景级抓取检测结果
Fig 3-6 Scene-level grasp detection results

3.4 本章小结

本章围绕机器人抓取任务中抓取质量的评估与其优化展开，提出了一套基于多维度指标的综合评价体系 and 一种具有通道交互注意力机制的抓取网络，并开展了全面的实验验证。

首先，为解决传统单一力闭合指标无法全面反映抓取质量的问题，本章设计了一个综合评价指标体系，包括扭矩平衡性、质心距离、接触点分布平衡性、接触点非共面性以及传统力闭合指标。通过定义明确的数学公式量化各维度，形成了一个可调节权重的综合评分公式，能够灵活适应不同的抓取任务需求。

其次，针对点云数据高维稀疏、缺乏明确空间结构的挑战，本章提出了通道交互注意力机制。CIAR 能够有效捕捉点云特征通道间的复杂关系，突出不同通道的重要性，实现更鲁棒、更具判别力的特征表示。基于 CIAR，进一步构建了融合稀疏卷积技术和多尺度特征的抓取网络架构，显著提升了机器人抓取位姿预测的精度与鲁棒性。

最后，本章在 GraspNet-1Billion 公开数据集和真实实验平台上进行了广泛的实验验证。结果表明，本章提出的 CIAR-Grasp 网络在抓取精度和稳定性方面均优于主流方法，在已见物体、相似物体和未见物体类别中表现突出。此外，真实环

境中的实验进一步证明，基于多维度指标的抓取算法显著提高了物体的抓取的成功率，验证了所提方法的有效性。

综上所述，本章所提出的基于多维度指标的抓取质量评估与优化方法，以及CIAR 抓取网络，为机器人在复杂环境下实现高效、鲁棒的抓取操作提供了有效的理论和方法支撑。

第四章 “视觉—语言—动作”模型的抓取与投掷任务规划

4.1 系统总体架构设计

本研究提出了一种“视觉-语言-动作”模型，旨在实现机器人抓取与投掷任务的自动化规划。系统总体架构如图 4-1 所示，包括视觉感知模块、开放词汇抓取检测模块、抓取位姿估计与优化模块、投掷技能学习模块以及大语言模型驱动的任务规划模块。




图 4-1 系统总体架构示意图
Fig 4-1 Overall system architecture diagram

首先，视觉感知模块利用 Realsense 摄像头实时采集环境的 RGB-D 数据，通过相机内参标定和手眼标定^[64]算法，构建相机坐标系到机器人基坐标系的转换矩阵。

其次，通过基于 YOLO-World 模型的开放词汇抓取检测模块，实现对 RGB

图像中目标的自由文本检测。该模块能够根据用户提供的任意文本，识别图像中的特定类别物体。

抓取位姿估计模块对目标物体进行精确抓取位姿的预测。具体而言，模块采用第三章的基于稀疏卷积的编码器-解码器网络，有效提高模型的特征提取能力与抓取预测精度。

在动作执行阶段，机器人可基于视觉感知与位姿估计结果执行具体动作计划，包括抓取动作与投掷动作。本研究中抓取动作利用 UR 机械臂的 RTDE 接口实时控制实现，具体动作规划包括移动到预抓取位置、执行抓取、抬起物体等；投掷动作通过基于软演员-评论家的强化学习方法训练得到动作策略，以实现指定目标位置的准确投掷。

在任务规划阶段，系统集成了 DeepSeek 大语言模型，通过自然语言指令实现任务的高效规划。例如用户指令“请帮我抓取香蕉并投掷到指定位置”，模型即可自动生成相应的动作计划，调用视觉感知、抓取检测与投掷动作执行模块，协同完成任务。

最终，通过系统架构的实际部署与验证，机器人能够在复杂动态环境中高效准确地完成抓取与投掷任务，充分体现了视觉感知、语言理解与动作执行的深度融合。

4.2 开放词汇抓取检测模块实现

本研究中的开放词汇抓取检测模块主要基于 YOLO-World^[65]模型实现，旨在实现灵活、高效的目标物体检测与定位，以适应机器人在未知环境中的任务规划需求，框架见下图 4-2。




图 4-2 Yolo-World 结构示意图
Fig 4-2 Yolo-World architecture

首先，YOLO-World 模型允许用户以自由文本形式输入目标物体的英文名称，例如“banana”，模型根据输入文本对场景中的 RGB 图像执行目标检测并返回候选目标的二维边界框（Bounding Box，BBBox）。具体实现流程包括以下步骤：

- (1) 获取实时 RGB 图像，并保存为临时图像文件；
- (2) 将临时图像数据以 Base64 编码形式，通过本地 REST API 请求方式调用基于 YOLO-World 模型的目标检测服务；
- (3) YOLO-World 模型根据输入的文本信息进行目标识别，返回检测到的物体类别、边界框坐标及置信度；
- (3) 根据检测结果，将获取到的二维 BBBox 与抓取位姿估计模块输出的候选抓取位姿进行匹配与筛选，从而选出符合目标要求的最优抓取位姿。

通过开放词汇抓取检测模块的部署，系统能够根据用户自由输入的英文文本精确地识别和定位目标物体，并与后续动作执行阶段无缝衔接，形成高效、精准的抓取与投掷动作规划，提高机器人在动态复杂环境中的智能性与适应能力。

4.3 基于 SAC 的机器人投掷技能学习

本节将详细阐述如何利用深度强化学习算法 SAC^[66]（Soft Actor-Critic）进行

机器人投掷技能的学习，包括状态空间与动作空间的设计、奖励函数的构建与策略学习，以及仿真平台的搭建与实验验证。

4.3.1 状态空间与动作空间设计

为了实现机器人精准且稳定的投掷技能，首先需要合理地设计状态空间与动作空间，以充分描述机器人投掷任务的物理特征和控制需求。

状态空间设计：机器人投掷任务的状态空间设计主要考虑机器人的关节角度、关节角速度、末端 TCP 的位置与速度，以及目标位置的信息。具体来说，状态向量可定义为：

$$S = [\theta, \dot{\theta}, p_{tcp}, v_{tcp}, p_{goal}] \quad (4-1)$$

式中， θ 表示机器人 6 个关节的角度； $\dot{\theta}$ 表示机器人 6 个关节的角速度； p_{tcp} 表示机器人末端执行器（TCP）的三维坐标位置； v_{tcp} 表示机器人 TCP 的三维速度； p_{goal} 表示目标位置的三维坐标位置。

通过以上设计的状态空间，机器人可以明确自身当前的姿态状态以及任务目标，有助于强化学习算法更加高效地学习投掷策略。

动作空间设计：考虑到机器人关节角度调节的实际物理限制以及控制精度要求，本研究将动作空间定义为机器人的 6 个关节角度的增量调整：

$$[\Delta\theta_1, \Delta\theta_2, \Delta\theta_3, \Delta\theta_4, \Delta\theta_5, \Delta\theta_6] \quad (4-2)$$

式中， $\Delta\theta_i$ 表示第 i 个关节的角增量。

每个动作的取值范围均限定在 $[-\alpha, \alpha]$ 之间，以确保动作输出的可控性和精细度。同时，为便于计算与优化，动作在训练时均归一化至 $[-1, 1]$ 。

4.3.2 奖励函数构建与策略学习

奖励函数的设计在强化学习中具有关键作用，尤其是在机器人投掷任务中。针对本研究投掷任务的特殊性，本研究设计了一种奖励函数，确保投掷任务的成功率。

本文提出一种奖励函数，公式如 4-3:

$$R = w_1 R_{acc} + w_2 R_{ori} \quad (4-3)$$

式中， R_{acc} 为落点与目标位置的距离函数，采用如公式 4-4 指数衰减形式，以有效缓解奖励稀疏问题。 R_{ori} 为方向奖励，采用余弦相似度衡量投掷落点到机器人工具中心点的向量与目标落点到机器人工具中心点向量之间的夹角， w_1 ， w_2 为奖励函数中的权重参数。

$$R_{acc} = e^{-d^2} - 1 \quad (4-4)$$

式中， d 表示物体的投掷落点与期望落点之间的距离。采用高斯型指数在 d 靠近 0 的时候， R_{acc} 的梯度也接近 0，有利于寻找全局最优解。

本研究的策略学习采用软演员评论家算法。基于强化学习中的软演员-评论家算法训练机器人投掷技能。SAC 是一种离策略的、基于熵正则化的强化学习算法，通过最大化策略的熵来有效地解决策略探索不足的问题。具体而言，SAC 在策略优化目标中增加了熵项，鼓励策略在有效执行任务的同时保持一定的随机性，从而提高策略探索效率和泛化能力。

SAC 算法包括三个核心部分，分别是演员网络、评论家网络和熵温度调节。其中，Actor 网络负责生成动作策略，通过概率分布的均值和方差参数化动作分布，并使用 $\tanh$ 函数限制动作输出范围。Critic 网络则利用两个独立但结构相同的 Q 网络对动作-状态对进行估值，采用“双 Q 学习”的方式来减少高估偏差，从而使学习过程更稳定。

在本研究中，状态空间包括机器人关节位置、速度、末端执行器的位置与速度等信息；动作空间定义为关节运动的连续控制指令。奖励函数设计考虑了多个因素，包括投掷精度、机器人末端位姿朝向目标方向的精确程度，以及动作执行的能耗等多维度指标，通过设计复合奖励，激励机器人逐步优化运动轨迹。总体流程见下图 4-3。




图 4-3 投掷任务 SAC 示意图
Fig 4-3 Throwing task SAC schematic diagram

软演员-评论家算法的整体结构包含三个关键模块：策略网络、价值网络和环境交互模块。

策略网络根据当前状态 s_t ，产生动作 a_t ：

$$a_t = \mu(s_t | \theta_\mu) + \sigma \cdot \varepsilon, \quad \varepsilon \sim N(0, I) \quad (4-5)$$

式中， a_t 为在时刻 t 产生的动作， $\mu(s_t | \theta_\mu)$ 为策略网络输出的确定性动作， σ 为探索的尺度参数， ε 为从标准高斯分布中采样的噪声。

动作 a_t 作用于环境，环境返回下一状态 s_{t+1} 与奖励 r_t 。随后，经验数据以元组 $(s_t, a_t, r_t, s_{t+1}, d_t)$ 的形式存入回放缓冲区。

Critic 模块包含两个 Q 网络 $Q(s, a | \theta_Q)$ 、 $Q'(s, a | \theta_{Q'})$ 与相应的目标网络 Q_{target} 。Critic 网络估计动作价值函数，用于指导策略更新：

$$Q(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim p, a' \sim \pi} [Q(s', a') - \alpha \log \pi(a' | s')] \quad (4-6)$$

式中， $Q(s, a)$ 为状态-动作对的价值函数， $r(s, a)$ 为即时奖励， γ 为折扣因子， α 为熵正则化系数， s' 为下一时刻状态， a' 为策略网络根据 s' 产生的下一动作。

目标网络参数通过软更新方式缓慢更新，以稳定训练过程：

$$\theta' \leftarrow \tau \theta + (1 - \tau) \theta' \quad (4-7)$$

式中， θ' 为目标网络的参数， θ 为当前 Critic 网络的参数， τ 为软更新的系数，

用于控制参数更新的速度。

整体结构通过此三者之间的协同交互，实现最大熵强化学习目标，有效提升策略探索能力和学习稳定性。

网络结构方面，Actor 与 Critic 均采用三层全连接网络，每层中有 256 个神经元，并使用 ReLU 作为激活函数。Actor 网络输出动作的均值与标准差，构成高斯策略分布；Critic 网络采用双 Q 架构，分别独立估计两个 Q 值，并取其最小值用于策略优化。优化过程中，Actor 网络通过最大化期望回报和策略熵的联合目标函数来实现策略更新；Critic 网络则通过最小化预测 Q 值与目标 Q 值之间的均方误差 (MSE) 进行参数优化。此外，引入熵温度因子 (α) 并进行自动调节，以确保策略熵的大小符合目标熵，从而自适应地控制策略的随机性。

在训练过程中，使用经验回放技术存储并随机抽取历史经验数据，以降低训练样本之间的相关性，提升训练稳定性。经验回放的容量设置为 80000，批量更新大小设定为 256。每个训练周期中执行软更新方法，以缓慢更新 Critic 网络的目标网络参数，防止过快的参数变化带来的不稳定性。经过仿真实验验证，见 4.3.3。

4.3.3 仿真平台搭建与实验

为了系统地评估 4.3.2 所设计的 SAC 算法在机器人投掷任务中的表现，本研究基于 MuJoCo 物理引擎搭建了机器人投掷人物的仿真实验平台。MuJoCo 拥有卓越的实时仿真能力，能够准确模拟机械臂的动力学特性、关节摩擦、以及投掷过程中物体与环境的交互行为。

在仿真环境中，以六自由度机械臂为主体构建机器人投掷任务。此外，定义了若干不同位置的目标区域，并在实验过程中随机生成投掷的目标位置，以评估机器人投掷策略的泛化能力与鲁棒性，场景如图 4-4。




图 4-4 Mujoco 仿真场景
Fig 4-4 Mujoco simulation scene

在上述仿真环境搭建完成后，本研究系统地评估了所设计的 SAC 算法在机器人投掷任务中的表现，并与 DDPG 算法和 TD3 算法进行了对比实验。训练的奖励曲线图如下图 4-5。




图 4-5 奖励函数对比曲线
Fig 4-5 Comparison curve of reward functions

在对比实验中，三种算法均采用相同的状态空间、动作空间及奖励函数，以确保实验条件的一致性和公平性。每种算法训练过程包括 2500 个 episodes，每个 episode 最多持续 60 个 steps。

评价指标采用两项，分别是成功率与平均步长。成功率是机器人投掷后，物体准确落入目标区域的成功次数占总投掷次数的比例。平均步长是机器人执行投掷所需的 steps 数量。投掷的过程如下图 4-6，实验结果如下表 4-1。




图 4-6 Mujoco 中的投掷过程
Fig 4-6 Throwing process in Mujoco

表 4-1 强化学习在投掷任务中的对比
Table 4-1 Comparison of reinforcement learning in the throwing task

算法	成功数	平均步长
DDPG	1470	25.41
TD3	1999	22.42
SAC	2059	23.04

实验结果表明，通过所提出的状态空间设计、奖励函数优化和策略学习，机器人能够自主地学习出高效且稳定的投掷策略，且对于不同的强化学习算法均可以实现奖励收敛与策略收敛。具体而言，经过训练，机器人实现了显著的策略收敛与性能提升。实验结果表明，SAC 算法表现出较高的成功率和较为合理的平均步长。SAC 算法在 2500 个回合中的成功次数达到 2059 次，明显高于 DDPG 算法的 1470 次和 TD3 算法的 1999 次。在平均步长方面，SAC 算法的平均步长为 23.04 步，略高于 TD3 算法的 22.42 步，但明显优于 DDPG 算法的 25.41 步。这说明 SAC 算法在保持高成功率的同时，投掷动作执行效率也较为出色。

综上所述，本研究所设计的 SAC 算法在机器人投掷任务中展现了更强的泛化

能力与鲁棒性,综合表现优于 DDPG 和 TD3 算法,进一步验证了所提方法的有效性与优越性。

4.4 大语言模型驱动的任务规划

4.4.1 LLM API 集成与 Prompt 设计

为了实现机器人操作任务的灵活性与通用性,将大语言模型集成至机器人操作规划中。选用 DeepSeek 作为大语言模型的后端,构建 API 接口以实现实时通信。在任务规划过程中,设计特定 Prompt 结构,将用户输入的自然语言指令转化为可执行的机器人动作序列。Prompt 的设计具体包括任务描述、技能 API 描述及明确的任务要求,使得 LLM 能够准确理解任务需求并输出对应的 Python 代码以执行抓取和操作任务。

为了确保 Prompt 能够有效地激发 LLM 对任务的理解能力并得到准确输出,引入了 Prompt 设计的最佳实践,包括:

(1) Prompt 包含任务目标与可调用 API 定义,明确 LLM 输出内容的格式,降低模型输出不确定性。

(2) 仅开放与任务直接相关的机器人技能 API 调用,使模型专注于规划任务步骤。

(3) 要求模型输出代码以函数形式返回,使任务执行流程清晰、易于调试。

通过上述设计,可确保大语言模型高效生成准确的任务执行代码,并与机器人操作系统无缝衔接。

4.4.2 LLM 任务规划与执行

本节探讨了如何基于大语言模型 (LLM) 实现机器人抓取任务的智能化规划与执行。结合第 3 章所述的 CIAR-Grasp 网络和第 4 章已建立的“视觉—语言—动作”联合框架,设计了一套由 LLM 驱动的机器人任务规划与执行系统。

首先，系统定义了一个与 LLM 交互的标准接口，其中包括以下核心 API：

- (1) LLM 将自然语言转化为具体任务目标，即识别需要抓取的物体类别。
- (2) 系统调用 YOLO-World 开放词汇检测模型，通过输入的物体名称对实时 RGB-D 图像进行检测，并确定目标物体的二维边界框。
- (3) 利用 CIAR-Grasp 抓取网络对环境的点云数据进行分析，生成多种潜在的抓取姿态。
- (4) 根据物体的二维检测结果对生成的抓取姿态进行筛选，确定最佳抓取点。
- (5) 机器人接收到选定的抓取姿态后，通过机械臂接口实时控制机械臂与夹爪执行精确抓取动作。
- (6) 根据双目相机的目标位置检测，确定需要投掷的目标框位置，通过 SAC 推理投掷轨迹，并通过机械臂的运动单元执行该投掷轨迹。

上述流程实现了从自然语言输入到机器人动作执行的无缝衔接。通过大语言模型驱动的任务规划，机器人能够更直观地理解用户需求，实现高效、精确的抓取任务。这种“视觉—语言—动作”模型进一步提高了机器人在动态和复杂环境中的智能操作能力，为后续更加复杂的任务如装配等操作提供了思路。

4.5 物理平台实验分析

4.5.1 投掷任务实验与分析

本节旨在对机器人投掷任务在物理平台上的实际表现进行详细实验与分析，验证基于 SAC 策略训练的投掷技能。

- (1) 实验平台由以下部分构成

选用一台 6 自由度机械臂（Universal Robots UR5）执行抓取动作，末端安装两指平行夹爪，Robotiq 2f-140 型，用于夹取物体；配置一台 Realsense D435i 相机固定在机械臂末端，用于抓取检测的输入；在投掷区域上方俯视配置一台 Zed 2i 双目深度相机，实现目标位置的实时采集；同时，传感器数据为后续动作调整提供反馈。

(2) 任务描述

机器人需在限定区域内将指定物体投掷至预设目标区。目标区位置以及距离均通过 Zed2i 相机采集并通过半全局块匹配^[67]方法计算得到。

(3) 实验流程

首先通过采集双目相机的左右图像，利用立体匹配算法计算像素视差，再结合相机的内参和基线，通过三角测量将二维图像转化为三维坐标，从而实时生成高精度的目标位置的笛卡尔坐标信息；其次基于 SAC 策略和实时相机数据，系统生成投掷动作的轨迹规划；再次机器人执行投掷动作，并记录物体落点信息；最后每次投掷后，系统自动统计成功率，即物体是否落入目标区域，投掷场景如图 4-7。




图 4-7 投掷场景图
Fig 4-7 Throwing scene

实验中采用投掷成功率指标进行量化评估，统计多次试验中物体落入目标区域的比例，反映系统整体精度。目标大小分别为 25×25 ， 20×20 ， 15×15 ，单位为厘米。本实验旨在评估机器人在不同投掷距离区间内对多种物体的投掷性能与成功率。实验中选取苹果、橙子、马克笔、玩具狮子及小球作为代表性物体，并将机器人基坐标系的 X 轴的正方向 1.2 米至 1.8 米的范围内，且该区域在机械臂的 Y

轴坐标随机分布在 ± 0.5 米的区间内，Z 轴的坐标分布在为 -0.8 至 -0.6 米内，按 0.2 米的间隔划分为若干区间（1.2–1.4 米、1.4–1.6 米、1.6–1.8 米）。在每个距离区间内，随机摆放目标区域的位置，针对每种物体进行多次投掷，记录总投掷次数、成功到达目标区域的次数，并计算成功率（成功次数占总次数的百分比）。本实验设计旨在系统分析机器人在不同距离条件下的投掷稳定性与精度变化，为后续动作优化与策略调整提供数据支持。结果如下表 4-2、表 4-3、表 4-4。

表 4-2 投掷实验结果(1.2-1.4 米)

Table 4-2 Throwing Experiment Results (1.2–1.4 meters)

物体	目标大小	投掷次数	成功数	成功率 (%)
苹果	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	8	80
橙子	25 × 25	10	10	100
	20 × 20	10	9	90
	15 × 15	10	9	90
马克笔	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	9	90
狮子	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	10	100
香蕉	25 × 25	10	9	90
	20 × 20	10	7	70
	15 × 15	10	4	40

表 4-3 投掷实验结果(1.4-1.6 米)

Table 4-3 Throwing Experiment Results (1.4–1.6 meters)

物体	目标大小	投掷次数	成功数	成功率 (%)
苹果	25 × 25	10	10	100

投掷实验结果(1.4-1.6 米) (续表)

物体	目标大小	投掷次数	成功数	成功率 (%)
橙子	20 × 20	10	10	100
	15 × 15	10	10	100
	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	8	80
马克笔	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	10	100
狮子	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	10	100
香蕉	25 × 25	10	9	90
	20 × 20	10	8	80
	15 × 15	10	3	30

表 4-4 投掷实验结果(1.6-1.8 米)

Table 4-4 Throwing Experiment Results (1.6–1.8 meters)

物体	目标大小	投掷次数	成功数	成功率 (%)
苹果	25 × 25	10	10	100
	20 × 20	10	9	90
	15 × 15	10	8	80
橙子	25 × 25	10	10	100
	20 × 20	10	9	90
	15 × 15	10	9	90
马克笔	25 × 25	10	10	100
	20 × 20	10	10	100
	15 × 15	10	9	90
狮子	25 × 25	10	10	100

物体	目标大小	投掷次数	成功数	成功率 (%)
投掷实验结果(1.6-1.8 米) (续表)				
香蕉	20 × 20	10	10	100
	15 × 15	10	9	90
	25 × 25	10	9	90
	20 × 20	10	7	70
	15 × 15	10	4	40

根据统计的投掷信息,首先,从不同距离区间的整体表现来看,在 1.2–1.4 米、1.4–1.6 米和 1.6–1.8 米区间的平均成功率分别为 90%、92%和 88.67%。结果表明,在机器人实际可以投掷到的范围内,采用 4.3 节的状态空间设计与策略学习方法部署的机器人投掷整体成功率约在 90.22%左右。

其次,在物体类别方面,狮子(玩具)和马克笔的平均成功率最高,分别达到 98.89%和 97.78%,苹果和橙子的平均成功率分别为 94.44%和 93.33%,而香蕉的平均成功率明显较低,为 66.67%。这一结果说明不同物体的尺寸、形状及质量特性对投掷性能具有显著影响,其中稳定性高、质心分布均匀的物体更易被精准投掷。这一结果说明不同物体的尺寸、形状及质量特性对投掷性能具有显著影响,其中稳定性高、质心分布均匀的物体更易被精准投掷。香蕉长约 16 厘米,而实验设置中最小目标区域仅为 15×15 厘米,因此投掷香蕉时,其形状和尺寸接近目标区域的大小,投掷受初始的姿态与落地时的姿态影响较大,成功率较低,且成功的案例中有部分依赖于类似于“打板”进入的方式。

最后,在目标区域尺寸方面,25×25cm、20×20cm 和 15×15cm 尺寸的平均成功率分别为 98%、92.67%和 80%。随着目标区域尺寸减小,成功率有所下降,表明目标区域的尺寸大小对系统整体的成功率有直接影响。这说明在较大目标区域内,基于 SAC 策略的机械臂投掷动作具有较高的稳健性与精度,而在更小目标区域内,对投掷动作的精度要求提高,误差容忍度降低,导致成功率下降。

此外,在投掷过程中,理想状态下应当在机械臂到达或经过某一特定点,通

常是规划好的释放点时刻准确释放物体，使得其沿着计算好的抛物线飞向目标区。如果夹爪在接收到释放指令后并没有即时响应，而是存在几十毫秒到上百毫秒的延迟，那么机械臂在继续运动的过程中，物体将被“多带”一定距离。由于此时机械臂正处于高速运动或转动姿态，物体在空中将偏离原先的计划轨迹，进而造成落点与目标中心的偏移，这也是造成目标区域变小的情况下，投掷成功率下降的原因。投掷实际过程如图 4-8。

综合分析上述结果可知，机器人系统在中近距离范围内对多种物体均表现出良好的投掷能力，且在较大目标尺寸条件下能够实现高成功率。然而，随着目标尺寸减小及投掷距离增加，系统的投掷精度和稳定性受到一定挑战，提示在更高精度要求下需进一步优化投掷策略与控制参数。




图 4-8 投掷过程
Fig 4-8 Throwing process

4.5.2 基于“视觉—语言—动作”模型的抓取与投掷任务实验与分析

为了验证本文提出的基于“视觉—语言—动作”（VLA）模型在实际环境中对机器人抓取与投掷任务的有效性与鲁棒性，开展了相应的物理平台实验。本实验在 UR 机械臂、Robotiq2f-140 夹爪与 Realsense D435i 相机组成的机器人平台上进行，采用本文提出的 CIAR-Grasp 抓取姿态检测网络与基于强化学习的投掷策略，以及大语言模型驱动的任务规划。

实验平台首先通过 Realsense 相机实时获取场景的 RGB-D 图像信息，并使用开放词汇的抓取检测模块对目标物体在图像中定位。然后，利用 CIAR-Grasp 网络获得 6 自由度抓取位姿，并基于 Tsai-Lenz 手眼标定方法将该位姿从相机坐标系映射到机械臂基坐标系下。抓取完成后，利用 zed 相机对投掷的目标位置进行定位。最后，根据目标位置，使用基于软演员评论家（SAC）的强化学习投掷策略进行机械臂的投掷动作规划，投掷区域大小选取 20×20 厘米。

实验过程中，以日常生活物体为抓取与投掷对象，例如水果、玩具和水壶等。在场景中设置 5 个物体，单个场景重复实验 10 次，记录并分析抓取成功率与投掷目标成功率等。结果如下表。

表 4-5 抓取与投掷联合任务成功率
Table 4-5 Success Rate of the Integrated Grasping and Throwing Task

序号	物体	抓取次数	抓取成功次数	抓取成功率(%)	投掷成功次数	投掷成功率(%)
1	苹果	10	9	90	8	88.9
2	柠檬	10	10	100	9	90
3	水壶	10	8	80	7	87.5
4	橙子	10	10	100	9	90
5	香蕉	10	10	100	8	80
总计	——	50	47	94	41	87.23

实验结果表明，基于“视觉-语言-动作”模型的抓取与投掷的任务规划，通过

自然语言指令实现高效、精准的抓取与投掷任务。

4.6 本章小结

本章针对机器人抓取与投掷任务的智能化规划，提出了一种融合视觉感知、语言理解与动作执行的“视觉—语言—动作”模型。首先构建了整体架构，其中包括视觉感知模块、开放词汇抓取检测模块、抓取位姿估计与优化模块、投掷技能学习模块及大语言模型驱动的任务规划模块。

在视觉感知阶段，利用Realsense相机与Tsai-Lenz算法实现环境感知与手眼标定。基于YOLO-World模型开发的开放词汇抓取检测模块，实现了用户指定物体的灵活检测。随后，通过CIAR-Grasp网络精确估计与优化目标物体的抓取位姿，提升抓取精度。

投掷技能采用软演员-评论家 (SAC) 强化学习算法，设计了合理的状态空间、动作空间与奖励函数，实现了对物体投掷技能的高效学习。仿真实验表明，SAC算法相比DDPG与TD3算法，在成功率和动作效率方面均表现出优势。

通过集成大语言模型，实现了机器人任务中，自然语言指令向具体动作规划。这一方法使得机器人任务规划更加灵活。在物理平台实验验证了本系统在实际环境下的抓取与投掷能力，整体抓取成功率达到94%，投掷成功率达87.23%，体现了所提模型的鲁棒性与智能性。

第五章 总结与展望

5.1 总结

本研究聚焦于机器人的抓取任务与投掷任务的自主决策与操作问题，创新性地提出了集成“视觉—语言—动作”的技能模型。具体总结如下：

首先，在抓取质量评估方面，针对传统单一力闭合指标的局限性，构建了一种基于扭矩平衡性、质心距离、接触点分布平衡性及非共面性的多维度综合评价体系。该体系通过精心设计的综合评分机制，显著提升了机器人抓取任务的成功率，从 82.61% 提高至 90.87%。在特征提取方面，设计了基于通道交互注意力机制 (CIAR) 的抓取位姿检测网络 (CIAR-Grasp)，有效捕捉点云特征通道间的差异与互补信息，融合稀疏卷积与多尺度特征技术，使网络在 GraspNet-1Billion 数据集评测中取得了优于现有方法的性能，Realsense 与 Kinect 传感器的 mAP 指标分别达到 53.29 和 45.01。

其次，在投掷任务中，本研究采用软演员-评论家 (SAC) 强化学习框架构建了高效的投掷技能学习系统。通过精细设计的状态空间、动作空间与奖励函数，实现了机器人自主学习精准投掷策略。对比实验表明，本文引入的 SAC 方法在投掷成功率方面优于传统 DDPG 与 TD3 算法。

最后，实现了一套基于“视觉—语言—动作”模型的机器人任务规划系统。该系统集成开放词汇抓取检测技术与大语言模型能力，使机器人能根据自然语言指令准确识别目标物体并生成相应动作序列。实际应用验证，系统表现出极高的环境适应性，抓取成功率达 94%，投掷成功率达 87.23%。

综上所述，本研究通过深入探索抓取质量评估、特征提取网络设计、强化学习技能学习及大模型任务规划等关键技术，不仅丰富了机器人抓取与投掷领域的理论基础，更提供了实用可行的技术解决方案，为智能机器人在复杂环境中的应用开辟了新途径。

5.2 展望

尽管本研究取得了一系列研究进展,机器人在复杂环境中执行精确抓取与投掷任务仍存在诸多待解决的挑战与研究方向。未来研究可以从以下几个方面展开:

(1) 当前深度学习驱动的机器人抓取与投掷方法,在未见物体与动态环境中的泛化性仍显不足,且训练和推理过程计算复杂,难以满足实时应用需求。未来可探索无监督、半监督及迁移学习方法,结合轻量化网络结构设计、模型压缩与硬件加速技术,以提升机器人的泛化性能与实时响应能力。

(2) 本研究初步探讨了语言驱动的任务规划技术,但在更复杂、更模糊的人机交互场景下仍有局限。未来研究应进一步引入更强大的多模态语言模型,加强机器人在多轮交互、意图理解与长期任务规划等方面的智能性。

(3) 当前方法虽已在实验室环境得到初步验证,但实际工业应用仍存在巨大挑战。未来应致力于多机器人协作通信与策略优化,推进机器人在复杂装配、精密操作及医疗辅助等实际工业任务中的应用与落地。

参考文献

- [1] ROA M A, SUÁREZ R. Grasp quality measures: review and performance [J]. *Autonomous Robots*, 2015, 38(1): 65-88. DOI:10.1007/s10514-014-9402-3.
- [2] BICCHI A. On the closure properties of robotic grasping[J]. *The International Journal of Robotics Research*, 1995, 14(4): 319-334.
- [3] NGUYEN V D. Constructing force-closure grasps[J]. *The International Journal of Robotics Research*, 1988, 7(3): 3-16.
- [4] MAHLER J, KRANZL S, KENNY B, et al. Dex-net 1.0: A cloud-based network of 3D objects for robust grasp planning using a multi-armed bandit model with correlated rewards[C]//2016 IEEE International Conference on Robotics and Automation (ICRA). Stockholm: IEEE, 2016: 1957-1964. DOI:10.1109/ICRA.2016.7487295.
- [5] FANG H S, SUN Q, WANG M, et al. GraspNet-1Billion: A large-scale benchmark for general object grasping[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2020: 11444-11453. DOI:10.1109/CVPR42600.2020.01146.
- [6] SONG S, ZENG A, LEE J, et al. Grasping in the wild: Learning 6DoF closed-loop grasping from low-cost demonstrations[J]. *IEEE Robotics and Automation Letters*, 2020, 5(3): 4978-4985. DOI:10.1109/LRA.2020.3002234.
- [7] TEN PAS A, GUALTIERI M, SAENKO K, et al. Grasp pose detection in point clouds[J]. *The International Journal of Robotics Research*, 2017, 36(13-14): 1455-1473. DOI:10.1177/0278364917735594.
- [8] MASON M T, LYNCH K M. Dynamic manipulation[C]//1993 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Yokohama: IEEE, 1993: 152-159. DOI:10.1109/IROS.1993.583128.
- [9] SENOO T, NAMIKI A, ISHIKAWA M. High-speed throwing motion based on kinetic chain approach[C]//2008 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Nice: IEEE, 2008: 3206-3211. DOI:10.1109/IROS.2008.4651227.

- [10] OKADA M, SEKIGUCHI T. Throwing motion design based on minimum sensitivity with respect to error covariance of robot dynamic parameters [J]. Mechanical Engineering Journal, 2021, 8(1): 20-00299. DOI:10.1299/mej.20-00299.
- [11] ZENG A, SONG S, LEE J, et al. TossingBot: Learning to throw arbitrary objects with residual physics[J]. IEEE Transactions on Robotics, 2020, 36(4): 1307-1319. DOI:10.1109/TRO.2020.2992939.
- [12] KASAEI H, KASAEI M. Throwing objects into a moving basket while avoiding obstacles[C]//2023 IEEE International Conference on Robotics and Automation (ICRA). London: IEEE, 2023: 6850-6856. DOI:10.1109/ICRA48891.2023.10160758.
- [13] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control[J]. arXiv:2307.15818, 2023.
- [14] MA Y, LU C, SHI Z, et al. A survey on vision-language-action models for embodied AI[J]. arXiv:2405.14093, 2024.
- [15] BROHAN A, CHEBOTAR Y, HAUSMAN K, et al. RT-1: Robotics Transformer for real-world control at scale[J]. arXiv:2212.06817, 2022.
- [16] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778. DOI:10.1109/CVPR.2016.90.
- [17] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30 (NeurIPS 2017). Long Beach: Curran Associates, 2017: 5998-6008.
- [18] CHI C, JAIN A, KURUTACH T, et al. Diffusion policy: Visuomotor policy learning via action diffusion[J]. The International Journal of Robotics Research, 2024: 02783649241273668. DOI:10.1177/02783649241273668.
- [19] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851.

- [20] AHN M, BROHAN A, SRINIVASA S S, et al. Do as I can, not as I say: Grounding language in robotic affordances[J]. arXiv:2204.01691, 2022.
- [21] CHOWDHER A, NARANG S, DEVLIN J, et al. PaLM: Scaling language modeling with pathways[J]. arXiv:2204.02311, 2022.
- [22] RIMON E, BURDICK J. On force and form closure for multiple finger grasps[C]//Proceedings of 1996 IEEE International Conference on Robotics and Automation (ICRA). Minneapolis: IEEE, 1996: 1795-1800.
- [23] LIU S, CARPIN S. Global grasp planning using triangular meshes[C]//2015 IEEE International Conference on Robotics and Automation (ICRA). Seattle: IEEE, 2015: 4902-4908. DOI:10.1109/ICRA.2015.7139883.
- [24] MURRAY R M, LI Z X, SASTRY S S. A mathematical introduction to robotic manipulation[M]. Boca Raton: CRC Press, 1994.
- [25] BORST C, FISCHER M, HIRZINGER G. A fast and robust grasp planner for arbitrary 3D objects[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). Detroit: IEEE, 1999: 1890-1896. DOI:10.1109/ROBOT.1999.772531.
- [26] FERRARI C, CANNY J. Planning optimal grasps[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). Nice: IEEE, 1992: 2290-2295. DOI:10.1109/ROBOT.1992.220020.
- [27] LI Z, SASTRY S. Task-oriented optimal grasping by multi-fingered robotic hands[J]. IEEE Journal of Robotics and Automation, 1988, 4(1): 32-44.
- [28] MAHLER J, MATAS J, GUALTIERI M, et al. Dex-Net: Deep learning for robotic grasping with synthetic point clouds and analytic grasp metrics [J]. Robotics: Science and Systems (RSS), 2017. DOI:10.15607/RSS.2017.XIII.068.
- [29] CHAVAL-DAFLE N, RODRIGUEZ A, PAOLY A, et al. Extrinsic dexterity: In-hand manipulation with external forces[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). Hong Kong: IEEE, 2014: 1578-1585. DOI:10.1109/ICRA.2014.6907079.
- [30] QI C R, SU H, MO K, et al. PointNet: Deep learning on point sets for

- 3D classification and segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 652-660. DOI:10.1109/CVPR.2017.16.
- [31] QI C R, YI L, SU H, et al. PointNet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in Neural Information Processing Systems, 2017, 30: 5099-5108.
- [32] WANG Y, SUN Y, LIU Z, et al. Dynamic graph CNN for learning on point clouds[C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems (NeurIPS). Montréal: Curran Associates, 2019: 1021-1031.
- [33] LIANG H, XIE L, DENG H, et al. PointNetGPD: Detecting grasp configurations from point sets[C]//2020 IEEE International Conference on Robotics and Automation. Paris: IEEE, 2020.
- [34] ZHOU Z, ZHU X, CAO Q. AAGDN: Attention-augmented grasp detection network based on coordinate attention and effective feature fusion method[J]. IEEE Robotics and Automation Letters, 2023, 8(4): 3462-3469. DOI: 10.1109/LRA.2023.3260050.
- [35] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City: IEEE, 2018: 7132-7141. DOI:10.1109/CVPR.2018.00745.
- [36] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV). Munich: Springer, 2018: 3-19. DOI:10.1007/978-3-030-01234-2_1.
- [37] LU Y H, DENG B X, WANG Z Y, et al. Hybrid physical metric for 6-DoF grasp pose detection[C]//Proceedings of the 2022 IEEE International Conference on Robotics and Automation (ICRA). Philadelphia: IEEE, 2022: 8238-8244. DOI:10.1109/ICRA46639.2022.9811954.
- [38] ZHANG Q, DENG B, LIU Q, et al. AMSC-Net: Adaptive multi-scale context aggregation network for 6-DoF grasp pose detection[C]//Proceedings of

- f the 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Kyoto: IEEE, 2022: 9505-9512. DOI:10.1109/IROS47612.2022.9981265.
- [39] REDMON J, ANGELOVA A. Real-time grasp detection using convolutional neural networks[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). Seattle: IEEE, 2015: 1316-1322. DOI: 10.1109/ICRA.2015.7139361.
- [40] YANG S, TANG S, ZHANG Y, et al. When transformer meets robotic grasping: Exploits context for efficient grasp detection[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12. DOI:10.1109/TIM.2023.3275669.
- [41] NI P, ZHANG W, ZHU X, et al. PointNet++ grasping: Learning an end-to-end spatial grasp generation algorithm from sparse point clouds[C]//Proceedings of the 2020 IEEE International Conference on Robotics and Automation (ICRA). Paris: IEEE, 2020: 3619-3625. DOI:10.1109/ICRA40945.2020.9196740.
- [42] WU J, LIU S, XU Z, et al. Reasoning grasping via multimodal large language model[J]. arXiv:2404.12652, 2024.
- [43] WANG J Q, SHI E Z, HU H W, et al. Large language models for robotics: Opportunities, challenges, and perspectives[J]. Journal of Automation and Intelligence, 2025, 4(1): 52-64. DOI:10.1016/j.jai.2024.12.003.
- [44] PUTERMAN M L. Markov decision processes: Discrete stochastic dynamic programming[M]. New York: John Wiley & Sons, 1994.
- [45] SUTTON R S, BARTO A G. Reinforcement learning: An introduction[M]. Cambridge: MIT Press, 2018.
- [46] WATKINS C J C H. Learning from delayed rewards[D]. Cambridge: University of Cambridge, 1989.
- [47] Mnih V, Kavukcuoglu K, Silver D, et al. "Human-level control through deep reinforcement learning." *Nature*, 2015, 518(7540): 529-533.
- [48] VAN HASSELT H, GUEZ A, SILVER D. Deep reinforcement learning w

- ith double Q-learning[C]//Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence (AAAI-16). Phoenix: AAAI Press, 2016: 2094-2100.
- [49] WANG Z, SCHAUL T, HESSEL M, et al. Dueling network architectures for deep reinforcement learning[C]//Proceedings of the 33rd International Conference on Machine Learning (ICML). New York: JMLR, 2016: 1995-2003.
- [50] WILLIAMS R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256. DOI:10.1007/BF00992696.
- [51] SCHULMAN J, LEVINE S, MORITZ P, et al. Trust region policy optimization[C]//Proceedings of the 32nd International Conference on Machine Learning (ICML). Lille: JMLR, 2015: 1889-1897.
- [52] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J]. arXiv:1707.06347, 2017.
- [53] MNIH V, BADIA A P, MIRZA M, et al. Asynchronous methods for deep reinforcement learning[C]//Proceedings of the 33rd International Conference on Machine Learning (ICML). New York: JMLR, 2016: 1928-1937.
- [54] LILICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[J]. arXiv:1509.02971, 2015.
- [55] FUJIMOTO S, VAN HOOF H, MEGER D. Addressing function approximation error in actor-critic methods[C]//Proceedings of the 35th International Conference on Machine Learning (ICML). Stockholm: JMLR, 2018: 1587-1596.
- [56] QIU S, ANWAR S, BARNES N. Geometric back-projection network for point cloud classification[J]. IEEE Transactions on Multimedia, 2022, 24: 1943-1955. DOI:10.1109/TMM.2021.3114847.
- [57] GOU M, FANG H S, ZHU Z, et al. RGB matters: Learning 7-DOF grasp poses on monocular RGBD images[C]//Proceedings of the 2021 IEEE International Conference on Robotics and Automation (ICRA). Xi'an: IEEE,

- 2021: 13459-13466. DOI:10.1109/ICRA48506.2021.9561297.
- [58] WANG C, FANG H S, GOU M, et al. Graspness discovery in clutters for fast and accurate grasp detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Montreal: IEEE, 2021: 15964-15973. DOI:10.1109/ICCV48922.2021.01568.
- [59] QIN R, MA H, GAO B, et al. RGB-D grasp detection via depth guided learning with cross-modal attention[C]//Proceedings of the 2023 IEEE International Conference on Robotics and Automation (ICRA). London: IEEE, 2023: 8003-8009. DOI:10.1109/ICRA48891.2023.10161029.
- [60] MA H, HUANG D. Towards scale balanced 6-DoF grasp detection in cluttered scenes[C]//Proceedings of the Conference on Robot Learning (CoRL). PMLR, 2023: 2004-2013.
- [61] QIU J, WANG F, DANG Z. Multi-source fusion for voxel-based 7-DoF grasping pose estimation[C]//Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Detroit: IEEE, 2023: 968-975. DOI:10.1109/IROS55552.2023.10341791.
- [62] CHEN S, TANG W, XIE P, et al. Efficient heatmap-guided 6-DOF grasp detection in cluttered scenes[J]. IEEE Robotics and Automation Letters, 2023, 8(8): 4895-4902. DOI:10.1109/LRA.2023.3272522.
- [63] LIU Z, CHEN Z, ZHENG W S. Simulating complete points representations for single-view 6-DoF grasp detection[J]. IEEE Robotics and Automation Letters, 2024, 9(3): 2901-2908. DOI:10.1109/LRA.2024.3351785.
- [64] TSAI R Y, LENZ R K. A new technique for fully autonomous and efficient 3D robotics hand/eye calibration[J]. IEEE Transactions on Robotics and Automation, 1989, 5(3): 345-358. DOI:10.1109/70.34770.
- [65] CHENG T H, SONG L, GE Y X, et al. YOLO-World: Real-time open-vocabulary object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2024.
- [66] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//

- Proceedings of the 35th International Conference on Machine Learning (ICML). Stockholm: JMLR, 2018: 1861-1870.
- [67] HIRSCHMÜLLER H. Accurate and efficient stereo processing by semi-global matching and mutual information[C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR). San Diego: IEEE, 2005, 2: 807-814. DOI:10.1109/CVPR.2005.56.