

硕士学位论文

基于物体位姿估计与模仿学习的机器人自主操作技术研究

RESEARCH ON AUTONOMOUS ROBOT OPERATION TECHNOLOGY BASED ON OBJECT POSE ESTIMATION AND IMITATION LEARNING

马浩飞

哈尔滨工业大学

2024 年 5 月

国内图书分类号：TP242.6

国际图书分类号：621

学校代码：10213

密级：公开

工程硕士学位论文

基于物体位姿估计与模仿学习的机器人 自主操作技术研究

硕 士 研 究 生：马浩飞

导 师：王伟东教授

申 请 学 位：工程硕士

学 科：机器人工程

所 在 单 位：机电工程学院

答 辩 日 期：2024 年 5 月

授予学位单位：哈尔滨工业大学

Classified Index: TP242.6

U.D.C: 621

Dissertation for the Master Degree in Engineering

**RESEARCH ON AUTONOMOUS ROBOT
OPERATION TECHNOLOGY BASED ON OBJECT
POSE ESTIMATION AND IMITATION LEARNING**

Candidate :	Ma Haofei
Supervisor :	Prof.Wang Weidong
Academic Degree Applied for :	Master of Engineering
Speciality :	Robotics Engineering
Affiliation :	School of Mechatronics Engineering
Date of Defence :	May, 2024
Degree-Conferring-Institution :	Harbin Institute of Technology

摘 要

利用机器人自主、智能地完成操作任务已经成为机器人研究领域的热点问题，但由于操作任务的多样性以及操作过程中环境的不确定性因素，机器人自主操作技术一直是机器人领域的研究重点与难点问题之一。针对机器人自主操作的诸多难点，本文从物体检测与位姿估计、机器人 6D 抓取生成与基于模仿学习的机器人动作规划等方面展开研究。最终实现机器人从人类演示中学习，在环境中自主操作完成任务，具有较高任务完成成功率和抗干扰能力。

理解场景是机器人实现自主操作的前提，本文建立检测场景中的目标物体识别和 6D 位姿估计方法。首先基于实例分割方法 YOLOv8 实现复杂场景中对被操作物体的准确识别，并将目标物体的 RGB 信息和深度图信息从场景中分割出来。然后基于视角选择原理实现了物体 6D 位姿估计，并利用姿态优化网络调整物体姿态，输出准确的目标物体 6D 位姿。最后开展实验研究，验证实例分割与位姿估计的精度和实时性。

针对不同目标物体操作所需要采取不同的抓取姿态，研究物体 6D 抓取生成方法。传统的抓取姿态生成方法依赖精确的物体模型，对多物体操作局限性较大，本文基于 RGB Matters 网络，提出一种结合位姿估计点云融合的机器人 6D 抓取姿态生成方法，从分割出的物体 RGB 信息和深度图信息中生成抓取姿态，并利用位姿估计过程中获取的物体稀疏点云模型弥补单一视角深度图的点云缺失，获得更准确的抓取。通过仿真和真实场景中实验验证生成 6D 抓取姿态可靠性和和抓取成功率。

在获得物体 6D 位姿和抓取姿态后，利用模仿学习方法让机器人学习复杂的操作技能。本文利用扩散生成模型作为机器人动作输出的网络基础，将从环境状态预测机器人动作的过程使用去噪过程表示，根据状态从高斯随机噪声中逐步去噪得到机器人动作矩阵。同时为了避免机器人动作过程中可能出现的多动作概率分布问题，将机器人的动作使用概率分布进行表示。最后使用遥操作主手收集数据，并在 Mujoco 仿真环境中训练模型进行了测试。

最后基于以上算法，本文设计机器人自主操作平台，用于验证物体检测与位姿估计、抓取姿态生成，以及遥操作数据收集和机器人自主操作测试。本文针对上述研究分别进行了实物实验，并对其它模仿学习算法进行了实物对比实验，结果表明本文的方法平均操作成功率较高，且具有一定的抗环境干扰能力。

关键词：位姿估计；抓取生成；自主操作；模仿学习；扩散模型

Abstract

Utilizing robots to complete operation tasks autonomously and intelligently has become a hot issue in the field of robotics research, but due to the diversity of operation tasks and the uncertainty factor of the environment during operation, the robot autonomous operation technology has been one of the research focuses and difficult problems in the field of robotics. Aiming at the many difficulties of autonomous robot operation, this paper carries out research from the aspects of object detection and position estimation, robot 6D grasping generation and robot action planning based on imitation learning. Ultimately, the robot learns from human demonstration and operates autonomously in the environment to complete the task, with a high success rate of task completion and anti-interference ability.

Understanding the scene is a prerequisite for robots to realize autonomous operation, this paper establishes the target object recognition and 6D position estimation method in the detection scene. Firstly, based on the instance segmentation method YOLOv8, we realize the accurate recognition of the manipulated object in the complex scene, and segment the RGB information and depth map information of the target object from the scene. Then the 6D position estimation of the object is realized based on the viewpoint selection principle, and the pose optimization network is used to adjust the object pose and output the accurate 6D position of the target object. Finally, an experimental study is carried out to verify the accuracy and real-time performance of instance segmentation and position estimation.

Aiming at different grasping poses required for different target object operations, the object 6D grasping generation method is investigated. The traditional grasping pose generation method relies on the accurate object model, which is more limited for multi-object operation. In this paper, based on the RGB Matters network, we propose a robotic 6D grasping pose generation method combined with bit-posture estimation and point-cloud fusion, which generates a grasping pose from the segmented object RGB information and the depth-map information, and makes use of the sparse point-cloud model of the object obtained in the bit-posture estimation process to compensate for the lack of point clouds in the single-view angle depth-map. The sparse point cloud model of the object obtained in the process of bit pose estimation is utilized to compensate for the lack of point cloud in the depth map of a

single view angle to obtain more accurate grasping. The reliability of the generated 6D grasping poses and the success rate of grasping are verified by simulation and experiments in real scenarios.

After obtaining the 6D object position and grasping pose, the robot is utilized to learn complex operation skills using imitation learning method. In this paper, the diffusion generation model is utilized as the network basis for robot action output, and the process of predicting robot actions from the environment state is represented using a denoising process, where the robot action matrix is obtained by stepwise denoising from Gaussian random noise according to the state. At the same time, in order to avoid the problem of multi-action probability distribution that may occur during the robot action process, the robot action is represented using probability distribution. Finally the data was collected using teleoperated master hand and the model was trained in Mujoco simulation environment for testing.

Finally based on the above algorithms, this paper designs the robot autonomous operation platform for verifying the object detection and position estimation, grasping pose generation, as well as teleoperation data collection and robot autonomous operation testing. In this paper, physical experiments were conducted for the above research respectively, and physical comparison experiments were conducted for other imitation learning algorithms, and the results show that the method in this paper has a high average operation success rate and a certain degree of anti-environmental interference ability.

Keywords: pose estimation, grasp generation, autonomous operation, imitation learning, diffusion model

目 录

第 1 章 绪论.....	1
1.1 课题研究背景及意义.....	1
1.2 国内外研究现状及分析.....	3
1.2.1 目标检测与位姿估计研究现状.....	3
1.2.2 6D 抓取姿态生成研究现状.....	7
1.2.3 机器人模仿学习动作策略研究现状.....	11
1.3 课题主要研究内容.....	15
1.4 论文章节安排.....	16
第 2 章 基于目标检测与视角选择的物体位姿估计	18
2.1 引言.....	18
2.2 物体 6D 位姿估计方案设计.....	18
2.3 目标检测与实例分割算法	19
2.3.1 基于 YOLOv8 的实例分割模型	19
2.3.2 实例分割数据准备与处理.....	22
2.4 基于视角选择策略的物体 6D 位姿估计算法	24
2.4.1 基于视角选择的位姿估计网络结构设计	24
2.4.2 基于 3D 残差的物体姿态优化方法.....	26
2.4.3 位姿估计数据收集与处理.....	27
2.5 物体 6D 位姿估计实验与分析.....	28
2.6 本章小结.....	31
第 3 章 基于角度分布与点云融合的机器人 6D 抓取生成	33
3.1 引言.....	33
3.2 机器人 6D 抓取任务分析.....	33
3.3 基于角度分布的物体 6D 抓取生成网络设计	34
3.3.1 机器人 6D 抓取表示方法.....	34
3.3.2 RGB Matters 抓取生成网络结构	35
3.4 利用 3D 融合点云的改进抓取生成方法	38
3.4.1 物体点云融合与噪点滤波算法.....	39
3.4.2 抓取姿态优化与快速搜索策略.....	41
3.5 机器人 6D 抓取仿真实验与分析.....	42
3.6 本章小结.....	43
第 4 章 基于扩散策略的机器人模仿学习规划	45
4.1 引言.....	45
4.2 机器人模仿学习规划的问题描述及分析	45

4.3 机器人主从控制与模仿学习规划策略	46
4.3.1 机器人模仿学习规划策略.....	46
4.3.2 主从控制与人类演示数据集建立.....	48
4.4 基于扩散策略的机器人动作规划方法	50
4.4.1 扩散模型的前向与反向过程.....	51
4.4.2 扩散策略的网络结构设计.....	52
4.4.3 多动作概率分布问题研究.....	54
4.5 扩散策略模仿学习规划实验与分析	56
4.6 本章小结.....	59
第 5 章 机器人自主操作系统及实验	60
5.1 引言.....	60
5.2 机器人自主操作实验平台设计	60
5.2.1 自主操作仿真与真实实验平台搭建.....	61
5.2.2 机器人手眼标定.....	63
5.3 机械臂自主操作实验.....	66
5.3.1 目标检测与位姿估计验证.....	66
5.3.2 物体 6D 抓取姿态生成与机器人抓取实验.....	67
5.3.3 基于模仿学习的机器人自主操作实验	69
5.4 本章小结.....	75
结论.....	76
参考文献.....	78

第1章 绪论

1.1 课题研究背景及意义

机器人技术尤其是具有自主操作能力的机器人是近年来世界各国与各大企业大力发展的方向，目前已经广泛应用于各行各业，在其中发挥了重要作用并减轻了人类负担。2023年工业和信息化部、教育部、公安部等十七个部门联合发布了《“机器人+”应用行动实施方案》^[1]，加速推进机器人应用拓展。各大企业如宇树科技、优必选、小米，以及特斯拉等企业，均争相在机器人产业发展布局，目前智能机器人市场规模不断扩大，该领域前景可观^[2]。随着机器人技术的日益成熟，其应用领域也不再局限于制造业，而是深入到医疗服务、智能驾驶等多个领域。且随着机器人技术的广泛应用，机器人的智能化需求越来越高，要求机器人能够通过学习获得自主完成某项任务的能力，进而在各领域中实现代替人类的智能化服务。

尤其在样品采集领域，例如病毒传播区、危化品爆炸区、生物战疫区等，机器人模仿人类采集样品已经成为唯一的可行途径。近年来发生的多起生物化学危险事件。例如感染死亡率极高的埃博拉病毒，传播影响范围极广的新型冠状病毒等，这些国际关注的公共卫生事件要么有着高致死率，要么具有高传染性，因此机器人代替人类前往病毒爆发场所进行采样就成为了一项必要且关键的技术。再如江苏响水天嘉宜化工厂爆炸事故导致的大量人员氯气中毒，天津港危化品仓库爆炸事故中由于不清楚化学成分而导致的二次爆炸等，使其成为迄今为止消防员牺牲最多的事故。这些场所由人类进入探测十分危险，但在救援时必须采集其中的样品以便执行下一步行动。因此当前社会迫切需要一种自主操作机器人代替人类实现危险场景中的工作。



(a) 天津港爆炸



(b) 非洲埃博拉病毒爆发

图 1-1 自主操作机器人的应用场景

目前实现类似功能的机器人大多需要操作人员遥操纵，该方法存在较大的问题。1)操作涉及采样工具或被采集物品的抓取，且需要机器人末端灵活动作，

很难通过遥操作实现准确的运动控制；2）由于远程控制时，遥操作主手与机器人运动之间存在时延，难以实现平滑控制，机器人动作抖动问题严重，且容易出现无效多余动作；3）由于遥操作视频画面较难直观判断物体距离，存在较大的误操作可能性。因此模仿人类的自主操作机器人成为一种更合理的解决方案。



图 1-2 机器人采样动作

利用模仿学习可以实现机器人实现自主样品采集，包括采样工具或样品的抓取、模仿人手实现复杂灵活采样动作。通过学习人类演示采样动作，实现机器人对目标样品的自主采集，代替遥操作并有效提高采样效率，避免采样过程的误操作。



图 1-3 人工样品采集动作

此外模仿学习还有广阔的应用前景，无论是近年成为研究重点的人形机器人，还是应用广泛的车臂协同，关键技术之一就是模仿人类的机械臂自主操作。近年来以人形机器人为代表的智能机器人逐步成为全世界的研究热点，伴随着 GPT 技术的出现，能够完成复杂任务的通用机器人必将是接下来数年乃至数十年的重要研究方向。人形机器人的一大重要挑战就是模仿人类实现各种复杂操作，例如拧开瓶盖、端茶倒水、收拾桌子、样品采集乃至手术操作等等。模仿人类的机器人操作在家用服务、医疗行业、人机协作、特种环境中均有着广泛的应用，是机器人智能化的重要体现。

目前机器人自主操作技术仍然处于发展阶段。现有机器人操作主要分为两个类型，一类是主要用于工业领域的以示教再现为代表的结构化场景操作，另一类是利用视觉辅助的机器人动作规划，即通过视觉获取环境状态，并利用行

为克隆等方法实现动作规划。但目前机器人自主操作虽然能够完成一些简单任务，但是距离通用机器人所需要的，在复杂可变的环境中执行复杂操作仍然有很大的距离。




图 1-4 基于模仿学习的机械臂操作

基于模仿学习的机器人操作是智能机器人的关键技术，也是一项具有挑战性的研究任务。这项技术可以细分为感知、抓取和操作三个研究内容。感知部分负责检测周围环境，识别和获取被操作物体的 6D 位姿；抓取部分负责计算目标的抓取位姿；操作部分负责实现从人类演示中学习机器人的模仿动作，操作物体完成指定任务。机器人的模仿操作的难点包括以下几个方面：（1）环境状态随机性大，如被操作物体形状各异、操作任务多样、任务过程中环境可能发生变化；（2）物体抓取困难，由于被操作物体种类多样，难以实现对多种物体的抓取；（3）复杂任务学习困难，机器人需要从人类演示中学习整个机器人操作过程，灵活执行机器人动作完成任务。综上所述，基于模仿学习的机器人自主操作对于机器人走向通用化，使机器人广泛应用于各行各业重要的意义。

1.2 国内外研究现状及分析

对于从人类演示中学习机器人自主操作的相关技术，国内外已经进行了诸多研究，且已经有了初步成果。机器人自主操作技术可以分为三个阶段：物体识别与 6D 位姿估计、抓取姿态生成、基于模仿学习的机器人动作规划。本文围绕机器人自主操作技术的三个子任务对国内相关研究进行了分析。

1.2.1 目标检测与位姿估计研究现状

物体的 6D 位姿估计是机器人实现复杂操作的基础，是一项十分重要的任务。而 6D 位姿估计方法一般需要提供先验的物体识别结果。在物体识别方面，主要可分为以 Faster RCNN^[3]为代表的两阶段方法，和以 YOLOv5^[4]为代表的单阶段方法。而对于机器人操作而言，物体识别的目的是获取目标物体的 RGB 和深度图信息，获取得到物体的 RGB 和点云信息用于后续抓取与模仿学习规划，

因此还需在识别的基础上进行实例分割。实例分割技术在早期是以 Mask RCNN^[5]为代表的两阶段方法,这些方法在传统物体识别网络的基础上增加掩膜预测分支实现实例分割,但在实时性和掩膜准确度上仍然不足。为了提高实时性,单阶段方法 YOLACT^[6]算法被提出,通过共享全局的掩膜特征和置信系数,实现了可用的实时性,但精度有所下降。近年来出现了 YOLOv8^[4]算法实现了实例分割功能,采用了分层注意力网络,在实时性和准确率上都实现了较高的水平,被广泛应用于工业界。基于实例分割的结果,可以对物体进行位置和姿态的估计,位姿估计方法包括基于关键点投票的方法、基于特征融合的方法等。

(1) 基于关键点投票的位姿估计算法

在位姿估计领域,NVIDIA 实验室提出的 PoseCNN^[7]是实现目标检测和位姿估计的一项基础性和代表性工作。该算法的主要网络框架如图 1-5 所示。网络通过三个分支从输入 RGB 图像中完成语义分割、物体位置预测、物体姿态预测。此外 PoseCNN 将深度图作为输入数据,通过 ICP 算法^[8]对位姿结果进行优化,该方法发布时在 Linemod 数据集^[9]和 YCB-Video 数据集^[7]上都取得了非常优秀的效果,因此为后续的物体位姿估计研究提供了非常有价值的思路。但是该算法虽然能够实现常规场景中的物体 6D 位姿估计,但当物体被部分遮挡或颜色纹理特征较少时,位姿估计准确率很低。

为了解决部分遮挡的物体的位姿估计问题,浙江大学提出了 PVNet^[10],该方法基于 3D 关键点检测来实现物体位姿估计,它融合了两种不同的思路,包括点对应 PnP (Perspective-n-Point) 求解和霍夫投票。PVNet 的核心思想是其提出的像素级的矢量场投票网络,网络能够为每个像素点生成一个指向物体关键点的矢量,从而为位姿估计提供了丰富的局部几何信息。同时,该方法引入了一种不确定性驱动的 PnP 算法用于优化位姿估计的结果。这种不确定性的考虑使其能够在处理遮挡情况下的位姿估计时取得更好的效果。此外 PVNet 还利用 RANSAC 算法滤除异常点云来保证位姿估计的精度。




图 1-5 PoseCNN 网络结构^[7]

虽然 PVNet 在一定程度上解决了部分遮挡情况下的物体位姿估计问题，但实际平均 6D 位姿估计准确率仍然较低，无法满足机器人操作的需求。为了提高遮挡情况下位姿估计的准确性问题，香港科技大学与旷视研究院联合提出了 PVN3D^[11]，充分利用了 3D 关键点特征以及驻点投票网络，实现在多种场景中位姿估计准确率的提升。此外，Duffhauss 等人提出了 MV6D^[12]方法，通过多视角点云信息融合的方式解决遮挡情况下的位姿估计问题，在严重遮挡情况下的位姿估计表现更为出色。




图 1-6 PVNet 的位姿估计实现过程^[10]




图 1-7 DenseFusion 的网络结构^[13]

(2) 基于特征融合的位姿估计算法

DenseFusion^[13]是由斯坦福大学李飞飞团队于 2019 年提出的经典 6D 位姿估计方法。该方法主要基于特征融合的思想实现位姿估计。DenseFusion 主要包括 RGB 与点云特征提取、稠密特征融合、位姿估计、位姿迭代优化四个步骤。

DenseFusion 从输入的 RGB 图像和点云数据中分别使用卷积神经网络和 PointNet 提取特征，并进行像素级的稠密特征融合，利用融合后的特征训练网络预测物体位姿。此外该框架还提出了一种位姿迭代优化方法，算法相较于此前发布的位姿估计算法，位姿估计准确率有了较大的提升。




图 1-8 FFB6D 的双向融合网络结构示意图^[14]

为了进一步提高位姿估计的精度，香港科技大学陈启峰团队于 2021 年提出了基于特征融合的 6D 位姿估计方法 FFB6D^[14]。该算法通过双向融合模块充分利用了 RGB 信息和点云信息。通过在 RGB 和深度信息的特征提取网络的每一层中建立双向融合通道，两个特征提取网络均可使用另一个网络的局部与全局特征，实现了精确的位姿估计。相较于 DenseFusion，FFB6D 算法在位姿估计准确性上得到了进一步的提高。

以上方法都是建立在拥有物体的精确 CAD 模型的基础上，实现网络训练和位姿估计预测，而 OnePose^[15]是一种依赖稀疏 CAD 模型即可实现位姿估计的方法，该方法由浙江大学周晓巍团队于 2022 年提出。




图 1-9 OnePose 算法实现过程^[15]

该方法借鉴了视觉定位的思想，对需要进行位姿估计的物体，仅利用三维

重建获得的点云模型即可实现位姿估计。预测物体位姿时，通过所提出的图注意力网络，将 SfM 点对应的 2D 特征聚合成 3D 特征，构建的 SfM 稀疏点云模型进行匹配，通过 PnP 回归计算出物体的位姿。该方法降低了位姿估计算法对模型精度的依赖，在算法通用性方面做出了明显的改进。

上述这些位姿估计方法各有优劣，例如 PVNet 虽然能够处理遮挡情况下的位姿估计，但平均识别准确率低，DenseFusion 和 FFB6D 等基于特征融合的方法在正常场景下位姿估计结果准确率高，但需要物体具有丰富的颜色特征，因此在物体受部分遮挡情况下，姿态误差较大。OnePose 在三维重建和 PnP 特征匹配时较为依赖物体 RGB 特征，对于弱纹理物体的位姿估计，但所提出的视角匹配定位方法是一个更合理的通用位姿估计方法。

（3）物体识别与 6D 位姿估计综述简析

根据调研的 6D 位姿估计算法研究现状，总结了其中具有代表性的算法的特点如表 1-1 所示。可以看到现在的 6D 位姿估计算法主要有三个主要研究方向，分别是：

- ① 提高物体受部分遮挡时的位姿估计准确率；
- ② 尽量减小 CAD 模型精度对位姿估计的影响，提高算法泛用性；
- ③ 提高位姿估计精度和推理速度。

表 1-1 现有代表性位姿估计算法分析

方法	CAD 模型	遮挡问题	位姿精度	推理速度
PoseCNN	需要	无法解决	低	较慢
PVNet	需要	部分解决	较低	较慢
DenseFusion	需要	部分解决	较高	较快
FFB6D	需要	部分解决	高	较快
OnePose	不需要	无法解决	较高	较慢

但是目前的位姿估计算法研究中大多只能解决其中一到两个问题，例如大多数传统的位姿估计算法都需要 CAD 模型，但是在速度、精度和遮挡问题上已经较为完善。而最近出现的算法逐渐向无 CAD 模型的方向发展，这是更符合未来的应用的。但是目前的算法在其他方面如遮挡问题和推理速度等仍然具有劣势。因此在解决无模型位姿估计算法的遮挡问题、速度和推理精度方面，仍有很大的研究空间。

1.2.2 6D 抓取姿态生成研究现状

在进行机器人的操作中，一定涉及对被操作物体的抓取，因此实现稳定的

物体抓取是机器人领域的一个重要研究方向，也就是在位姿估计的基础上回归目标物体 6D 抓取姿态。近年来 6D 抓取姿态生成涌现出许多突出的研究工作。

(1) 基于卷积神经网络的 6D 抓取算法

基于深度学习的 6D 抓取方法近年来取得了显著进展。例如 GraspNet^[16], PointNet++^[17]等工作提出了基于卷积神经网络的抓取生成模型。这类方法利用大规模的数据进行网络训练，可以预测多个抓取姿态，并通过采样和评估策略选择最佳的抓取姿态。虽然这些方法可以直接从 RGB 图像中生成抓取姿态，直接从在一些场景中取得了较好的抓取效果，但它们通常需要大量的数据 GraspNet^[18], Acronym^[19]进行训练。




图 1-10 GraspNet 的抓取网络概述^[16]




图 1-11 CaTGrasp 通过 3D 模型数据库学习抓取网络，并转移到真实世界中^[20]

为了解决训练困难的问题，Volumetric Grasping Network^[21]和 CaTGrasp^[20]提出了利用仿真合成数据进行训练的思想，TransGrasp^[22]尝试将训练单一实例的抓取姿态迁移到同类其它物体上，但是由于训练数据与真实被抓物体存在差异，这两种方法在真实世界抓取时不可避免会出现一些误差。上海交通大学卢策吾等人为了实现更可靠的抓取，在抓取生成前先估计了每个点的可抓取性得

分，选择可抓取性得分高的点云，将点云信息输入抓取姿态生成网络来生成抓取姿态。但是，这些方法大多是利用单一 RGB-D 信息进行抓取姿态生成，因此通常对物体表面的纹理和光照条件非常敏感，对于边缘点云稀疏或光照变化剧烈的物体，生成的抓取姿态容易产生误差。

（2）基于多视角点云融合的抓取算法

针对点云稀疏和姿态估计误差的问题，一些研究工作提出了利用多视角点云融合的方法来提高抓取准确性的方法。例如 PointNetGPD^[23], Closed-Loop NBV^[24]提出了一个基于点云的抓取姿态生成方法，利用最佳视角（Next-Best View, NBV）思想提高抓取的稳定性和成功率。该方法使用点云特征提取网络和多视角融合网络来生成全局特征表示，并通过回归网络预测抓取姿态。然而，这些方法通常依赖密集的点云数据，对边缘点云稀疏的物体仍然存在一定挑战。




图 1-12 Closed-Loop NBV 方法通过多视角补全点云进行抓取姿态生成^[24]




图 1-13 Contact GraspNet 的整体框架^[25]

此外 Contact GraspNet^[25]、RGB Matters^[26]等工作提出了端到端的抓取姿态生成方法。其中 Contact GraspNet 以 RGB-D 数据作为输入，经过网络直接预测 6D 抓取姿态。而 RGB Matters 使用 RGB 信息生成抓取姿态候选，然后使用点云进行抓取的快速筛选。这类方法通常以大量抓取数据训练，因此具有一定的

泛化能力，对于其它物体也能生成较为可靠的抓取姿态。但是这类网络要求目标物体的 RGB 和点云信息，因此需要将输入的 RGBD 数据经过实例分割算法处理，利用得到的掩膜分割获得物体的 RGB 和点云信息。虽然这种方法使得抓取姿态的获取成本大幅降低，但其准确度也有所降低。

（3）基于模仿学习的 6D 抓取算法

以上所提到方法要么需要计算目标物体的 6D 位姿，要么需要学习一组抓取点。前者的方法不能很好的扩展到多个对象实例或类，后者需要大型注释数据集，并且由于其对新物体的泛化能力而受到阻碍。为了提高抓取规划的泛用性，出现了基于模仿学习的抓取姿态生成算法，如慕尼黑工业大学提出的 DemoGrasp^[27]、北京理工大学的相似物体抓取算法^[28]等。




图 1-14 DemoGrasp 模仿人手抓取物体的流程图^[27]

这些方法在一组人类演示 RGB-D 图像上分割手和物体，并提取物体形状和手部姿态。然后检测物体姿态，然后使用该姿态变换手部模型，并用手部模型的拇指和食指计算抓握点。

（4）6D 抓取姿态生成综述简析

现有的抓取姿态生成算法的特点总结如表 1-2 所示，可以看出抓取姿态生成算法也有三个主要的研究方向：

- ① 训练数据尽量容易获取并接近真实情况；
- ② 对数据集以外的物体也能保证一定的抓取效果；
- ③ 提高抓取姿态生成的准确度和速度。

目前的抓取生成算法主要存在两方面问题，一方面是在实时生成抓取姿态时，由于视角的限制，一般只能获取物体一侧的点云，在生成抓取时容易生成出错误的抓取姿态。针对此问题，目前的研究主要集中在多视角点云补全上，

通过融合多个视角的点云信息来获取更稳定的抓取。另一方面是对于多类待抓取物体，需要大量抓取注释数据，尽可能覆盖到多类物体，但这种方式数据标注时非常困难繁琐。目前的解决该问题的主要思路在于使用仿真数据生成抓取注释，或在同类物体之间实现抓取策略的迁移。

表 1-2 现有代表性抓取姿态生成算法分析

方法	数据集	未知物体	准确度	推理速度	特点
GraspNet	标注抓取	无法抓取	较低	较慢	提出大型抓取注释数据集
VGN	标注抓取	无法抓取	较高	较慢	杂乱场景中抓取目标
TransGrasp	标注抓取	无法抓取	较低	较快	训练某实例抓取同类物体
CaTGrasp	仿真抓取	无法抓取	较低	较快	使用仿真数据训练网络
Closed-Loop NBV	仿真抓取	无法抓取	高	慢	多视角补全点云然后抓取
Contact GraspNet	大量标注抓取	能够抓取	较高	较慢	能够抓取未知物体
RGB Matters	大量标注抓取	能够抓取	较低	较快	基于 RGB 生成抓取列表
DemoGrasp	人类抓取视频	无法抓取	高	较快	模仿人手的抓取

综合而言，目前的抓取姿态生成方法虽然在一定条件下能够实现稳定抓取，但是受到视角限制，且在多类物体甚至未知物体的抓取上仍然存在问题。因此需要一种能够针对多类物体的，不受单一视角限制的抓取姿态生成算法。

1.2.3 机器人模仿学习动作策略研究现状

传统机器人执行复杂任务时，往往需要编写复杂机器人动作数据和算法，且缺乏鲁棒性，无法适应场景的改变，更加复杂的操作只能通过人类遥操作实现。而近年来随着机器学习技术的发展，从多样化的人类演示操作中学习机器人动作成为了一种可行的途径。近年来该方向也出现了一些研究进展。




图 1-15 One-Shot 算法策略^[29]

加州大学于 2018 年提出了 One-Shot^[29]，从提供的多个人类演示的机器人动作中学习机器人操作策略，虽然实现了模仿学习，但是只能实现较简单动作，局限性较大。




图 1-16 基于图像结构的视觉模仿方法^[30]

Adversarial Skill Networks^[31]提出了一种基于对抗性技能网络 ASN 技能学习方法，并尝试使用强化学习组合学习到的技能来解决更广泛的任务。其中 ASN 框架可以从无标签的视频中学习任务。该方法虽然提出了一种基于模仿学习的机器人操作解决思路，但是任务技能的提取和操作实现准确度都比较低。索尼也提出了一种基于图像结构的视觉模仿方法^[30]，主要的训练原理为当机器人的动作使工作空间中检测到的相应的视觉实体相对空间配置于演示能够匹配时，会得到奖励。通过提取关键点映射到真实机器人，并通过关键点动作的训练实现运动策略的生成，能够实现人手臂于手指动作的模仿。该方法不仅需要大量的视频数据，而且需要进行实例分割制作合成数据，实现过程相较于其他方法较为复杂。

斯坦福大学于 2022 年提出的 R3M^[32]，提出了一种新的机器人操作表示方法，旨在建立通用有效的模型，从大量人类与环境交互的视频中学习各种任务的操纵方式。通过训练一个编码器，学习图像中的语义特征，并降低状态空间的维度来保证训练得到的操作策略符合状态分布。最后实现了在未知场景中完成抓取放置任务等操作。但是从实验结果中可以看出，即使是训练过的任务，当环境发生变化时，执行时成功率也很低。Meta AI 实验室于 2023 年提出了 VIP^[33]方法，在 R3M 的基础上增加了隐含的时间对比学习和预训练步骤，利用时间对比策略，在任务开始和结束的两帧指尖捕获长程语义的时间依赖性。实现将从大型长视频中学习多个操作任务。但单一模仿实验效果于 R3M 相似，因

此还有着很大的发展空间。




图 1-17 VIP 算法网络结构图^[33]




图 1-18 BC-Z 从人类演示视频中学习任务并执行未知任务^[34]

以谷歌为首的团队于 2022 年提出了 BC-Z^[34]方法，尝试通过学习一定的人类演示任务视频，实现机器人在任务对象、场景的泛化，甚至能够根据操作人员的指令完成新任务。该方法通过基于 ResNet-18 的卷积网络对视频进行编码，通过 XYZ 和轴角预测的 Huber 损失和抓取器角度的对数损失来进行网络训练。实验结果发现该方法能够实现在未知环境中执行已知任务，甚至能够执行部分未知任务，但总体上成功率平均只有 44%，且数据收集方面较为复杂，仍然不能满足实用要求。卡内基梅隆大学也在 2022 年提出了从人类演示中学习重复任务的方法^[35]，重点解决的是可变性物体和颗粒状物体的操作，如用布擦拭物体、缠绕线缆、搅拌操作等。但是算法需要提供人类演示动作和手动操纵机器人的演示动作，算法学习两者的相似性，因此在数据收集方面略微复杂。

不同于通过基于视觉模仿学习的方法，Learning by Watching^[36]和 Third-Person Visual Imitation^[37]两项工作采用了基于图像翻译的思路实现模仿学习。具体来说，使用如 CycleGAN^[38]的对抗性网络，将人类手臂操作物体的视频翻译

成机械臂操作物体的视频，再借由关键点检测其提取机器人操作的关键点，形成轨迹实现抓取动作。这些方法巧妙地将模仿学习问题转化为图像翻译问题，减轻了计算量与网络复杂度，同样的操作成功率也有所降低。




图 1-19 基于图像翻译原理的模仿学习策略^[36]

现有的从人类视频演示进行模仿学习的机器人操作规划算法的特点总结如表 2-3 所示，可以看出机器人模仿学习算法也有三个主要的研究方向：

- ① 减少训练数据的获取难度；
- ② 提高模仿学习的机器人操纵策略的任务执行成功率；
- ③ 提高算法对环境变化的抗干扰程度。

表 1-3 现有代表性模仿学习机器人操作算法分析

方法	数据需求	环境变化适应	成功率
One-Shot	低维动作数据	较差	低
Adversarial Skill	机器人操作视频	较差	低
Learning by Watching	人类演示视频	较好	低
Graph-Structured	低维动作数据	较差	较低
R3M	人类与机器人演示视频	较好	较低
VIP	人类与机器人演示视频	较好	较低

目前在基于模仿学习的机器人操作方面，许多算法仍然需要给定人类演示或机器人演示视频作为数据样本进行学习，而这些高维的图像数据包含了过多的信息，在训练以及实际网络预测时实时性受算力影响较大，这种方式极大的限制了机器人的多任务学习能力，增加了使用成本。同时，在实际使用时，例如移动机械臂操作任务，需要模仿学习算法的执行尽可能达到实时性。此外，

模仿学习方法需要尽可能提高对环境变化的适应性，以实现不同场景下执行相同任务的成功率。

1.3 课题主要研究内容

本课题旨在提出一种基于物体位姿估计和模仿学习的机器人自主操作方法，通过从场景中估计物体位姿，预测物体抓取姿态，通过模仿学习生成机器人动作。本文的主要研究内容如图 1-20 所示：




图 1-20 课题主要研究内容

（1）基于目标检测与视角选择的物体 6D 位姿估计研究

研究如何在不依赖精确 CAD 模型的情况下估计物体 6D 位姿。实现基于视角选择的位姿估计算法，利用 YOLOv8 进行识别并分割出目标的 RGB 和 Depth 图像，利用视角匹配估计目标物体的粗略位姿，并通过姿态迭代优化获得目标的较准确 6D 位姿。

（2）基于角度分布与点云融合的机器人 6D 抓取姿态生成研究

研究如何从杂乱场景中生成目标物体的 6D 抓取位姿。设计基于角度分布思想的抓取预测网络，从 RGB 中获得一系列可能的抓取候选列表，通过快速搜索策略，利用点云信息筛选得到合理的抓取位姿。此外，为了保证单视角抓取姿态生成的准确性，需要研究点云优化方法，以获得更鲁棒的抓取姿态。

（3）基于扩散策略的机器人模仿学习规划研究

研究如何使机器人从人类演示中学习任务技能。提出基于扩散模型的模仿学习方法，学习从被操作物体位姿、机器人末端位姿等状态信息到机器人动作

的策略。研究遥操作主手与机器人的主从映射和控制方法；在 Mujoco 仿真环境中搭建实验平台，采集数据并进行模型训练和测试。

（4）实验研究

针对所提出的算法，进行任务实验，搭建机械臂仿真实验场景，以及用于验证机器人自主操作的真实实验平台。对上述研究分别设计各类实验验证算法性能。

其中第 1 部分研究内容通过实例分割识别和检测场景中的物体，通过位姿估计方法获取场景中物体的准确位置和姿态信息，对于机器人在环境中感知物体十分重要。该部分的位姿估计结果为第 2 部分抓取姿态生成和第 3 部分模仿学习提供了信息基础，因为抓取姿态的生成需要物体位姿与重建的点云进行点云融合补全，模仿学习也需要物体位姿作为状态输入用于噪声预测网络的去噪过程。

在知道物体位姿的基础上，要使机器人能够有效的抓取这些被操作物体，还需要确定合适的抓取姿态，也就是第 3 部分研究所关注的研究，这一部分研究基于角度分布与点云融合的机器人 6D 抓取姿态生成方法，结合视觉和三维点云数据来提高抓取姿态的准确性和鲁棒性。抓取姿态的准确性对于机器人成功执行物体操作任务非常重要，模仿学习需要从人类演示中学习合适的动作策略，而在执行物体抓取时依赖于准确的抓取姿态。

第 3 部分的研究目标是使机器人能够从人类演示中学习任务技能，实现自主操作，本文提出了一种基于扩散策略的模仿学习方法，通过人类演示中学习执行特定任务。机器人在学习和执行任务时，需要包含物体的位姿的状态生成机器人动作，同时依赖准确的抓取姿态完成物体操作任务。

三部分研究内容共同组成了一个完整的系统，第 1 部分研究提供场景感知基础，为抓取姿态生成和模仿学习提供关键信息，第 2 部分实现抓取姿态的生成，为模仿学习提供必要的物体抓取方式信息，第 3 部分则利用前两部分的结果，使机器人能够从人类演示中学习任务技能，实现机器人在复杂环境中的自主操作。

1.4 论文章节安排

本文的章节安排如下：

第一章介绍了课题的研究背景和意义，并对机器人自主操作所涉及的国内外研究工作进行了分析。主要从物体检测与 6D 位姿估计、抓取姿态生成、机器人自主操作技能学习三个方面介绍了相关的研究工作，并分析了现有研究的优

点和不足。最后介绍了本课题的主要研究内容。

第二章主要研究了物体检测与 6D 位姿估计方法。首先设计了整体的目标识别与位姿估计方案。在对不同的实例分割算法进行深入研究之后，选择了 YOLOv8 作为实例分割任务的基线算法。然后设计了一种基于视角选择的位姿估计算法，详细介绍了其网络结构，位姿估计策略和位姿估计优化方法。为了训练和验证模型，制作了实例分割和位姿估计数据集。通过实验测试了模型在不同场景下的实例分割与位姿估计的准确率和推理速度。

第三章研究了机器人 6D 抓取姿态生成算法。首先对机器人自主操作中的抓取姿态需求进行了分析。在抓取生成网络 RGB Matters 的基础上，本文进行了进一步的优化，结合位姿估计的结果进行点云融合与滤波，提高抓取生成结果的稳定性和准确性。通过仿真实验验证所改进的抓取姿态生成算法的实际场景中的性能。

第四章研究了基于模仿学习的机器人动作规划方法。首先设计了整体的机器人操作任务学习的方案。设计了基于扩散策略的机器人模仿学习动作规划方法。所实现的模型根据环境状态从噪声中推理动作，并解决了机器人动作生成中的多动作概率分布问题。通过仿真实验并与其它模仿学习算法对比，验证了本文方法的优越性。

第五章介绍了本文搭建的实物机器人自主操作实验平台。为保证实验准确性，首先对所有设备进行了标定与配置，基于此平台对所有提出的算法进行了实验。根据实验结果进行分析，验证了本文的结论。

第 2 章 基于目标检测与视角选择的物体位姿估计

2.1 引言

为了让机器人在未知环境中完成操作任务，首先需要使机器人能够在环境中识别出需要操作的目标物体，并确定目标物体相对于机器人的位置和姿态。根据这些状态信息机器人才能生成动作执行任务。为了实现这一目的，基于视觉的感知是最直观且高效的方式。且在机器人操作过程中，对物体识别和位姿估计的准确性和实时性有一定要求。基于以上需求，本章通过分析视觉感知进行方案设计，建立一套基于实例分割与视角选择的位姿估计算法，制作数据集并对所提出的算法模型进行训练，通过实验测试识别和位姿估计的准确度和推理速度。

2.2 物体 6D 位姿估计方案设计

在机器人操作任务中，机器人必须要清楚感知周围环境，进而做出合理的动作决策，这个过程中最关键的就是目标物体的位置和姿态。准确的目标检测与位姿估计方法是机器人后续对该目标进行抓取以及执行复杂操作任务的基础。为此，本文分别设计了目标检测与位姿估计系统，如图 2-1 所示，机器人利用所安装相机实时进行目标检测，并对目标物体进行 6D 位姿估计。




图 2-1 物体 6D 位姿估计子系统方案

在目标检测阶段，使用相机的实时 RGB 图像作为输入，在 YOLOv8 网络中完成对目标物体的检测、类别识别、包围框和掩膜结果输出。这些信息将作为位姿估计和抓取的先验信息用于执行后续抓取与操作任务。

在检测到物体并获取了物体的掩膜以及类别信息后,需要进行物体的 6D 位姿估计。由于在机器人操作过程中需要实时获取物体的位姿信息,因此为了尽可能快的完成物体位姿估计,考虑使用基于视角选择的方案估计物体位姿。利用 RGBD 相机采集的彩色图像与深度图,以及实例分割的掩膜,通过位姿估计网络获得粗略的 6D 位姿,再经过姿态优化网络获得优化后的准确物体 6D 位姿。

以上步骤所获得的物体掩膜、类别信息以及 6D 位姿信息,将用于机器人抓取姿态的估计以及后续的模仿人类操作的动作生成。所生成的机器人动作发送到机器人的控制器,最后驱动机器人完成指定任务。

2.3 目标检测与实例分割算法

机器人操作物体的过程中,需要实时判断场景中是否存在目标物体,以及获取目标物体所在区域的详细 RGB 信息,以及深度图点云信息等。而目标检测算法一般负责生成图像中物体的边界框,这些边界框不仅包含了物体本身,还不可避免地包括了背景元素,并且常常出现多个物体的边界框相互重叠的现象。而实例分割可以判断图像上的每一个像素所属的物体实例,从而确定物体的种类和物体所在像素区域,因此实例分割算法是机器人视觉感知的基础,通过对目标物体进行实例分割,可以将物体的 RGB 信息和深度图点云信息从场景中分离出来,用于后续的抓取以及模仿学习,因此是抓取任务的关键步骤。

2.3.1 基于 YOLOv8 的实例分割模型

(1) YOLOv8 实例分割算法

计算机视觉的常见的任务包括图像分类、目标检测、语义分割和实例分割等。对于机器人操作过程中的物体识别而言,通常而言需要进行实例分割。实例分割主要分为单阶段方法和两阶段方法两大类。

两阶段方法主要为 RCNN 系列,此类算法的特点在图像上根据锚点生成若干候选区域,通过神经网络提取图像特征,获取候选框类别并修正候选框位置,例如由何凯明提出的 Mask RCNN 就是此类算法中最主流的方法,该方法为了实现实例分割,在 Faster RCNN 的基础上增加了掩膜预测分支,并构建了特征金字塔通过多尺度特征融合保证识别精度。

单阶段方法以 YOLO 系列为代表,这类算法的主要特点是推理速度快,早期此类算法无法实现实例分割,且目标检测的准确率略低于两阶段方法,但目前 YOLOv8 的准确率也达到了较高的水平,且能够推理目标的 2D 边界框、标

签、置信度以及掩膜信息。相比较于单阶段方法，两阶段方法虽然早期准确率较高，但目前单阶段方法准确率也逐步提高，且两阶段方法分割过程较为复杂，导致推理速度较慢。单阶段方法将实例分割和目标检测任务采用相同的方式来表达，极大的简化了实例分割问题的建模复杂度。因此本文针对任务要求基于 YOLOv8 基础网络进行设计，通过实验验证所设计网络的有效性。

YOLOv8 是对前一代 YOLOv5 进行改进的算法，其在性能上有了显著提升，且相比较于前代，YOLOv8 实现了包括实例分割在内的多个功能。相较于其他目前的实例分割框架，YOLOv8 是目前最先进的实例分割算法之一。YOLOv8 系列共包括五种不同规模的网络，尽管这些网络共享相同的网络架构，但随着模型规模的增加，网络的深度、通道数会更多，相应的识别与分割精度也会更高。然而随着模型规模的增加，其计算量也会大幅增加，导致推理时间变慢。本文选择了推理速度相对最快的 YOLOv8n 架构，以满足本文的机器人操作任务对实例分割的实时性要求。

(2) YOLOv8 网络结构

YOLOv8 的网络结构大致可分为主干网络和检测头两部分，如图 2-2 所示。

主干网络（Backbone）是 YOLOv8 实现特征提取的深度卷积神经网络。它可以有效地从输入图像中提取特征，并保持较高的处理速度。主干网络主要由 Conv 模块、C2f 模块以及 SPPF 模块三部分组合而成。

其中 Conv 模块是 YOLOv8 网络中的基础，主要实现图像特征的提取和学习。该模块由卷积层、批量归一化层、激活函数层三部分组成。该模块运算过程中，首先由卷积层对输入数据进行卷积，完成特征提取与数据的降采样，然后数据由批量归一化层处理，提高训练的稳定性和收敛速度，最后通过激活函数完成模块输出。C2f 模块作为主干网络中主要的特征提取单元，由残差块 Bottleneck 和 Conv 模块共同构成。相比较于 YOLOv5 中起同样作用的 C3 模块，其计算量明显降低且由于梯度流的增加，收敛速度和效果也会得到明显提升。该模块将输入特征进行卷积运算，然后经过 n 次残差计算。最后通过两个卷积模块将输入的特征图转化为高维特征图，并完成多尺度的特征融合。空间金字塔池化模块（Spatial Pyramid Pooling-Fast, SPPF）由 Conv 模块、MaxPool 最大池化模块以及 Concat 模块组成，主要目的是融合全局信息，提升感受野，进而提高目标检测的性能。该模块将输入的特征图使用进行多次池化操作，获得特征图上不同尺度的空间信息。该模块使得 YOLOv8 模型有效地融合了不同尺度的空间特征，提高了模型对不同空间特征的鲁棒性，提高检测精度。




图 2-2 YOLOv8 网络结构

YOLOv8 的检测头部分负责在图像中检测和定位目标物体。它采用了多尺度的特征融合策略，利用多层特征图构造特征金字塔实现特征图融合以提高检测性能，如图 2-3 所示。YOLOv8 的检测头结构包括多个卷积层和池化层，以及用于输出预测的最终卷积层。这些层级将输入特征图映射到目标检测结果，同时通过使用不同大小的卷积核来捕获不同尺度的特征信息，使得模型能够在不同尺度下进行准确的目标检测。此外，YOLOv8 的检测头还包括与 YOLOv5 相比更多的激活函数和规范化层，提高了模型的非线性建模能力和泛化性能。




图 2-3 特征金字塔示意图

2.3.2 实例分割数据准备与处理

在实例分割领域，Pascal VOC 和 COCO 数据集是两个广泛使用的基准数据集。其中 Pascal VOC 2012 数据集涵盖了 20 个类别的物体，共计一万余张图片用于实例分割的训练与验证过程。而 COCO 数据集包含的物体类别多达 80 个，是目标检测和语义分割任务中最主流的测试验证数据集，被广泛应用于学术界和工业界。

虽然现有的数据集图片资源丰富，目标种类较多，但所标注的目标类别大多为日常生活中的常见对象，例如行人、汽车等，而非机器人的可操作对象。因此需要根据本文的机器人任务需求，重新制作用于机器人自主操作实验的实例分割数据集。综合考虑操作任务需求、物体的尺寸、夹爪尺寸等，暂时选择 5 类物品用于进行机器人自主操作实验，也作为实例分割的数据集的基础类型进行测试，如图 2-4 所示。



图 2-4 实例分割测试用物品




图 2-5 实例分割数据集标注

对于每一类物体，使用 RealSense D435i 采集 500 张不同角度、不同距离、不同背景的图像，其中随机选择 80% 的数据作为训练集，用于模型的训练与优化，剩余的 20% 数据作为测试集，在网络训练完成后验证模型的推理效果。数据集的制作使用 Labelme 工具对训练集中每张图片包含的物体进行标注，如图 2-5 所示，标注每个物体的分割边缘作为掩膜，将所有的数据保存为 JSON 文件，数据主要包括每个实例对象的类别信息、边界框坐标与掩膜信息。为了增强算法的泛化能力和在杂乱场景下的检测分割能力，制作数据集时考虑了多种场景，多个视角，不同物体摆放方式和复杂的遮挡情况，尽可能保证数据的多样化和随机化。

为了增强算法在不同光照条件、不同场景以及遮挡情况的实例分割能力，需要对数据集进行数据增强。并且由于深度神经网络的特点，数据量越大数据随机化程度越高，网络训练效果一般而言会更好。但受限于手动标注数据集过于繁琐和复杂，制作大规模的数据集耗时较长，而通过图像增强来扩充数据集规模可以在一定程度上解决数据量不足的问题。本文采用了一系列图像处理技术对训练样本进行了变换操作，改变原始图像的图像特点，生成大量相似但不同的图像和数据样本，从而实现了数据集的扩种。进而有效提升了神经网络模型的泛化性能。




图 2-6 数据增强示例

本文使用的图像处理方案包括高斯模糊、仿射变换、亮度和对比度变换、色相饱和度变换、高斯噪声引入、模拟遮挡等。对于实例分割而言，引入图像增强，特别是模拟遮挡会有效地提高模型的泛化能力。如图 2-6 所示是经过图

像增强技术处理后的图像。对于每一组原始数据，选择一到多种不同的图像处理方案对原始数据进行随机变换，通过使用该图像增强技术，可以将原数据集扩展数倍。大量的数据可以有效避免过拟合现象的过早出现。同时为了提高训练的速度，本课题将 COCO 训练模型作为预训练模型，由于 COCO 训练模型中特征提取融合等部分的网络参数均已稳定，在此基础上继续本文的物体实例分割网络训练可以在更少的训练轮次中获得更优网络模型效果。这种方式不仅可以加快学习过程，还能增强模型的鲁棒性和泛化能力，经过较短时间的训练即在本文制作的数据集上达到较高的精度。

2.4 基于视角选择策略的物体 6D 位姿估计算法

6D 位姿估计算法根据对输入 RGBD 数据的处理方法可以分为三类，第一类将 RGB 和深度信息在特征提取截断就进行融合，来完成 6D 目标位姿估计。一般方法是将深度图作为 RGB 图像的第四通道，将两者相连接输入到卷积神经网络中进行位姿估计。第二类方法使用 RGB 信息提取特征，预测粗略的 6D 目标位姿，然后使用深度信息，通过 ICP 算法配准点云来优化目标物体的位姿，例如 PoseCNN、PVNet 等。第三类方法则是分别对 RGB 图像和深度图分别进行特征提取，然后融合颜色特征和点云特征，利用融合后的特征预测物体位姿，由于输入的 RGB 信息和深度信息代表不同空间的特征，数据结构不同，因此一般使用两种不同的网络处理两种信息，这种基于特征融合的位姿估计算法的代表是 DenseFusion。

但这些方法由于复杂的特征提取步骤，大多无法满足机器人操作过程中，对被操作物体的实时位姿估计要求。相较于以上方法，以 Gen6D 为代表的基于视角选择的位姿估计算法则只需要一些物体的参考图像，就能在任意环境中预测物体的位姿^[39]。该网络可以应用于任意的物体抓取和操作，只需要一些参考图像来定义物体参考坐标系。

2.4.1 基于视角选择的位姿估计网络结构设计

基于视角选择的位姿估计网络由物体检测器、视角选择器、姿态优化器三部分组成，如图 2-7 所示。进行位姿估计时，首先通过视角选择器，此处使用 YOLOv8 检测目标物体所在区域，然后视角选择器将查询图像与参考图像位姿相匹配，并结合查询时所使用的面内旋转角度得到粗略的初始位姿，然后由姿态优化器根据三维空间特征对当前姿态进行多次迭代优化，以得到精确的物体 6D 位姿。




图 2-7 基于视角选择的位姿估计实现流程

该位姿估计方法需要采集 N_r 张图像作为参考图像，通过 COLMAP 处理并从图像中重建物体三维点云模型，根据点云模型定义物体坐标轴方向。因此参考图像中每一帧的位姿可以直接计算获得。为了便于物体的位姿计算以及姿态优化，本文将重建出的物体点云根据式(2-1)归一化至半径为 1 的球体内。

$$\mathbf{p}_{norm} = \frac{2(\mathbf{p} - \mathbf{c})}{d_{max}} \quad (2-1)$$

其中 $\mathbf{p}_{norm}$ 为归一化后的物体坐标， $\mathbf{p}$ 为原尺寸物体坐标， $\mathbf{c}$ 为物体点云中心坐标， d_{max} 为物体点云的最大直径。

通过将查询图像与参考图像进行匹配，得到物体的大致区域，并确定最相似的参考图像，从而提供了物体的初始姿态。对所采集的 N_r 个参考图像，考虑其与查询图像可能存在目标尺度不同和旋转方向不同的问题，将各个参考图像进行 N_R 次旋转，得到 $N_r \times N_R$ 个查询图像，将查询图像进行 N_S 个比例尺度的缩放。使用 VGG 网络提取查询图像和所有参考图像的特征图，将所有参考图像特征图作为卷积核对查询图像进行卷积，这样就能确定最相似的参考图像，如图 2-8。

由于该参考图像的相机位姿已经在三维重建时进行过记录，因此物体的姿态可以直接获得。物体的位置通过物体在图像上的位置和大小，利用相机内参可以计算得出。结合已有信息，可以通过式(2-2)估计目标物体的初始平移 $\mathbf{t}$ 。

$$\mathbf{t} = scale \cdot \left(\frac{(u - c_x) \cdot f}{f_x}, \frac{(v - c_y) \cdot f}{f_y}, \frac{2f}{D} \right) \quad (2-2)$$

其中 f 为相机焦距, c_x, c_y, f_x, f_y 为标定的相机内参, u, v 为目标物体中心点在图像坐标系下的坐标, S_q 为物体包围框尺寸, $scale$ 为三维重建后归一化模型时模型的缩放比例。

选择与查询图像拍摄角度最接近的参考图像, 匹配得到的误差最小的参考图像的观测角度视为当前观测角度, 则当前物体的位姿可以根据参考图像中物体位姿与平面内旋转角计算得到。

$$R = R_z(\theta) \cdot R_{ref} \quad (2-3)$$




图 2-8 位姿估计模块的结构

2.4.2 基于 3D 残差的物体姿态优化方法

通过位姿估计网络获得的初始物体位姿可能存在一些偏差, 为了进一步提高物体位姿估计精度, 需要进行位姿估计优化。




图 2-9 姿态优化流程

姿态优化过程如图 2-9 所示, 首先构建一个中心位置与归一化后物体点云

中心相同的 32^3 体素大小的立方体，选择与初始位姿最接近的 N_n 个参考图像，使用卷积神经网络提取这些参考图像的特征，并将这些特征从 2D 平面映射到 3D 空间中，同样提取查询图像的特征，将其反投影至上述立方体中。在拼接的体积特征中，使用 3D CNN 来预测 3D 残差，并利用 3D 残差来更新输入姿态，从而得到更准确的姿态信息。

由于在三维重建时对物体点云进行了归一化处理，为了确定目标物体在相机坐标系下的真实位置，用一个最小外接长方体将目标物体包裹起来，使得长方体的边与点云的坐标轴方向平行，这样就得到了一个包围目标的三维边界框。通过将实际尺寸与点云空间中的 3D 边界框尺寸进行比较，根据前文得到的目标位置计算得到目标的真实位置。具体转换方法如式(2-4)所示。

$$\begin{bmatrix} x_{real} \\ y_{real} \\ z_{real} \end{bmatrix} = \frac{1}{3} \left(\frac{l_{real}}{l_{est}} + \frac{w_{real}}{e_{est}} + \frac{h_{real}}{h_{est}} \right) \begin{bmatrix} x_{est} \\ y_{est} \\ z_{est} \end{bmatrix} \quad (2-4)$$

其中 $x_{est}, y_{est}, z_{est}$ 是估计得到的目标位置， $l_{est}, w_{est}, h_{est}$ 是位姿估计的目标物体 3D 边界框尺寸， $x_{real}, y_{real}, z_{real}$ 是物体的真实位置， $l_{real}, w_{real}, h_{real}$ 是目标物体的真实长宽高。

2.4.3 位姿估计数据收集与处理

为了收集多视角数据，需要拍摄多张具有丰富背景颜色纹理的 RGB 图像作为参考图像。这些图像将用于后续的相机姿态估计以及三维点云重建。在拍摄这些图像时，尽可能覆盖不同的角度和视角，以确保对物体的全面观察。这样的多样性有助于提高算法的鲁棒性，使其能够适应不同场景下的位姿估计需求。



(a) 多视角数据收集

(b) 三维模型重建

图 2-10 数据收集与三维模型

本文从这些参考图像中提取特征点，并进行相机姿态估计和三维点云重建，将这些视角下的图像进行配准和融合，得到物体的精确三维模型。通过拟合和滤除背景平面，我们可以得到仅包含目标物体的精确三维模型。这些不同视角

的相机姿态将用于位姿估计，而三维点云模型将用于抓取姿态预测。

2.5 物体 6D 位姿估计实验与分析

本次实验的训练和测试平台如表 2-1 所示。

表 2-1 实验训练与测试平台

CPU	GPU	内存	系统	CUDA
Intel Core i7-13700HX (5.00GHZ)	NVIDIA GTX4060 (8G)	16G	Ubuntu 20.04	12.1

(1) 实例分割模型训练与评估

YOLOv8 可以实现多目标的同时检测与分割，本节的实例分割网络是为了后续位姿估计与抓取做准备，由于位姿估计数据采集较为繁琐，为了减轻后续网络的压力，本节使用所制作的包含四个物体的数据集进行训练。为了与传统两阶段方法进行对比，选择了经典的 MaskRCNN 算法进行对比实验。利用自制数据集对 MaskRCNN 网络进行训练，在预训练模型的权重基础上进行迁移训练。

训练过程中的损失 Loss 变化如图 2-11 所示，可以看出在训练的初期，两个模型的损失都大幅下降。其中 YOLOv8 模型经过 200 次迭代后，Loss 曲线基本趋近于平稳，模型基本趋近于收敛，最终 Loss 值收敛至 0.162。而 MaskRCNN 同样在 200 次迭代后曲线逐渐平稳，但相较于 YOLOv8，其 Loss 下降更慢，最终 Loss 收敛到 0.224。上述结果说明相较于 MaskRCNN，YOLOv8 模型更容易收敛，训练更加稳定。




图 2-11 实例分割模型训练 Loss 曲线图

对所训练得到的网络输入 RGB 图像，模型得出的实例分割结果如图 2-12

所示。实例分割网络可以准确预测目标物体的类别以及该类别的置信度，所在区域的边界框，以及最重要的物体掩膜，利用所获得的物体掩膜，就可提取出物体的 RGB 和点云信息。




图 2-12 实例分割测试

为了进一步比较两个算法的分割精度，将两个模型在测试数据集上进行比较，通过计算模型对各类别预测掩膜和真实掩膜的交集与并集的比值，使用 IoU 掩膜覆盖率来评估分割准确度。实验测试的结果如表 2-2 所示，可以看出相较于 Mask RCNN，YOLOv8 网络具有较高的分割精度，满足使用要求。

表 2-2 实例分割 IOU 对比结果(%)

物体类别	MaskRCNN	YOLOv8
香蕉	82.8	92.9
瓶子	88.6	97.9
水杯	91.5	95.7
纸杯	91.9	97.6
盒子	92.8	99.2
平均	89.5	96.7

此外，在机器人自主操作的过程中，视觉检测的实时性也十分关键，由于后续的位姿估计，抓取姿态生成等依赖于实例分割获得的掩膜，因此实例分割的速度会直接影响机器人模仿学习动作输出的速度。

为此，本文对模型的实时性进行了测试，利用两模型处理 1000 张图像，计算平均每张图像的推理时间作为评价指标，测试结果如表 2-3 所示。因为本实验所有图像均采用 1280x720 分辨率，在此条件下，YOLOv8 网络的分割速度已经几乎达到了实时推理，处理速度大于视频帧率 30fps，完全能够满足实例分割

的实时性要求。

表 2-3 实例分割模型推理速度对比结果(ms)

模型	MaskRCNN	YOLOv8
推理速度	62.89	18.78

(2) 位姿估计模型训练与评估

为了验证该位姿估计方法，本文设计了在实际工作环境中的目标物体位姿估计测试。具体流程为，保持目标物体静止，环绕一周不同角度对其进行拍摄，移动时尽量保证相机不发生抖动，以及目标物体在视野内。获取到目标物体参考图像后，使用 COLMAP 对目标物体进行三维点云重建。此外本文还与基于特征融合的位姿估计算法进行了对比测试。以经典的 DenseFusion 为例，DenseFusion 需要获取目标物体的颜色和深度信息。对于深度信息，使用 PointNet 将点附近信息和点云编码，建立几何特征，生成密集的逐点特征。颜色特征使用 CNN 编码解码架构，将图像($H, W, 3$)映射为(H, W, d_{rgb})，每像素特征向量表示颜色。特征融合目的是融合局部像素特征，基于融合特征预测，可选择物体可见部分以减少遮挡和分割噪声影响。将几何和颜色特征组合，送入网络，用对称下降函数生成全局特征，丰富每像素特征。像素特征输入最终网络预测 6D 位姿，从融合特征预测所有姿态及置信度。以 realsensebox 物体为例，位姿估计测试结果如图 2-13 所示。




图 2-13 基于视角选择的位姿估计算法实验

由于本文所使用的位姿估计结果，将作为状态参与后续的模仿学习动作生成，如果出现较大的位姿偏差，这种不稳定性对于机器人操作而言是十分危险的，因此需要尽可能保证位姿估计结果的准确性。为了评价位姿估计的结果，本文采用 ADD 和 ADD-S 来比较位姿估计精度。假设 $\{R^*|T^*\}$ 是预测的物体 6D 位姿， $\{R|T\}$ 是真实的物体位姿。ADD 通过计算模型上的每一个点分别经过 $\{R|T\}$ 和 $\{R^*|T^*\}$ 变换之后的坐标之间的平均距离。而对于对称物体例如瓶子、碗等，位姿估计会产生视角歧义，因此使用 ADD-S 采用最近点距离来进行评价，具体的计算公式为

$$ADD = \frac{1}{m} \sum_{x \in model} \|(R\mathbf{x} + \mathbf{T}) - (R^* \mathbf{x} + \mathbf{T}^*)\| \quad (2-5)$$

$$ADD = \frac{1}{m} \sum_{x_1 \in model} \min_{x_2 \in model} \|(R\mathbf{x}_1 + \mathbf{T}) - (R^* \mathbf{x}_2 + \mathbf{T}^*)\| \quad (2-6)$$

其中 m 为模型上点的个数， $\mathbf{x}, \mathbf{x}_1, \mathbf{x}_2$ 为模型上的点。上述两式用于计算预测姿态和标准姿态之间的三维模型点之间的平均距离。本文将该平均距离小于模型直径 10% 的预测结果视为正确物体姿态，记该指标为 ADD-0.1d。测试结果如表 2-4 所示。

表 2-4 位姿估计平均精度对比(%)

物体类别	DenseFusion	基于视角选择的位姿估计
香蕉	82.0	84.6
瓶子	83.7	87.2
水杯	90.3	92.1
纸杯	81.4	80.9
盒子	94.4	98.4
平均	86.3	88.6

可以看出，本文的位姿估计算法算法的精度有了较大的提升。所使用的基于视角选择的位姿估计算法的预测结果精度相比较于 DenseFusion 提升了 9.61%。

与实例分割相同，位姿估计的推理也需要尽可能保证实时性。为了对本文的基于视角选择的位姿估计算法和 DenseFusion 算法的推理速度测试，从测试数据集中随机选择 100 张数据作为输入，计算其平均推理速度，测试结果如表 2-5 所示，可以看出相比较于 DenseFusion，本文的位姿估计的推理速度略慢一些，但相对于机器人的动作速度而言，该推理速度已经完全满足要求。

表 2-5 位姿估计推理速度(ms)

算法	DenseFusion	Ours
平均推理速度	182.7	194.6

综上，本文的目标检测与位姿估计算法具有准确和稳定的性能，能够满足机器人自主操作需求。

2.6 本章小结

本章对机器人自主操作场景下的目标检测与物体 6D 位姿估计进行了研究。为了实时识别被操作物体并估计物体 6D 位姿，本章基于 YOLOv8 算法完成目

标识别和分割任务。然后基于视角选择原理设计了物体 6D 位姿估计网络以及实现了一个姿态优化网络。此外考虑到机器人自主操作过程中的任务设置，选择了 5 类物体制作了实例分割数据集，并进行了稀疏点云模型重建用于位姿估计。在测试中实例分割算法分割精度和位姿估计精度较高，两者实时性也能满足要求，说明模型具备满足使用要求。

第3章 基于角度分布与点云融合的机器人 6D 抓取生成

3.1 引言

机器人在执行操作过程中一定涉及对物体进行抓取，每一类物体的稳定抓取姿态各不相同，在不同场景下的抓取姿态也不尽相同，通过模仿学习操作技能的方式只能学习演示数据中物体的抓取姿态，而对于其它类物体，抓取姿态可能不同。本章在已获取物体位姿的基础上，基于角度分布生成可靠、无碰撞的 6D 抓取姿态。并针对单一视角物体点云的空洞可能导致的抓取姿态生成错误的问题，基于点云融合的原理优化抓取姿态生成以获得更准确的抓取姿态。

3.2 机器人 6D 抓取任务分析

6D 抓取姿态生成算法的输入为单视角的 RGB 与深度图像，使用的传感器为 RealSense D455 相机。传统的针对平面的抓取检测算法已经基本成熟，这类方法算法简单，实际效果显著，因此研究较为深入，其中的典型代表方法是 Dex-Net^[40]，从输入的深度图中预测平行板夹爪的平面抓取表示，即抓取点和抓取角度 $[x, y, \theta] \in \mathbb{R}^3$ 。但实际机器人操作中，平面抓取无法满足所有任务需求，6D 抓取在某些任务中是必不可少的操作，而 6D 抓取需要计算平行板夹爪的空间抓取位置和姿态 $[\mathbf{R}, \mathbf{t}] \in \mathbb{R}^{4 \times 4}$ 。相比较于平面抓取，6D 抓取预测难度更大，并且由于机器人操作过程中，由于单视角点云存在空洞，机械臂运动中可能对物体产生遮挡等，6D 抓取的预测存在较大的不确定性，机器人的抓取存在较大的挑战。

为了实现稳定的机器人抓取，首先需要确定抓取生成方法。一种可行的 6D 抓取方法是基于物体模型的 6D 抓取预测方法，也就是首先建立物体的三维模型，并在此基础上构建该物体的抓取数据集。在实际进行抓取时，只需要进行物体识别和物体的位姿估计，确定位姿后直接从预先构建的该物体抓取数据集中匹配抓取姿态即可实现抓取。这种方法虽然抓取生成过程简单，但是需要针对所有需要的物体进行抓取标注，对于未进行过抓取数据标注的物体无法进行抓取，适用性和可扩展性较差。而近年来出现了一些端到端的抓取姿态生成网络，降低了抓取预测过程中对模型的依赖。此类方法从大量的抓取数据中训练抓取预测网络，可以直接从 RGB 信息和点云信息中预测目标物体的 6D 抓取姿态。并且这种方式对于未知的物体也能生成具有较高准确率的抓取结果。因此考虑使用该方法作为机器人自主操作过程中的抓取姿态生成方法。

6D 抓取姿态的生成可以分为两个步骤：（1）根据输入生成目标物体的 6D 抓取位姿候选列表；（2）利用筛选策略，从 6D 抓取位姿候选中选择最优的抓取姿态。本文的算法也是通过这两个步骤实现 6D 抓取姿态生成。

3.3 基于角度分布的物体 6D 抓取生成网络设计

在 6D 抓取任务中，网络一般以物体的 RGB 图像与深度图作为输入，其中 RGB 图像用于颜色特征提取，深度图包含了物体空间几何特征。网络回归物体 6D 抓取位姿。由于 6D 抓取姿态维度较高且抓取姿态的分布一般不连续，直接使用神经网络回归具有较大的挑战性。因此考虑将抓取姿态生成分为两个阶段，分别是抓取角度预测和抓取姿态筛选。本文基于 RGB Matters 抓取姿态生成网络进行了优化，实现一种稳定的 6D 抓取姿态生成方法。

3.3.1 机器人 6D 抓取表示方法

在本文的抓取姿态生成方法中，抓取姿态的初步生成与筛选主要依赖于物体点云，这些点云数据在本文中是通过将深度图像转换而得。点云数据区别于传统的二维图像，在于其存储了三维空间信息，例如物体表面各点的精确空间坐标，从而描绘出物体的三维结构特征。这种数据表达形式更为真实地反映了物体的空间几何特征。由于点云是物体上各个点的三维坐标组成的集合，因此对数据的排列不敏感，这导致物体点云具有无序性、不变性、密度不均匀性等特点，在数据处理和使用上也存在一定的挑战。此外，由于本文的点云从深度图中转换而来，在物体边缘点云较为稀疏甚至出现点云空洞，这为抓取姿态的准确生成与抓取的执行带来了额外的复杂性。

在物体点云的基础上，需要定义物体 6D 抓取的数学表示方式，因为基于学习的方法最终需要回归出抓取位姿，而该位姿的表达方式将对神经网络的梯度下降优化过程产生显著影响，需要确保网络在优化过程中可以有效地调整其权重，以最小化预测位姿与实际位姿之间的差异。同时 6D 抓取的表达方式需要能够有效的覆盖到所有可能的抓取姿态。本文主要讨论二指平行板夹爪。机器人抓取姿态定义为

$$\mathbf{g} = (x, y, z, r_x, r_y, r_z, w) \quad (3-1)$$

其中 x, y, z 分别代表夹爪的位置， r_x, r_y, r_z 代表夹爪的旋转， w 代表夹爪的宽度。本文仅考虑平行板式夹爪，夹爪的尺寸参数使用 $\mathbf{G} = (h, l, w_{max})$ 定义，三个参数分别代表夹爪的高度、长度和最大宽度，如图 3-1 所示




图 3-1 夹爪表达与参数

3.3.2 RGB Matters 抓取生成网络结构

本课题所实现的 RGB Matters 抓取生成算法是一个端到端的抓取生成网络。该网络以单视角的 RGB 图像作为输入，回归 6D 抓取角度，并使用深度图点云筛选得到最终抓取姿态。




图 3-2 RGB Matters 网络结构

具体实现流程为使 Angle-View Net 网络生成图像不同位置的夹爪方向 $P_{img} = (u, v, r_x, r_y, r_z, c)$ ，即图像中坐标的位置，其对应的夹爪旋转姿态，以及置

信度。对置信度高的预测，利用深度图像通过快速搜索策略计算这些抓取的抓取宽度和距离。

对于输入的 RGB 图像和深度图，直接预测像素级的夹爪的姿态，直接回归四元数难以实现，而且由于同一个位置进行抓取会有不止一个可行的姿态，因此直接通过神经网络回归抓取姿态也难以收敛。故考虑使用如图 3-3 所示的模型，将夹爪的姿态解耦为接近方向（共 V 个方向）和绕平面的旋转（共 A 个旋转角度），将夹爪的姿态预测作为一个分类问题进行预测，总共有 $V \times A$ 类方向。




图 3-3 抓取角度分布示意图^[26]

通过 Angle-View Net 网络将 RGB 图像栅格化，对于每一个栅格，网络预测一个一维的 $V \times A$ 个元素的向量，包含每个方向的置信度，最终输出为每个角度的热力图，从而可以得到置信度最高的抓取姿态。Angle-View Net 网络结构如图 3-4 所示，网络以 RGB 图像作为输入，使用 Resnet50 提取稠密的特征，然后将像素进行随机排序，并利用稠密降采样卷积层 DUC 对特征进行降采样，最后得到所有方向的热力图。




图 3-4 AVN 抓取方向生成网络结构图

例如，在本课题中将所有的抓取方向分为了 60 个接近向量和 6 个面内转

角，共计有 360 种可能的抓取方向。Angle-View Net 网络为每种可能的抓取方向生成一张热力图，图像上的每一个点的值即代表在该抓取方向上，向该位置抓取的可行性，例如图 3-5 所示。而具体的抓取接近距离和夹爪宽度等需要通过后续的快速搜索策略来确定。




图 3-5 所有抓取方向热力图示例

AVN 网络就是建立了 RGB 图像于热力图之间的映射关系。设 AVN_{θ} 代表以 θ 为参数的网络，给定数据集 $\{(C_1, AVH_1), \dots, (C_n, AVH_n)\}$ ，其中 (C_i, AVH_i) 代表第 i 张 RGB 图像 C_i 及其对应的真值热力图 AVH_i 。该网络的损失函数定义为网络预测的热力图于标准值之间的 L2 损失。

$$\theta = \arg \min_{\theta} \sum_i L(AVN_{\theta}(C_i), AVH_i), i = (1, 2, \dots, n) \quad (3-2)$$

Angle-View Net 网络针对目标物体生成一系列可能的抓取姿态，构成抓取姿态候选列表，但由于从单一视角获取的点云在点云边缘存在空洞，因此绝大部分抓取姿态是错误的。为了解决这个问题，快速找到可行的抓取姿态，本文提出了物体点云融合与滤波方法，经过点云补全后可提高抓取姿态生成的精度。




图 3-6 GraspNet-1Billion 数据集中的抓取标注^[18]

RGB Matters 算法之所以能在目标物体三维模型的情况下为各种物体生成

大量准确且稳定的抓取姿态，主要原因在于其利用了大规模抓取数据集 GraspNet-1Billion 训练网络，该数据集包含了 190 多个杂乱场景，88 种不同物体，共计近 10 万张 RGBD 图像。如图 3-6 所示，为 GraspNet-1Billion 数据集中的物体抓取标注，由于所有物体都是布置在杂乱环境中，网络可以学习到更复杂场景中的 6D 抓取能力。

3.4 利用 3D 融合点云的改进抓取生成方法

大多数传统的抓取姿态生成方法都是基于物体的 RGBD 数据，利用计算机视觉的学习方法，生成抓取姿态并评估抓取质量。为了实现机器人自动化抓取的要求，位姿估计需要足够精确，以实现稳定可靠的抓取。现有的方法仍然不能达到一般系统精度的要求。近两年提出的方法在抓取已知和未知物体方面表现出了良好的性能，但这些方法通常依赖于物体的表面特征和姿态估计，然而，由于物体表面的不规则性和光照变化，这些方法在处理边缘点云稀疏问题时表现出不稳定性和误差累积的现象。并且来自 RGB-D 相机的输入源将包含噪声，并且与理想 3D 模型的匹配可能是不准确的。当场景过于复杂或物体形状不规则时，抓取的成功率将受到很大影响。




图 3-7 基于位姿估计与点云融合的抓取姿态优化系统框架

为了解决这一问题，提出了一种基于位姿估计和点云融合的对象抓取方法，旨在提高抓取的准确性和稳定性。通过利用位姿估计算法将模型点云与输入点云融合，解决物体边缘点云稀疏导致的抓取姿态生成错误问题。所提出的系统由三个部分组成，三个部分相互耦合，最后生成抓取姿态。系统的输入是单个 RGB-D 图像，RGB 和深度图分别被提供给位姿估计网络与点云处理模块。位姿估计网络输出模型输出根据 6D 位姿变换后的模型点云以及分割出的目标物体 RGB。点云处理模块将模型投影的点云与深度点云融合，并进行噪点滤除。最后将融合后的点云与分割的目标 RGB 提供给抓取建议网络生成抓取 $g_{cam} =$

$(x, y, z, r_x, r_y, r_z, w)$ 。

3.4.1 物体点云融合与噪点滤波算法

(1) 基于位姿估计的点云融合

本文提出了一种基于位姿估计的点云融合方法如图 3-8, 以解决物体边缘点云稀疏导致的抓取姿态生成错误的问题。该方法利用位姿估计算法获得物体的 6D 位姿, 并将模型点云转换到相机坐标下。然后将输入点云与变换后的模型点云进行融合, 从而获得被补全的点云, 避免了单帧点云在物体边缘处稀疏以及物体后方缺乏点云, 导致的抓取姿态错误的问题。

具体而言, 本文首先利用位姿估计算法获取物体的 6D 位姿矩阵, 将物体的模型点云 P_m 根据位姿矩阵 $T \in \mathbb{R}^{4 \times 4}$ 进行变换, 获得相机视角下的模型点云 $P \in \mathbb{R}^{3 \times M}$ 。




图 3-8 点云融合模块

通过这个变换, 我们可以得到一个虚拟的模型点云 P , 它与实际输入点云 $Q \in \mathbb{R}^{3 \times N}$ 在相机坐标系下处于相同的位置和姿态。接下来, 我们通过 ICP 点云配准算法将当前帧的输入点云与转换后的模型点云进行融合。首先为每个输入点云找到转换后的模型点云中最近的对应点, 然后通过计算点之间的欧氏距离并最小化点对之间的距离实现。

$$d(P_i, Q_i) = \sqrt{(x_{P_i} - x_{Q_i})^2 + (y_{P_i} - y_{Q_i})^2 + (z_{P_i} - z_{Q_i})^2} \quad (3-4)$$

$$E = \frac{1}{N} \sum_{i=1}^N d(P_i, Q_i)^2 \quad (3-5)$$

其中 E 是匹配点对之间的均方误差, N 是输入点云的数量, $P_{j(i)}$ 是模型点云中 与 Q_i 对应的点。经过点云配准与融合, 我们可以得到一个被补全的点云, 其

中补充了缺失的表面信息以及几何形状信息。这样一来，物体边缘处由于点云稀疏而导致的抓取姿态生成错误的问题得到了有效解决。

通过点云融合过程，我们能够充分利用位姿估计的结果，将模型点云与输入点云相结合，从而提供更准确和鲁棒的抓取姿态生成结果。与传统的单帧抓取相比，我们的方法能够获得更完整的点云信息，避免了由于点云稀疏导致的估计错误，与融合多个视角的点云方法相比，我们的方法节省了抓取计算成本和时间成本。通过实验证明，基于位姿估计的点云融合方法能够显著提高抓取任务的成功率和精度，为机器人在实际应用中的抓取任务提供了可行的解决方案。

（2）面向物体边缘分割的点云滤波算法的实现

在深度图中，不可避免会出现由于传感器测量不准确、物体表面特性的复杂性、以及其他潜在的问题导致的噪声，这一问题在物体边缘处尤为明显，如图 3-9 左侧所示。这些噪声点云可能会导致抓取姿态生成过程的不准确性，因为姿态估计算法通常依赖于点云数据的连续性和一致性。为了解决这个问题，我们提出了点云滤波算法。




图 3-9 点云滤波模块

点云滤波算法的核心思想是利用卷积操作的局部感知能力，对深度图中的每个像素点周围的区域进行分析。通过计算该区域内各像素点的深度值的变化，我们可以提取出深度图中的异常点。此时我们将其标记为无效点云，并从点云数据中剔除。同时，使用中值滤波器有助于调整那些与周围像素深度值差异显著的像素，使其深度值更接近于邻域内的中值，进而有效消除孤立的噪声点。通过卷积操作与中值滤波，我们就可以消除点云中的深度错位现象，提高生成的抓取姿态的准确性和稳定性。

通过实验证明，我们的点云滤波算法能够有效地消除异常点云，并提高点云数据的质量。这种滤波算法基于单层卷积操作和中值滤波，具有较低的计算复杂度和较小的模型参数量，适用于实时的点云处理应用。通过在位姿估计和抓取姿态生成流程中应用点云滤波算法，我们可以获得更准确和稳定的结果，提高机器人在抓取任务中和可靠性。

3.4.2 抓取姿态优化与快速搜索策略

由于深度相机在物体边缘点云较为稀疏，因此直接生成抓取会导致抓取姿态生成错误的问题，如图 3-10(a)所示，在物体点云缺失的地方出现了错误的抓取。因此为了保证抓取姿态的结果正确，利用物体点云融合与滤波方法将物体边缘的点云进行补全，获得完整的点云来生成可靠抓取，如图 3-10 (b)所示。




图 3-10 抓取姿态生成对比

相比较于基于 NBV 思想的多视角点云融合的抓取方法，每次执行抓取前需要移动并改变机器人的位姿，使其从不同角度观察物体，获得物体的完整点云信息并生成最优的抓取姿态^[24]，本文提出的方法在每次抓取时只需要单一视角的 RGBD 信息，结合位姿估计的结果即可补全点云，进而获得更可靠的抓取，抓取执行效率更高。

此外物体 6D 抓取网络预测了一系列抓取姿态候选，但是部分抓取姿态在经过融合后的点云中是无法到达的。该方法提出了基于碰撞和空抓取检测的快速分析搜索来计算夹爪宽度和沿轴平移。通过对 $(0, w_{max})$ 采样，假设夹爪靠近由深度图重建的点云的对应夹取点，过滤掉夹爪占用的空间中存在点云，即有碰撞的情况，以及夹爪抓取空间中没有点的情况。进而实现快速搜索夹爪宽度和沿轴平移的目的。




图 3-11 快速搜索策略

3.5 机器人 6D 抓取仿真实验与分析

由于抓取姿态生成网络获取的抓取姿态 $\mathbf{g} = (x, y, z, r_x, r_y, r_z, w)$ 是相对于相机坐标系的姿态，在实际夹取过程中，需要利用“手眼标定”的结果，将抓取姿态从相机坐标系转换到基座坐标系中，才能够实现抓取动作。

为了实现这一转换，我们可以利用手眼标定的结果 $\mathbf{T}_{cam}^{base} \in \mathbb{R}^{4 \times 4}$ ，它描述了相机坐标系到基座坐标系的变换关系。首先，我们可以将抓取姿态 $\mathbf{g}$ 表示为一个齐次变换矩阵 $\mathbf{G}_{cam} \in \mathbb{R}^{4 \times 4}$ ，该矩阵描述了相机坐标系中的姿态。在 $\mathbf{G}_{cam}$ 中，平移部分表示为 (x, y, z) ，而旋转部分由欧拉角 (r_x, r_y, r_z) 组成。因此基座坐标系中的抓取姿态可以表示为 $\mathbf{G}_{base}$ ：

$$\mathbf{G}_{base} = \mathbf{T}_{cam}^{base} \cdot \mathbf{G}_{cam} \quad (3-6)$$

通过该计算得到抓取姿态从相机坐标系到机器人基座坐标系的坐标变换，获得基座坐标系中的抓取姿态矩阵 $\mathbf{G}_{base}$ ，确保了机器人在执行抓取动作时可以基于基座坐标系的参考进行操作。

为了验证抓取姿态生成算法的性能，我们进行了仿真实验。在这个仿真环境中，我们使用一个虚拟的机械臂和物体，以及相机传感器进行模拟。本文在 Gazebo 中布置了仿真机械臂工作台与被测物体。

同时本文模拟了一个虚拟的 RGBD 相机，它可以捕获物体和环境的图像与点云。相机的参数和分辨率与实际应用中的相机相符。仿真实验如图 3-12 所示，所提出的抓取姿态生成算法在仿真环境中可以实现稳定的抓取姿态生成，并能够实现物体抓取。




图 3-12 抓取姿态生成仿真实验

为了验证所提出的抓取策略能够有效的抓取各类物体，机器人在仿真环境中对多类物体进行了抓取测试。在仿真环境使用所提出的机器人抓取策略对物体进行多次抓取，计算抓取方法的抓取成功率。

本文将所提出的方法与不包含点云处理模块的方法进行比较。在仿真实验

中评估了三类物体的抓取成功率：杯子、瓶子和盒子。在抓取过程中，首先使用 6D 位姿估计算法对每个实例进行 6D 位姿估计。将模型点云通过位姿估计结果与深度点云进行融合，通过抓取模块获得优化的抓取位姿作为最终抓取，并在仿真环境中实施抓取，图 3-13 展示了一些仿真环境中的抓取结果。




图 3-13 一些仿真环境中的抓取结果

本文对每个种类的物体进行了 50 次实验，表 3-1 显示了两种方法的定量结果，与不包含点云处理模块的方法相比，本文所提出的方法在瓶子和盒子类别中获得了更高的成功率。一个主要的原因是使用模型点云通过估计得到的位姿，通过补全点云获得了物体的完整形状，而不是直接从部分输入点云估计抓取姿态，因此获得了更好的抓取。此外本文的点云配准模块也保证了所估计的 6D 位姿与输入点云的匹配，保证了点云融合的精度。

表 3-1 仿真环境下抓取成功率比较

方法	杯类	瓶类	盒类	平均
无点云处理	37/50 (74%)	43/50 (86%)	39/50 (78%)	79.33%
经过点云处理	39/50 (78%)	45/50 (90%)	42/50 (84%)	84.00%

3.6 本章小结

本章主要针对物体 6D 抓取姿态生成问题进行研究。采用了 6D 抓取姿态生成网络 RGB Matters 作为基础算法，该算法通过将抓取方向预测转换为分类问题，通过抓取角度预测网络回归抓取姿态候选，然后利用点云信息，对得到的抓取姿态候选列表进行筛选，删除所有可能发生碰撞与无意义的抓取，最终得到可能的抓取姿态。在抓取姿态生成过程中，由于物体边缘点云的空洞可能导致错误的抓取，本章在物体 6D 位姿估计的基础上优化了抓取姿态生成过程。利用位姿估计过程中重建出的物体稀疏点云模型，根据物体 6D 位姿对当前输入点云进行点云融合，补全输入点云中的空洞。利用经过融合后的点云生成的

抓取姿态，抓取成功率得到了提高。保证了抓取过程的稳定性。本章最后进行了实际场景的机器人抓取实验，记录了各种物体抓取、以及经过点云融合前后抓取成功率。结果表明，本文提出的方法可以有效地生成物体的可靠无碰撞的6D 抓取姿态。

第 4 章 基于扩散策略的机器人模仿学习规划

4.1 引言

随着机器人被应用在更广泛的领域，机械臂将会代替或辅助人类在日常生活以及各项工作中完成各类任务。为了实现该过程中的机器人技能学习与自主操作，本文使用模仿学习方法训练机器人学习人类技能。本章基于扩散策略设计模仿学习规划算法，通过去噪过程生成机器人动作，使得机器人可以更高效、直接地学习技能。本文将机器人的动作表示为概率分布，解决传统神经网络在学习复杂动作序列中同一状态对应多种可能动作情况的局限性。本文建立机器人主从控制策略，收集人类演示数据用于机器人模仿学习训练，并在仿真环境对所提出的算法进行实验测试。

4.2 机器人模仿学习规划的问题描述及分析

传统的基于强化学习的算法要求算法在训练过程中实时与环境进行交互，然而直接在机器人实体上采用强化学习方法，在训练初期由于策略不稳定，很容易生成错误的动作，训练过程中危险性较高。若在仿真环境中训练强化学习算法，则需要保证仿真环境与真实环境完全相同，其中涉及物体位姿的获取、机器人本体状态等，由于仿真环境很难做到与真实环境相同，因此仿真训练的强化学习策略通常需要进行 Sim2Real 过程，这个过程也会引入很多不必要的噪声。此外，强化学习的效果非常依赖于奖励函数的设计，对于每一个不同的任务，都需要单独设计一个合适的奖励函数来保证训练的稳定性。




图 4-1 模仿学习动作规划算法框架

模仿学习可以通过观察人类示教演示的任务，通过建立收集部分演示数据，

构建一个状态与动作的行为库，机器人从离线数据中学习动作和技能。这种方式相较于强化学习更加安全可靠，且训练稳定性较好。因此最终决定采用模仿学习算法训练机器人，使其学习人类演示数据进而学习动作和技能。模仿学习训练框架如图 4-1 所示。

4.3 机器人主从控制与模仿学习规划策略

模仿学习是一种基于示范的学习方法，一般通过观察和学习示范者的动作来实现。在现实生活中，很多动作往往是由多个步骤组成的长序列动作，如做菜、整理书桌等。这些复杂的动作对机器人的学习能力提出了更高的要求，需要机器人能够理解并学会长序列动作中的各个步骤和相互关系。长序列复杂动作的学习在实际应用中具有重要意义。例如，在服务机器人领域，机器人需要能够执行一系列复杂的动作来完成服务任务，如为客人倒水、整理餐具等。因此，研究机器人在仿真环境中学习长序列复杂动作的能力对于提高其在实际应用中的性能具有重要意义。

4.3.1 机器人模仿学习规划策略

机器人模仿学习策略将模仿学习的概念应用于机器人动作规划与控制中，实现机器人的自主操作。模仿学习通过引入示教的概念来实现机器人的复杂运动控制问题。相较于强化学习等方法让智能体自行学习策略，模仿学习这种基于示范的方法更为直观和易于理解。因此对于机器人自主操作问题而言，从人类的演示中学习机器人的复杂动作规划策略是一种较为直观有效的方法。模仿学习目标在于从人类演示中学习机器人的控制策略，使其能够再执行某个任务时，根据当前观测情况预测下一步动作，实现机器人的控制。然而由于机器人操作场景的动态性，例如在操作过程中物体位置可能发生无法预料的变化等因素，简单的示教并不能满足整个动作的要求。因此在机器人操作中，模仿学习需要具备从给定的人类演示中学习策略的能力，即能够根据当前状态动态的调整动作执行任务，而不仅是简单机械的复制演示动作。

相较于强化学习，模仿学习被认为是更可行的机器人走向通用性的关键技术，因为它赋予了机器人在与人类演示相接近的场景中的自主完成任务的能力。在工业与家用机器人自主操作、医疗辅助机器人等应用场景中，我们都需要机器人能够和人类一样，利用自身传感器感知信息并执行自主操作。

而模仿学习中一类常见的任务就是从人类演示中学习机器人动作，这需要机器人从一组未被标记的状态和序列轨迹中，学习人类的行为。而人类演示数

据的特点是数据多样化且存在许多无意义的噪声动作，这种特点使得从数据中学习有意义的行为变得非常困难。模仿学习算法需要从数据中学习有效地动作策略，并学习长期动作规划的能力。

在模仿学习中，行为克隆是最基础且应用最广泛的方法之一。它是一种直接从专家的示教数据中学习策略的方法。行为克隆的核心在于通过监督学习从专家数据中学习状态 $\mathbf{s}$ 到动作 $\mathbf{a}$ 的映射关系 π 。机器人的目标就是学习该映射函数 π ，使得在给定状态 $\mathbf{s}$ 下，可以产生正确的动作 $\mathbf{a}$ 。训练行为克隆网络需要收集人类演示数据，行为克隆的数据集可以记为 $\mathbf{D} = \{(\mathbf{s}_0, \mathbf{a}_0), (\mathbf{s}_1, \mathbf{a}_1), \dots, (\mathbf{s}_n, \mathbf{a}_n)\}$ ，其中每一组状态和动作对 $(\mathbf{s}_i, \mathbf{a}_i)$ 被称为一条经验， n 条经验共同组成一个机器人行为克隆数据。为了学习行为克隆的映射函数 π ，通常使用各种方法来最小化损失函数 L ：

$$L = \sum_{i=1}^n \text{MSE}(\pi(\mathbf{s}_i; \boldsymbol{\theta}), \mathbf{a}_i) \quad (4-1)$$

其中 $\text{MSE}()$ 代表均方误差 (Mean Square Error, MSE)，用于衡量预测动作 $\hat{\mathbf{a}}$ 和实际动作 $\mathbf{a}$ 之间的差异， $\boldsymbol{\theta}$ 为行为克隆模型参数。模仿学习中通常使用均方误差，也可使用其它损失函数衡量预测与真实值之间的差异。基于行为克隆的各类方法的机器人模仿学习过程可以用算法 1 来表示：

算法 1 基于行为克隆的机器人模仿学习规划

输入： 专家行为数据集 $\mathbf{D}$ ，包含状态-动作对

初始化： 模仿策略参数 $\boldsymbol{\theta}$

过程：

- 1: **repeat**
- 2: 从专家行为数据集 $\mathbf{D}$ 中随机采样状态-动作对
- 3: 提取状态特征，并利用模仿策略将其映射到动作空间
- 4: 使用监督学习训练模仿策略，最小化预测动作与专家行为间的误差
- 5: 更新模仿策略参数 $\boldsymbol{\theta}$ 以减小误差
- 6: **until** 收敛或达到最大迭代次数

输出： 优化的模仿策略参数 $\boldsymbol{\theta}$

行为克隆方法需要大量的训练数据用于学习，网络的效果非常依赖于数据的质量，对于噪声较大的数据训练效果较差，但是这种方式的优点是结构简单，学习速度快，因此常被作为模仿学习的基础算法，在行为克隆的基础上进行改进，其中两类具有代表性的算法是 BC-RNN^[41]和 IBC (Implicit Behavioral Cloning)。其中 BC-RNN 修改神经网络的基础结构，使用循环神经网络来学习

状态和动作的映射关系。隐性行为克隆 IBC 则改变了传统的行为克隆的输入与输出，不再是预测状态和动作的映射关系，而是将状态和动作作为输入，学习一个评分函数，对每一组状态和动作进行评价，当状态和预测动作接近演示数据时，评分越高，通过最大化每一组状态和动作的得分，实现机器人的动作模仿。

4.3.2 主从控制与人类演示数据集建立

为了训练模仿学习动作规划算法，需要首先建立一个人类演示数据集。建立人类演示数据集通常采用示教的方式来获取轨迹，常见的人类演示数据收集方式有两种：一种是通过外部传感器例如 3D 空间鼠标、遥操作 6 自由度主手等采集人类动作轨迹，并将其映射到机器人上实现机器人的动作控制；另一种是通过规划算法构造示教轨迹，设计一个针对特定任务的底层控制器根据当前机器人状态和物体状态来生成动作。本文主要采用遥操作主手机构采集人类演示数据，同时设计了底层控制器收集数据集进行训练效果的对比。

(1) 主从控制策略

根据主从映射的空间对应关系以及主手和机器人的关节构型关系，主从控制策略可以分为关节空间控制和笛卡尔空间控制。其中关节空间控制要求主手和机器人为同一构型，在这种情况下可以直接将主手的各个关节的运动映射到机器人的各个关节上，无需机器人的逆运动学计算就可以实现机器人控制。这种控制策略对主手和机器人的结构要求较高，如今各类机器人设备越来越多样化的，我们不可能为每类机械臂都设计一套对应的主手，而是会采用通用的主手来采集人类数据，此时可以通过笛卡尔空间控制策略解决主从关节结构不对应的控制问题。




图 4-2 主从控制策略结构

笛卡尔空间控制策略主要根据主手结构与正运动学求解获得主手的空间 6D 位姿，然后将该位姿作为机器人期望的末端位姿，进行逆运动学计算和机器

人的位置控制。这种方法简单高效，可以实现主从工作空间的匹配映射，使用通用主手即可实现对多类机器人的主从控制。

本课题采用笛卡尔空间主从映射控制策略，主从控制系统的结构如图 4-2 所示。主手采集人类演示者的实时动作信息，主手的笛卡尔空间末端位姿信息被发送给主从控制系统，主从控制系统根据主手末端位姿进行信息处理，计算机器人逆运动学后将相应的关节控制指令发送给从收机器人，机器人执行相应的运动。

(2) 遥操作主手动作滤波算法

在收集人类演示数据时，需要人手操作遥操作主手来控制机械臂运动，但由于人的生理特性，在进行精细操作时手部容易发生无意识的生理性震颤，反映在遥操作控制过程中则对应遥操作主手的末端抖动，并且由于遥操作主手的笛卡尔空间需要经过放大后与从手机器人工作空间对齐，因此，主手的微小抖动也会同时放大，在从手机器人上更加显著。机器人的末端运动轨迹发生抖动会严重影响人类收集数据时，机器人执行任务的精度，为人类演示数据收集带来困难。更重要的是这种无规则抖动相当于为收集的数据样本增加了无意义、非必要的噪声，会增加模仿学习算法训练的收敛难度。因此在进行主从控制收集数据时，需要滤除人类人手动作的抖动。

针对此问题，本文设计了基于滑动窗口的加权平均滤波器作为消除人手抖动现象的滤波算法。该滤波器实时获取遥操作主手的当前位姿，并存储前 $N-1$ 个时刻的主手位姿（ N 为滑动窗口大小）。主手每获取一次当前主手的位姿，将滑动窗口向后移动一位，保证窗口内位姿数量不变。对于滑动窗口内的各个时刻的主手位姿，利用加权平均滤波器进行处理，对窗口内的每一个位姿赋予独立的加权系数，以此来实现消除人手的抖动带来的数据噪声问题。同时为了尽量减小该滤波器导致的主从控制滞后性，需要合理设计滑动窗口中的位姿加权系数，保证当前位姿的采样权重较大，以此来满足主控控制的实时性要求。该算法的基本实现原理如式(4-2)所示：

$$T_{smooth}(t) = \sum_{k=1}^{k \leq N} \alpha_k T_{real}(t - N + k) \quad (4-2)$$

其中 $T_{smooth}(t)$ 代表 t 时刻经过滤波后的主手位姿， $T_{real}(t)$ 代表 t 时刻采样得到的主手位姿； α_k 代表滑动窗口内第 k 个位姿点的加权系数； N 为滑动窗口的长度。

本课题利用主手采集数据，使用该滤波器对主手数据进行仿真，观察位姿数据的抖动滤除效果。使用 Omega.7 主手采集数据，人手操作主手设备进行动

作，对人手的抖动进行滤波，对各旋转角度的滤波测试结果如图 4-3 所示，对于位置的滤波原理相同。




图 4-3 滤波前后动作对比

实验表明使用基于滑动窗口的加权平均滤波器对手部动作进行抖动滤除后，主手的输出位姿变得更加平滑，微小抖动基本可以被滤除，针对的较大抖动也能起到一定的减弱作用，并且滤波前后时间延迟和误差都较小。

4.4 基于扩散策略的机器人动作规划方法

模仿学习是从离线的人类演示数据中学习机器人技能的一种框架。尤其是对于涉及机器人复杂或精细操作时，例如长序列动作或高精度动作，模仿学习相较于强化学习更加有利。而机器人复杂操作体现在数据上则为复杂的动作状态分布。模仿学习目标是学习与演示数据的状态和动作分布相匹配的策略。扩散模型已经被发现对于复杂的数据分布，例如图像，进行建模时表现出色。因

此将扩散模型应用之机器人决策过程中，学习人类的复杂行为是一种较为可行的思路。

4.4.1 扩散模型的前向与反向过程

扩散模型^[42,43]是一类生成模型，通过不断迭代生成与数据分布相匹配的样本。在图像生成和其它数据生成领域中，扩散模型已经表现出了强大的能力。这种模型不断将高斯噪声加入到数据中，并使用神经网络来学习添加的噪声，从而实现从噪声中生成新的数据样本。

在机器人复杂动作规划模型中，存在一些无法直接观察但可以通过模型推断出的潜变量（Latent Variable），由于这些变量代表观测数据背后的隐藏状态或属性，因此这些变量对于理解数据的复杂结构非常重要。而扩散模型就是一个潜变量模型。扩散模型可以分为前向过程和反向过程两部分，前向过程中算法向数据中添加噪声，反向过程则是从噪声中生成输出。

前向过程是向原始数据中逐步添加噪声直到成为完全噪声的过程，可以将前向过程视为将图像逐渐变模糊的过程，在本文中对应的动作数据逐渐模糊的过程。可以表示为：

$$q(\mathbf{x}_{1:K} | \mathbf{x}_0) := \prod_{k=1}^K q(\mathbf{x}_k | \mathbf{x}_{k-1}) \quad (4-3)$$

其中 $\mathbf{x}_0$ 代表不包含噪声的原始数据，例如机器人的动作 $\mathbf{a}$ ，最终得到的 $\mathbf{x}_K$ 代表完全噪声，对于每一时间步 k ，都根据当前状态添加高斯噪声：

$$q(\mathbf{x}_k | \mathbf{x}_{k-1}) := N(\mathbf{x}_k; \sqrt{1 - \beta_k} \mathbf{x}_{k-1}, \beta_k \mathbf{I}) \quad (4-4)$$

其中 β_k 是当前时间步 k 对应的噪声增量参数，一般为一个小的正值且不断增加； $\mathbf{I}$ 代表单位矩阵。

反向过程则是从纯噪声 $\mathbf{x}_T$ 中恢复原始数据的过程，可以直观地理解为从一个完全被噪声污染的图像，通过训练好的神经网络逐步去除噪声，每一步都让图像变得更清晰，直到恢复到原始数据的样子。对于本课题则是从随机生成的噪声动作数据中逐步去噪，最终恢复出可行的机器人动作。去噪过程可以表示为：

$$p_\theta(\mathbf{x}_{0:K}) := p(\mathbf{x}_K) \prod_{k=1}^K p_\theta(\mathbf{x}_{k-1} | \mathbf{x}_k) \quad (4-5)$$

$$p(\mathbf{x}_K) = N(\mathbf{x}_K; \mathbf{0}, \mathbf{I}) \quad (4-6)$$

其中对每一步 k ，模型会根据当前的数据 $\mathbf{x}_k$ 预测出前一步数据 $\mathbf{x}_{k-1}$ ，具体过

程为：

$$p_{\theta}(\mathbf{x}_{k-1} | \mathbf{x}_k) = N(\mathbf{x}_{k-1}; \mu_{\theta}(\mathbf{x}_k, k), \sigma_{\theta}(\mathbf{x}_k, k)) \quad (4-7)$$

其中 $\mu_{\theta}(\mathbf{x}_k, k)$ 是模型预测的噪声均值， $\sigma_{\theta}(\mathbf{x}_k, k)$ 是预测的噪声方差。反向过程的训练目标就是通过最大化证据下界（Evidence Lower Bound, ELBO）来逼近数据的真实分布。

$$E_q = \left[\log \frac{p_{\theta}(\mathbf{x}_0, \mathbf{x}_{1:K})}{q(\mathbf{x}_{1:K} | \mathbf{x}_0)} \right] \quad (4-8)$$

其中 $p_{\theta}(\mathbf{x}_0, \mathbf{x}_{1:K})$ 是反向过程的概率， $q(\mathbf{x}_{1:K} | \mathbf{x}_0)$ 是前向过程的概率，由于前向过程的定义是固定的高斯分布，可以将 ELBO 分解为一系列逐步去噪的损失函数：

$$L_{k-1} = E_q \left[\frac{\|\mu_{k-1} - \mu_{\theta}(\mathbf{x}_k, k)\|^2}{2\sigma_{k-1}^2} \right] \quad (4-9)$$

这个损失函数衡量的是模型预测的图像与真实图像之间的距离，通过最小化总损失来优化参数 θ ：

$$L_{total} = \sum_{k=1}^K L_{k-1} \quad (4-10)$$

由于扩散模型的特点，其非常适合作为序列生成模型，将多个机器人的状态和动作对建模为动作矩阵的生成问题。扩散策略^[44]是一个以扩散模型为基础的模仿学习算法，通过生成式的方法训练机器人，解决传统模仿学习算法中的问题。

4.4.2 扩散策略的网络结构设计

模仿学习算法是通过模仿人类演示动作来训练机器人的方法，然而传统的模仿学习存在问题，例如样本效率低，需要大量的演示数据进行训练；泛化能力差，环境发生改变时表现较差等。由于扩散模型在生成式任务中表现出色，具有优秀的数据生成能力和灵活性，本课题实现的扩散策略将扩散模型应用在机器人模仿学习任务中来解决传统模仿学习的限制。为了实现这个目的，主要在扩散模型的基础上，将反向过程的输出 $\mathbf{x}$ 表示为机器人动作 $\mathbf{a}$ ，同时反向过程以观测 $\mathbf{s}_t$ 为条件进行去噪。

扩散策略包括两个部分：前向过程和用于策略生成的反向过程。其中前向过程向人类演示数据中逐步添加噪声，是一个从原始动作数据向完全噪声转变的过程。反向去噪模型则是从一个初始的随机噪声开始，通过多步去噪逐步生

成动作序列，生成的动作序列能够有效地模仿人类演示动作。

其中的前向过程定义了一个逐步添加高斯噪声的过程，使得人类演示数据集中的动作序列变得越来越接近噪声分布。具体过程为，对每一时间步 t 经过 k 次加噪处理的动作 $\mathbf{a}_t^k$ 被转换为 $\mathbf{a}_t^{k+1}$ 。

$$q(\mathbf{a}_t^{k+1} | \mathbf{a}_t^k) = N(\mathbf{a}_t^{k+1}; \sqrt{1 - \beta_k} \mathbf{a}_t^k, \beta_k \mathbf{I}) \quad (4-11)$$

反向过程是扩散策略的核心，在机器人动作空间上进行条件去噪扩散如图4-4所示，生成机器人动作。机器人的动作被表示为一系列7维向量，包括六自由度机器人各关节转角以及夹爪状态。




图 4-4 基于扩散策略的模仿学习框架

在这个过程中，扩散策略并不直接输出动作，而是根据环境的观测来预测动作的概率分布。即我们训练一个神经网络，从随机高斯噪声采样 $\mathbf{a}_t^K$ 作为动作样本，以观测状态 $\mathbf{s}_t$ 为条件预测动作的梯度来消除噪声。使用 DDPM 进行 K 次去噪迭代过程，产生一系列噪声水平逐渐降低的中间动作 $(\mathbf{a}_t^K, \mathbf{a}_t^{K-1}, \dots, \mathbf{a}_t^1)$ ，直到生成无噪声动作输出 $\mathbf{a}_t^0$ ，该数据就是机器人可执行的操作，该去噪迭代过程可以表示为：

$$\mathbf{a}_t^{k-1} = \alpha(\mathbf{a}_t^k - \gamma \epsilon_\theta(\mathbf{s}_t, \mathbf{a}_t^k, k) + N(0, \sigma^2 \mathbf{I})) \quad (4-12)$$

其中 ϵ_θ 是通过学习的得到的噪声预测网络， $N(0, \sigma^2 \mathbf{I})$ 是每次迭代过程中添加的高斯噪声。其中的噪声预测网络 $\epsilon_\theta(\mathbf{s}, \mathbf{a}, t)$ 可以预测梯度场 $\nabla E(\mathbf{a})$ ，因此上面的去噪过程中的每一步噪声梯度下降过程如下：

$$\mathbf{a}' = \mathbf{a} - \gamma \cdot \nabla E(\mathbf{a}) \quad (4-13)$$

其中的 α, γ, σ 为噪声调度，三者共同决定梯度下降过程中的学习率调整。

扩散模型网络在训练时首先从数据集中随机抽取样本 $\mathbf{a}_t^0$ ，对于每个样本，网络选择一个去噪迭代次数 K ，然后在样本 $\mathbf{a}_t^0$ 中添加迭代 K 次的随机噪声 ϵ^K ，噪声预测网络则需要从添加了噪声的数据样本中预测噪声：

$$L = \text{MSE}(\epsilon^k, \epsilon_\theta(s_t, \mathbf{a}_t^0 + \epsilon^k, k)) \quad (4-14)$$

最小化该损失函数均方误差，也就可以使噪声预测网络达到所要求。虽然扩散模型 DDPM 经常被用于图像生成，但其也可以被应用于学习机器人的运动策略。具体过程可以用算法 2 来表示。

算法 2 基于扩散策略的机器人模仿学习规划

输入： 人类演示数据集 $\mathbf{D}$ ，包含状态-动作对

初始化： 噪声参数 σ ，扩散参数 α, γ ，扩散迭代次数 K

噪声预测网络参数 θ ，学习率 η

过程：

1: **repeat**

2: 从人类演示数据集 $\mathbf{D}$ 中随机采样状态-动作对 $(s_t, \mathbf{a}_t)$

3: 随机选择扩散迭代次数 K

4: **for** $t = 1 \cdots K$ **do**

4: 从高斯分布中采样噪声 ϵ^K

5: 计算 $\mathbf{a}_t^k = \alpha(\mathbf{a}_t^{k-1} - \gamma \epsilon_\theta(s_t, \mathbf{a}_t^{k-1}, k-1) + N(0, \sigma^2 \mathbf{I}))$

6: 计算损失函数 $L = \text{MSE}(\epsilon^k, \epsilon_\theta(s_t, \mathbf{a}_t^k + \epsilon^k, k))$

7: 更新网络参数 θ 以最小化损失函数 L

8: **end for**

9: **until** 收敛或达到最大迭代次数

10: **for** 每个时间步 t **do**

11: 获取最新的观测数据 s_t

12: 使用噪声预测网络生成动作 $\mathbf{a}_t$

13: 机器人执行动作

14: 更新观测

15: **end for**

4.4.3 多动作概率分布问题研究

为了将扩散策略应用于机器人学习，需要更改扩散模型的输出并以环境观测量为条件进行去噪过程。设机器人的输出动作为 $[x, y, z, q_w, q_x, q_y, q_z, w]$ 。其中

x, y, z 分别代表接下来的机器人末端相对于当前时刻末端位置的相对位置变化量。并且为了保证扩散策略的性能,需要对数据进行归一化,也就是将所有任务中的每个动作维度的最大值和最小值缩放到 $[-1, 1]$ 范围内来确保稳定性。此时若数据的方差很小,例如机器人处于静止,动作保持恒定值时,数据会移至零均值位置,避免了梯度消失问题。 q_w, q_x, q_y, q_z 代表机器人末端的四元数表示机器人的姿态变化, w 表示夹爪的绝对位置, 0 为夹爪最大打开状态, 1 为夹爪关闭状态。有效的机器人动作的生成需要长期规划的时间一致性和平滑性。为了解决这个问题,该策略选择将当前时刻的前 T_o 步观测数据 O_t 作为输入,预测接下来可能的 T_p 步动作,在机器人上执行其中的 T_a 步动作,执行完成后再重新进入规划阶段。

从人类示范中学习机器人运动策略,简单而言可以表示为将观测量(机器人本体与环境信息)映射到动作的监督回归任务。但是在实际中,由于机器人的动作具有独特的多动作概率分布问题特点和序列相关性特点,导致机器人动作生成不同于其它监督学习问题。

对于同样的环境状态输入,机器人可以有多种动作选择来完成任务,但这种多种动作的预测对于传统的神经网络是非常困难的。例如传统的行为克隆通过最小化预测与数据的误差来学习策略,这种方式非常简单,但是存在很大的限制,行为克隆无法建模人类的完整、复杂动作。由于行为克隆会最小化分布的误差,会导致结果更偏向于在数据中更频繁发生的动作,甚至可能出现在数据分布之外的动作,例如在两个动作模式的中间生成动作,如图 4-5 (a) 所示。另一种动作学习方式通过将机器人的 6 个自由度动作离散化为 $6 \times N$ 个分类,将动作生成转换为分类任务。但是这种方式由于将动作进行了分类处理,因此对于同一分类中只会生成单个值的动作,无法实现精细操作。此外由于每个动作维度是单独处理的,忽略的机器人 6 个动作维度之间的依赖关系,可能出现每个自由度得分最高的动作组合并不是所需的动作,而所需的动作在某个自由度上的动作分类得分可能并不是最高。虽然这些问题可以通过调整优化回归建模的方式来进行优化,但是固有问题仍然存在。

相较于传统的动作生成方式,扩散模型由于可以输出稳定的条件概率联合分布,甚至处理实现文本到图像、视频生成这些复杂问题。因此在学习模仿人类演示的动作策略时,避免了对动作选择的限制,能够准确地重建出人类动作。

如图 4-5 所示,对于前往目标物体上方准备抓取的动作,对于现有的一些方法,有的尝试使用分类来近似该分布,或者使用高斯混合模型来表示,这些方法都会限制动作生成的精度,例如传统的行为克隆最小化数据样本中的均方

误差，但是由于演示数据中部分数据绕左侧旋转抓取，部分数据绕右侧旋转抓取，直接回归可能得到错误的抓取姿态。但是该方法所使用的扩散策略，通过将输出端改变为概率分布，使机器人在遇到同样的环境状态输入时，可以有不止一种的动作可能输出，但是这些动作输出都是可以完成任务的。




图 4-5 多动作概率分布问题示意图

4.5 扩散策略模仿学习规划实验与分析

在研究机器人的动作规划的过程中，选择合适的仿真环境是至关重要的。基于模仿学习或强化学习的机器人动作规划，作为一种基于示范的学习方法，对仿真环境有着独特的要求，需要提供一个与现实世界尽可能接近的场景，并且能够实现和环境的快速交互，以便机器人能够从中学习到有效的动作策略和规划技巧。

模仿学习需要仿真环境具有高度的真实性。这意味着仿真环境应能够准确地模拟现实世界中的物体、场景和物体之间的交互。例如，在模拟机器人抓取物体的任务中，仿真环境需要考虑到物体的形状、质量、摩擦力等因素，以便机器人能够模仿真实世界中的抓取动作。并且仿真环境应具有一定的灵活性和可定制性。对于不同的研究目标和任务需求可以快速地布置场景进行测试。

尽管 Gazebo 作为一款流行的开源仿真环境在机器人领域应用广泛，但 Gazebo 在处理大规模复杂场景时的计算效率相对较低，尤其是在模仿学习或强化学习这种需要反复与环境交互训练的方法中，容易出现数值困难问题，导致仿真过程中的延迟和不稳定性。

而 Mujoco 则是目前更适合对机器人模仿学习算法和强化学习算法进行仿真的环境。采用了更先进的物理引擎，能够以高精度模拟物体之间的碰撞、摩擦和动力学行为。使其具有高效的计算性能，能够快速准确地模拟大规模复杂物体之间的交互。且 Mujoco 提供了丰富的物体建模和环境配置选项，因此可以

根据实际需求自由定制仿真场景。无论是简单的物体抓取任务还是复杂的机器人操作场景，Mujoco 都能够提供灵活的解决方案，满足不同研究的需求。为了尽可能使仿真与真实场景保持一致，本文根据真实机器人结构在仿真环境中创建了仿真机器人本体，并设置了多种任务场景。本文设计的仿真任务包括了一系列复杂的动作。目标物体包括抽屉和水杯，任务的整体流程可以概括为“拉开抽屉、抓取杯子、放置杯子、关闭抽屉”，如图 4-6 所示。这个任务旨在模拟现实世界中机器人在日常生活中可能遇到的场景，例如在厨房中完成收纳物品的操作。以该任务为基础，本文训练模仿学习网络，使机器人能够学习到适应长序列复杂动作的动作规划和执行策略，从而提高其在实际环境中的应用性能。




图 4-6 “拉开抽屉、抓取杯子、放置杯子、关闭抽屉”仿真任务

为了进行模仿学习训练，必须首先获取足够数量和质量的演示数据，这些数据将用于指导机器人学习执行任务所需的动作。本文我们需要采集机器人本体信息以及环境状态信息。机器人本体信息包括机械臂各关节的转角与速度，以及夹爪的位置与速度等，而环境状态信息则包括抽屉和水杯的 6D 位姿等。

针对该仿真环境，本课题使用遥操作主手结合 Mujoco 仿真环境，完成主手对仿真机器人的运动控制。在收集数据时，记录水杯和抽屉的 6D 位姿信息，以及主手发送给从手的机器人笛卡尔空间动作信息，使用遥操作主手控制仿真环境中的机器人完成“拉开抽屉-放置水杯-关闭抽屉”任务。并且为了保证数据的充分性和多样新，在每次数据采集前，进行水杯和抽屉位置的随机化，提高采

集的数据的质量和 学习后的泛化能力。

利用上文提到的基于扩散策略的模仿学习算法，在 Mujoco 仿真环境中对该策略进行训练，以使机器人能够学习到有效的动作规划策略，从而完成复杂的任务。模仿学习策略的状态为目标物体的位置、姿态以及速度，机器人末端执行器 6D 位姿以及各关节速度，策略输出动作为机械臂的末端位姿相对位移两，通过运动学逆解计算各关节转角完成动作驱动。训练过程中的参数设置如表 4-1 所示。

表 4-1 模仿学习仿真训练参数

参数	数值
状态维度	37
动作维度	8
学习率	1×10^{-4}
学习率衰减率	1×10^{-6}
单次最大时间步数	1500
训练迭代次数	1000

实验结果如图 4-7 所示，整个动作过程大致分为“拉开抽屉-放置水杯-关闭抽屉”三个步骤，经过学习训练，机器人可以完整学习整个操作流程。机器人的 3D 空间动作路径如图 4-8，可以看出在面对长序列复杂任务时，算法的仍然能够收敛，根据当前状态均匀的生成机器人动作并执行，训练得到的结果能够较好地完成任务。




图 4-7 仿真模仿学习动作生成实验

观察机器人末端的位置和欧拉角变化曲线，如图 4-9，可以看出生成的机器人动作较为平滑，没有明显的位置姿态跳变，除了在拉取抽屉时发生了较小幅度、快速的机器人姿态变化，其它时刻机器人均能平稳的执行动作。




图 4-8 机器人末端位姿运动路径




图 4-9 机器人末端的位置与欧拉角变化曲线

4.6 本章小结

本章实现了一种基于扩散策略的模仿学习机器人动作规划方法，该方法以扩散模型为基础，将机器人的动作生成过程表示为对状态和动作对构成的矩阵的去噪过程，应用扩散策略从状态中生成机器人动作。同时，为了解决机器人动作的多动作概率分布问题，将机器人的动作表示为概率分布，允许机器人在针对同一种状态时有多种可能的动作输出，提升任务执行的成功率。

第 5 章 机器人自主操作系统及实验

5.1 引言

本章搭建了机器人自主操作实验平台，基于 ROS 实现了机械臂的伺服控制和各设备通信。本文的第二章至第四章分别介绍了机器人自主操作过程所需要的目标识别与物体位姿、抓取姿态生成，自主操作动作学习等内容。本章将在这些内容的基础上进行整合，针对所提出的自主操作系统方案进行一系列实验。基于实验结果进行分析，验证本文所提出的方法的有效性，并对所设计的机器人自主操作系统进行性能测试和评估。

5.2 机器人自主操作实验平台设计

根据本课题的研究内容，确定了系统结构如图 5-1 所示，系统由三部分组成，包括用于实现物体实例分割与 6D 位姿估计的视觉感知模块，基于角度分布和点云融合与滤波处理的 6D 抓取姿态生成模块，以及基于模仿学习的机器人规划控制模块。三个模块彼此耦合，最终实现机器人根据环境状态信息生成并执行机器人动作。




图 5-1 机器人自主操作系统结构框图

根据系统功能，确定实验所需设备如表 5-1 所示，包括硬件设备如 6 自由度机械臂、自适应夹爪、RGBD 相机等实现机器人自主操作功能，以及上位计算机以及其它辅助硬件用于处理和传输传感器信息，并运行本文所提出的各类算法实现机器人规划。

表 5-1 实验所需设备

类型	名称	型号	功能
硬件设备	6DOF 机械臂	法奥 FR5	机器人复杂动作实现
	关节型自适应夹爪	大寰 AG-95	抓取物体并进行操作
	深度相机	Realsense D455	获取图像与点云信息
计算机	HP Victus Laptop	Intel i7-13700HX NVIDIA GTX4060	运行机器人相关算法
辅助器件	交换机	TP-LINK	机器人与传感器及计算机通信

5.2.1 自主操作仿真与真实实验平台搭建

（1）仿真环境搭建与测试

为了验证本文所实现的各算法以及机器人自主操作技术的可行性和有效性，包括实例分割与物体位姿估计、6D 抓取姿态生成等、基于模仿学习的机器人动作规划方法等。首先需要建立一个完整的机器人 6D 抓取系统，实验中我们选择了 FAIRINO-FR5 协作机器人作为实验对象，机器人的参数如表 5-2 所示。机器人安装有大寰 AG-95 关节型自适应电爪，其最大开合宽度为 95mm，位置重复精度为±0.03mm，夹持力为 45~160N，最大负载 3kg。

表 5-2 FAIRINO-FR5 机器人参数

参数	有效工作半径	有效负载	重复定位精度	最大末端速度
值	922mm	5kg	±0.02mm	3m/s

相机使用 Intel RealSense D455，通过相机支架安装在机器人的对侧，即“眼在手外”。机器人通过相机实现视觉感知，获取环境信息用于自主操作的学习和动作推理。



图 5-2 Gazebo 机器人仿真环境

为了保证在课题初期的实验安全性与成本问题，首先需要构建一个机器人 6D 抓取系统仿真环境，本文采用了 Gazebo 作为机器人抓取实验的仿真环境，其在模拟机器人行为和环境交互方面具有很高的灵活性和准确性，能够在不同条件下对机器人进行测试和验证。本文搭建的 Gazebo 仿真环境如图 5-2 所示。

在该仿真环境中，机器人的各个关节通过 ROS 的 MoveIt! 工具进行控制。MoveIt! 提供了运动规划、运动控制、碰撞检测等功能，为机器人的控制和操作提供了便利。使用 MoveIt! 设置碰撞矩阵、虚拟节点、规划组以及关节属性等参数后，可以在 Rviz 中对机器人进行手动控制快速调整参数并进行实验验证，如图 5-3 所示。




图 5-3 MoveIt! 与 Rviz 运动控制

所有的视觉算法、轨迹规划与机器人控制均通过 ROS 系统连接。ROS 作为一个灵活且强大的机器人操作系统，为机器人系统的集成和协作提供了良好的平台。通过 ROS 的消息传递机制，不同模块之间能够实现信息的共享和交互，从而实现了整个系统的协同工作。

上述 Gazebo 仿真环境主要用于机器人抓取算法仿真，而要进行模仿学习算法的测试，需要仿真环境具有需要更高的可靠性和更快的训练速度。因此，本文引入了 Mujoco 仿真环境，相较于 Gazebo，Mujoco 在训练过程中有着更高的稳定性，训练过程中的数值困难问题更少，降低了训练崩溃的风险。同时，Mujoco 的训练速度也相对更快，能够更迅速地进行算法验证和参数调整。此外 Mujoco 仿真环境还具有支持可变柔性物体（如绳、布料等）仿真和软体接触仿真的优势，以及对多种摩擦力仿真的支持。这些特性使得 Mujoco 能够更好地模拟真实场景，从而提高模仿学习算法的实用性。

为了满足模仿学习算法测试的需求，本文搭建了一套基于 Mujoco 的仿真环境，如图 5-4。并根据不同的任务配置了不同的机器人场景，这些场景用于训练和测试模仿学习任务，例如抓取放置方块、将杯子放入抽屉中等。通过利用 Mujoco 为机器人在各种实际场景中的智能行为提供更可靠的基础。




图 5-4 Mujoco 机器人仿真环境

(2) 真实实验平台搭建与预测试

本实验的机器人自主操作平台如图 5-5 所示，平台上安装有 6 自由度机械臂 FR5 作为机器人自主操作的主体，机械臂的末端安装有自适应二值夹爪；Omega.7 遥操作主手用于人类演示数据的收集；右侧的 RealSense D455 深度相机实时观察作业区，用于各物体的 6D 位姿估计与抓取姿态生成。

除图中展示的实验设备外，本课题所设计的机器人自主操作系统还包含用于处理传感器数据实现位姿估计、抓取姿态生成以及模仿学习规划的计算机，以及 6 自由度机械臂控制器。本课题基于所展示的实验设备，使用遥操作主手收集人类演示动作，使机器人从动作数据中学习模仿学习策略，完成自主操作。




图 5-5 机器人自主操作实验平台

5.2.2 机器人手眼标定

在进行机器人手眼标定前，首先需要标定相机的内参。相机内参标定主要

目的是准确估计相机的内部参数，包括焦距、主点位置和镜头畸变系数等。这些参数对于后续图像处理的准确性至关重要。本实验使用 RealSense D455 深度相机作为主要的视觉传感器，使用图像分辨率格式为 1280×720 。此外还制作了棋盘格标定板，该标定板包含已知尺寸的 12×9 个黑白方格用于相机的标定。

将标定板放置在不同的位置和角度，通过 RealSense D455 相机采集相应的图像，通过移动相机和标定板使棋盘格出现在不同的位置和角度，提取出图像中棋盘格的角点信息如图 5-6 所示。




图 5-6 相机内参标定过程

利用采集到的角点信息进行相机内部参数标定，得到焦距、主点位置和畸变参数如下：

$$\mathbf{P} = \begin{bmatrix} 632.985720 & 0 & 632.246735 \\ 0 & 633.924216 & 364.925934 \\ 0 & 0 & 1 \end{bmatrix} \quad (5-1)$$

$$\mathbf{D} = [-0.045339 \quad 0.028786 \quad 0.000364 \quad 0.000840 \quad 0] \quad (5-2)$$

在获得了相机内参后，进行相机与机械臂的手眼标定。由于 6D 位姿估计获得的位姿与生成的抓取姿态均相对于相机坐标系，而机器人的控制基于基座坐标系实现，因此需要将物体位姿转换到机器人基座坐标系下，也就是需要通过手眼标定计算机器人与相机的坐标系变换关系 T_{base}^{cam} 即可。

本课题使用的眼在手外（Eye-to-Hand）连接方式，相机通过支架固定在机器人对侧，不随机器人移动，相机能够稳定的获取整个工作空间的图像信息，避免了由于机械臂位姿变化导致目标物体超出视野范围的问题，可以充分发挥移动机器人的灵活性。标定过程如下：

- (1) 使用机械臂夹爪夹持标定板，要求夹爪不能遮挡标定板；

(2) 移动机械臂使标定板出现在相机视野内, 且标定板位姿可以被准确识别不发生跳变, 记录标定板位姿;

(3) 改变机器人的姿态, 并保证标定板不超出视野, 再次记录标定板位姿。



图 5-7 机器人手眼标定过程

采集尽可能多的机器人在不同姿态下的标定板位姿数据, 以获得更精确手眼标定结果。如图 5-7 所示为机器人手眼标定的过程。

取任意两个以上的位姿点, 由机器人控制器得到的末端位姿可以得到相机坐标系下的两个 Aruco 二维码位姿矩阵 $T_{cam}^{mark1}, T_{cam}^{mark2}$, 并且可以得到机器人末端的变换矩阵 $T_{end1}^{base}, T_{end2}^{base}$, 并且由于在标定的过程中, 相机和机械臂的基座是固定的, 因此有以下关系:

$$T_{end1}^{base} \cdot T_{base}^{cam} \cdot T_{cam}^{mark1} = T_{end2}^{base} \cdot T_{base}^{cam} \cdot T_{cam}^{mark2} \quad (5-3)$$

式(5-3)中 T_{base}^{cam} 即为待求的手眼标定变换矩阵, 矩阵方程两边同时左乘 $T_{end1}^{base^{-1}}$, 同时右乘 $T_{cam}^{mark2^{-1}}$, 则公式转换为:

$$T_{end1}^{base^{-1}} \cdot T_{end2}^{base} \cdot T_{base}^{cam} = T_{base}^{cam} \cdot T_{cam}^{mark1} \cdot T_{cam}^{mark2^{-1}} \quad (5-4)$$

式(5-4)可以视为矩阵方程:

$$AX = XB \quad (5-5)$$

本文采用 Tsai-Lenz^[45]算法求解该矩阵方程, 采集 100 组手眼标定数据, 通过最小二乘法拟合得到相机相对于机器人基坐标系的变换矩阵, 本实验中相机与机械臂手眼标定结果为:

$$T_{base}^{cam} = \begin{bmatrix} 0.41704078 & -0.40340637 & 0.81445705 & -0.918645 \\ -0.90876954 & -0.19953154 & 0.36650387 & -0.437532 \\ 0.01465987 & -0.89300082 & -0.44981621 & 0.34288 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (5-6)$$

对于相机获取到的任一物体位姿 T_{cam}^{obj} 可以通过式(5-7)将物体位姿转换为机

器人基坐标系下的物体位姿 T_{base}^{obj} 。

$$T_{base}^{obj} = T_{base}^{cam} \cdot T_{cam}^{obj} \quad (5-7)$$

5.3 机械臂自主操作实验

本节在由 Fairino FR5 六自由度机械臂、Realsense D455 相机以及工作台所组成的实验平台上，对前文所提出的目标检测与位姿估计、抓取生成以及机器人自主操作等任务进行实验。各设备在实验前均已完成标定和单独调试。

5.3.1 目标检测与位姿估计验证

如图 5-8 所示为经过训练后的实例分割网络的测试结果，采用 MaskRCNN 算法作为对比，可以看出传统的 MaskRCNN 实例分割算法在处理较严重遮挡情况时，无法准确识别出物体，而 YOLOv8 相比较而言，即使在物体被大部分遮挡的情况下，仍然可以分割出物体掩膜，并有着更高的识别率和更准确的分割边缘，在处理多物体场景时更加稳定。




图 5-8 实例算法结果对比

完成目标物体的实例分割后，需要利用分割结果进一步估计目标物体的位姿，本文使用基于视角选择的位姿估计方法，根据物体分割结果进一步估计目标物体位姿。在进行位姿估计前，首先采集各个物体的多视角图像作为参考图像，并使用 COLMAP 对各个物体的三维模型进行重建，获得各物体的稀疏点云

模型，如图 5-9 所示。同时，在三维点云模型中定义物体的坐标系，网络所估计得到 6D 位姿，其中旋转为定义的物体坐标系相对于相机坐标系的 X, Y, Z 轴的旋转角度，平移为物体中心与相机坐标系原点的距离。



图 5-9 实验物体三维重建稀疏点云模型

使用深度相机获取工作区的 RGB 和深度图，将图片输入到训练后的网络，输出各物体的 6D 位姿，并将物体位姿通过 3D 包围框的形式在 RGB 图像中可可视化，如图 5-10 所示。本文实现的位姿估计方法由于通过视角匹配的方式生成粗略位姿，再利用稀疏点云经过特征匹配优化位姿估计结果。同样的场景下，使用本文的方法与基于特征融合的位姿估计方法 DenseFusion 相比，总时间基本一致。但 DenseFusion 的位姿估计精度十分依赖于三维模型的精度，相比之下本文的位姿估计方法易用性与可推广性更强，更适合于机器人操作中对多物体位姿估计的需求。




图 5-10 位姿估计结果可视化

5.3.2 物体 6D 抓取姿态生成与机器人抓取实验

本文设计了实物抓取实验来测试所提出的 6D 抓取姿态生成方法，在实验中对抓取的成功率进行测试。抓取方法性能越好，意味着抓取成功率越高，因此本文以抓取成功率作为评价指标。实验选择了 5 种形状不同，质量与质量分布不同，表面粗糙度不同的物体，主要包括香蕉 (banana)、瓶子 (bottle)、水杯 (cup)、纸杯 (papercup)、盒子 (realsensebox)，尽量模拟日常使用情况下机

机器人的抓取场景。

本实验统一抓取步骤如下：（1）根据相机获取的 RGB 和深度图，以及 YOLOv8 生成的掩膜，生成抓取姿态，机器人移动至抓取点上方；（2）机器人下移到达抓取位姿，执行抓取操作；（3）机器人抓取物体后，向上移动 200mm，静止保持。在整个抓取过程中，成功抓取起物体，且物体没有发生脱落或滑动则视为抓取成功。

在真实机器人上进行抓取实验如图 5-11 所示，在实验中与不包含点云处理模块的方法进行了比较。在抓取过程中，首先使用 6D 位姿估计算法对每个实例进行 6D 位姿估计。将模型点云通过位姿估计结果与当前相机获取的深度图点云进行融合，通过抓取姿态生成网络获得优化的抓取位姿，并直接在真实场景中测试我们的方法。本文对每个物体类别进行了 20 次实验，计算出的成功率如表 5-3 所示，可以观察到，相比较于没有经过点云处理的抓取姿态，经过点云处理的抓取姿态成功率更高。




图 5-11 抓取过程图（左图为实验设置，右图为抓取实现过程）

表 5-3 真实场景下抓取成功率比较

物体/方法	无点云处理	经过点云处理
香蕉	13/20 (65.0%)	15/20 (75.0%)
瓶子	16/20 (80.0%)	17/20 (85.0%)
水杯	14/20 (70.0%)	15/20 (75.0%)
纸杯	15/20 (75.0%)	14/20 (70.0%)
盒子	15/20 (75.0%)	17/20 (85.0%)
平均	73.0%	78.0%

如表 5-4 所示，比较不同环境下的抓取成功率，可以发现场景的复杂程度

会小幅影响本文提出的抓取算法的抓取成功率，因为 6D 位姿估计算法中，背景虽然增加了特征点的计算，但是并不会显著影响位姿估计结果，但在抓取生成过程中，由于使用了场景点云进行抓取候选快速筛选，因此在复杂场景下可行的抓取姿态相对较少。根据五种物体的抓取成功率的差异，在各种环境条件下，盒子与瓶子的平均抓取成功率最高，其次是杯子类，而香蕉抓取成功率最低。基于上述结果，可以判断物体形状越规则，颜色特征越丰富的物体，在不同环境中抓取准确率更高。而物体形状较不规则，物体高度较低的物体，在抓取时非常容易与环境其它物体发生碰撞。但综合而言，本文所提出的基于点云融合的抓取姿态生成方法，相比较于无点云处理的方法，抓取姿态的可行性和抓取成功率更高。

表 5-4 杂乱环境下抓取成功率比较

物体/场景	简单场景	杂乱场景	平均
香蕉	15/20 (75.0%)	13/20 (65.0%)	70.0%
瓶子	17/20 (85.0%)	15/20 (75.0%)	80.0%
水杯	15/20 (75.0%)	17/20 (85.0%)	80.0%
纸杯	14/20 (70.0%)	14/20 (70.0%)	70.0%
盒子	17/20 (85.0%)	15/20 (75.0%)	80.0%
平均	78.0%	74.0%	76.0%

5.3.3 基于模仿学习的机器人自主操作实验




图 5-12 自主操作数据收集过程

利用前文所搭建的机器人自主操作实验平台收集操作数据，使用遥操作主

手控制机械臂运动，抓取目标盒子，将其放入到抽屉中。在这个过程中进行实例分割、位姿估计获取目标物体的位姿，同时实时读取机械臂末端位姿和速度，将以上信息保存为状态，将主手发送给从手机械臂的末端位姿变化保存为动作，将对应的状态和动作组成一条经验保存在数据文件中。使用遥操作主手收集人类演示数据的过程如图 5-12 所示。

本文针对该任务收集了 60 组数据用于训练，各网络训练参数尽可能保持一致，具体参数与仿真相同。整个操作任务流程较长，包含多个复杂动作，在实验中本文利用扩散策略学习在不同状态下的机器人动作，通过训练实现整个操作任务的学习，实现自主完成任务并保持较高的稳定性和鲁棒性。




图 5-13 不同网络训练 Loss 曲线对比




图 5-14 不同网络训练 MSE 曲线对比

为了验证本文所提出的算法效果,选择了 IBC 与 BC-RNN 两种经典的模仿学习算法作为对比。IBC 是一种隐式行为克隆 (Implicit BC) 方法,该方法放弃了传统行为克隆的显式神经网络直接从观测预测动作的方法,而是将观测和动作作为神经网络的输入,输出一个价值,对于正确的观测和动作,输出的价值高,反之不匹配的观测和动作输出值较低,由此将行为克隆转换为类似基于能量的建模问题。BC-RNN 则是使用循环神经网络 RNN 网络来实现行为克隆,并且网络使用高斯混合模型表示策略,以实现复杂任务的建模。

对三种方法设置相同的初始条件和训练参数,经过训练测试,得到网络训练的 Loss 曲线和训练过程的均方误差如图 5-13 与图 5-14 所示。可以看出相比较于 IBC 和 BCRNN,本文的扩散策略模型虽然收敛速度略慢,但 Loss 曲线收敛后一直保持稳定。此外,IBC 方法在进行动作学习时,随着训练次数的增加,动作的均方误差处于一直处于波动,尽管其损失 Loss 较低,但是实际的学习效果并不稳定。分析其原因,可能是因为隐式行为克隆方法学习对观测和动作的评价函数,但对于复杂长时间任务,不同时刻可能环境状态也就是观测相同,但是会执行不同的动作,因此在对此情况进行学习评价策略时出现无法收敛的问题。

进一步评估不同算法在真实机器人上部署学习自主操作的成功率,利用训练后的三个网络模型驱动实验平台机器人进行操作实验,保持不同算法在进行测试时各物体的初始位姿相同,机器人初始位姿相同,光照条件、硬件条件等均保持一致,验证机械臂自主操作过程如图 5-15 所示。




图 5-15 真实环境下不同算法执行相同任务对比

在实验中，本文的扩散策略能够较好的执行任务，完成拉开抽屉，抓取物体并放置物体的整个流程；BCRNN 在抓取物体时由于输出的夹爪动作不稳定，发生了物体掉落的情况；而 IBC 算法由于任务过于复杂，无法学习到正确的策略，导致无法完成任何一个任务，始终输出错误的动作。




图 5-16 不同算法执行相同任务的轨迹对比

为了进一步比较三种算法生成的动作轨迹，本文绘制了三种算法生成的空间轨迹图如图 5-16 所示，可以看出扩散策略的轨迹比较平滑，且轨迹点分布均匀，因此机器人在执行动作时速度较为均匀，而 BCRNN 预测的动作序列轨迹分布较不均匀，并且在对抽屉进行操作（图中 $x=1.3$, $y=0.8$ 附近位置）时，会出现较多的冗余动作，在机器人执行时表现为陷入到某个局部最优反复多次执行某一段动作。

为了避免偶然性，对三种算法分别进行了 20 次测试，将完成整个动作流程，机器人将目标物体放置进抽屉中视为成功，记录不同算法的成功次数，测试得到不同算法的任务成功率如图 5-17 所示。




图 5-17 不同算法的任务执行成功率对比

从图中可以看出, 三种算法都存在成功执行完成任务的概率, 但是相比较于 IBC 和 BC-RNN, 扩散策略的任务成功率更高, 达到了 95%。而 IBC 任务无法成功实现。对实验结果进行分析, 首先隐式行为克隆 IBC 学习的本质是学习价值函数, 将数据中的动作和状态标记为高价值, 非演示数据标记为低价值。在推理时通过根据状态寻找最大化价值对应的动作来实现机器人操作, 这种方式训练十分困难, 特别是在复杂任务中, 价值函数的优化可能是非凸的, 因此很难学习到合适的策略。

比较本文的扩散策略与 BC-RNN 两类方法, 扩散策略将机器人的动作生成表示为条件去噪扩散过程, 根据多次去噪迭代从状态中推理机器人的动作, 而 BCRNN 使用循环神经网络架构来获取数据中的空间和时间依赖性, 但这种循环神经网络难以学习长时间的状态和动作关系, 相比之下, 去噪扩散模型可以通过迭代的预测噪声来有效地处理长时间状态和动作的学习。在网络表达能力方面, RNN 网络的表示能力有限, 在机器人进行具有高维输出的复杂任务时, 难以对数据进行建模, 而扩散策略将机器人的动作表示为归一化的概率分布, 更适合处理复杂的状态和动作的数据分布问题。此外在对输入的鲁棒性方面, RNN 等神经网络对噪声更加敏感, 当输入与演示数据存在差距或输入噪声较大时, 性能下降较大, 而本文的扩散策略以及其扩散模型在本质上对噪声的输入就更加具有鲁棒性, 因此在输入存在噪声的情况下能获得更鲁棒的性能。此外扩散策略可以准确学习多动作分布情况, 即对于同一个物体, 可以有一定概率从左或者右侧接近物体执行抓取, 而 BCRNN 表现的动作偏向于其中的一种。

在实际机器人执行任务过程中, 可能会遇到各种其它干扰, 为了测试本文提出的方法的鲁棒性, 在进行实际测试中人为加入干扰, 例如在机器人即将抓取物体时, 移动物体至其它位置, 或机器人在拉取抽屉后, 将抽屉重新关闭, 测试算法对场景的理解。基于以上干扰设置对算法进行测试, 实验过程如图 5-18。

经过实验测试, 当机器人拉开抽屉后人为关闭抽屉, 算法将会视场景为初始状态, 重新尝试打开抽屉且成功率较高。机器人在抓取前, 将物体移动至其它位置, 若物体移动距离较短, 则机器人能够成功移动至物体上方完成抓取, 若移动距离较长, 机器人则存在一定的任务失败概率, 可能会与物体发生碰撞。分析其原因, 可能是由于第一种干扰情况下, 环境状态相当于恢复到了执行动作前的状态, 例如未拉开抽屉, 在这种情况下机器人能够正确生成下一步动作。但在第二种情况下, 环境状态和机器人状态与收集数据相差较大, 任务执行成功概率相对有所降低。但综合而言, 该方法已经能够处理部分环境干扰情况, 具有一定的环境变化鲁棒性。




图 5-18 不同干扰下机器人任务执行情况

此外考虑到收集数据质量对训练结果可能存在的影响，本文对比了使用遥操作主手熟练程度不同的人收集相同数量的数据，训练过程的 Loss 曲线和训练之后进行测试的成功率如图 5-19 所示。可以明显看出熟练使用遥操作主手的数据样本在训练时更容易收敛，且训练之后的任务测试成功率也更高。原因在于熟练使用遥操作主手收集的数据，动作分布更加均匀，相比之下初次使用遥操作主手时，动作可能存在停顿以及存在大量的多余非必要动作，这相当于为模仿学习网络训练增加了大量噪声，因此从中学习正确动作变得更加困难。




图 5-19 不同质量数据训练 Loss 曲线对比




图 5-20 不同质量数据训练和 MSE 曲线对比

5.4 本章小结

本章首先搭建了机器人自主操作的仿真和真实实验平台，用于采集任务数据作为模仿学习训练的数据样本。在该平台上测试了本文的目标检测和基于视角选择的位姿估计算法，以及 6D 抓取姿态生成算法，并进行了可视化效果对比。在此基础上，使用遥操作主手收集了任务数据，训练模仿学习网络，通过与其它模仿学习算法进行对比，以及验证算法在不同干扰情况、不同数据质量情况下的学习效果，结果表明该算法能够实现长时间复杂任务的学习，并且具备一定的环境变化鲁棒性。

结 论

机器人从人类演示学习技能并实现自主操作一直是机器人领域的研究重点和难点，但由于任务的复杂性，环境的不确定性等问题，机器人需要更加智能的学习方法。本文基于此目的研究了一套解决方案，使用 6D 位姿估计网络获取环境中被操作物体的状态信息，然后估计物体的 6D 抓取姿态，基于模仿学习使机器人从人类演示中学习策略，本文的研究工作总结如下：

(1)建立了基于目标检测与视角选择的原理目标物体的 6D 位姿估计方法。以 YOLOv8 算法为基础进行实时目标物体检测和实例分割，利用物体掩膜并结合视角选择的原理进行物体位姿估计与姿态优化，实现了准确的物体 6D 位姿估计。本文制作数据集对所建立算法进行测试，实验结果表明算法具有较高的实例分割精度和位姿估计精度，推理速度满足机器人自主操作需求。

(2)提出了一种基于角度分布和物体点云融合的 6D 抓取姿态生成算法。利用抓取角度预测网络和抓取姿态快速搜索策略获得 6D 抓取位姿。并针对单一视角物体点云的空洞可能导致生成错误抓取姿态的问题，利用位姿估计过程中获得的物体稀疏点云对当前输入点云进行融合，实现了更稳定的 6D 抓取姿态生成。实验结果表明改进后的抓取姿态生成算法具有较高的抓取成功率。

(3)设计了基于扩散策略的模仿学习规划算法，从人类演示中学习机器人自主操作。扩散模型根据当前环境状态从高斯随机噪声中逐步去噪生成机器人动作，实现了复杂的操作任务的自主完成。为了解决同一状态下多种可行动作的问题，将机器人动作输出用概率分布表示，使机器人可以从同一状态生成多种可能的操作。为了收集人类演示数据，设计了主从控制策略使用遥操作主手采集人类演示数据。本文对所提出算法进行仿真实验，结果表明机器人能够完整完成复杂任务，并具有一定的抵抗环境干扰的能力。

(4)搭建了机器人自主操作实验平台并进行了实验测试验证所提出的算法。结果表明本文的机器人自主操作方法的平均任务成功率较高，且和 BCRNN、IBC 两类模仿学习算法相比，本文的方法能够通过不断迭代预测噪声学习到长时间的状态和动作关系，且对于输入噪声的鲁棒性更好。同时由于将机器人动作通过概率分布表示，相比较于其他方法更加适应复杂任务的建模。

虽然本文在机器人自主操作技术上进行了一定的研究，但是距离真正实现从人类演示中学习机器人的自主操作仍然还有一定差距，本课题未来可以在以下方向继续研究：

(1) 物体位姿估计的扩展性和实时性改进。位姿估计方法应通过一段视频采集目标物体信息，经过简单的标记后可以直接实时获取目标物体位姿。

(2) 改变模仿学习的数据来源，目前所实现的使用遥操作主手收集人类演示数据的方式较为繁琐且依赖设备，未来可以研究利用动作捕捉系统建立人手坐标系，代替机器人末端执行器采集数据，进行模仿学习训练。或直接普通人类视频中学习机器人操作，这对位姿估计和人类关节识别等图像信息的理解提出了更高要求。

(3) 考虑提高物体在部分遮挡情况下的位姿估计精度，以及物体从视野中消失或部分遮挡情况下的模仿学习能力。

参考文献

- [1] 工业和信息化部. “机器人+”应用行动实施方案[EB]. (2023-01-18).
- [2] 陈丹. 我国机器人产业迈向高质量发展阶段[J]. 电气时代. 2022(07): 31-33.
- [3] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2017, 39(6): 1137-1149.
- [4] Couturier R, Salman O, Noura H N, et al. A deep learning object detection method for an efficient clusters initialization[J]. arXiv e-prints. 2021, arXiv: 2104.13634.
- [5] K. He, G. Gkioxari, P. Dollár, et al. Mask R-CNN[C]. International Conference on Computer Vision (ICCV). 2017, 2980-2988.
- [6] Bolya D, Zhou C, Xiao F, et al. YOLACT: Real-time instance segmentation[C]. International Conference on Computer Vision (ICCV). 2019, 9156-9165.
- [7] Xiang Y, Schmidt T, Narayanan V, et al. PoseCNN: A Convolutional Neural Network for 6D Object Pose Estimation in Cluttered Scenes[C]. Robotics: Science and Systems. 2018.
- [8] Besl P J, McKay N D. A method for registration of 3-D shapes[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 1992, 14(2): 239-256.
- [9] Hinterstoisser S, Holzer S, Cagniart C, et al. Multimodal templates for real-time detection of texture-less objects in heavily cluttered scenes[C]. International Conference on Computer Vision (ICCV). 2011, 858-865.
- [10] Peng S, Liu Y, Huang Q, et al. PVNet: Pixel-Wise Voting Network for 6DoF Pose Estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018, 4556-4565.
- [11] He Y, Sun W, Huang H, et al. PVN3D: A Deep Point-Wise 3D Keypoints Voting Network for 6DoF Pose Estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2019, 11629-11638.
- [12] Duffhauss F, Demmler T, Neumann G. MV6D: Multi-view 6D pose estimation on RGB-D frames using a deep point-wise voting network[C]. IEEE/RSJ international conference on intelligent robots and systems (IROS). 2022, 3568-

3575.

- [13] Wang C, Xu D, Zhu Y, et al. DenseFusion: 6D object pose estimation by iterative dense fusion[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2019, 3338-3347.
- [14] He Y, Huang H, Fan H, et al. FFB6D: A Full Flow Bidirectional Fusion Network for 6D Pose Estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2021, 3002-3012.
- [15] Sun J, Wang Z, Zhang S, et al. OnePose: One-Shot Object Pose Estimation without CAD Models[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2022, 6815-6824.
- [16] Fang H S, Wang C, Gou M, et al. Graspnet-1billion: A large-scale benchmark for general object grasping[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2020, 11441-11450.
- [17] Ni P, Zhang W, Zhu X, et al. PointNet plus plus Grasping: Learning An End-to-end Spatial Grasp Generation Algorithm from Sparse Point Clouds[C]. IEEE international conference on robotics and automation (ICRA). 2020, 3619-3625.
- [18] Fang H S, Wang C, Gou M, et al. GraspNet: A Large-Scale Clustered and Densely Annotated Dataset for Object Grasping[J]. arXiv e-prints. 2019, arXiv: 1912.13470.
- [19] Eppner C, Mousavian A, Fox D. ACRONYM: A Large-Scale Grasp Dataset Based on Simulation[C]. IEEE international conference on robotics and automation (ICRA). 2021, 6222-6227.
- [20] Wen B, Lian W, Bekris K, et al. CaTGrasp: Learning Category-Level Task-Relevant Grasping in Clutter from Simulation[C]. IEEE international conference on robotics and automation (ICRA). 2022, 6401-6408.
- [21] Breyer M, Chung J J, Ott L, et al. Volumetric grasping network: Real-time 6 DOF grasp detection in clutter[C]. Conference on Robot Learning (CoRL). 2020, 155:1602-1611.
- [22] Wen H, Yan J, Peng W, et al. TransGrasp: Grasp Pose Estimation of a Category of Objects by Transferring Grasps from Only One Labeled Instance[C]. Avidan S, Brostow G, Cisse M, et al. European Conference on Computer Vision (ECCV). 2022, 13699:445-461.
- [23] Liang H, Ma X, Li S, et al. PointNetGPD: Detecting grasp configurations from

- point sets[C]. IEEE international conference on robotics and automation (ICRA). 2019, 3629-3635.
- [24] Breyer M, Ott L, Siegwart R, et al. Closed-Loop Next-Best-View Planning for Target-Driven Grasping[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2022, 1411-1416.
- [25] Sundermeyer M, Mousavian A, Triebel R, et al. Contact-GraspNet: Efficient 6-DoF Grasp Generation in Cluttered Scenes[C]. IEEE international conference on robotics and automation (ICRA). 2021, 3133-3139.
- [26] Gou M, Fang H S, Zhu Z, et al. RGB Matters: Learning 7-DoF Grasp Poses on Monocular RGBD Images[C]. IEEE international conference on robotics and automation (ICRA). 2021, 13459-13466.
- [27] Wang P, Manhardt F, Minciullo L, et al. DemoGrasp: Few-Shot Learning for Robotic Grasping with Human Demonstration[C]. 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2021, 5733-5740.
- [28] Liu C, Fang B, Sun F, et al. Learning to Grasp Familiar Objects Based on Experience and Objects' Shape Affordance[J]. IEEE Transactions on Systems Man Cybernetics-Systems. 2019, 49(12): 2710-2723.
- [29] Yu T, Finn C, Xie A, et al. One-shot imitation from observing humans via domain-adaptive meta-learning[J]. Robotics: Science and Systems. 2018.
- [30] Sieb M, Xian Z, Huang A, et al. Graph-Structured Visual Imitation[C]. The Conference on Robot Learning (CoRL). 2019, Vol. 100, 979-989.
- [31] Mees O, Merklinger M, Kalweit G, et al. Adversarial Skill Networks: Unsupervised Robot Skill Learning from Video[C]. IEEE international conference on robotics and automation (ICRA). 2020, 4188-4194.
- [32] Nair S, Rajeswaran A, Kumar V, et al. R3M: A Universal Visual Representation for Robot Manipulation[C]. Conference on Robot Learning (CoRL). 2023, Vol. 205, 892-909.
- [33] Ma Y J, Sodhani S, Jayaraman D, et al. VIP: Towards Universal Visual Reward and Representation via Value-Implicit Pre-Training[J]. arXiv preprint. 2022: arXiv:2210.00030.
- [34] Jang E, Irpan A, Khansari M, et al. BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning[C]. Conference on Robot Learning (CoRL). 2021, Vol. 164, 991-1002.

- [35] Yang J, Zhang J, Settle C, et al. Learning Periodic Tasks from Human Demonstrations[C]. IEEE international conference on robotics and automation (ICRA). 2022, 8658-8665.
- [36] Xiong H, Li Q, Chen Y C, et al. Learning by Watching: Physical Imitation of Manipulation Skills from Human Videos[C]. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2021, 7827-7834.
- [37] Sharma P, Pathak D, Gupta A. Third-person visual imitation learning via decoupled hierarchical controller[C]. Conference on Neural Information Processing Systems. 2019, Vol. 32.
- [38] Zhu J Y, Park T, Isola P, et al. Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks[C]. International Conference on Computer Vision (ICCV). 2017, 2242-2251.
- [39] Liu Y, Wen Y, Peng S, et al. Gen6D: Generalizable Model-Free 6-DoF Object Pose Estimation from RGB Images[C]. European Conference on Computer Vision (ECCV). 2022, Vol. 13692, 298-315.
- [40] Mahler J, Matl M, Satish V, et al. Learning ambidextrous robot grasping policies[J]. Science Robotics. 2019, 4(26): eaau4984.
- [41] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C]. Conference on Robot Learning (CoRL). 2021, Vol. 164, 1678-1690.
- [42] Sohl-Dickstein J, Weiss E A, Maheswaranathan N, et al. Deep Unsupervised Learning using Nonequilibrium Thermodynamics[J]. arXiv e-prints. 2015, arXiv: 1503.03585.
- [43] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[C]. Larochelle H, Ranzato M, Hadsell R, et al. Advances in Neural Information Processing Systems. 2020, Vol. 33, 6840-6851.
- [44] Chi C, Feng S, Du Y, et al. Diffusion policy: Visuomotor policy learning via action diffusion[C]. Proceedings of robotics: Science and systems (RSS). 2023.
- [45] R. Y. Tsai, R. K. Lenz. A new technique for fully autonomous and efficient 3D robotics hand/eye calibration[J]. IEEE Transactions on Robotics and Automation. 1989, 5(3): 345-358.